



土壤宏基因组学

小白系统学习库 · 完整合订本

第一性原理 · 20 个必学模型 · 7 个思维框架 · 10 个案例 · 实操教程 · 难点图解 · 前沿与多组学

共 41 章 · 自动合并生成 · 用浏览器「打印 → 另存为 PDF」即得电子书

目录

土壤宏基因组学·小白系统学习库

学习路线图（建议顺序）

目录结构

一张图看懂整个领域的工作流

学完自测（能答上来就算入门了）

00·零基础启蒙：用大白话把这门学科讲清楚

- 一、先建立一个画面：一勺土里藏着一座看不见的城市
- 二、我们到底想知道什么？——三个核心问题
- 三、笨办法行不通：为什么不能把微生物"养出来"数？
- 四、DNA：每个微生物随身带的"身份证 + 技能清单"
- 五、测序：把 DNA 变成电脑能读的一长串字母
- 六、关键一步：一堆"字母碎片"怎么变成"土里有谁、能干啥"？
- 七、两种打开方式：查身份证 vs 读简历
- 八、跟着走一遍：一个完整研究长什么样？
- 九、四个一定要破除的"小白误区"
- 十、我能学会吗？——心态、基础和怎么用这个库

01·第一性原理：从最基本的事实推出整个领域

- 原理 0（前提）：土壤里几乎全是微生物，而且绝大多数我们"养不活"
- 原理 1：DNA 是生命的信息载体，"我是谁 + 我能干什么"都写在里面
- 原理 2：环境里所有生物的 DNA 是混在一起的——这正是"宏（meta）"的含义
- 原理 3：测序把"生物学问题"变成了"数据/计算问题"
- 原理 4：我们测到的是"相对比例"，不是"绝对数量"
- 原理 5：我们永远只看到"样本"，看不到"全部"——所以一切都带不确定性
- 原理 6：土壤是地球上最复杂、最不均匀的微生物栖息地

把 7 条串起来：领域的逻辑闭环

下一步

02·20 个必学模型·总览

20 个模型总览表

20 个模型如何对应工作流

给小白的精读优先级

A 类·实验与测序模型（模型 1–4）

模型 1·中心法则 / "基因即功能潜力"模型

模型 2 · 扩增子 vs 鸟枪法宏基因组模型 必懂

模型 3 · 测序深度与稀释曲线 (饱和) 模型 必懂

模型 4 · Phred 质量分数与测序错误模型

B 类 · 生信分析模型 (模型 5–10)

模型 5 · 序列比对与同源性模型

模型 6 · de novo 组装 : de Bruijn 图模型

模型 7 · 分箱 (Binning) : 组成 + 丰度聚类模型

模型 8 · MAG 质量评估 : 单拷贝标记基因模型 必懂

模型 9 · 物种分类 : k-mer / LCA 模型

模型 10 · 功能注释 : 直系同源 / 数据库映射模型

C 类 · 多样性与统计模型 (模型 11–14)

模型 11 · α 多样性与 Hill 数模型 必懂

模型 12 · β 多样性与排序 (PCoA/NMDS) 模型 必懂

模型 13 · 物种丰度分布 / 等级-丰度模型

模型 14 · 组成型数据模型 (CLR / 差异丰度) 必懂

D 类 · 群落构建生态模型 (模型 15–18)

模型 15 · 中性群落模型 (Sloan Neutral Community Model)

模型 16 · 确定性 vs 随机 : 零模型框架 (β NTI / RCbray) 进阶必懂

模型 17 · 共现网络与关键种模型 (SparCC / SPIEC-EASI) 进阶必懂

模型 18 · 生物地理 : 距离衰减与"万物无处不在"模型

E 类 · 功能与生态系统模型 (模型 19–20)

模型 19 · 生物地球化学循环的功能基因模型 必懂

模型 20 · 结构-功能关系与功能冗余模型 进阶必懂

20 个模型小结

03 · 7 个重要思维框架

框架 1 · 尺度框架 (Scale Thinking)

框架 2 · 样品到洞见 : 数据生命周期框架 (Sample-to-Insight)

框架 3 · 结构 → 功能 → 过程框架 (多组学阶梯) 最重要

框架 4 · 群落构建四过程框架 (Community Assembly)

框架 5 · 假说驱动 vs 数据驱动框架 (Hypothesis vs Data-driven)

框架 6 · 对照 · 重复 · 可重复框架 (Controls & Reproducibility)

框架 7 · 相关 → 因果的证据阶梯 (Correlation to Causation)

七框架协同 : 一次"靠谱研究"的内心独白

04 · 案例库 : 10 个真实研究案例

案例 1 · 全球表土微生物组图谱 (奠基性大尺度研究)

案例 2 · 中国陆地生态系统表土微生物组 (区域对比)

案例 3 · 全球土壤功能冗余 (结构-功能解耦)

案例 4 · 长期施肥对碳氮循环功能的影响 (农业经典设计)

案例 5 · 减少耕作改善根际碳氮磷循能 (管理实践)

案例 6 · 氮沉降下荒漠草原的碳氮循环响应 (全球变化)

案例 7 · 土壤抗性组：抗生素抗性基因的环境分布 (One Health)

案例 8 · 沿降水梯度跨土壤深度恢复 679 个 MAG (数据资源型)

案例 9 · 超深度长读长测序挖掘土壤生物合成潜力 (前沿技术)

案例 10 · 群落构建：随机 vs 确定性如何随土壤剖面变化 (生态机制)

跨案例规律 (小白重点)

案例文献链接

05 · 工具与数据库速查

按流程阶段的工具地图

主流数据库速查

一体化流程 (小白强烈推荐从这里入门)

给小白的现实提醒

06 · 术语表与延伸阅读

中英文术语表

几个最常被误解的点 (小白避坑)

延伸阅读与入门资源

建议的学习节奏 (4 周入门计划)

07 · 手把手实操教程 · 总览

先读这段 (很重要, 能帮你避坑)

实操教程地图 (按顺序)

一眼看懂: 整个流程的"命令骨架"

给小白的策略建议

07.1 · 环境与软件安装

一、你需要一个 Linux 环境

二、装 conda (软件管家) —— 强烈推荐用 miniforge / mamba

三、用 conda 建环境、装工具

四、下载数据库 (最费时间和硬盘的一步)

五、整理你的数据和目录

本篇完成检查

07.2 · 质控与读长分析 (路线甲: 快速出第一批结果)

第 0 步 · 看一眼原始数据长什么样

第 1 步 · 质控：洗掉垃圾 (fastp)

第 2 步 · 去宿主 (土壤常需去植物/人 DNA)

第 3 步 · 物种谱：土里有谁？ (Kraken2 + Bracken)

第 4 步 · 功能谱：这群菌能干啥？ (HUMAnN / MetaPhlAn)

串起来：一个多样本的小脚本

本篇完成检查

07.3 · 组装、分箱与 MAG (路线乙：重建基因组)

第 1 步 · 组装：把碎片拼成长片段 (MEGAHIT)

第 2 步 · 预测基因 (Prodigal)

第 3 步 · 算覆盖度：为分箱准备"丰度信号"

第 4 步 · 分箱：把 contig 按物种归堆 (MetaBAT2)

第 5 步 · 给 MAG 质控 (CheckM2)

第 6 步 · 给 MAG 分类 (GTDB-Tk)

第 7 步 · 给 MAG 做功能注释 (eggNOG-mapper / DRAM)

这一篇的产物，如何连到结论

本篇完成检查

07.4 · 统计与可视化 (用 R 把表变成图)

一、准备：装 R 和需要的包

二、你需要两张表 (最常见的输入格式)

三、读数据 (R 代码)

四、 α 多样性：单样本里种类多不多 (模型 11)

五、 β 多样性 + 排序：样本之间差多大 (模型 12)

六、找出差异物种/功能 (组成型差异，模型 14)

七、(可选) 共现网络：谁和谁在一起 (模型 17)

出图小贴士

本篇完成检查

07.5 · 常见报错与排查 (新手急救手册)

排错总原则 (先做这 4 件事)

一、环境与安装类

二、数据与格式类

三、内存 / 资源类 (土壤最常见！)

四、结果"不对劲"类 (不报错但结果可疑)

五、统计 / R 类

六、什么时候该求助 & 怎么问得到答案

心态提醒

08 · 难点图解专版 · 总览

本模块内容

怎么用这个模块

一句话先剧透四个难点的"恍然大悟点"

08.1 · 图解：组成型数据与 CLR（最容易踩的坑）

- 一、问题的根源：你拿到的是"比例"，不是"数量"
 - 二、陷阱长什么样：一个菌"涨"，逼着别的菌"假跌"
 - 三、CLR 怎么救场：不比"占整张饼的比例"，比"相对全体的倍数"
 - 四、几何平均？对数？——再用大白话兜一遍
 - 五、还有个麻烦：零值（很多物种丰度是 0）
 - 六、落到实操：你该怎么做（对接模型 14、教程 07.4）
- 一图总结

08.2 · 图解：组装与分箱（看不见的过程，画出来）

- 第一部分：组装——把碎片接成长片段
- 第二部分：分箱——把 contig 归回各自的基因组
- 全流程一图

08.3 · 图解：群落构建 β NTI 与 RCbray（环境筛选 还是 运气？）

- 一、先想清楚要回答的问题
- 二、零模型的灵魂：造一把"纯随机"的尺子
- 三、第一把尺子： β NTI —— 测"环境筛选"
- 四、第二把尺子：RCbray —— 把"随机"再细分
- 五、两把尺子合起来：一张判定流程图
- 六、动手怎么做（对接模型 16、教程）
- 七、最容易误解的 3 个点

08.4 · 图解：多样性与排序（ α 、 β 、距离、PCoA 到底在算啥）

- 一、 α 多样性：单个样本内部，多不多样？
 - 二、 β 多样性：两个样本之间，差多少？
 - 三、排序（PCoA/NMDS）：把大表压成一张散点图
 - 四、 α 和 β ，别搞混（一张对照）
- 从数据到图，一条线

09 · 速记卡片与速查图

- 卡片 1 · 关键数字/阈值速查（最高频）
- 卡片 2 · 分析流程命令骨架（照着改）
- 卡片 3 · 工具速查（按流程阶段）
- 卡片 4 · 标志基因速查（碳氮磷硫循环）

卡片 5 · 决策速查 (我该选哪个?)

卡片 6 · 20 个模型一句话索引

卡片 7 · 7 个思维框架口诀

卡片 8 · 新手避坑清单 (贴脑门上)

10 · 前沿模型与方法 · 总览

一句话先看懂：每个前沿在补哪块短板

本模块内容

前沿的总趋势 (记住这条主线)

10.1 · AI 与基础模型：用人工智能照亮"暗物质"

一、先回忆痛点：暗物质问题

二、关键思想：把"序列"当成"语言"来学

三、两大类模型 (小白只需记住"是什么、能干啥")

四、另一条 AI 应用线：机器学习做"预测" (很实用的他山之石)

五、和你已有知识的连接 (别把它当孤立新知识)

六、给小白的态度建议

延伸阅读

10.2 · Hi-C 邻近连接 与 病毒组

一、先回忆痛点

二、核心思想：在细胞被打碎前，先把"邻居"焊在一起

三、它能做到普通分箱做不到的事

四、代表工具

一、一个被基础篇略过的整片大陆

二、难点：病毒是"暗物质中的暗物质"

三、关键问题：这个病毒感染谁？——CRISPR 间谍档案

四、和你已有知识的连接

延伸阅读

10.3 · 从"基因潜力"到"活性与互作"

一、痛点回顾

二、核心思想：让活跃的菌"自己变重"

三、qSIP (定量版) 让它更强

四、和你已有知识的连接

一、痛点回顾

二、核心思想：给每个菌建一张"代谢地图"，再让它们"做生意"

三、代表工具 (小白只需知道名字和分工)

四、用处与坑

两件利器在"证据阶梯"上的位置 (呼应框架7)

延伸阅读

11 · 多组学整合 与 他山之石 · 总览

- 一、先纠正一个常见误解
- 二、本模块内容
- 三、一图看懂"地基 + 楼层 + 外援"

11.1 · 组学阶梯与多组学整合

- 一、组学阶梯：从"能干"到"真干了"的四级台阶
- 二、为什么"地基"既是优点也是局限
- 三、多组学整合：把几层楼"对齐"着看
- 四、整合到底难在哪 (小白要有心理准备)
- 五、给小白的路线建议

延伸阅读

11.2 · 他山之石：向别的领域借智慧

1. 海洋：Tara Oceans —— "大科学 + 大数据"的范本
2. 人体肠道：方法学的"练兵场"
3. 地球微生物组计划(EMP)：跨生境的"大一统"
1. 生态学 / 宏观生态 —— 把研究大象老虎的理论搬给微生物
2. 网络科学 —— 研究社交网络/互联网的工具
3. 系统生物学 / 代谢工程 —— 把"细胞代谢网络"搬到群落
4. 人工智能 / 数据科学 —— 最猛的一股外援
5. 还有更多"娘家"
- 三、怎么用好"他山之石" (方法论)

延伸阅读

11.3 · 各类组学详解：宏基因组的"楼上邻居"们

1. 宏转录组 (Metatranscriptomics) —— 测 RNA，看"在表达什么"
2. 宏蛋白组 (Metaproteomics) —— 测蛋白，看"真造出了什么"
3. 代谢组 (Metabolomics) —— 测代谢物，看"产出了什么"
4. 宏表观组 (Metaepigenomics) —— 测 DNA 甲基化，一个新维度
- 三、一张图：宏基因组和它的"邻居们"

延伸阅读

11.4 · 从组学领域借方法：最该借的"他山之石"

- 一、从人类基因组学借：GWAS → MWAS
- 二、从单细胞组学借：单细胞分辨 (看清"一个个体")
- 三、从空间组学借：原位定位 (看清"在哪里")

四、从单细胞分析借：数据分析方法

五、方法论：怎么判断一个组学方法"能不能借"

延伸阅读

11.5 · 他山之石进阶：更多生态系统与跨学科

1. 极端环境 —— 宏基因组学的"发源地"之一

2. 植物微生物组 —— 天然的"模式系统"

3. 建成环境 —— 标准化大规模采样的范本

4. 古 DNA / 古微生物 —— 时间维度

1. 博弈论 / 经济学 —— 解释"合作与背叛"

2. 流行病学 —— 溯源与传播

3. 信息论 —— 多样性的数学根基

4. 因果推断 —— 从"相关"突围到"因果"

5. 地统计学 / 遥感 GIS —— 把微生物"画上地图"

6. 药物化学 / 天然产物 —— 土壤是"新药矿"

三、一张"借用地图" (总览)

四、把"借"变成你的核心能力

延伸阅读

12 · 自测与练习 · 总览

四套练习

怎么用

掌握度自评 (做完四套后)

自测 01 · 基础概念

一、选择题 (单选)

二、判断题 (对/错, 并说明为什么)

三、简答题

自测 02 · 分析与统计

一、选择题 (单选)

二、计算题 (每题一步即可)

三、简答题

自测 03 · 生态与功能

一、选择题 (单选)

二、判断题 (对/错, 并说明)

三、简答题

自测 04 · 纠错与案例分析

第一部分 · 找错题（每段至少 1 个错误）

第二部分 · 案例分析（综合题）

第一部分 · 找错题

第二部分 · 案例分析

全部做完了？

13 · 资源导航与优质教程（站在巨人肩上）

- 一、• 中文一体化流程（小白首选，最省心）
 - 二、▪ 国际标准化流程（要可复现、要发论文）
 - 三、◦ 免费实操培训（零基础 / 零代码也能练手）
 - 四、统计与可视化（R 为主，本库 07.4 的延伸）
 - 五、权威综述与教材（先建立认知地图）
 - 六、数据库与公共平台官方入口
 - 七、怎么把这些资源和本库配合（避免重复）
- 一句话总清单（收藏版）



土壤宏基因组学 · 小白系统学习库

一句话定义：土壤宏基因组学（Soil Metagenomics）= 直接从土壤里提取所有微生物的 DNA 一起测序，用计算的办法搞清楚"土里有谁、它们能干什么、为什么是它们"。

这个库是零基础设计的。它不堆术语，而是从最基本的事实（第一性原理）出发，一步步推出这个领域为什么要用那些方法、那些模型、那些工具。学完你应该能：

- 看懂一篇土壤宏基因组论文的方法和图；
- 知道一个项目从采样到出结论要经过哪些步骤、每步用什么工具；
- 用正确的"思维框架"去判断一个结论靠不靠谱。

想离线 / 打印通读？整本电子书（PDF 186 页 / HTML / Markdown）已生成在 [合订本/](#)。

学习路线图（建议顺序）

第 0 步 完全零基础先看这 → 00-零基础启蒙.md 新手从这开始
(大白话 + 生活类比, 不需要任何基础, 先建立整体感觉)

第 1 步 搞懂"为什么" → 01-第一性原理.md
(领域存在的根本逻辑, 全部后续内容的地基)

第 2 步 搞懂"用什么想" → 03-思维框架.md
(7 个思维框架, 先装上"思维操作系统"再学细节)

第 3 步 搞懂"用什么算" → 02-必学模型/ (20 个模型, 分 5 类)
├— A 实验与测序模型 (数据怎么来的)
├— B 生信分析模型 (序列怎么变成结论)
├— C 多样性与统计模型 (怎么量化和比较)
├— D 群落构建生态模型 (怎么解释"为什么是它们")
└— E 功能与生态系统模型 (怎么连到碳氮磷循环)

第 4 步 看"别人怎么做的" → 04-案例库.md (10 个真实研究案例)

第 5 步 动手时随时查 → 05-工具与数据库速查.md
→ 06-术语表与延伸阅读.md

以下为进阶模块 (想更详细 / 动手 / 啃硬骨头时看)

第 6 步 真的把流程跑起来 → 07-实操教程/ (手把手, 装软件→出图, 5 篇)

第 7 步 把难概念彻底搞懂 → 08-难点图解/ (CLR/组装分箱/βNTI/多样性, 5 篇)

随时查 速记卡片扫一眼 → 09-速记卡片与速查图.md (阈值/流程/工具/口诀)

以下为拔高模块 (想看前沿 / 升维到多组学时看)

第 8 步 看正在发生的前沿 → 10-前沿模型与方法/ (AI/Hi-C/病毒组/qSIP/代谢建模)

第 9 步 升维: 组学全貌+借鉴 → 11-多组学整合与他山之石/ (组学阶梯 + 跨领域借智慧)

检验 边学边测、查漏补缺 → 12-自测与练习/ (4 套题, 含找错题, 附答案解析)

外援 站在巨人肩上找好教程 → 13-资源导航与优质教程.md (精选外部资源, 避免重复造轮子)


小白提示：完全没基础就先读 00-零基础启蒙（纯大白话，当故事看）。之后第一遍按"00 → 01 → 03 → 案例库"建立直觉，不必一开始就读懂全部模型公式；第二遍再回来啃 02 的 20 个模型。

目录结构

文件 / 文件夹	内容	给谁看
00-零基础启蒙.md	纯大白话 + 生活类比 + 一个贯穿到底的小故事，零基础也能懂"这门学科在干嘛"	完全小白，第 0 课
01-第一性原理.md	7 条不可再分的基本事实，整个领域都是从这里推出来的	所有人，必读第一篇
02-必学模型/	20 个必学模型，分 5 大类，每个含"是什么/解决什么/小白怎么理解/坑"	入门核心
03-思维框架.md	7 个思维框架：尺度、数据生命周期、结构-功能-过程、群落构建、假说vs数据、对照与可重复、相关到因果	入门核心
04-案例库.md	10 个真实案例：全球图谱、施肥、耕作、氮沉降、抗性基因组、MAG 恢复、长读长、关键种……	建立直觉、找选题
05-工具与数据库速查.md	按流程阶段排好的工具清单 + 主流数据库 + 中文友好的一体化流程	动手时查
06-术语表与延伸阅读.md	中英文术语对照 + 经典论文 + 入门资源	随时查
07-实操教程/	手把手实操：装环境→质控→读长分析→组装分箱→R 统计画图→报错排查（5 篇，含命令）	想动手跑数据
08-难点图解/	难点深扩：组成型/CLR、组装与分箱、 β NTI/RCbray、多样性与排序，全用图解讲透（5 篇）	某概念卡住时
09-速记卡片与速查图.md	阈值/流程/工具/标志基因/口诀/避坑，做成速查卡片	随时扫一眼
10-前沿模型与方法/	前沿：AI 基础模型(Evo/ESM)照亮暗物质、Hi-C 分箱、病毒组 + CRISPR、qSIP 测活性、群落代谢建模(3 篇)	想看最新进展
11-多组学整合与他山之石/	升维：组学阶梯(讲透"宏基因组是地基不是简化版")、各类组学详解、从组学领域借方法(MWAS/单细胞/空间)、跨学科他山之石(5 篇)	想看大图景

文件 / 文件夹	内容	给谁看
12-自测与练习/	检验：4 套题(基础/分析统计/生态功能/找错题与案例)，全部附答案解析 + 掌握度自评	边学边测、查漏补缺
13-资源导航与优质教程.md	外援：精选社区优质教程/流程/数据库/综述(EasyMetagenome、nf-core/mag、Galaxy、phyloseq…)，带评价与"何时用"，避免重复造轮子	想找现成好资源

一张图看懂整个领域的工作流



这张图里的每一个方块，背后都对应 02-必学模型/ 里的一个或几个模型。学模型的时候随时回来对照这张图，就不会"只见树木不见森林"。

学完自测（能答上来就算入门了）

1. 宏基因组和扩增子（16S）有什么本质区别？各自适合回答什么问题？（→ 模型 2）
 2. 为什么宏基因组测出来的丰度是"相对的"，不能直接比较绝对数量？这会带来什么坑？（→ 模型 14）
 3. 什么是 MAG？一个"高质量 MAG"的标准是什么？（→ 模型 8）
 4. 怎么判断一个土壤群落是"环境筛选（确定性）"还是"随机扩散（中性）"组装出来的？（→ 模型 15、16）
 5. 宏基因组只能告诉你微生物"能干什么"，不能告诉你"正在干什么"。为什么？想知道"正在干什么"该上什么技术？（→ 思维框架 3）
-

本库内容基于公开文献与主流工具整理，链接见各篇「延伸阅读」。领域发展很快，工具版本与数据库以官方最新为准。

00 · 零基础启蒙：用大白话把这门学科讲清楚

这一篇写给完全零基础的你——不懂生物、没碰过测序、不会编程，统统没关系。读完你会对"土壤宏基因组学到底在干嘛"有一个清楚的整体感觉。它是你的第 0 课，读它不需要任何准备。读法：放轻松，当故事看。遇到新词我都会立刻用大白话解释，不用怕，也不用记。

一、先建立一个画面：一勺土里藏着一座看不见的城市

随手挖一勺你家菜园子的土，大概几克重。你看它就是一坨土，但在显微镜下，这一勺土里住着几十亿个微生物（细菌、真菌、古菌等），种类成千上万。

打个比方：一勺土 $\approx$ 一座超级大城市。里面有：

- 各行各业的"居民"（不同种类的微生物）；
- 有人多的大族群（优势菌），也有人数极少、平时不起眼的小群体（稀有菌）；
- 每个居民都有自己的"工作"——有的在分解落叶（碳循环），有的在帮植物固定养分（氮循环），有的在对付污染物……

这座城市完全看不见、摸不着、听不到。土壤宏基因组学，就是一套"给这座看不见的城市做人口普查 + 职业普查"的办法。

记住这个"一勺土 = 一座城市"的画面，后面所有内容都能挂到它上面。

二、我们到底想知道什么？——三个核心问题

对这座看不见的城市，科学家其实就想搞清楚三件事：

问题	大白话	行话叫法
1. 有谁？	城里住着哪些居民？各有多少？	物种组成 / 多样性
2. 能干啥？	这些居民都会哪些"工作技能"？	功能潜力
3. 为啥是它们？	为什么是这些居民住这儿，而不是别的？	群落构建

整个学科、所有那些复杂工具和模型，归根到底都是为了回答这三个问题。你以后看任何一篇论文、学任何一个方法，都可以先问一句："它在回答这三个问题里的哪一个？"

三、笨办法行不通：为什么不能把微生物"养出来"数？

你可能会想：那简单啊，把土里的微生物挑出来，放培养皿里养大，一个个数、一个个看不就行了？

问题来了：土里的微生物，超过 99% 在实验室里根本养不活。

为什么？因为它们在土里是抱团生活的——A 菌的"废料"正好是 B 菌的"口粮"，C 菌要靠 D 菌发的化学信号才肯生长……你把某一个单独拎出来放进培养皿，它就像一个离开了整个城市供应链的人，断了水电粮食，活不下去。

这就好比：你想研究一座城市，却规定"只能研究那些愿意单独住到无人荒岛上还能活下来的人"——你最后看到的，是被严重扭曲的、极少数特殊居民，根本代表不了整座城。

结论：既然养不活，那就别养了，直接去读它们的"身份信息"。这就是这门学科的出发点，行话叫"免培养"（不靠培养）。

想看更系统的逻辑推导，读完这篇可以去看 01-第一性原理.md 。

四、DNA：每个微生物随身带的"身份证 + 技能清单"

那"身份信息"指的是什么？答案是 DNA。

你可以把 DNA 理解成每个生命体都随身携带的一份说明书，这份说明书有两个作用：

1. 它是身份证：每种微生物的 DNA 都不一样，读到这段 DNA，就能认出"哦，这是某某菌"。
2. 它是技能清单：DNA 是由一段段叫"基因"的片段组成的，一个基因大致对应一项本领（比如"会分解纤维素""会固定氮气"）。读完一个微生物的全部基因，就大致知道它会哪些活儿。

打个比方：DNA 就像一个人随身带的简历——上面既写了名字（身份），又列了"会计证、驾照、厨师证"（技能）。

DNA 本身是一条很长的链，由四种叫"碱基"的小积木组成，简写为 A、T、C、G 四个字母。所以一段 DNA，在电脑里看就是一长串字母，像这样：

```
...ATGCCGTTAGGCATTCGGATCCAGT...
```

生命的全部信息，就编码在这串字母的排列顺序里。这是个惊人但真实的事实：读懂了字母顺序，就读懂了"它是谁、它会什么"。

这里有个特别重要、贯穿全库的细节：简历上写着"会做饭"，不代表他此刻正在做饭。同理，一个微生物有某个基因，只代表它有能力做某件事，不代表它正在做。这个区别后面会反复提醒（第九节、思维框架 3）。

五、测序：把 DNA 变成电脑能读的一长串字母

知道了"信息在 DNA 的字母顺序里"，下一步自然就是：想办法把这串字母读出来。

把 DNA 的字母顺序读出来、变成电脑里的文本，这个过程就叫"测序"（sequencing）。干这活的机器叫"测序仪"。

但这里有个绕不开的现实困难：

- 测序仪没法一口气从头读到尾读完一条很长的 DNA。它只能把 DNA 打断成很多短片段，每段读个一两百个字母，读出成千上万亿条这样的小短串。
- 每一条小短串，行话叫一条 "read"（读段）。

更麻烦的是（这正是"宏"字的由来）：你从土里提取 DNA 时，是把一勺土里所有微生物的 DNA 全部混在一起提出来的，没法区分哪段来自哪个菌。

打个比方：

你把这座城市里每个居民的简历都收集起来，全部塞进一台碎纸机绞碎，最后得到一大堆碎纸条（reads）。每张碎纸条上只有几个字，而且不知道它原来属于谁。

"宏基因组测序"得到的，就是这样几千万到几十亿张混在一起、来历不明的碎纸条。

听起来一团乱？别急，下一步就是把它们重新整理出意义。

六、关键一步：一堆"字母碎片"怎么变成"土里有谁、能干啥"？

这一步是整个学科的核心魔法，全靠计算机和算法完成（这也是为什么做这行要懂一点编程和数据分析）。整理碎纸条主要有两条思路，配合使用：

思路 A：直接查字典（基于读长） 拿每一张碎纸条，去一个巨大的"已知 DNA 字典"里搜：哪段已知序列跟它最像？ - 像某个已知细菌 → 这张纸条多半来自那种菌（回答"有谁"）； - 像某个已知的"固氮基因" → 说明城里有居民会固氮（回答"能干啥"）。这种方法快，但只能认出"字典里已经收录"的东西。

思路 B：先拼回去，再研究（基于组装） 先像玩拼图一样，把大量碎纸条里边缘文字重叠的拼接起来，还原成更长的段落（行话叫 contig），甚至尽量拼回一个个居民的"简历全文"——也就是一个个基因组（行话叫 MAG，意思是"从宏基因组里拼出来的基因组"）。拼得越完整，对这个居民的了解就越深。这种方法信息更全，但很费算力，而且土壤太复杂、碎片太杂，常常拼不完整（这是土壤研究公认的难点）。

整理完之后，你就得到了梦寐以求的两张表： - 一张"居民名册"：土里有哪些菌、各占多少比例； - 一张"技能清单"：这群菌总共拥有哪些功能基因、各类功能有多强。

有了这两张表，就可以做统计、画图、和别的样本比较，最后得出结论了。

上面这一整段，就是后面 02-必学模型 里一连串模型（比对、组装、分箱、分类、注释）在做的事。现在只要懂这个大白话版就够了。

七、两种打开方式：查身份证 vs 读简历

刚才说的"把所有简历碎纸条全测"，是最全面的一种做法，叫"鸟枪法宏基因组"（就是本库的主角）。但它贵、数据量大、算起来累。

还有一种更省钱的做法，叫"扩增子"（比如常听到的"16S 测序"）：

它不读整本简历，只查每个居民的"身份证号"那一栏。

- 扩增子（查身份证）：便宜、快，能告诉你"城里有谁、各占多少"，但几乎说不清每个人会什么技能。适合样本特别多、只想知道"群落组成怎么变"的研究。
- 宏基因组（读简历全文）：贵、累，但"有谁 + 能干啥"都知道，还能拼出基因组。适合想深挖"功能、代谢、具体基因"的研究。

没有谁绝对更好，看你的问题和预算。很多研究两个一起用：先用便宜的扩增子大范围扫，再用宏基因组挑重点深挖。

详见 02-必学模型/01 的"模型 2"。

八、跟着走一遍：一个完整研究长什么样？

光讲零件还不够，我们用一个具体的小故事把所有零件拼起来跑一遍。看完你就有整体感了。

小张的问题：他想知道——给菜园施有机肥，会不会让土里"会固氮（帮土壤变肥）"的微生物变多、功能变强？

他会这样一步步做（括号里是对应本库的内容，现在不用点进去，先感受流程）：

1. 先想清楚问题和设计 —— 设两组地：一组施有机肥，一组不施（对照）。每组至少挖 3 块地分别取样，不能只挖一块（否则没法判断差异是真的还是巧合）。 这一步最关键，决定成败（思维框架 2、6）。

2. 取土、保存 —— 按规范采土，尽快冷冻，别让 DNA 坏掉。
3. 提 DNA、送测序 —— 把每份土里所有微生物的 DNA 提出来，送测序仪，拿回一大堆"碎纸条"(reads)。 第五节讲的那一步。
4. 质控（清垃圾） —— 先用软件把读得模糊不清的碎纸条、混进来的植物 DNA 等清理掉。不做这步，后面全是错的（模型 4）。
5. 整理出两张表 —— 用计算机把碎纸条整理成"居民名册"和"技能清单"。 第六节那两条思路（模型 5-10）。
6. 比一比、算一算 —— 比较施肥组和对照组：固氮基因（比如叫 `nifH` 的那个）是不是真的变多了？群落整体差异大不大？而且要做统计检验确认"这差异不是碰巧"。 模型 11-14、19。
7. 小心解读 —— 就算 `nifH` 基因变多了，小张也只能说"固氮的潜力变强了"，不能直接说"固氮量真的增加了"——因为基因多不等于真在干活。想下更硬的结论，得再测它们的"工作记录"（RNA）或直接测固氮速率。 这就是那条铁律：能干 $\neq$ 在干（思维框架 3、7）。
8. 出结论 —— "施有机肥后，土壤固氮相关微生物及其功能基因显著增加，提示固氮潜力增强（但实际速率有待进一步验证）。"

看，从一勺土到一个结论，中间这 8 步，每一步都对应本库里的某些模型和思维框架。你不用一下子全记住，但这个整体流程感非常重要——它就是你脑子里那张地图。

九、四个一定要破除的"小白误区"

这四个坑，几乎每个新手都踩过。现在就记住它们，能帮你省下大量冤枉路：

1. "测到这个基因 = 它正在发挥作用" → 只是有能力，不代表正在做（简历写了"会做饭" $\neq$ 正在做饭）。这是最大、最常犯的误区。
2. "某个菌占比 3%，就是说它数量是另一个占比 1.5% 的菌的两倍" → 测序给的是相对比例，不是绝对数量。而且比例有个怪脾气：一个菌"涨"了，会逼着别的菌在数字上"跌"，哪怕它们实际没变。所以比较时要用专门的统计方法（模型 14），不能想当然。

3. "我没测到它，所以土里没有它" → 可能只是你测得不够深（碎纸条收得不够多），稀有的居民没被抽到。"没看到"不等于"不存在"（模型 3）。
4. "A 菌和 B 菌总是一起出现，所以它俩肯定在合作 / 互相依赖" → 一起出现，可能只是它俩都喜欢同样的环境，并不一定真有来往。相关不等于因果（模型 17、思维框架 7）。

这四条，建议读完整个库之后再回来看一遍，你会有更深的体会。

十、我能学会吗？——心态、基础和怎么用这个库

能。但要有正确的预期：

- 这是一门交叉学科：一半是微生物/生态学，一半是数据科学（要用命令行、跑软件、做统计）。两边都不用一开始就精通，边学边补即可。
- 需要慢慢补的基础：① 一点点生物学常识（这个库够用了）；② Linux 命令行的基本操作；③ 一点 R 或 Python 做统计画图。这些都可以后面再说，现在不用怕。
- 算力现实：真正跑土壤数据需要服务器/云，个人电脑只够学命令、练小数据——这很正常，不是你的问题。

心态最重要：第一遍只求"看懂大概在讲什么"，看不懂的术语跳过去没关系。学习是螺旋上升的，第二遍、第三遍才慢慢"会判断""能动手"。别指望一遍到位，没人能一遍到位。

这个库，建议你这样用：

你现在在这 ——▶ 00 零基础启蒙（就是本篇，先建立整体感觉）

|
01 第一性原理（把"为什么"想得更透一点）

|
03 思维框架（学会怎么判断对错，比记知识点更重要）

|
04 案例库（看真实研究长啥样，建立直觉）

|
02 必学模型（20 个模型，第二遍再慢慢啃，别硬背）

|
05 工具速查 / 06 术语表（动手和查词的时候随时翻）

- 不懂的词 → 翻 06-术语表与延伸阅读.md，里面有中英对照和"避坑清单"。
- 想跟着电脑跑跑看 → 05-工具与数据库速查.md 里推荐了中文友好的入门流程 EasyMetagenome。
- 那篇还附了一个 4 周入门计划，照着走就行。

一句话总结这一课：土壤宏基因组学，就是通过读取一勺土里所有微生物混在一起的 DNA，来搞清楚"土里有谁、它们能干什么、为什么是它们"。剩下的所有复杂内容，都是为了把这件事做得更准、更可信。

准备好了，就翻开 01-第一性原理.md，我们把"为什么"想得更透一点。

01 · 第一性原理：从最基本的事实推出整个领域

第一性原理（First Principles）：不靠“别人都这么做”的类比，而是回到不可再分的基本事实，从这些事实一步步往上推。这篇是全库的地基。把这 7 条想透，后面 20 个模型、所有工具，你都能“猜”出它们为什么要存在。

读法：每条原理 = 一个基本事实 ➡ 推出一个必然的后果 ➡ 于是领域里诞生了某种方法/模型。

原理 0（前提）：土壤里几乎全是微生物，而且绝大多数我们“养不活”

基本事实：一克土壤里有约 $10^9 \sim 10^{10}$ 个微生物细胞、上万到百万级别的物种（OTU/类群）。但其中 99% 以上在实验室里培养不出来（缺它需要的伙伴、信号或环境）。

必然后果：如果只研究“能在培养皿里长出来的那 1%”，我们看到的是一个被严重扭曲的世界。要研究真实的土壤微生物，必须绕开培养。

于是诞生了：免培养（culture-independent）技术路线——不养细菌，直接去读它们的“分子身份证”。这就是宏基因组学的出发点。

一句话：养不活 → 只能直接读 DNA。这是这门学科存在的根本理由。

原理 1：DNA 是生命的信息载体，“我是谁 + 我能干什么”都写在里面

基本事实：每个细胞的 DNA 既编码了它的身份（谁的基因组就是谁），也编码了它潜在能做的所有事（每个基因 $\approx$ 一种蛋白 $\approx$ 一种功能/酶）。这就是分子生物学的中心法则：DNA → RNA → 蛋白质 → 功能。

必然后果：只要能读到一段 DNA，就能（通过和已知序列比对）推断它来自谁、以及它编码什么功能。

于是诞生了：用序列回答两个核心问题——"Who is there?"（物种组成）和 "What can they do?"（功能潜力）。后面的"物种分类模型""功能注释模型"都是为这两个问题服务的。

注意"潜力"二字：基因存在 ≠ 正在表达。这点会反复出现，见思维框架 3。

原理 2：环境里所有生物的 DNA 是混在一起的——这正是"宏 (meta) "的含义

基本事实：你从土里提的 DNA，不是某一个菌的，而是成千上万个物种的 DNA 碎片混在一桶里。

必然后果：测出来的不是一个基因组，而是一锅"基因组沙拉"。你拿到的是海量短片段（reads），每一段不知道来自哪个物种、哪个位置。

于是诞生了两条技术路线（这是全领域最重要的分叉，对应模型 2）：

路线	怎么做	比喻
扩增子（Amplicon，如 16S/ITS）	只挑一段"身份证基因"（16S rRNA）扩增测序	只查每个人的身份证号 → 便宜、快、只知道"有谁"
鸟枪法宏基因组（Shotgun Metagenomics）	把所有 DNA 随机打碎、全部测	把每个人的整本日记都撕碎了测 → 贵，但"有谁 + 能干啥"都知道

本库讲的"宏基因组"主要指鸟枪法；但扩增子是必须先理解的对照（模型 2 会讲清楚区别）。

原理 3：测序把"生物学问题"变成了"数据/计算问题"

基本事实：高通量测序的产物是文本——由 A/T/C/G 组成的字符串，配一个质量分数。

必然后果：一旦生物变成了字符串，生物学问题就变成了字符串处理 + 统计问题：怎么把碎片拼起来（组装）、怎么判断两段相不相似（比对）、怎么把它们归类（聚类/分箱）、怎么比较两组样本（统计检验）。

于是诞生了：整个生物信息学 (bioinformatics) 流程。模型 5–10（比对、组装、分箱、分类、注释）本质上都是在解字符串/算法问题。这也是为什么学宏基因组绕不开命令行和一点编程。

心态转变：做土壤宏基因组，一半是微生物学，一半是数据科学。

原理 4：我们测到的是"相对比例"，不是"绝对数量"

基本事实：一次测序的总数据量（总 reads 数）是仪器和上样量决定的人为上限，不是样品真实的细胞总数。所以你只能知道"A 菌占了 3%"，不知道"每克土里有多少个 A 菌"。

必然后果：数据是组成型的 (compositional) ——所有比例加起来必须等于 100%。这带来一个反直觉的陷阱：一个菌"涨"了，会逼着别的菌在数字上"跌"，哪怕它们绝对数量没变。直接用常规相关/比较会产生大量假阳性。

于是诞生了：组成型数据分析方法——CLR（中心对数比）变换、Aitchison 距离、ALDEx2/ANCOM 等差异分析工具（模型 14）。这是新手最容易忽视、最容易出错的地方。

记住这句话："看到的是比例，不是数量。" 它会救你很多次。

原理 5：我们永远只看到"样本"，看不到"全部"——所以一切都带不确定性

基本事实：你采的几克土、测的那些 reads，都只是真实土壤（一片地、一个生态系统）的一次抽样。抽样必然不完整：测得越浅，漏掉的稀有物种越多。

必然后果：

1. 同样的土，测两次结果不会完全一样 → 必须有生物学重复和统计。
2. 测序深度不够时，你"看到的多样性"会低于"真实多样性" → 需要稀释曲线判断够不够（模型 3）。
3. 任何结论都该带"误差棒"，不能因为"测到了 1 条 reads"就说"这里有这个功能"。

于是诞生了：多样性估计与稀释/饱和模型（模型 3、11）、重复设计与统计检验的整套规范（思维框架 6）。

一句话："没测到"不等于"不存在"，"测到一点点"也可能是噪声。

原理 6：土壤是地球上最复杂、最不均匀的微生物栖息地

基本事实：相比人肠道、海水，土壤的微生物多样性最高、最异质——隔几厘米的两团土，菌群可能完全不同；而且有巨大的"稀有生物圈（rare biosphere）"和大量"微生物暗物质（microbial dark matter）"（没有任何已知基因组可比对的未知类群）。

必然后果：

1. 复杂度极高 → 组装很难拼完整、覆盖度低、能恢复的高质量基因组（MAG）比例低（这是土壤生信公认的难点）。
2. 异质性强 → 采样设计极其关键，采错了后面神仙难救。
3. 大量序列比不上任何数据库 → 很多"功能未知"，结论天然不完整。

于是诞生了：针对土壤的深度测序、混合/长读长测序、bin 精炼等策略（模型 6–8、案例 8、9），以及"承认未知、谨慎下结论"的科研态度。

把 7 条串起来：领域的逻辑闭环

微生物养不活（原理0）

└─▶ 只能直接读 DNA（原理1：DNA 编码身份+功能）

└─▶ 但 DNA 是混在一起的（原理2：meta）

└─▶ 测序把它变成海量字符串（原理3：变成计算问题）

└─▶ 得到的是相对比例（原理4：组成型 → 要特殊统计）

└─▶ 只是抽样（原理5：不确定 → 要重复/稀释/多样性估计）

└─▶ 而且土壤极复杂（原理6：难组装/采样关键/大量未知）

这就是整个学科的骨架。之后你学的每一个模型、每一个工具，都是为了解决这条链上的某个具体困难。学新东西时问自己一句：

"它在解决上面哪一条原理带来的麻烦？"

能答上来，你就真懂了，而不是死记流程。

下一步

- 装上"思维操作系统"：03-思维框架.md
- 或直接学解决这些麻烦的工具：02-必学模型/

02 · 20 个必学模型 · 总览

这里的"模型"是广义的：既包括概念模型（一种理解世界的方式）、算法模型（一种计算方法），也包括统计/生态模型（一种量化和解释的工具）。它们共同构成了"从土壤到结论"所需的全部核心思想工具。20 个不要求一次记住，先看总览表建立全局，再按需精读。

每个模型在正文里都按统一格式讲解：① 是什么 ② 解决第一性原理中的哪个麻烦 ③ 小白怎么直观理解 ④ 关键参数/指标 ⑤ 常见坑

20 个模型总览表

A 类 · 实验与测序模型（数据是怎么来的）→ 01-实验与测序模型.md

#	模型	一句话
1	中心法则 / "基因即功能潜力"模型	为什么读 DNA 就能推断"谁 + 能干啥"
2	扩增子 vs 鸟枪法宏基因组模型	全领域最重要的分叉：查身份证 vs 读全本日记
3	测序深度与稀释曲线（饱和）模型	我测得够不够深？漏了多少没看见？
4	Phred 质量分数与测序错误模型	Q20/Q30 是什么，为什么必须先质控

B 类 · 生信分析模型（序列怎么变成结论）→ 02-生信分析模型.md

#	模型	一句话
5	序列比对与同源性模型	两段序列像不像？E-value、相似度怎么读
6	de novo 组装：de Bruijn 图模型	把海量碎片拼成长片段 contig
7	分箱（Binning）：组成+丰度聚类模型	把 contig 按"它属于谁"分堆，凑出基因组
8	MAG 质量评估：单拷贝标记基因模型	拼出来的基因组完整吗？污染吗？(MIMAG 标准)
9	物种分类：k-mer / LCA 模型	一条序列归到哪个物种（Kraken2 思想）
10	功能注释：直系同源 / 数据库映射模型	一个基因对应哪个功能（KEGG/eggNOG/CAZy/CARD）

C 类 · 多样性与统计模型（怎么量化和比较）→ 03-多样性与统计模型.md

#	模型	一句话
11	α 多样性与 Hill 数模型	单个样本里"种类多不多、均不均匀"怎么量化
12	β 多样性与排序（PCoA/NMDS）模型	样本之间差异多大，怎么画在一张图上
13	物种丰度分布 / 等级-丰度模型	为什么永远是"少数很多、多数很少"
14	组成型数据模型（CLR / 差异丰度）	比例数据的正确打开方式，避免假阳性


D 类 · 群落构建生态模型（怎么解释"为什么是它们"）→ 04-群落构建生态模型.md

#	模型	一句话
15	中性群落模型（Sloan Neutral Model）	假设"全凭运气"，能解释多少？
16	确定性 vs 随机：零模型框架（ β NTI/RCbray）	是环境筛选还是随机扩散在主导？
17	共现网络与关键种模型（SparCC/SPIEC-EASI）	谁和谁共存，谁是"枢纽"物种
18	生物地理：距离衰减与"万物无处不在"模型	越远越不同？还是环境说了算？

E 类 · 功能与生态系统模型（怎么连到碳氮磷循环） → 05-功能与生态系统模型.md

#	模型	一句话
19	生物地球化学循环的功能基因模型	用标志基因量化土壤的碳/氮/磷/硫循环能力
20	结构-功能关系与功能冗余模型	物种变了，功能一定变吗？(冗余 vs 脆弱)

20 个模型如何对应 workflow



给小白的精读优先级

- 第一优先（必懂）：2、3、8、11、12、14、19 —— 不懂这些读不了论文。
- 第二优先（进阶）：5、6、7、9、10、16、17、20。
- 第三优先（拓展）：1、4、13、15、18 —— 理解背景，不必先精通。

从 01-实验与测序模型.md 开始。

A 类 · 实验与测序模型（模型 1–4）

这一类讲"数据是怎么来的"。不懂数据怎么产生，后面所有分析都是空中楼阁。

模型 1 · 中心法则 / "基因即功能潜力"模型

- ① 是什么 分子生物学中心法则：DNA → 转录 → RNA → 翻译 → 蛋白质（酶）→ 执行功能。推论：每一个基因 ≈ 一种潜在功能。一个微生物拥有哪些基因，就大致决定了它"能做哪些代谢"。
 - ② 解决哪个麻烦 原理 1。它是"读 DNA 就能推断功能"这件事的理论依据——没有它，宏基因组数据就只是无意义的字符串。
 - ③ 小白怎么理解 把基因组想成一个人的技能证书清单。看到他有"会计证""驾照""厨师证"，你就知道他能做账、开车、做饭。宏基因组就是在统计一片土里所有微生物的"技能证书"。
 - ④ 关键概念 - 基因 (gene) → 蛋白 → 酶 → 反应：功能注释就是沿这条链反推。 - 功能潜力 (functional potential)：注意是"能做"，不是"正在做"。
 - ⑤ 常见坑 - "有证书 ≠ 正在上班"：基因存在不代表正在表达、正在起作用。要知道"正在干什么"，得用宏转录组 (metatranscriptomics, 测 RNA) 或宏蛋白/代谢组。这是宏基因组最根本的局限，贯穿全库（见思维框架 3）。★
-

模型 2 · 扩增子 vs 鸟枪法宏基因组模型 必懂

- ① 是什么 两种从环境 DNA 获取信息的根本不同策略：

维度	扩增子 Amplicon (16S/18S/ITS)	鸟枪法 Shotgun Metagenomics
测什么	只测一段标志基因 (细菌 16S rRNA、真菌 ITS)	随机打碎、测全部 DNA
能回答	有谁 (物种组成、多样性)	有谁 + 能干什么 (功能、通路、基因)
分辨率	通常到属, 难到种/株	可到种/株, 能拼出基因组(MAG)
成本	低 (适合大样本量)	高 (数据量大、算力贵)
功能	只能间接预测 (PICRUSt2 等, 误差大)	直接测到功能基因
偏差	PCR 引物偏好、拷贝数差异	受 DNA 提取、宿主污染、数据库覆盖影响

② 解决哪个麻烦 原理 2 (DNA 混在一起, 怎么取信息)。这是全领域最重要的一次方法分叉。

③ 小白怎么理解 一个班级 (一片土) : - 扩增子 = 只收每个人的身份证号统计 → 快速知道"班里有哪些人、男女比例", 但不知道每个人会什么技能。 - 鸟枪法 = 把每个人的简历全文都收来 → 既知道有谁, 又知道谁会什么, 但贵、读起来累。

④ 怎么选 - 只想知道"群落组成随处理怎么变"、样本量大、预算紧 → 扩增子。 - 想知道"功能/代谢通路/具体基因/恢复基因组" → 鸟枪法。 - 很多研究两者结合: 扩增子铺广度, 宏基因组挖深度。

⑤ 常见坑 - 把扩增子 PICRUSt 预测的功能当成"真实测到的功能"——它只是基于 16S 的统计猜测。 - 16S 拷贝数在不同菌里差很多, 扩增子的"丰度"会被系统性扭曲。 - 误以为"宏基因组样样比扩增子强"——大样本量的生态学问题, 扩增子常更划算。

模型 3 · 测序深度与稀释曲线 (饱和) 模型 必懂

① 是什么 测序深度 (depth) = 一个样本测了多少数据 (reads/碱基数)。稀释曲线 (rarefaction curve) : 横轴是抽到的 reads 数, 纵轴是"已发现的物种/基因数"。曲线爬升 → 变平 (饱和) 意味着"再多测也发现不了多少新东西了"。

② 解决哪个麻烦 原理 5 (只是抽样, 可能漏)。它回答一个生死攸关的问题: 我测得够深吗?

- ③ 小白怎么理解 像在一片森林里数鸟的种类。刚开始每走几步都见到新鸟（曲线陡升）；走久了新种越来越少（曲线变平）。没变平说明森林里还有很多种你没遇到——你的"测序深度"不够。
- ④ 关键指标 - 曲线是否到平台期：到了 → 深度足够；没到 → 低估了多样性。 - 土壤因极高多样性，常常测不饱和，这是土壤宏基因组的常态难点（原理 6）。
- ⑤ 常见坑 - 不同样本测序深度不一样就直接比多样性 → 深的样本天然"看起来"物种更多，是假象。要么抽平（rarefy 到相同深度），要么用对深度不敏感的方法。 - 把"没测到"当成"不存在"——可能只是没测够深。

模型 4 · Phred 质量分数与测序错误模型

- ① 是什么 测序仪给每个碱基一个置信度，用 Phred 质量值 Q 表示： $Q = -10 \times \log_{10}(P\text{出错})$ 。
- | Q 值 | 出错概率 | 准确率 |
|-----|--------|-------|
| Q20 | 1/100 | 99% |
| Q30 | 1/1000 | 99.9% |
- ② 解决哪个麻烦 原理 3 的副产品：序列里自带噪声。不先把噪声清掉，后面组装、比对、定量全会被污染（垃圾进、垃圾出）。
- ③ 小白怎么理解 像听一段有杂音的录音，每个字旁边标了"我有多确定听对了"。Q30 ≈ "千里挑一才错一个字"。质控就是把听不清的字和杂音剪掉。
- ④ 关键操作（质控 QC） - 切除低质量碱基/接头（adapter）；过滤过短、低复杂度序列。 - 去宿主/去污染：土壤样本可能混入植物根、动物 DNA。 - 常用工具：fastp、Trimmomatic、KneadData；查看质量报告：FastQC/MultiQC。
- ⑤ 常见坑 - 跳过质控直接分析——新手最常见、最致命的错误。 - 切得过猛把好数据也丢了，或忘记去接头导致组装出现嵌合。 - 忘了去宿主，导致"土壤里查出大量植物基因"的笑话。

下一类：02-生信分析模型.md（序列怎么变成结论）

B 类 · 生信分析模型（模型 5–10）

这一类是"把一堆短序列变成生物学结论"的核心算法思想。不要求会推导，但要懂它们在干什么、输出怎么读、坑在哪。

模型 5 · 序列比对与同源性模型

① 是什么 判断两段 DNA/蛋白序列像不像，从而推断它们是否同源（来自共同祖先）。相似 $\Rightarrow$ 很可能同源 $\Rightarrow$ 功能/身份很可能相近。这是几乎所有"注释"的底层逻辑。

② 解决哪个麻烦 原理 1 + 3：怎么把"未知序列"和"已知数据库"挂上钩，从而推断身份和功能。

③ 小白怎么理解 像搜索引擎：拿一段未知序列去庞大的"已知序列图书馆"里搜最像的几条。找到了高度相似的，就借用它的身份和功能标签。

④ 关键指标 - 相似度 / identity (%)：两条序列有多少位点一样。 - 覆盖度 / coverage：比对上的长度占比。 - E-value（期望值）：这个匹配"纯属巧合"的概率，越小越可信（如 $1e-50$ 远比 $1e-3$ 可靠）。 - 常用工具：BLAST、DIAMOND（快很多，宏基因组首选）、MMseqs2。

⑤ 常见坑 - 只看 identity 不看 coverage/E-value——一小段高相似可能是误导。 - 数据库里没有 $\neq$ 没功能：土壤大量序列比不上任何库（微生物暗物质，原理 6），这部分被默默丢掉，结论天然偏向"已知功能"。

模型 6 · de novo 组装：de Bruijn 图模型

① 是什么 组装（assembly）：把海量短 reads 拼接成更长的连续片段 contig。主流算法用 de Bruijn 图：把每条 read 切成更短的 k-mer，让重叠的 k-mer 首尾相连成图，再在图里找路径拼出长序列。

② 解决哪个麻烦 原理 2 + 3：reads 太短（100–250 bp），装不下一个完整基因/基因组，必须先拼长。

③ 小白怎么理解 像把一本被碎纸机绞碎的书复原：每个碎片 (read) 边缘和别的碎片有重叠的字，靠重叠把它们接回长段落 (contig)。k-mer 就是"用来对齐的那几个重叠的字"。

④ 关键概念 - k-mer 长度：小 k 容易连但易出错/产生假连接；大 k 更准但需要更高深度。 - N50：组装质量常用指标，越大通常越好（一半碱基位于 $\geq N50$ 长度的 contig 中）。 - 常用工具：MEGAHIT（省内存、土壤大数据常用）、metaSPAdes（质量高）；长读长用 metaFlye / hifiasm-meta。

⑤ 常见坑 - 土壤极难组装（原理 6）：多样性高、覆盖度低，大量 reads 拼不进去、contig 短而碎。 - 嵌合 contig：把不同物种的片段错接到一起，会污染后续分箱。 - 近缘菌株多时图里"分叉"严重，组装会断裂。

模型 7 · 分箱 (Binning)：组成 + 丰度聚类模型

① 是什么 分箱：把成千上万条来历不明的 contig，按"它们可能来自同一个基因组"分成一堆堆 (bin)。依据两条信号：1. 序列组成：同一基因组的 contig，四核苷酸频率 (tetranucleotide frequency) 等"文风"相似；2. 丰度共变：来自同一个菌的 contig，在多个样本里丰度同涨同落。

② 解决哪个麻烦 原理 2：组装只把碎片拼成 contig，还是"基因组沙拉"。分箱是把沙拉按物种重新归堆，逼近"一个箱 $\approx$ 一个基因组"。

③ 小白怎么理解 一地撕碎又拼成段落的多本书混在一起。分箱靠两点把它们分开：① 文风（每本书用词习惯不同 = 序列组成）；② 出现规律（同一本书的段落总是一起出现在某几个样本里 = 丰度共变）。

④ 关键概念 - 多个样本一起分箱（差异覆盖度）效果远好于单样本。 - 常用工具：MetaBAT2、MaxBin2、SemiBin2、CONCOCT、binny； - bin 精炼/整合：metaWRAP、DAS Tool；去冗余：dRep。

⑤ 常见坑 - 土壤分箱回收率低：高质量 MAG 占比小，bin 精炼几乎是必需步骤（土壤生信公认难点）。 - 单一分箱工具结果不稳，多工具 + 精炼才靠谱。

模型 8 · MAG 质量评估：单拷贝标记基因模型 必懂

- ① 是什么 分箱产物叫 MAG (Metagenome-Assembled Genome，宏基因组组装基因组)。怎么知道它好不好？用一组通用单拷贝标记基因（每个基因组应当不多不少正好有一份）来估：- 完整度 (completeness)：该有的标记基因找到了多少 → 越高越完整。- 污染度 (contamination)：本应只有一份的标记基因出现了多份 → 说明混进了别的基因组。
- ② 解决哪个麻烦 原理 5 + 6：拼出来的基因组可能残缺或污染，必须有客观质量标准，不能拿垃圾 MAG 下结论。
- ③ 小白怎么理解 像检查拼好的乐高套装：说明书规定每种特殊零件正好一个。- 缺零件 → 不完整 (completeness 低)；- 同一种特殊零件冒出两三个 → 混进了别套 (contamination 高)。
- ④ 关键标准 (MIMAG，业界通用)

等级	完整度	污染度	额外要求
高质量 High-quality	>90%	<5%	含 5S/16S/23S rRNA + ≥18 种 tRNA
中等质量 Medium	≥50%	<10%	—

- 常用质量评估：CheckM / CheckM2、GUNC (查谱系混杂)；
 - 标准化分类：GTDB-Tk (基于 GTDB 基因组分类数据库)。
 - GTDB 物种代表常用质量指数：完整度 - 5×污染度 > 50。
- ⑤ 常见坑 - 拿中低质量 MAG当成完整基因组解读其代谢通路——可能只是没拼到那段。- 只看完整度忽略污染度——高污染会让你"发现"根本不属于它的功能。

模型 9 · 物种分类：k-mer / LCA 模型

- ① 是什么 给每条 read 或 contig 贴"它来自谁"的标签 (taxonomic classification)。快速法 (如 Kraken2)：把序列切成 k-mer，去预建的数据库里查每个 k-mer 属于哪些物种；若一个 k-mer 在多个物种里都有，就归到它们的最近共同祖先 (LCA, Lowest Common Ancestor)。
- ② 解决哪个麻烦 原理 1 的"Who is there?"。在不组装的情况下也能快速出物种谱 (基于读长路线)。

- ③ 小白怎么理解 像通过口音/方言词猜一个人是哪里人：某些词只有特定地区用（物种特异 k-mer）→ 直接定位；某些词好几个地区都用 → 只能说"南方人"（退到更高层级 = LCA）。
- ④ 关键概念 - 基于读长：Kraken2 + Bracken（重估丰度）、MetaPhlAn（标志基因法）——快，但受数据库覆盖限制。 - 基于组装/基因组：GTDB-Tk 给 MAG 做标准化分类——准，但需先组装分箱。 - 分类层级：界→门→纲→目→科→属→种（domain→...→species）。
- ⑤ 常见坑 - 数据库偏差：库里没有的土壤未知菌会被错分或漏分（原理 6）。 - 不同工具/数据库结果不可直接横比（命名体系不同，如 NCBI vs GTDB）。 - 把"未分类比例高"当成数据差——在土壤里这恰恰是常态和真相。

模型 10 · 功能注释：直系同源 / 数据库映射模型

- ① 是什么 给基因贴"它能干什么"的标签（functional annotation）。先用基因预测工具（Prodigal）找出基因，再把蛋白序列比对到功能数据库，借用其中直系同源基因（ortholog，不同物种里由同一祖先基因演化来、功能通常保守）的功能标注。
- ② 解决哪个麻烦 原理 1 的"What can they do?"——把序列翻译成"代谢通路/酶/功能类别"。
- ③ 小白怎么理解 像给一堆零件查标准件目录：把每个零件比对到目录里"已知用途的标准件"，就知道它是螺丝、轴承还是齿轮，进而推断这台机器（群落）能完成哪些工序（代谢通路）。
- ④ 主流功能数据库（按用途）

数据库	看什么
KEGG	代谢通路、KO 功能号（最常用的"通路地图"）
eggNOG	直系同源分组 + 多层功能注释（eggNOG-mapper 很常用）
CAZy	碳水化合物活性酶（GH/GT/PL/CE/CBM）→ 碳降解能力
CARD	抗生素抗性基因（ARGs）→ 土壤抗性组
COG / Pfam	基础功能分类 / 蛋白结构域
NCyc / PCyc / SCyc	氮 / 磷 / 硫 循环专用基因库（见模型 19）

- 常用工具：eggNOG-mapper、DRAM（代谢整合）、antiSMASH（次级代谢/天然产物 BGC）。

⑤ 常见坑 - 仍然是"潜力 $\neq$ 活性" (模型 1 的坑) : 注释到基因不代表它在表达。 - 大量基因功能未知 (hypothetical protein) , 结论系统性偏向"已知功能"。 - 不同数据库对同一功能定义/粒度不同, 跨库比较要谨慎。

下一类 : 03-多样性与统计模型.md (怎么量化和比较)

C 类 · 多样性与统计模型（模型 11–14）

拿到物种谱/功能谱之后，怎么量化一个群落、怎么比较不同处理？这一类是统计的核心，也是论文里图最多的部分。

模型 11 · α 多样性与 Hill 数模型 必懂

① 是什么 α 多样性 (alpha diversity) = 单个样本内部的多样性，包含两个侧面：- 丰富度 (richness)：有多少种（物种数）。- 均匀度 (evenness)：各物种数量是否均衡。

经典指标可用统一的 Hill 数 (qD) 框架表达，由参数 q 控制"对稀有种的重视程度"：

q	对应经典指标	含义
$q=0$	物种丰富度 Richness	只数种类，不管多少（最看重稀有种）
$q=1$	Shannon 的指数 $\exp(H')$	按比例加权（不偏不倚）
$q=2$	Simpson 的倒数 $1/D$	主要反映优势种（最忽视稀有种）

② 解决哪个麻烦 原理 5：把"群落有多丰富"变成一个可比较的数。

③ 小白怎么理解 形容一个班级"多元不多元"：- 丰富度 = 有多少个不同省份的人；- 均匀度 = 是不是某个省占了一大半（不均匀）还是各省差不多（均匀）；- Hill 数的 q = 你统计时"多在乎人数极少的省份"—— q 越小越在乎稀有的。

④ 关键点 - Hill 数单位统一为"有效物种数"，可直接比较，比混用 Shannon/Simpson 更清晰。
- 对测序深度敏感（尤其 $q=0$ ），比较前需抽平或校正（见模型 3 的坑）。

⑤ 常见坑 - 不校正深度就比 α 多样性（最常见错误）。- 只报 Shannon 一个数——优势种和稀有种的变化会被混淆，最好同时看 $q=0/1/2$ 。

模型 12 · β 多样性与排序 (PCoA/NMDS) 模型 必懂

- ① 是什么 β 多样性 (beta diversity) = 样本之间的差异。两步：1. 用距离/相异度量化任意两样本差多少：Bray-Curtis (基于丰度)、Jaccard (基于有无)、UniFrac (考虑进化亲缘)、Aitchison (组成型，见模型 14)。2. 用排序 (ordination) 把高维距离压成二维图：PCoA (主坐标分析)、NMDS (非度量多维标度)。图上点离得近 = 群落像。
- ② 解决哪个麻烦 原理 5 + 实际需求：成百上千个物种没法直接看，必须降维成"一张点图"才能肉眼判断分组。
- ③ 小白怎么理解 给全国城市画"相似度地图"：先算每两座城市的"差异分" (距离矩阵)，再把它们摆到一张平面图上，相似的城市自然聚成一团。PCoA/NMDS 就是这张"群落相似度地图"。
- ④ 关键搭档：显著性检验 - 光看图"好像分开了"不算数，要做统计：PERMANOVA (adonis) 检验分组差异是否显著 (给 R^2 、p 值)；ANOSIM、betadisper (检验组内离散度差异) 等。
- ⑤ 常见坑 - 只看图说"分开了"不做 PERMANOVA——肉眼会骗人。- PERMANOVA 显著 $\neq$ 真有生物学差异，可能是组内离散度不同造成的假象 (要配合 betadisper)。- 距离选择影响结论：有无 vs 丰度、是否考虑进化，要按问题选。
-

模型 13 · 物种丰度分布 / 等级-丰度模型

- ① 是什么 描述"群落里各物种丰度如何分配"。几乎所有自然群落都呈现：极少数物种非常多 (优势种) + 绝大多数物种非常少 (稀有生物圈) ——这就是"长尾"。常用等级-丰度曲线 (rank-abundance) 展示，常用对数正态等分布拟合。
- ② 解决哪个麻烦 原理 6：解释"稀有生物圈 (rare biosphere)"为什么是土壤的常态，以及它为什么重要。
- ③ 小白怎么理解 像一个城市的财富分布：少数富豪掌握大量财富 (优势菌)，绝大多数是收入很低的普通人 (稀有菌)。但"普通人"数量巨大，是社会的潜力和韧性储备——环境一变，原本沉默的稀有菌可能突然"上位"。
- ④ 关键意义 - 稀有生物圈是功能的"种子库/备胎"：平时不显眼，扰动后可被"唤醒"接管功能，提供群落韧性 (与模型 20 功能冗余相关)。- 长尾意味着永远测不完 (呼应模型 3 稀释曲线难饱和)。

⑤ 常见坑 - 分析时把稀有种全部当噪声过滤掉——可能滤掉了重要的功能储备，要按问题谨慎设阈值。 - 组成型偏差会扭曲丰度排序（见模型 14）。 *

模型 14 · 组成型数据模型 (CLR / 差异丰度) 必懂

① 是什么 测序数据是组成型 (compositional) 的：只有相对比例、总和固定为 1（原理 4）。直接对比例做常规统计（相关、t 检验）会产生大量假阳性。正确做法是先做对数比变换，最常用 CLR（中心对数比，centered log-ratio）：把每个分量除以样本内所有分量的几何平均再取对数，把“受约束的比例”转回“可正常做统计的空间”。

② 解决哪个麻烦 原理 4——这是新手最容易踩、后果最严重的统计坑。

③ 小白怎么理解 切披萨：每块的“百分比”是被绑死的——一块变大，别块在百分比上必然变小，哪怕它实际没动。直接比“百分比”会得出“它俩此消彼长”的假关系。CLR 相当于不再比“占整张饼的比例”，而是比“每块相对于全体平均的倍数关系”，从而解开这个绑定。

④ 关键工具与方法 - 变换/距离：CLR、Aitchison 距离（= CLR 后的欧氏距离，常用于模型 12 的排序）。 - 差异丰度分析（找出处理间显著变化的物种/基因）：ALDEx2、ANCOM/ANCOM-BC、LinDA、LEfSe 等。

⑤ 常见坑 - 直接用原始比例算 Pearson 相关 → 共现网络全是假边（这也是模型 17 要用 SparCC/SPIEC-EASI 的原因）。 - 零值处理：很多物种丰度为 0，取对数前要加伪计数 (pseudocount) 或专门方法。 - 不同差异分析工具结果常不一致，重要结论最好用 2–3 种方法取交集。

下一类：04-群落构建生态模型.md（怎么解释“为什么是它们”）

D 类 · 群落构建生态模型（模型 15–18）

量化完"有谁、差多少"之后，更深的问题是：为什么是这些微生物？是环境挑出来的，还是纯属运气？谁和谁在一起？这一类是微生物生态学的"解释引擎"。

总纲：Vellend 把群落构建归为四种基本过程——选择（selection，环境/相互作用筛选）、扩散（dispersal，迁移）、漂变（drift，随机生灭）、物种形成（speciation）。下面的模型都是在量化这四种力的相对大小（详见思维框架 4）。

模型 15 · 中性群落模型（Sloan Neutral Community Model）

① 是什么 一个故意"什么都不假设"的零模型：假定所有物种生态上完全等价（没有谁更适应环境），群落只由随机扩散 + 随机生灭（漂变）决定。Sloan 模型用一个参数 m （迁移率）去拟合"物种的出现频率 vs 其在总库中的相对丰度"的关系。

② 解决哪个麻烦 原理 5/6 的延伸：先看看"纯随机能解释多少观测"，没被解释的部分，才需要用"环境选择"去解释。

③ 小白怎么理解 先假设"班级座位完全随机分配"，画出理论上的座位分布。再看真实座位：- 大体符合随机预测 → 说明"运气"主导；- 某些人总是坐第一排（高于随机预测）或总是坐角落 → 说明有"非随机的力"（环境选择）在起作用。

④ 关键参数 - m （迁移/扩散率）：越大说明扩散越畅通、越不受扩散限制。- R^2 ：模型对数据的拟合优度——中性能解释的比例。- 落在中性预测区间外的物种，往往是受确定性选择（环境特别偏好或排斥）的对象。

⑤ 常见坑 - 把"中性拟合得好"误读成"环境不重要"——它只是基线，需配合模型 16 一起下结论。- 数据稀疏、抽样不足会让拟合失真。

模型 16 · 确定性 vs 随机：零模型框架 (β NTI / RCbray) 进阶必懂

① 是什么 当前定量群落构建最主流的框架 (Stegen 等提出)。用系统发育 + 零模型把构建过程拆成可量化的几类：

第一步 β NTI (β -最近种间亲缘指数) ——衡量"环境选择"：| β NTI 取值 | 含义 | 归类 | | --- | --- |
--- | | > +2 | 比随机更"亲缘疏远" | 变量选择 (异质环境筛选) → 确定性 | | < -2 | 比随机更"亲缘相近" | 同质选择 (相似环境筛选) → 确定性 | | -2 ~ +2 | 与随机无显著差异 | 交给第二步判断 → 随机 |

第二步 RCbray (基于 Bray-Curtis 的 Raup-Crick) ——把 β NTI 判为"随机"的那部分再细分：- | RCbray | < 0.95 → 漂变 (drift) 主导；- RCbray > +0.95 → 扩散限制 (迁移太少)；- RCbray < -0.95 → 同质扩散 (迁移太强、各地被"抹平")。

② 解决哪个麻烦 把抽象的"为什么是它们"变成可量化的百分比：例如"本研究中 60% 由同质选择主导、30% 漂变、10% 扩散限制"。

③ 小白怎么理解 判断一个小区为什么住着这些人：- β NTI 先问："是不是房价/学区 (环境) 把特定人群筛进来的？" (确定性) - 若不是，RCbray 再问："那是大家随机搬来搬去 (漂变)？还是交通太差没人搬得进来 (扩散限制)？还是四通八达谁都能来、各小区趋同 (同质扩散)？"

④ 关键工具 - R 包 iCAMP (一体化框架)、picante、ade4、minpack.lm；常和中性模型 (模型 15) 一起报告。

⑤ 常见坑 - β NTI 依赖"系统发育信号" (亲缘近的菌生态位也近) 这一假设，需先检验，否则结论不可靠。- 框架对采样设计、分类分辨率很敏感，结论要谨慎、别过度解读具体百分比。

模型 17 · 共现网络与关键种模型 (SparCC / SPIEC-EASI) 进阶必懂

① 是什么 把"哪些物种倾向于一起出现/此消彼长"画成网络图：节点 = 物种，连线 = 显著的共现/互斥关系。再用网络拓扑找出关键种 (keystone taxa) ——连接度极高的"枢纽 (hub)"节点，它们对群落结构和稳定性影响最大。

② 解决哪个麻烦 从"物种清单"升级到"关系网"，逼近群落里的相互作用与组织结构。

③ 小白怎么理解 像画社交网络：谁和谁总一起出现（朋友圈）、谁和谁从不同框（竞争）。其中"好友极多的网红"（hub）一旦离开，整个圈子可能散架——这就是关键种。

④ 关键方法与指标 - 因为是组成型数据（模型 14），不能用普通相关，要用专门方法：SparCC、SPIEC-EASI（精度更高）、FlashWeave、CoNet。 - 拓扑指标：度（degree）、中介中心性、模块（module）、网络的连通性/稳定性。 - 关键种判定：高度数 + 高中心性 + 在模块间起桥梁作用。

⑤ 常见坑 - 共现 $\neq$ 相互作用：两菌一起出现可能只是都喜欢同一种环境，并非真在"互动"（相关 $\neq$ 因果，思维框架 7）。 - 用普通 Pearson/Spearman 直接建网 $\rightarrow$ 组成型假阳性爆炸。 - "关键种"是统计推断，需实验（如接种、合成群落）验证才能确证。 - 数据过滤、阈值选择会显著改变网络结论，需说明并稳健性检验。

模型 18 · 生物地理：距离衰减与"万物无处不在"模型

① 是什么 研究微生物在空间上如何分布。两个核心命题： - 距离衰减（distance-decay）：地理距离越远，群落相似度越低（斜率反映空间结构强弱）。 - "Everything is everywhere, but the environment selects"（万物无处不在，但环境选择）（Baas Becking）：微生物因数量巨大、易扩散，理论上到处都有；最终谁能立足，由当地环境决定。

② 解决哪个麻烦 原理 6 的空间维度：土壤极端异质，群落差异到底来自地理隔离（扩散限制）还是环境差异（选择）？

③ 小白怎么理解 连锁奶茶店：种子（菌）四处都飘得到（无处不在），但只有符合当地口味/气候的店才开得起（环境选择）。两家店越远口味通常越不同（距离衰减），但到底是"距离"还是"当地条件不同"导致的，要拆开看。

④ 关键发现（呼应案例 1） - 全球尺度研究表明：土壤微生物的基因/群落组成随环境变量（尤其 pH、降水）的变化，常强于随地理距离的变化 $\rightarrow$ 支持"环境选择"在很多情形下占上风。 - 方法上常用 Mantel 检验、方差分解（VPA）区分"空间 vs 环境"的贡献。

⑤ 常见坑 - 空间和环境往往共变（近的地方环境也像），要用统计手段（偏 Mantel、VPA）拆分，别简单归因。 - 尺度依赖：厘米尺度和大陆尺度的主导因素完全不同，结论不能跨尺度套用。

下一类：05-功能与生态系统模型.md (怎么连到碳氮磷循环)

E 类 · 功能与生态系统模型 (模型 19–20)

土壤宏基因组的终极意义，是把"微观的基因"连到"宏观的地球过程"——碳氮磷硫循环、温室气体、土壤肥力、污染修复。这一类是"落地"环节。

★

模型 19 · 生物地球化学循环的功能基因模型 必懂

- ① 是什么 土壤微生物驱动着全球碳 (C)、氮 (N)、磷 (P)、硫 (S) 循环。每一步反应由特定的酶/功能基因催化，所以可以用"标志基因 (marker gene) 的丰度"来量化群落"做某一步"的潜力。这把化学过程翻译成了可在宏基因组里直接统计的基因清单。
- ② 解决哪个麻烦 原理 1 的终点：把"功能潜力"具体化为"这片土固氮/硝化/反硝化/降解纤维素的能力有多强"。
- ③ 小白怎么理解 把土壤微生物群落想成一座化工厂，每条生产线（碳线、氮线…）由若干工序组成，每道工序需要特定"工人证"（功能基因）。数某种工人证有多少，就能估这条生产线的产能。
- ④ 关键标志基因（建议记住几个核心的）

循环	过程	标志基因（示例）
氮 N	固氮	nifH
	硝化（氨氧化）	amoA
	反硝化	nirK/nirS 、 nosZ （产/消 N ₂ O 温室气体）
碳 C	复杂碳降解	CAZy 家族（纤维素酶 GH 等）
	甲烷生成/氧化	mcrA / pmoA
	固碳	rbcL （RuBisCO） 、 accA
磷 P	溶磷/转运/有机磷矿化	phoD 、 pstB 、 phnJ 、 ppk
硫 S	硫氧化/还原	dsrAB 、 soxB

- 专用数据库：NCycDB（氮）、PCycDB（磷）、SCycDB（硫），比通用库注释这些循环更准更全。

⑤ 常见坑 - 永远的"潜力 ≠ 通量"：nifH 多 ≠ 真的固了很多氮。要落到速率，需配合同位素、气体通量、宏转录组等（思维框架 3、7）。 - 同一功能可能有多条通路/多个基因，只盯一个基因会以偏概全。 - 组成型偏差（模型 14）同样影响功能基因的"相对丰度"解读。

模型 20 · 结构-功能关系与功能冗余模型 进阶必懂

① 是什么 回答一个深刻问题：群落的"物种组成（结构）"变了，它的"功能"一定跟着变吗？ - 功能冗余（functional redundancy）：很多不同物种能做同一件事。于是即便物种组成大变，整体功能可能基本不变（系统有韧性）。 - 反之，若某功能只有少数特定物种能做，物种一丢功能就崩（系统脆弱）。

② 解决哪个麻烦 连接 C 类（结构/多样性）与 E 类（功能）：解释为什么"多样性—功能"的关系有时强、有时弱，以及生态系统对扰动的韧性从何而来。

③ 小白怎么理解 一家公司： - 如果很多员工都会做关键工序（冗余高），走掉几个人公司照转（韧性强）； - 如果某关键工序只有一个老师傅会（冗余低），他一走整条线停摆（脆弱）。微生物群落的稳定性，很大程度取决于关键功能的"会做的人多不多"。

④ 关键意义与证据 - 全球尺度研究发现土壤微生物广泛存在功能冗余：物种谱差异巨大，但核心代谢功能谱相对保守。 - 稀有生物圈（模型 13）是冗余的重要来源：平时沉默的稀有菌是功能的"备胎库"，扰动后可被唤醒顶上。 - 实践含义：评估生态系统健康/恢复力，不能只看物种多样性，要看功能多样性与冗余度。

⑤ 常见坑 - 把"功能冗余"绝对化——并非所有功能都冗余，狭窄功能（如某些特化的氮/甲烷过程）常常冗余低、很脆弱。 - 用基因丰度论"功能稳定"时仍受"潜力≠活性"限制。 - "结构变了功能没变"也可能是注释分辨率不够掩盖了真实差异。

20 个模型小结

你现在手里有了一套完整的"思想工具箱"：

A 数据怎么来(1-4) → B 序列变结论(5-10) → C 量化比较(11-14) → D 生态解释(15-18) → E 功能落地

下一步强烈建议： - 用 03-思维框架.md 把这些模型"串成判断力"； - 去 04-案例库.md 看真实研究里这些模型怎么组合使用。

03 · 7 个重要思维框架

模型是"算什么工具"，思维框架是"怎么想的操作系统"。同样的数据，思维框架决定了你是得出可靠洞见，还是被噪声和假象牵着走。这 7 个框架是判断力的来源——比任何单个工具都重要。

#	框架	一句话	防什么错
1	尺度框架	你的问题住在哪一层？	张冠李戴、跨尺度乱套
2	样品到洞见（数据生命周期）	垃圾进，垃圾出	重分析、轻设计
3	结构→功能→过程	能干 ≠ 在干 ≠ 干了多少	把"潜力"当"活性"
4	群落构建四过程	选择/扩散/漂变/形成	"为什么是它们"答不清
5	假说驱动 vs 数据驱动	探索 ≠ 验证	在同一批数据里自我证明
6	对照·重复·可重复	没有对照就没有结论	批次效应、伪发现
7	相关→因果的证据阶梯	相关 ≠ 因果	过度解读相关性

框架 1 · 尺度框架（Scale Thinking）

核心：土壤宏基因组对象横跨多个层级，先想清楚你的问题在哪一层，再选对应的方法。


碱基/序列 → 基因 → 通路 → 基因组(MAG) → 种群 → 群落 → 生态系统 → 全球
(模型4) (模型10) (模型19) (模型8) (模型17) (模型11-18) (模型19-20) (案例1)
↑ 物理空间也分尺度：微团聚体 → 根际 → 土壤剖面 → 田块 → 区域 → 大陆

怎么用：- 问"施肥改变了哪个层级？"——是某个基因丰度（基因层）、某条通路（通路层）、还是整个群落结构（群落层）？层级不同，分析方法和结论都不同。- 警惕跨尺度乱推：厘米尺度主导群落的因素（微环境）和大陆尺度（气候、pH）完全不同，结论不能互相套用（见模型18的坑）。

每次开始分析前先问：“我这个问题，住在哪一层楼？”

框架 2 · 样品到洞见：数据生命周期框架（Sample-to-Insight）

核心：结论的可靠性由最薄弱的那一环决定，而最薄弱的往往是最前面、最不“高大上”的环节——采样设计。



怎么用：- GIGO（Garbage In, Garbage Out）：采样没设计好（重复不够、混淆因素没控制、保存不当 DNA 降解），后面再花哨的算法也救不回来。- 看论文时，先翻方法学的前半段（采样与重复设计），那里藏着结论能不能信的关键。- 新手最大误区：把 90% 精力放在“跑哪个软件”，只给采样设计 10%——应该反过来。

"实验设计阶段花的一小时，胜过分析阶段熬的十个夜。"

框架 3 · 结构 → 功能 → 过程框架（多组学阶梯） 最重要

核心：宏基因组只能到“能干什么（潜力）”，到不了“正在干什么”和“干了多少”。想往上爬，要换/加技术。

层级	回答	技术	在测什么
结构 Who	有谁	扩增子 / 宏基因组分类	DNA（身份）
功能潜力 What can	能干什么	宏基因组	DNA（基因）
功能活性 What doing	正在干什么	宏转录组（RNA）、宏蛋白组	RNA / 蛋白
过程/通量 How much	干了多少	代谢组、同位素示踪、气体通量、酶活	代谢物 / 速率

怎么用：- 看到"土壤含大量 nifH 基因，固氮能力强"——立刻警觉：这只是潜力，不代表真在固氮。- 想说"功能上调"，至少要有宏转录组；想说"过程加快"，要有速率/通量数据。- 设计研究时主动想：我的结论需要爬到哪一层？就配哪一层的技术。

把"潜力 ≠ 活性 ≠ 通量"刻进脑子。这是审稿人最爱挑、新手最爱犯的问题（呼应模型 1、19）。

框架 4 · 群落构建四过程框架（Community Assembly）

核心（Vellend 综合框架）：任何群落"为什么长成这样"，都可归结为四种基本力的组合：

过程	是什么	类比	对应模型
选择 Selection	环境/相互作用筛选出适应者（确定性）	房价学区筛选住户	βNTI（模型16）
扩散 Dispersal	物种从别处迁入/迁出	交通是否便利	RCbray、m（模型15/16）
漂变 Drift	随机的出生/死亡涨落	纯运气	中性模型（模型15）
物种形成 Speciation	新物种产生（长时间尺度）	本地新移民诞生	进化分析

怎么用：- 面对"这片土为什么是这些菌"，不要只答"因为 pH 高"，而要拆：选择、扩散、漂变各占多少？（用模型 15、16 量化）。- 这是把零散生态现象统一归因的总框架，让你的讨论有结构、不流于罗列。

一句口诀："筛选、迁移、运气、新生"——四个字解释一切群落。

框架 5 · 假说驱动 vs 数据驱动框架 (Hypothesis vs Data-driven)

核心：宏基因组天然产出海量相关性，极易"在数据里找到任何你想找的东西"。必须分清两种模式，不能用同一批数据既生成假说又验证假说。

模式	干什么	风险	正确姿势
数据驱动（探索）	海里捞针、生成假说	多重比较 → 大量假阳性	当成"线索"，需 FDR 校正
假说驱动（验证）	检验一个明确预测	事后编故事 (HARKing)	预先注册、独立数据验证

怎么用：- 做了 5000 个基因的差异检验，总有几百个"显著"——必须做多重检验校正（FDR/BH），否则全是噪声。- 探索阶段发现的模式，理想情况下用另一批独立样本或实验去验证，而不是在原数据里反复挖。- 写讨论时诚实区分："这是我们发现的相关线索"还是"这是我们验证的假说"。

"在同一锅数据里既出题又判卷"= 自欺欺人。

框架 6 · 对照 · 重复 · 可重复框架 (Controls & Reproducibility)

核心：没有对照和重复的"发现"不是科学发现。宏基因组还有几类特有的混淆来源必须主动防。

三个"复"：1. 生物学重复 (biological replicates)：≥3，缺了无法做统计、无法估变异（呼应原理 5）。注意区别于"技术重复"。2. 对照 (controls)：处理组 vs 对照组；还要有阴性对照/空白来发现试剂污染 (kitome，提取试剂自带的微生物 DNA，对低生物量样本尤其致命)。3. 可重复 (reproducibility)：记录软件版本、参数、数据库版本；数据与流程公开 (FAIR 原则)，别人能复现。

宏基因组特有的坑（务必主动控制）：- 批次效应 (batch effect)：不同时间提取/测序/试剂批次会引入系统差异，可能完全盖过真实生物学差异。设计时把处理打散到各批次，别让"处理"和"批次"重合。- 组成型偏差 (模型 14)、测序深度差异 (模型 3) 也是系统性混淆，比较前要校正。

怎么用：看到一篇没有重复、没有阴性对照、不交代批次安排的论文，对其结论大幅打折。

"n=1 不是数据点，是轶事。"

框架 7 · 相关 → 因果的证据阶梯 (Correlation to Causation)

核心：宏基因组绝大多数结果是相关性。从"相关"走到"因果"，需要一级一级往上爬证据。相关 ≠ 因果是这门学科被滥用最多的地方。

- | | |
|---|--------------------------------------|
| 弱 | └─ ① 观测到相关 / 共变（某菌随某处理变化） |
| | ② 共现网络关系（模型17：但共现 ≠ 互作） |
| | ③ 功能富集 / 标志基因证据（模型19：但潜力 ≠ 活性） |
| | ④ MAG 层面证据（该基因确属某基因组，链条更完整） |
| | ⑤ 宏转录/宏蛋白/代谢组（证明真在表达/进行，框架3） |
| 强 | └─ ⑥ 操控实验验证：接种、敲除、合成群落(SynCom)、同位素示踪 |
| | （微生物组版"科赫法则"，才能谈因果） |

怎么用：- 下"A 菌导致了 B 现象"这类因果结论前，问自己：我的证据爬到了第几级？停在①②③ 就只能说"相关/可能相关"。- 强结论配强证据：越往上越接近因果，但成本也越高。明确你的结论需要爬到哪一级。

"相关给你假设，实验给你结论。"（呼应框架 5、模型 17）

七框架协同：一次"靠谱研究"的内心独白

"我的问题在哪一层（框1）？采样和重复设计够稳吗（框2、6）？我得到的是结构、功能潜力还是真实活性（框3）？群落差异是选择还是随机（框4）？这是探索线索还是验证结论（框5）？我做了对照、校正了批次和组成型偏差吗（框6）？我的证据爬到了因果阶梯的第几级（框7）？"

把这段独白养成习惯，你看论文、做研究的判断力会立刻上一个台阶。

下一步：去 [04-案例库.md](#) 看这些框架和模型在真实研究里怎么组合。

04 · 案例库：10 个真实研究案例

模型和框架是"招式"，案例是"实战录像"。每个案例按统一格式拆解：① 研究问题 ② 怎么做的 ③ 关键发现 ④ 用到了哪些模型/框架 ⑤ 小白能学到什么

案例按"从宏观到方法、从经典到前沿"排列。文末有完整文献链接。

案例 1 · 全球表土微生物组图谱（奠基性大尺度研究）

- ① 问题：全球尺度上，土壤微生物的多样性和功能由什么决定？是地理距离，还是环境？
 - ② 怎么做：跨全球 189 个样点采集表土，结合宏基因组 + 扩增子，刻画细菌、真菌的多样性与基因功能组成。
 - ③ 关键发现：- 细菌（而非真菌）遗传多样性在温带最高；- 微生物基因组成随环境变量的变化，强于随地理距离的变化；- 真菌与细菌存在全球生态位分化，对降水和 pH 的多样性响应相反。
 - ④ 用到的模型/框架：生物地理（模型18）、多样性（模型11/12）、功能注释（模型10）、尺度框架（框架1）、相关→因果（框架7）。
 - ⑤ 学到什么：大尺度上"环境选择"常压过"地理距离"——印证 Baas Becking 的"环境选择"。这是理解土壤微生物生物地理的标杆。
-

案例 2 · 中国陆地生态系统表土微生物组（区域对比）

- ① 问题：中国六大陆地生态系统（森林、草原、荒漠、农田、湿地、喀斯特等）的土壤微生物功能谱有何差异？
- ② 怎么做：采集六大生态系统 41 份表土做宏基因组，比较代谢通路、碳/氮/硫循环基因。

③ 关键发现：- 寡营养环境（荒漠、喀斯特）的代谢通路多样性反而显著更高（资源贫瘠 → 代谢更"全能"以求生存）；- 鉴定出 6 个核心 CAZyme 基因（土壤有机碳降解/合成）、62 个氮循环基因（7 个酶簇）、15 个硫循环基因（3 个酶簇）。

④ 用到的模型/框架：功能基因/生物地球化学（模型19）、CAZy 注释（模型10）、结构-功能（模型20）、尺度框架（框架1）。

⑤ 学到什么："贫瘠 ≠ 功能简单"，反直觉的发现往往最有价值；也展示了如何用循环基因横向对比不同生态系统。

案例 3 · 全球土壤功能冗余（结构-功能解耦）

① 问题：土壤物种组成差异巨大，但功能是否也同样多变？

② 怎么做：基于全球多点宏基因组数据集，比较物种组成（结构）与功能基因组成（功能）在空间上的变异程度。

③ 关键发现：土壤微生物群落存在广泛的功能冗余——物种谱差异大，但核心功能谱相对保守。不同物种"接力"完成相同功能。

④ 用到的模型/框架：功能冗余（模型20）、结构→功能阶梯（框架3）、多样性（模型11/12）。

⑤ 学到什么：评估生态系统韧性不能只看物种多样性，要看功能冗余度；这也是"物种变了功能没变"现象的机制解释。

案例 4 · 长期施肥对碳氮循环功能的影响（农业经典设计）

① 问题：长期施化肥 vs 有机肥，如何改变黑土区土壤碳、氮循环的功能潜力？

② 怎么做：依托长期定位施肥试验（同一地块多年不同施肥处理），对土壤做宏基因组，比较 C/N 循环功能基因丰度。

③ 关键发现：化肥与有机肥导致碳氮循环功能谱分化；有机肥通常富集更多有机质降解和氮转化相关功能；不同处理下固氮/硝化/反硝化基因丰度此消彼长。

④ 用到的模型/框架：氮/碳循环基因（模型19）、差异丰度（模型14）、对照·重复（框架6，长期定位试验是绝佳对照设计）、相关→因果（框架7）。

⑤ 学到什么：长期定位试验是农业土壤研究的黄金对照框架；同时牢记功能基因丰度变化是"潜力"，要落到速率需配套测定（框架3）。

案例 5 · 减少耕作改善根际碳氮磷循能（管理实践）

① 问题：少耕/免耕相比传统耕作，是否改善土壤（本体土与根际）碳、氮、磷循环功能？

② 怎么做：宏基因组对比不同耕作方式下本体土 vs 根际土的 C/N/P 循环功能谱。

③ 关键发现：减少耕作改善了 C/N/P 循环的功能profile；根际与本体土的功能组成存在系统差异（根际效应）。

④ 用到的模型/框架：功能基因（模型19）、尺度框架（框架1：根际 vs 本体土是空间微尺度）、差异丰度（模型14）。

⑤ 学到什么："在哪取样"本身就是一个变量——根际和几厘米外的本体土是不同的世界（呼应框架1、2 的采样设计）。

案例 6 · 氮沉降下荒漠草原的碳氮循环响应（全球变化）

① 问题：大气氮沉降增加，如何影响荒漠草原微生物群落及其碳氮循环功能基因？

② 怎么做：设置不同氮添加梯度，宏基因组追踪群落结构与 C/N 循环功能基因的响应。

③ 关键发现：氮添加重塑群落结构，并改变碳氮循环关键功能基因丰度（如硝化/反硝化相关基因响应明显），揭示荒漠草原对氮输入的敏感性。

④ 用到的模型/框架：氮循环基因（模型19）、梯度实验设计（框架6）、群落构建（框架4）。

⑤ 学到什么：梯度实验（而非简单两组对比）能揭示剂量-响应关系，是研究全球变化驱动因子的有力设计。

案例 7 · 土壤抗性组：抗生素抗性基因的环境分布（One Health）

- ① 问题：土壤里有哪些抗生素抗性基因（ARGs）？它们如何随人为活动（施肥、用药）变化？
 - ② 怎么做：宏基因组 reads/contig 比对 CARD 等抗性数据库，量化抗性组（resistome）组成与丰度，常结合可移动遗传元件（MGE）评估传播风险。
 - ③ 关键发现：土壤是巨大的天然抗性基因库；畜禽粪肥施用等会显著富集 ARGs 并增加其向病原菌水平转移的风险——直接关系食品安全与公共卫生。
 - ④ 用到的模型/框架：功能注释/CARD（模型10）、组成型差异（模型14）、相关→因果（框架7：检出 ARG ≠ 证明传播，需进一步证据）。
 - ⑤ 学到什么：宏基因组的应用远超生态学，直通 One Health（人-动物-环境一体化健康）；也是“功能注释”在公共卫生上的落地。
-

案例 8 · 沿降水梯度跨土壤深度恢复 679 个 MAG（数据资源型）

- ① 问题：能否从不同深度、不同降水条件的土壤中，系统恢复出大量基因组（MAG）？
 - ② 怎么做：沿降水梯度、跨不同土壤深度采样测序，经组装→分箱→质控，恢复出 679 个 MAG，发布为数据资源。
 - ③ 关键发现：得到一批跨深度/气候的 MAG，可用于研究深层土壤、未培养类群的代谢潜力；展示了土壤 MAG 恢复的完整工程化流程。
 - ④ 用到的模型/框架：组装（模型6）、分箱（模型7）、MAG 质量/MIMAG（模型8）、分类 GTDB-Tk（模型9）、尺度框架（框架1：深度梯度）。
 - ⑤ 学到什么：“基因组分辨（genome-resolved）宏基因组”是当前主流方向——不止看基因碎片，而是重建出一个个基因组。也体现了土壤 MAG 恢复之难（需精炼、回收率有限）。
-

案例 9 · 超深度长读长测序挖掘土壤生物合成潜力（前沿技术）

- ① 问题：短读长难以组装土壤复杂群落，长读长能否捕获更完整的基因组和生物合成基因簇（BGC，新药/抗生素来源）？

② 怎么做：对土壤做超深度长读长宏基因组测序，组装出更长更完整的 contig 和 MAG，挖掘其分类与生物合成潜力。

③ 关键发现：长读长显著提升了组装连续性，捕获到更完整的 BGC 和更广的分类/功能多样性——短读长会系统性漏掉这些复杂区域。

④ 用到的模型/框架：组装（模型6，长读长 vs 短读长）、MAG（模型8）、功能注释/antiSMASH（模型10）、尺度框架（框架1）。

⑤ 学到什么：测序技术决定你能看到什么（呼应框架2/3）。土壤难组装的瓶颈，长读长/混合测序是当前突破口；BGC 挖掘把土壤变成"新药矿"。

案例 10 · 群落构建：随机 vs 确定性如何随土壤剖面变化（生态机制）

① 问题：从表层到深层土壤，群落是被"环境选择"主导还是"随机过程"主导？这与代谢有何关系？

② 怎么做：沿土壤剖面采样，用 β NTI/RCbray 零模型框架 + 中性模型量化各层的确定性/随机比例，并与微生物代谢联系起来。

③ 关键发现：群落构建的"确定性 vs 随机"随深度/环境梯度系统变化（常见表层确定性更强、深层随机性上升或扩散限制增强），且与代谢策略耦合。

④ 用到的模型/框架：中性模型（模型15）、 β NTI/RCbray（模型16）、群落构建四过程（框架4）、尺度框架（框架1：深度）。

⑤ 学到什么：把生态学理论（构建过程）与功能/代谢结合，是从"描述现象"走向"解释机制"的范例——这正是高水平研究的特征。

跨案例规律（小白重点）

1. 几乎都靠"对照/梯度"：长期定位试验、降水/氮/深度梯度——好研究先有好设计（框架2、6）。
2. 功能基因是连接微观与宏观的桥：C/N/P/S 循环基因反复出现（模型19）。

3. 反复强调"潜力≠活性"：再前沿的研究也守这条线（框架3）。

4. 方向趋势：read-based 描述 → genome-resolved (MAG) → 长读长/多组学机制。

案例文献链接

1. 全球表土微生物组 · Nature 2018 : <https://www.nature.com/articles/s41586-018-0386-6>
2. 中国陆地生态系统表土微生物组 · Frontiers in Microbiology 2025 : <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC12414936/>
3. 全球土壤功能冗余 · 2022 : <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9108720/>
4. 黑土区长期施肥碳氮功能 · Geoderma 2022 : <https://www.sciencedirect.com/science/article/abs/pii/S0016706122001537>
5. 减少耕作与 C/N/P 循环 · Soil & Tillage Research 2024 : <https://www.sciencedirect.com/science/article/abs/pii/S0167880924004894>
6. 氮沉降下荒漠草原 · Frontiers in Microbiology 2024 : <https://www.frontiersin.org/journals/microbiology/articles/10.3389/fmicb.2024.1369196/full>
7. CARD 抗生素抗性数据库 2023 : <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9825576/>
8. 跨深度降水梯度 679 个 MAG · Scientific Data 2025 : <https://www.nature.com/articles/s41597-025-04884-2>
9. 超深度长读长土壤宏基因组 · GigaScience 2024 : <https://academic.oup.com/gigascience/article/doi/10.1093/gigascience/giaf135/8300805>
10. 土壤剖面群落构建与代谢耦合 · 2020 : <https://pmc.ncbi.nlm.nih.gov/articles/PMC7289589/>

动手分析时查：05-工具与数据库速查.md

05 · 工具与数据库速查

按分析流程的先后顺序排好。小白不必全装全会——先认识"每一步该用什么类的工具"，需要时再深入某一个。 版本/参数以各工具官方文档最新为准；土壤数据量大，多数步骤需要服务器/集群而非个人电脑。

按流程阶段的工具地图

①质控 → ②(可选)组装 → ③分箱 → ④质控/分类/注释 → ⑤丰度定量 → ⑥统计可视化
或 ② 基于读长分类/功能

① 质量控制（QC） — 对应模型 4

工具	用途
fastp	一步搞定切接头、去低质量、出报告（最常用）
Trimmomatic	经典质控/切除
KneadData	质控 + 去宿主一体化
FastQC / MultiQC	查看质量报告（多样本汇总）
Bowtie2 / BWA	比对到宿主基因组以去宿主（如去植物/人 DNA）

② 序列组装 (Assembly) — 对应模型 6

工具	适用
MEGAHIT	省内存、速度快，土壤大数据首选
metaSPAdes	组装质量高，资源消耗更大
metaFlye / hifiasm-meta	长读长 (PacBio/Nanopore) 组装
QUAST / metaQUAST	评估组装质量 (N50 等)

③ 基因预测 & 分箱 (Binning) — 对应模型 7

工具	用途
Prodigal	从 contig 预测基因 (ORF)
MetaBAT2 / MaxBin2 / CONCOCT / SemiBin2 / binny	分箱 (建议多工具并用)
metaWRAP / DAS Tool	bin 整合与精炼 (土壤几乎必需)
dRep	多样本 MAG 去冗余
CoverM	计算 contig/MAG 的覆盖度与丰度

④ MAG 质控 / 物种分类 / 功能注释 — 对应模型 8/9/10

工具	用途
CheckM / CheckM2	MAG 完整度 & 污染度 (MIMAG 标准)
GUNC	检测谱系混杂 (chimerism)
GTDB-Tk	MAG 标准化分类 (基于 GTDB)
Kraken2 + Bracken	基于读长的快速物种分类与丰度重估
MetaPhlAn	基于标志基因的物种profile
eggNOG-mapper	功能注释 (直系同源 + 多层注释)
DRAM	MAG 代谢功能整合注释 (很适合解读循环)
antiSMASH	次级代谢/生物合成基因簇 (BGC) 挖掘
HUMAnN	基于读长的物种+通路功能profile

⑤ 比对/定量

BWA、Bowtie2、minimap2 (长读长)、Salmon、CoverM。

⑥ 统计与可视化（多在 R / Python） — 对应模型 11–18

包	用途
vegan (R)	多样性、距离、PCoA/NMDS、PERMANOVA（生态分析主力）
phyloseq (R)	微生物组数据整合管理与画图
microeco (R)	一体化微生物组分析（中文社区常用）
ALDEx2 / ANCOM-BC / LinDA / LEfSe	组成型差异丰度分析（模型14）
iCAMP (R)	群落构建定量（ β NTI/RCbray，模型16）
SpiecEasi / SparCC	共现网络（模型17）
QIIME2	扩增子为主的一体化平台（也涉宏基因组）
Python: pandas / scikit-bio / scikit-learn /  matplotlib	通用数据科学

主流数据库速查

物种 / 基因组分类

数据库	说明
GTDB	基因组分类数据库，MAG 分类的标准（配 GTDB-Tk）
NCBI nr / nt	最全的核酸/蛋白库（比对兜底）
NCBI RefSeq、SILVA（16S）、UNITE（真菌 ITS）	参考序列 / 扩增子专用

功能注释 (对应模型 10、19)

数据库	看什么
KEGG	代谢通路、KO 功能号 (最常用通路地图)
eggNOG	直系同源分组 + 多层功能注释
CAZy	碳水化合物活性酶 (GH/GT/PL/CE/CBM) → 碳降解
CARD	抗生素抗性基因 (ARGs) → 抗性组
COG / Pfam / TIGRFAM	基础功能分类 / 蛋白结构域
NCycDB / PCycDB / SCycDB	氮 / 磷 / 硫 循环专用基因库 (比通用库更准)
MIBiG / antiSMASH DB	生物合成基因簇 (天然产物)

一体化流程 (小白强烈推荐从这里入门)

流程	特点
EasyMetagenome (易宏基因组)	中文友好, 刘永鑫团队, 含安装/分析/可视化/答疑全套, 配套"宏基因组"公众号与 B 站视频, 最适合中文小白
nf-core/mag	基于 Nextflow 的标准化、可复现 MAG 流程, 社区维护
metaWRAP	经典的基因组分辨宏基因组一体化 (分箱+精炼强)
anvi'o	强大的交互式可视化与精炼平台
ATLAS / MetaflowX / MAGNETO	自动化、可扩展到集群的端到端流程

入门建议：先用 EasyMetagenome 跟着跑通一个完整 demo，建立"从 reads 到结果"的整体感，再逐个深入单个工具。

给小白的现实提醒

1. 算力：土壤宏基因组组装/分箱动辄要几十 GB~上百 GB 内存，需要服务器或云，个人笔记本只够学命令、跑小数据。
 2. Linux + 命令行是基本功；conda/mamba 管理软件环境；学一点 R 或 Python 做统计画图。
 3. 先读长(read-based)后组装(assembly-based)：新手先用 Kraken2/HUMAnN 快速出谱建立直觉，再挑战组装+分箱。
 4. 存好中间文件和参数：可重复性是科研底线（思维框架 6）。
-

遇到不懂的词：[06-术语表与延伸阅读.md](#)

06 · 术语表与延伸阅读

遇到陌生词先查这里。术语按主题分组，附英文，方便读英文文献时对照。

中英文术语表

基础概念

中文	英文	一句话解释
宏基因组学	Metagenomics	直接对环境全部微生物 DNA 测序研究
扩增子	Amplicon	只测某段标志基因（如 16S）的测序方法
鸟枪法宏基因组	Shotgun metagenomics	随机打碎、测全部 DNA
免培养	Culture-independent	不依赖实验室培养的研究手段
微生物组	Microbiome	某环境中全部微生物及其基因/产物的总和
微生物群落	Microbial community	共存于同一环境的微生物集合
功能潜力	Functional potential	基因层面"能做什么"（≠ 正在做）

数据与序列

中文	英文	解释
读长/读段	Read	测序仪输出的一段短序列
重叠群	Contig	由 reads 拼接成的连续长片段
k-mer	k-mer	长度为 k 的短序列子串
测序深度	Sequencing depth / coverage	测了多少数据 / 某位点被覆盖的次数
质量值	Phred quality (Q)	单碱基测序置信度，Q30≈99.9%
组成型数据	Compositional data	只有相对比例、总和固定的数据
抽平	Rarefaction	把样本随机降到相同深度以便比较

分析产物

中文	英文	解释
组装	Assembly	把 reads 拼成 contig
分箱	Binning	把 contig 按来源基因组分堆
宏基因组组装基因组	MAG	从宏基因组分箱重建出的（近似）基因组
完整度 / 污染度	Completeness / Contamination	MAG 质量两大指标（MIMAG 标准）
操作分类单元	OTU / ASV	序列聚类出的"物种"近似单位
直系同源	Ortholog	不同物种中源自同一祖先基因、功能常保守
功能注释	Functional annotation	给基因贴"功能"标签
物种分类	Taxonomic classification	给序列贴"来自谁"标签

生态与统计

中文	英文	解释
α / β 多样性	Alpha / Beta diversity	样本内 / 样本间多样性
Hill 数	Hill numbers	统一多样性指标的框架 ($q=0/1/2$)
排序	Ordination (PCoA/NMDS)	把高维群落差异降维成图
稀有生物圈	Rare biosphere	大量低丰度物种构成的"长尾"
微生物暗物质	Microbial dark matter	无已知基因组可比对的未知类群
功能冗余	Functional redundancy	多个物种能做同一件事
关键种	Keystone taxa	对群落结构/稳定性影响超大的物种
群落构建	Community assembly	群落如何形成 (选择/扩散/漂变/物种形成)
确定性 / 随机过程	Deterministic / Stochastic	环境筛选 vs 随机扩散漂变
中性理论	Neutral theory	假设物种生态等价、由随机主导的模型
β NTI / RCbray	β NTI / RCbray	量化确定性 vs 随机的零模型指标
共现网络	Co-occurrence network	物种共存/互斥关系的网络图
距离衰减	Distance-decay	地理越远群落越不同
批次效应	Batch effect	不同批次操作引入的系统性偏差
多重检验校正	Multiple testing correction (FDR)	控制大量比较带来的假阳性

功能与应用

中文	英文	解释
生物地球化学循环	Biogeochemical cycling	C/N/P/S 等元素在生态系统中的循环
标志基因	Marker gene	代表某功能/分类的指示基因（如 nifH）
抗生素抗性基因	ARG (Antibiotic Resistance Gene)	赋予抗药性的基因，环境健康热点
抗性组	Resistome	一个环境中全部 ARG 的集合
生物合成基因簇	BGC (Biosynthetic Gene Cluster)	合成天然产物/抗生素的基因簇
根际	Rhizosphere	受植物根系影响的土壤微区
水平基因转移	HGT (Horizontal Gene Transfer)	基因在物种间横向传递

几个最常被误解的点（小白避坑）

1. "测到基因 = 有这个功能在运行" —— 只是潜力（框架3）。
2. "丰度高 = 数量多" —— 是相对比例，组成型数据（模型14）。
3. "没测到 = 不存在" —— 可能测序不够深（模型3）。
4. "PCoA 图上分开了 = 有显著差异" —— 要做 PERMANOVA（模型12）。
5. "共现 = 相互作用 = 因果" —— 相关≠因果（模型17、框架7）。
6. "宏基因组比扩增子全面所以总是更好" —— 看问题和预算（模型2）。

延伸阅读与入门资源

中文友好资源（小白首选）

- EasyMetagenome（易宏基因组）流程 · GitHub：<https://github.com/YongxinLiu/EasyMetagenome>
- 论文（iMeta 2025）：<https://news.qq.com/rain/a/20250221A0903Z00>
- 国内镜像 Gitee：<https://gitee.com/yongxinliu/EasyMetagenome>

- 配套 B 站视频（扩增子和宏基因组分析）：<https://www.bilibili.com/video/BV1Hg411G7Fx/>
- "宏基因组"公众号 / iMeta 期刊：大量中文教程、可视化与方法解读。

经典 / 综述文献

- 全球表土微生物组（生物地理奠基）· Nature 2018：<https://www.nature.com/articles/s41586-018-0386-6>
- 稀有生物圈生态 · Nature Reviews Microbiology：<https://www.nature.com/articles/nrmicro3400>
- 功能多样性与冗余综述 · FEMS Microbiology Reviews 2024：<https://academic.oup.com/femsre/article/doi/10.1093/femsre/fuae031/7926968>
- MAG 进展、挑战与生态洞见 · Microorganisms 2025：<https://www.mdpi.com/2076-2607/13/5/985>
- 群落构建确定性 vs 随机框架（综述）· Frontiers 2019：<https://www.frontiersin.org/journals/microbiology/articles/10.3389/fmicb.2019.01536/full>

工具 / 方法

- 比较共现网络指南 · iMeta 2023：<https://onlinelibrary.wiley.com/doi/full/10.1002/int2.71>
- 微生物组归一化与差异丰度分析 · npj Biofilms and Microbiomes 2020：<https://www.nature.com/articles/s41522-020-00160-w>
- CARD 抗性数据库 2023：<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9825576/>
- NEON 土壤宏基因组组装与分析（实操示例）· F1000Research：<https://f1000research.com/articles/10-299>

数据库官网

- GTDB：<https://gtdb.ecogenomic.org/> | KEGG：<https://www.genome.jp/kegg/>
 - eggNOG：<http://eggnogetool.embl.de/> | CAZy：<http://www.cazy.org/> | CARD：<https://card.mcmaster.ca/>
-

建议的学习节奏（4 周入门计划）

周	目标	做什么
第 1 周	建立全局观	读完 01 第一性原理 + 03 思维框架 + 04 案例库
第 2 周	啃核心模型	精读模型 2/3/8/11/12/14/19（必懂优先级）
第 3 周	跑通流程	用 EasyMetagenome 跑一个小 demo（QC→分类→功能）
第 4 周	啃进阶 + 复盘	模型 5-7/9-10/16-17/20 + 用思维框架重读一篇论文

学习是螺旋上升的：第一遍求"懂大意"，第二遍求"会判断"，第三遍求"能动手"。别指望一遍到位。

[回到 知识库总览](#)

07 · 手把手实操教程 · 总览

这个模块带你真的把流程跑起来——从一台空白的 Linux 机器，到最后画出能放进论文的图。面向小白，每条命令都告诉你"这是在干嘛、为什么要这步、跑出来该长什么样"。

先读这段（很重要，能帮你避坑）


- 1. 命令是"教学示例"，不是圣经。生信工具版本、参数、数据库名更新很快。本教程给的是长期稳定的核心用法 + 每个参数的含义，你照着改即可；遇到报错，永远以该工具官方文档/GitHub 最新说明为准。
- 2. 这些步骤需要 Linux + 一定算力。组装/分箱动辄要几十~上百 GB 内存，个人笔记本只够练命令和跑超小数据，真实数据要用服务器或云。没有服务器也没关系——先在小数据上把流程跑通、把每步看懂，比什么都重要。
- 3. 路径、文件名按你自己的改。教程里 `sample`、`~/db` 这种都是占位符。
- 4. 强烈建议先跟 EasyMetagenome（易宏基因组）跑一遍——它是中文的一体化流程，安装/分析/可视化/答疑都有，本教程的思路和它一致，可以对照着用。

实操教程地图（按顺序）

篇	内容	你会得到
01-环境与软件安装.md	装 Linux/conda、装齐工具、下数据库	一个能干活的分析环境
02-质控与读长分析.md	原始数据 → 质控 → 物种谱 + 功能谱	不用组装就能出的第一批结果
03-组装分箱与MAG.md	组装 → 分箱 → MAG 质控/分类/注释	一个个重建出来的基因组(MAG)
04-统计与可视化.md	用 R 做多样性、差异、排序、画图	论文级别的图表
05-常见报错与排查.md	新手最常撞的坑和解法	卡住时的急救手册

一眼看懂：整个流程的"命令骨架"

下面是你接下来几篇会敲的命令的全景缩略图（现在看不懂没关系，跑完回来看就懂了）：



给小白的策略建议

- 先跑"路线甲"（基于读长）：不用组装，快、门槛低，能马上出物种和功能结果，建立成就感和直觉。
- 再挑战"路线乙"（基于组装）：理解了甲再做乙，组装分箱的概念会清楚很多。
- 每一步都先在"超小数据"上跑通：可以拿工具自带的 test data，或把自己的数据用 seqkit head 截一小段，确认命令通了，再上全量。
- 把命令和参数记进一个脚本文件：别在终端里手敲一次性命令。写进 run.sh，可重复、可追溯（思维框架 6）。

开始：01-环境与软件安装.md

07.1 · 环境与软件安装

目标：从零搭一个能干活的分析环境。核心就三件事：① 有个 Linux ② 装 conda 管软件 ③ 用 conda 把工具和数据库装齐。

一、你需要一个 Linux 环境

生信工具几乎都在 Linux 上跑。你有几种选择：

你的情况	建议
有实验室/学校的服务器或集群	最佳，直接用（土壤数据必须靠它）
只有 Windows 电脑	装 WSL2（Win 自带的 Linux 子系统），适合学习练手
只有 Mac	终端是类 Unix，可用；但大数据仍需服务器
啥都没有	用云服务器（按量付费），或先在小数据上学

小白练习用 WSL2 或一台小云主机即可。真实土壤数据 = 服务器，这点改变不了。

检查你在不在 Linux 里、有多少资源：

```
uname -a      # 看系统信息，出现 Linux 就对了
nproc         # 有几个 CPU 核
free -h       # 有多少内存（土壤组装建议 ≥128G，学习够用即可）
df -h         # 硬盘空间（宏基因组很占地，预留几百 G）
```

二、装 conda（软件管家）——强烈推荐用 miniforge / mamba

为什么要 conda？生信工具依赖关系极其复杂（A 工具要 python3.8、B 要 python3.10……）。conda 能为每个项目建独立小房间（环境），互不打架。mamba 是 conda 的加速版，装东西快很多。

```
# 下载并安装 miniforge（自带 conda + mamba，且默认用国内外都友好的 conda-forge 源）
wget "https://github.com/conda-forge/miniforge/releases/latest/download/Miniforge3-Linux-x86_64"
bash Miniforge3-Linux-x86_64.sh      # 一路回车/yes，装完重开终端

# 验证
conda --version
mamba --version
```

国内下载慢的话，给 conda 和 pip 配国内镜像源（清华 TUNA 等），速度会快很多。具体配置搜"conda 清华镜像"。

三、用 conda 建环境、装工具

核心思想：按流程阶段分几个环境，别全堆一个环境里（容易冲突）。下面是一套够用的分组。


```
# 环境1：质控 + 读长分析
mamba create -n qc -c bioconda -c conda-forge \
    fastp fastqc multiqc bowtie2 samtools seqkit kraken2 bracken
# -n qc      给环境起名叫 qc
# -c bioconda -c conda-forge  从这两个频道找软件（生信软件几乎都在 bioconda）

# 环境2：组装 + 分箱
mamba create -n assembly -c bioconda -c conda-forge \
    megahit spades prodigal metabat2 maxbin2 das_tool drep

# 环境3：MAG 质控 + 分类 + 功能注释
mamba create -n annot -c bioconda -c conda-forge \
    checkm2 gtdbtk eggno-mapper

# 用某个环境前先“进房间”，用完“出房间”
conda activate qc      # 进入 qc 环境
fastp --version        # 测一下装好没
conda deactivate       # 退出
```

有些大工具（如 GTDB-Tk、HUMAnN）单独建环境更稳，避免和别人抢依赖。

四、下载数据库（最费时间和硬盘的一步）

工具是“引擎”，数据库是“字典”——没有字典，工具认不出任何序列。数据库通常很大（几十 G 到上百 G），提前下、放在固定目录。

```
mkdir -p ~/db      # 统一放数据库的地方
```

数据库	给谁用	大小量级	说明
Kraken2/Bracken 库	物种分类	几十~几百 G	有 Standard、PlusPF 等预建库可下；越大
GTDB (GTDB-Tk 用)	MAG 标准分类	~100 G	用 GTDB-Tk 自带脚本下，注意版本(如 R220)
CheckM2 库	MAG 质控	几 G	<code>checkm2 database --download</code> 一键下
eggNOG 库	功能注释	几十 G	<code>download_eggnog_data.py</code> 下载
KEGG/CAZy/CARD	功能/碳酶/抗性	视情况	部分需授权或用公开镜像

示例（具体命令以官方为准，这里给你"长什么样")：

```
# CheckM2 数据库
conda activate annot
checkm2 database --download --path ~/db/checkm2

# eggNOG 数据库
download_eggnog_data.py --data_dir ~/db/eggnog -y

# GTDB-Tk 数据库（按官方指示下载对应版本并设置环境变量 GTDBTK_DATA_PATH）
# 下载脚本：download-db.sh，下完 export GTDBTK_DATA_PATH=~/db/gtdbtk/release220
```

数据库下载常常是新手的第一个大坑：慢、断、占满硬盘。建议用 `nohup / screen / tmux` 后台挂着下，别让 SSH 一断就前功尽弃（见第 05 篇）。

五、整理你的数据和目录

养成清晰的目录习惯，未来的你会感谢现在的你：

```
project/
├── raw/          # 原始测序数据 sample_1.fq.gz, sample_2.fq.gz ...
├── clean/        # 质控后的干净数据
├── taxonomy/     # 物种分类结果
├── function/     # 功能注释结果
├── assembly/     # 组装 contigs
├── bins/         # 分箱得到的 MAG
├── results/      # 统计与图
├── scripts/      # 你写的所有 run.sh 脚本（可重复！）
└── db -> ~/db    # 数据库（软链接过来）
```

```
mkdir -p project/{raw,clean,taxonomy,function,assembly,bins,results,scripts}
```

本篇完成检查

- [] `conda activate qc` 能进环境，`fastp --version` 有输出
- [] 三个环境（qc / assembly / annot）都建好了
- [] 至少下好了 CheckM2 和（如果要做读长分类）Kraken2 的库
- [] 建好了清晰的项目目录

下一篇：02-质控与读长分析.md ——开始真正处理数据！

07.2 · 质控与读长分析（路线甲：快速出第一批结果）

这一篇你会：把脏数据洗干净 → 不用组装，直接得到"物种谱"和"功能谱"。这是最快见到成果的一条路，适合新手第一次跑。

对应模型：质控=模型 4；物种分类=模型 9；功能注释=模型 10。

第 0 步 · 看一眼原始数据长什么样

测序公司给你的通常是成对的压缩文件（双端测序）：`sample_1.fq.gz`（正向）、`sample_2.fq.gz`（反向）。

```
cd project
zcat raw/sample_1.fq.gz | head -8      # 看前两条 read
seqkit stats raw/sample_*.fq.gz       # 看有多少条、多长、质量如何
```

每条 read 占 4 行：① @ 开头的名字 ② 序列(ATCG) ③ + ④ 质量字符串。看懂这个就够了。

第 1 步 · 质控：洗掉垃圾（fastp）

为什么：原始数据里有接头序列、低质量碱基、太短的 read——不洗掉，后面全是错（垃圾进垃圾出）。

```
conda activate qc
```

```
fastp \  
-i raw/sample_1.fq.gz -I raw/sample_2.fq.gz \      # 输入：正向/反向  
-o clean/sample_1.fq.gz -O clean/sample_2.fq.gz \   # 输出：洗干净的  
-q 20 \      # 质量阈值 Q20（出错率<1%），低于的剪掉  
-l 50 \      # 长度阈值：洗完短于 50bp 的扔掉  
--detect_adapter_for_pe \   # 自动识别并切除接头  
-w 8 \      # 用 8 个线程  
-j clean/sample.fastp.json -h clean/sample.fastp.html # 生成报告
```

怎么看结果：打开 `clean/sample.fastp.html`（浏览器），重点看：- 过滤前后 read 数：掉了多少（掉太多说明数据质量差）；- Q20/Q30 比例：洗后应明显提升；- 接头、重复序列比例。

多个样本想一次看完？用 `multiqc clean/` 把所有报告汇总成一张总表。

第 2 步 · 去宿主（土壤常需去植物/人 DNA）

为什么：土壤样本常混入植物根、动物或操作人员的 DNA。不去掉，你会“在土里查出一堆植物基因”。

思路：把干净 read 比对到宿主基因组，比对上的扔掉，剩下的才是微生物的。

```
# 1) 先把宿主基因组（如某植物）建索引（只需一次）  
bowtie2-build host_genome.fa db/host_index  
  
# 2) 比对，并只保留“没比对上宿主”的 read  
bowtie2 -x db/host_index \  
-1 clean/sample_1.fq.gz -2 clean/sample_2.fq.gz \  
--un-conc-gz clean/sample_nohost_%.fq.gz \   # 没比对上的（=微生物）输出到这  
-p 8 -S /dev/null                          # 比对结果本身不要，丢弃
```

不知道宿主是什么 / 没有明显宿主？可以跳过这步，但要意识到可能有污染。KneadData 工具能把质控+去宿主一步搞定，新手可考虑。

第 3 步 · 物种谱：土里有谁？（Kraken2 + Bracken）

做什么：把每条 read 归到物种（模型 9 的 k-mer/LCA 思想），再用 Bracken 估算各物种的丰度。

```
# Kraken2 分类
kraken2 --db ~/db/kraken2_db \
  --paired clean/sample_nohost_1.fq.gz clean/sample_nohost_2.fq.gz \
  --threads 8 \
  --report taxonomy/sample.kreport \    # 关键输出：各分类层级的统计
  --output taxonomy/sample.kout         # 每条 read 的归属（文件大，可后续删）

# Bracken 重估“种”水平丰度（让丰度更准）
bracken -d ~/db/kraken2_db \
  -i taxonomy/sample.kreport \
  -o taxonomy/sample.bracken \
  -r 150 \      # 你的 read 长度（按实际改）
  -l S          # 估算到 species（种）水平；也可 G=属
```

怎么看结果：taxonomy/sample.bracken 里每行一个物种和它的估计丰度。多个样本各跑一遍后，合并成一张“物种 × 样本”的丰度表，就能进 R 分析了（第 04 篇）。

未分类比例高很正常——土壤大量未知菌（微生物暗物质，原理 6），别慌，这是真相不是 bug。

第 4 步 · 功能谱：这群菌能干啥？（HUMAnN / MetaPhlAn）

做什么：不组装，直接估算样本里有哪些通路/基因家族及其丰度（模型 10）。HUMAnN 会顺带用 MetaPhlAn 出物种谱。

```
# HUMAnN 需要把双端 read 先合并成一个文件输入
cat clean/sample_nohost_1.fq.gz clean/sample_nohost_2.fq.gz > clean/sample_merged.fq.gz

humann --input clean/sample_merged.fq.gz \
       --output function/sample_humann \
       --threads 8
```

主要输出三个表：- *_pathabundance.tsv：通路丰度（最常用，能说“碳/氮代谢通路强不强”）；- *_genefamilies.tsv：基因家族丰度；- *_pathcoverage.tsv：通路完整度。

跑完多样本后，用 humann_join_tables 合并，再 humann_renorm_table 做标准化，就能比较了。

想专门看碳氮磷硫循环基因（模型 19）？常见做法是：把基因预测出的蛋白比对到 NCyc/PCyc/SCyc 等专用库——但那通常基于组装结果，见第 03 篇。

串起来：一个多样本的小脚本

真实项目有很多样本，别一个个手敲。写个循环（存进 scripts/run_qc.sh）：

```
#!/bin/bash
conda activate qc
for s in sampleA sampleB sampleC; do          # 你的样本名列表
    fastp -i raw/${s}_1.fq.gz -I raw/${s}_2.fq.gz \
        -o clean/${s}_1.fq.gz -O clean/${s}_2.fq.gz \
        -q 20 -l 50 --detect_adapter_for_pe -w 8 \
        -j clean/${s}.json -h clean/${s}.html
    kraken2 --db ~/db/kraken2_db --paired clean/${s}_1.fq.gz clean/${s}_2.fq.gz \
        --threads 8 --report taxonomy/${s}.kreport --output /dev/null
    bracken -d ~/db/kraken2_db -i taxonomy/${s}.kreport -o taxonomy/${s}.bracken -r 150 -l 5
done
echo "全部跑完！"
```

```
bash scripts/run_qc.sh          # 一条命令搞定所有样本
```

本篇完成检查

- [] 每个样本都有了 `clean/` 里的干净数据 + fastp 报告
- [] 有了每个样本的物种丰度表 (bracken)
- [] (可选) 有了功能/通路丰度表 (humann)
- [] 把命令写进了 `scripts/` 里的脚本

想更深入 (重建基因组) : 03-组装分箱与MAG.md 想直接出图 : 04-统计与可视化.md

07.3 · 组装、分箱与 MAG（路线乙：重建基因组）

这一篇你会：把碎片拼成长片段(contig) → 把 contig 按物种归堆(分箱) → 得到一个个基因组(MAG) → 给 MAG 质控、分类、注释。这是宏基因组的"硬核"部分，也是最有成就感的部分——你将亲手"复活"一个个从未被培养过的微生物的基因组。

对应模型：组装=模型 6；分箱=模型 7；MAG 质控=模型 8；分类=模型 9；注释=模型 10。

前提：先做完第 02 篇的质控、去宿主，拿到干净 read。

第 1 步 · 组装：把碎片拼成长片段（MEGAHIT）

做什么：把几千万条 read，按重叠关系拼成更长的 contig（模型 6 的 de Bruijn 图）。

```
conda activate assembly

megahit \
  -1 clean/sample_1.fq.gz \
  -2 clean/sample_2.fq.gz \
  -o assembly/sample_megahit \   # 输出目录
  -t 16 \                         # 线程
  --min-contig-len 1000           # 只保留 ≥1000bp 的 contig（短的没分析价值）
# 结果在 assembly/sample_megahit/final.contigs.fa
```

为什么用 MEGAHIT：省内存、快，土壤这种超大数据首选。追求更高质量、内存够 → 可用 `metaspades.py`。

检查组装质量：

```
seqkit stats assembly/sample_megahit/final.contigs.fa
# 关注：contig 数量、总长度、N50（越大通常越好，模型6）
```

土壤极难组装（原理 6）：大量 read 拼不进去、contig 又短又碎、N50 偏低，都很正常，不是你做错了。

进阶：把多个样本一起组装（co-assembly）或分别组装后合并，能帮后面分箱（提供"丰度共变"信号）。

第 2 步 · 预测基因（Prodigal）

做什么：在 contig 上找出一个个基因（开放阅读框 ORF），翻译成蛋白序列，供后面功能注释。

```
prodigal \
-i assembly/sample_megahit/final.contigs.fa \
-a function/sample.proteins.faa \    # 蛋白序列（功能注释要用）
-d function/sample.genes.fna \      # 核酸序列
-p meta                             # 宏基因组模式（关键！多物种混合）
```

第 3 步 · 算覆盖度：为分箱准备"丰度信号"

为什么：分箱要靠"同一基因组的 contig 在各样本里丰度同涨同落"（模型 7）。所以先把 read 比回 contig，算每条 contig 在每个样本的覆盖深度。

```
# 1) 给 contig 建索引
bowtie2-build assembly/sample_megahit/final.contigs.fa assembly/sample_index

# 2) 把每个样本的 read 比回去, 得到排序好的 bam
bowtie2 -x assembly/sample_index \
  -1 clean/sample_1.fq.gz -2 clean/sample_2.fq.gz -p 16 | \
  samtools sort -@ 8 -o assembly/sample.bam
samtools index assembly/sample.bam

# 3) 汇总成深度表 (MetaBAT2 自带工具)
jgi_summarize_bam_contig_depths \
  --outputDepth assembly/sample.depth.txt \
  assembly/sample.bam
```

多样本时, 把所有样本的 bam 都列在最后, 得到"多样本深度表", 分箱效果会好很多。

第 4 步 · 分箱：把 contig 按物种归堆 (MetaBAT2)

```
metabat2 \
  -i assembly/sample_megahit/final.contigs.fa \      # contig
  -a assembly/sample.depth.txt \                      # 深度表
  -o bins/sample_bin \                                # 输出前缀：会生成 sample_bin.1.fa, .2.fa ...
  -m 1500 \                                           # 参与分箱的最小 contig 长度
  -t 16
# 每个 bins/sample_bin.N.fa 就是一个候选基因组(MAG)
```

进阶但强烈推荐：用多个分箱工具 (MetaBAT2 + MaxBin2 + CONCOCT/SemiBin2) 各跑一遍, 再用 DAS_Tool 或 metaWRAP 的 bin_refinement 整合精炼——土壤分箱质量低, 精炼几乎是必需的 (模型 7 的坑)。多样本还要用 dRep 去冗余。

第 5 步 · 给 MAG 质控 (CheckM2)

做什么：评估每个 MAG 的完整度和污染度（模型 8、MIMAG 标准）。

```
conda activate annot

checkm2 predict \
  --threads 16 \
  --input bins/ \           # 放所有 .fa 的目录
  --extension fa \
  --output-directory results/checkm2
# 看 results/checkm2/quality_report.tsv：每个 MAG 的 Completeness 和 Contamination
```

筛选标准（MIMAG）：- 高质量：完整度 >90% 且 污染度 <5% - 中等质量：完整度 ≥50% 且 污染度 <10% - 一个常用综合门槛：完整度 - 5×污染度 > 50

```
# 示例：用 awk 挑出“完整度>50 且 污染度<10”的 MAG 名单
awk -F'\t' 'NR>1 && $2>50 && $3<10 {print $1}' results/checkm2/quality_report.tsv
```

别拿中低质量 MAG 当完整基因组解读它的通路——缺的那段可能只是没拼到（模型 8 的坑）。

第 6 步 · 给 MAG 分类 (GTDB-Tk)

做什么：用标准化的 GTDB 数据库，告诉你每个 MAG 是“门→纲→…→种”的什么（模型 9）。

```
gtdbtk classify_wf \
  --genome_dir bins/ \
  --extension fa \
  --out_dir results/gtdbtk \
  --cpus 16 \
  --skip_ani_screen      # 新版本常需此参数或提供 --mash_db；以官方文档为准
# 结果 results/gtdbtk/*.summary.tsv 里有每个 MAG 的分类
```

第 7 步 · 给 MAG 做功能注释 (eggNOG-mapper / DRAM)

做什么：给 MAG 里的基因贴功能标签 (KEGG/COG/CAZy 等，模型 10)。

```
# 先对某个 MAG 预测蛋白（或用第2步的整体蛋白按 bin 拆分）
prodigal -i bins/sample_bin.1.faa -a bins/sample_bin.1.faa -p single

# eggNOG-mapper 注释
emapper.py \
  -i bins/sample_bin.1.faa \
  -o results/sample_bin.1 \
  --output_dir results/egglog \
  --data_dir ~/db/egglog \
  --cpu 16
# 结果 *.emapper.annotations 里有每个基因的 KEGG KO、COG、CAZy 等注释
```

想系统看 MAG 的代谢全貌 → 用 DRAM（自动整理出碳氮硫等代谢通路表）。想看碳氮磷硫循环基因（模型 19）→ 把蛋白比对到 CAZy / NCyc / PCyc / SCyc 专用库。想挖新药/ 抗生素生物合成基因簇 BGC（案例 9）→ 用 antiSMASH。

这一篇的产物，如何连到结论

```
clean reads
├── megahit → contigs ───┬── prodigal → 蛋白 → egglog/DRAM → 功能表
                        │
                        └── 覆盖度 → metabat2 → MAG ───┬── checkm2 → 质量表
                                                         ├── gtdbtk → 分类表
                                                         └── egglog → 各MAG功能表
全部表 → 进 R（第 04 篇）做统计、比较、画图 → 结论
```

本篇完成检查

- [] 有了 final.contigs.faa，看过 N50

- [] 分箱得到一批 bins/*.fa
- [] CheckM2 质量表出来了，会挑高/中质量 MAG
- [] GTDB-Tk 给出了分类
- [] (可选) 做了功能注释

下一篇：04-统计与可视化.md ——把这些表变成图。

07.4 · 统计与可视化（用 R 把表变成图）

前面几步得到的都是"表"（物种丰度表、功能表）。这一篇用 R 把它们变成论文里那些图：多样性箱线图、PCoA 排序图、差异物种图。不用怕 R——你只需会改路径、改分组、跑现成代码块。

对应模型： α 多样性=模型 11； β 多样性/排序=模型 12；组成型差异=模型 14。

一、准备：装 R 和需要的包

```
mamba create -n rstats -c conda-forge -c bioconda \
    r-base r-vegan r-tidymverse r-ape bioconductor-phyloseq \
    r-igraph bioconductor-aldex2
conda activate rstats
R          # 进入 R 交互界面；或用 RStudio
```

中文社区的 `microeco`、`amplicon`（刘永鑫团队）等 R 包把很多分析"傻瓜化"了，强烈推荐小白试试。

二、你需要两张表（最常见的输入格式）

1. 丰度表 `feature_table.tsv`：行=物种/功能，列=样本，值=丰度。
2. 分组信息 `metadata.tsv`：行=样本，列里至少有一列是"分组"（如 `group`：施肥 vs 对照）。

```
# feature_table.tsv (示意)
species      sampleA sampleB sampleC sampleD
Bacillus...   120    98    300    280
Pseudomon...  45     60    12     20
...

# metadata.tsv (示意)
sample  group
sampleA control
sampleB control
sampleC fertilized
sampleD fertilized
```

三、读数据 (R 代码)

```
library(vegan); library(tidyverse)

# 读丰度表：第一列做行名
otu <- read.delim("results/feature_table.tsv", row.names = 1, check.names = FALSE)
meta <- read.delim("results/metadata.tsv", row.names = 1)

# vegan 习惯：行=样本、列=物种，所以转置一下
otu_t <- t(otu)
# 确保样本顺序一致
otu_t <- otu_t[rownames(meta), ]
```


四、 α 多样性：单样本里种类多不多（模型 11）

```
# 抽平到相同深度再比，避免“测得深=多样性高”的假象（模型3的坑！）
set.seed(123)
otu_rare <- rrarefy(otu_t, min(rowSums(otu_t)))

# 算三个常用指标
richness <- specnumber(otu_rare)           # 丰富度 (q=0)
shannon  <- diversity(otu_rare, "shannon") # 香农 (q=1)
simpson  <- diversity(otu_rare, "simpson") # 辛普森 (q=2 方向)

alpha <- data.frame(meta, richness, shannon, simpson)

# 检验两组差异是否显著
wilcox.test(shannon ~ group, data = alpha) # 两组用 Wilcoxon

# 画箱线图
ggplot(alpha, aes(group, shannon, fill = group)) +
  geom_boxplot() + geom_jitter(width = .15) +
  labs(y = "Shannon 多样性", x = "") + theme_bw()
ggsave("results/alpha_shannon.pdf", width = 4, height = 4)
```

五、 β 多样性 + 排序：样本之间差多大（模型 12）

```
# 1) 算 Bray-Curtis 距离（基于丰度的“群落差异分”）
bray <- vegdist(otu_rare, method = "bray")

# 2) PCoA 降维
pcoa <- cmdscale(bray, k = 2, eig = TRUE)
pts <- data.frame(pcoa$points, meta)
colnames(pts)[1:2] <- c("PCoA1", "PCoA2")
var <- round(pcoa$eig / sum(pcoa$eig) * 100, 1) # 每轴解释度

# 3) 画图
ggplot(pts, aes(PCoA1, PCoA2, color = group)) +
  geom_point(size = 3) + stat_ellipse() +
  labs(x = paste0("PCoA1 (", var[1], "%)"),
       y = paste0("PCoA2 (", var[2], "%)")) + theme_bw()
ggsave("results/pcoa.pdf", width = 5, height = 4)

# 4) ★关键★ 别只看图！做 PERMANOVA 检验分组是否真的显著（模型12的坑）
adonis2(bray ~ group, data = meta, permutations = 999)
# 看 R2（差异有多大）和 Pr(>F)（p值，<0.05 才算显著）
```

图上“看起来分开了”不算数，必须 PERMANOVA 显著才能说有差异。再配 `betadisper()` 排除“组内离散度不同”造成的假象。

六、找出差异物种/功能（组成型差异，模型 14）

别用普通 t 检验比比例（组成型陷阱，原理 4）。用专门方法，例如 ALDEx2：

```
library(ALDEx2)
# 输入：原始计数表（行=物种，列=样本），分组向量
conds <- meta$group
x <- aldex(otu, conds, mc.samples = 128, test = "t", effect = TRUE)

# 看结果：wi.eBH = 校正后 p 值；effect = 效应量
sig <- x[x$wi.eBH < 0.05, ]      # 显著差异的物种
head(sig[order(sig$effect), ])
```

ALDEx2 内部用了 CLR 变换（模型 14）处理组成型问题，比直接比比例可靠得多。重要结论最好再用 ANCOM-BC / LinDA 等换一种方法验证，取交集更稳。

七、（可选）共现网络：谁和谁在一起（模型 17）

```
# 思路：用 SpiecEasi（专门处理组成型数据）建网，再用 igraph 画
# install: remotes::install_github("zdk123/SpiecEasi")
library(SpiecEasi); library(igraph)
se <- spiec.easi(as.matrix(otu_t), method = "mb") # 计算量大，先用小数据试
g <- adj2igraph(getRefit(se))
plot(g, vertex.size = 4, vertex.label = NA)
# 找“枢纽”关键种：看度(degree)最高的节点
sort(degree(g), decreasing = TRUE)[1:10]
```

网络对参数/过滤很敏感，共现≠因果（模型17、框架7），结论要谨慎。

出图小贴士

- 存 PDF/SVG（矢量图）放论文，不要存模糊的 PNG。
- 配色用色盲友好方案（如 `viridis`、`RColorBrewer`）。
- 每张图都问自己：它回答了哪个科学问题？（别为画图而画图）

本篇完成检查

- [] 出了 α 多样性箱线图 + 显著性检验
- [] 出了 PCoA 图 + 做了 PERMANOVA
- [] 用 ALDEx2 (或同类) 找出了差异物种/功能
- [] 图都存成了矢量格式

卡住了？看 [05-常见报错与排查.md](#)

07.5 · 常见报错与排查（新手急救手册）

跑流程卡住是常态，不是你笨。这一篇收录新手最常撞的坑和解法。遇到报错，先按这里对号入座。

排错总原则（先做这 4 件事）

- 1. 完整读报错信息：真正的原因往往在最后几行，或带 `Error` / `command not found` / `No such file` 的那行。
- 2. 从小数据复现：用 `test data` 或截一小段（`seqkit head -n 10000`）重跑，快速定位。
- 3. 一次只改一个变量：别同时改 5 个参数，改完不知道哪个起作用。
- 4. 复制报错去搜：把关键那行（去掉你自己的路径）丢进搜索引擎 / 工具的 GitHub Issues，99% 别人遇到过。

一、环境与安装类

报错/现象	原因	解法
<code>command not found</code>	没激活环境，或没装该工具	<code>conda activate <env></code> ； <code>conda list grep 工具名</code> 确认装了
conda 装包卡住/解不开依赖	用了慢的 solver	改用 mamba；减少一次装的包数；分环境装
装包报 <code>PackagesNotFoundError</code>	频道不对	加 <code>-c bioconda -c conda-forge</code>
下载极慢/断	网络	配国内镜像源；用 <code>nohup</code> / <code>tmux</code> 挂后台下

二、数据与格式类

报错/现象	原因	解法
No such file or directory	路径/文件名打错	ls 确认文件真在那；注意相对/绝对路径
双端数据"不配对"报错	R1/R2 顺序或条数不一致	确认 _1 / _2 正确配对；seqkit stats 看条数
中文/空格路径出错	路径有空格或中文	文件和目录名只用英文、数字、下划线
.gz 文件报错	文件下载不完整/损坏	gzip -t file.gz 测完整性；重新下

三、内存 / 资源类（土壤最常见！）

报错/现象	原因	解法
进程被 Killed（无报错直接死）	内存爆了（OOM），土壤组装常见	换更大内存机器；MEGAHIT 比 metaSPAdes 省内存；减少 co-assembly 样本数
跑到一半磁盘满 No space left	中间文件巨大	清理 .bam / 中间文件；换大硬盘；及时压缩
跑得极慢	线程没给够 / IO 瓶颈	加 -t/--threads；数据放本地盘别放网络盘
SSH 一断任务就没了	前台运行	用 tmux / screen / nohup 后台跑（见下）

后台挂任务（必学）：

```
tmux new -s job      # 建一个会话；断网也不丢
# 在里面运行你的长任务...
# 按 Ctrl+b 再按 d 离开 (detach)，任务继续跑
tmux attach -t job    # 下次回来重新接上
```

四、结果"不对劲"类（不报错但结果可疑）

现象	可能原因	怎么办
未分类比例特别高	土壤未知菌多（暗物质）	正常现象（原理6），不是 bug
组装 N50 很低、 contig 很碎	土壤复杂 + 深度不足	正常（原理6）；加深测序、co-assembly 可改善
几乎分不出高质量 MAG	土壤分箱本就难	多工具 + bin 精炼（DAS_Tool/ metaWRAP）；提高深度
"查出大量植物基因"	忘了去宿主	回第 02 篇做去宿主
某物种丰度异常高	可能是宿主/污染/试剂污 染(kitome)	查去宿主、设阴性对照
两组多样性差异巨大	可能是测序深度不同造成 假象	先抽平再比（模型3）
PCoA 图分组完美分 开	可能是批次效应而非生物 学	查样本是否按批次聚集（框架6）

五、统计 / R 类

报错/现象	原因	解法
could not find function	没 library() 加载包，或没装	先 install.packages() / library()
样本对不上、行列错位	丰度表与 metadata 样本顺序/ 名称不一致	用样本名对齐： otu[rownames(meta),]
取 log 出现 -Inf	数据里有 0（组成型零值）	加伪计数，或用 ALDEx2 等自带处 理的方法
PERMANOVA 显著但图 没分开	效应小但稳定，或离散度问题	看 R ² ；配 betadisper

六、什么时候该求助 & 怎么问得到答案

先自己查（搜报错、读官方文档/GitHub Issues），还不行再问。会问问题能极大提高得到帮助的概率：

好的提问 = 我想做什么 + 用了什么命令（贴出来）+ 完整报错（贴出来）+ 软件版本 + 我已经试过什么。 差的提问 = "我的代码报错了，怎么办？"

求助去处：- 工具的 GitHub Issues（最权威，先搜有没有人问过）；- 中文社区："宏基因组"公众号、iMeta、生信技能树等；- EasyMetagenome 的问答部分 专门收录常见问题。

心态提醒

报错和卡壳是这一行的日常，连资深的人每天也在 debug。把每个解决掉的报错记进一个 `notes.md`，半年后你就是别人眼里的"高手"了。

回到 07 实操教程总览 | 想把概念彻底搞懂：08-难点图解/

08 · 难点图解专版 · 总览

有些概念，第一次看必然懵。这个模块专挑最劝退的几个，用图解 + 一步步拆 + 具体数字例子讲到你“啊原来如此”。这也是对 02-必学模型 里几个硬核模型的深度展开版——模型篇给你“骨架”，这里给你“血肉”。

本模块内容

篇	讲透什么难点	对应模型	为什么难
01-组成型数据与 CLR.md	为什么“比例数据”不能直接算，CLR 到底干了啥	模型 14	反直觉，但最容易出错
02-组装与分箱.md	碎片怎么拼成基因组，k-mer/de Bruijn 图、分箱怎么归堆	模型 6、7	抽象，看不见过程
03-群落构建βNTI与 RCbray.md	怎么判断群落是“环境筛选”还是“运气”，零模型在干嘛	模型 15、16	概念绕，统计黑箱
04-多样性与排序.md	α/β 多样性、距离、PCoA 到底在算什么	模型 11、12	名词多，几何直觉缺失

怎么用这个模块

- 配合模型篇读：先读 02-必学模型 对应模型的概览，再来这里看图解深挖。
- 不必按顺序：哪个概念卡住就读哪篇。
- 跟着数字算一遍：每篇都有“拿具体数字走一遍”的例子，自己拿笔跟着算，比读十遍都管用。

一句话先剧透四个难点的"恍然大悟点"

1. 组成型/CLR：测序给的是"切好的披萨各占几分之几"，不是"披萨多重"。一块变大别块占比必然变小——所以要换成"每块相对全体平均的倍数"来比。
 2. 组装/分箱：组装靠"碎片边缘重叠的字"接龙；分箱靠"文风像 + 在各样本里同进同退"把段落归回各自的书。
 3. β NTI/RCbray：先假设"纯随机"会长啥样，再看真实数据偏离随机多远——偏得多=环境在筛选，偏得少=运气主导。
 4. 多样性/排序： α =一个样本内部多不多样； β =样本两两差多少；PCoA=把"两两差多少"这张大表压成一张能用眼睛看的散点图。
-

从最容易踩坑的开始：01-组成型数据与CLR.md

08.1 · 图解：组成型数据与 CLR（最容易踩的坑）

深扩模型 14。这是新手最容易忽视、后果最严重的统计问题。读完你会彻底明白：为什么不能直接比"百分比"，CLR 又是怎么救场的。

一、问题的根源：你拿到的是"比例"，不是"数量"

回忆原理 4：测序总量是仪器决定的人为上限。所以你永远只知道"谁占百分之几"，不知道"每克土里有多少个"。

打个比方：

真实的土壤（你看不到绝对数量）		测序后你拿到的（只有比例）	
A菌 1000个		A菌 50%	
B菌 600个	总共2000个	B菌 30%	（加起来=100%）
C菌 400个		C菌 20%	
↑ 你想知道这个		↑ 你只能拿到这个	

关键：100% 是一块固定大小的饼。这就埋下了陷阱。

二、陷阱长什么样：一个菌"涨"，逼着别的菌"假跌"

假设从"对照"到"施肥"，只有 A 菌真的暴涨，B、C 的绝对数量根本没变。看看比例会怎样：

	绝对数量（真实）				→ 比例（你看到的）			
	A菌	B菌	C菌	总数	A菌	B菌	C菌	
对照	1000	600	400	2000	50%	30%	20%	
施肥	4000	600	400	5000	80%	12%	8%	← B、C 的“数量”没变！
						↑ ↑ ↑	↑ ↑ ↑	
						但比例却“跌”了！纯属被 A 挤的		

致命后果：如果你只看比例，会得出“施肥让 B、C 菌减少了”——完全错误，它们根本没变。更糟的是，你还会发现 A 和 B/C “此消彼长”，误以为它们之间有“竞争关系”——假的。

这就是组成型数据陷阱：比例之间被“总和=100%”这根绳子绑死了，一个动，其余被动跟着变。直接拿比例做相关、做差异检验、建共现网络，会产生大量假阳性。

三、CLR 怎么救场：不比“占整张饼的比例”，比“相对全体的倍数”

CLR = 中心对数比（Centered Log-Ratio）。它的思路特别朴素：

与其问“A 占整张饼的百分之几”（受总量绑架），不如问“A 相对于这个样本里所有成分的‘平均水平’，是高还是低、高多少倍”（不受绑架）。

三步走（拿上面“施肥”那组的比例 80%、12%、8% 算给你看）：

- 第1步：取每个成分的值

A=80 B=12 C=8 （用比例或计数都行）
- 第2步：算它们的几何平均

几何平均 = $(80 \times 12 \times 8)^{(1/3)}$
= $(7680)^{(1/3)} \approx 19.7$
- 第3步：每个值 ÷ 几何平均，再取对数(ln) ← 这就是 CLR 值

CLR(A) = $\ln(80 / 19.7) = \ln(4.06) \approx +1.40$ （远高于平均→正且大）
CLR(B) = $\ln(12 / 19.7) = \ln(0.61) \approx -0.50$ （低于平均→负）
CLR(C) = $\ln(8 / 19.7) = \ln(0.41) \approx -0.90$ （更低→更负）

为什么这能解开绑定？ - "除以几何平均"= 用样本自己的"内部基准"做参照，不再依赖会乱动的总和。 - "取对数"= 让"涨 2 倍"和"跌到 1/2"在数值上对称 (+0.69 和 -0.69)，符合"比例变化"的本质。

变换之后，CLR 值就回到了普通统计能正常处理的空间——可以算欧氏距离（就是 Aitchison 距离，模型 12 排序常用）、做线性模型、建网络，假阳性大大减少。

四、几何平均？对数？——再用大白话兜一遍

- 为什么用几何平均不用普通平均：比例/倍数的世界里，"乘除"才是自然运算（A 是 B 的 2 倍）。几何平均是"乘除世界"的中心，普通平均是"加减世界"的中心。用错了中心，参照就歪。
- 为什么取对数：把"倍数关系"拉直成"加减关系"。 $\ln(\text{涨}3\text{倍})=+1.1$ ， $\ln(\text{缩到}1/3)=-1.1$ ，一正一负、大小相等——公平。

一句话记住：CLR = "我比这桌菜的平均水平高几倍/低几倍"，而不是"我占整桌菜的百分之几"。前者不受"这桌一共多少菜"影响。

五、还有个小麻烦：零值（很多物种丰度是 0）


取对数前不能有 0 ($\ln(0)$ = 负无穷)。而宏基因组里大量物种在某些样本丰度为 0。怎么办？

- 最简单：加一个很小的伪计数 (pseudocount)，比如所有值 +0.5，再做 CLR。
 - 更讲究：用专门处理零值的方法（贝叶斯估计等）——ALDEx2 等工具内部已经替你处理好了，这也是推荐用现成工具而非手搓的原因。
-

六、落到实操：你该怎么做（对接模型 14、教程 07.4）

你要做的事	别这样	该这样
比较样本整体差异	用比例算欧氏距离	CLR 后算欧氏距离（=Aitchison），或用 Bray-Curtis
找差异物种	比例直接做 t 检验	ALDEx2 / ANCOM-BC / LinDA（内置 CLR 思想）
✱ 建共现网络	比例做 Pearson 相关	SparCC / SPIEC-EASI（模型 17）

一图总结



恍然大悟点：测序数据是“切好的披萨占比”，不是“披萨重量”。CLR 把“占整张饼几分之几”换成“相对这桌平均的几倍”，从而挣脱那根绑死所有成分的绳子。

下一难点：02-组装与分箱.md

08.2 · 图解：组装与分箱（看不见的过程，画出来）

深扩模型 6、7。组装和分箱最难点地方在于“看不见过程”。这篇把它画出来，用一句话剧透：组装 = 靠碎片边缘“重叠的字”接龙拼长；分箱 = 靠“文风像 + 在各样本同进同退”把段落归回各自的书。

第一部分：组装——把碎片接成长片段

1. 我们手上有什么？

测序把基因组打碎，得到一堆短 read（每条一两百字母），而且来历不明、还互相重叠：

真实的一段基因组（你不知道）：

A T G C A T T G C A T C G

测序得到的碎片 reads（你拿到的，乱序、重叠）：

read1: A T G C A T

read2: A T T G C A ← 注意和 read1 尾巴有重叠

read3: G C A T C G

2. 核心技巧：k-mer 接龙（de Bruijn 图）

把每条 read 切成更短、长度固定为 k 的小片段（k-mer），让首尾重叠的 k-mer 连起来。这里用 k=4 演示：

把 read 切成 4-mer (每次右移一位) :

ATGCAT → ATGC, TGCA, GCAT

ATTGCA → ATTG, TTGC, TGCA, GCAT ...

让“后3位 = 前3位”的 k-mer 接龙 (重叠部分对齐) :

ATGC

TGCA ATGC → TGCA → GCAT → CATT → ATTG → TTGC ...

GCAT

CATT

...

拼出更长的连续序列 (contig) :

A T G C A T T G C A ...

这就是 de Bruijn 图：每个 k-mer 是一个节点，重叠就连一条边，沿着边走就拼出 contig。
计算机能在几亿个 k-mer 里高速做这件事。

3. 为什么 k 的大小是个权衡？

k 太小 → 几乎所有片段都能接上，但“撞车”多：

不同位置碰巧有相同短串 → 接错 → 假连接、图很乱

k 太大 → 接得准，但要求每处都被测到足够多次（高深度）：

深度不够就接不上 → contig 断成一截截

土壤深度常不足 → 这就是它难组装的原因之一（原理 6）。

4. 现实里会断裂的两个“拦路虎”

① 重复序列：基因组里有两段一模一样

...XYZ[重复R]ABC...XYZ[重复R]DEF...

走到重复 R 时，图分叉，不知道该接 ABC 还是 DEF → contig 在此断开

② 近缘菌株：两个很像的菌混在一起

它们的序列时同时异 → 图里大量小分叉（“泡泡”）→ 拼出嵌合或断裂

结论：土壤组装出来又碎又短、N50 低，是正常的，不是你做错了。

第二部分：分箱——把 contig 归回各自的基因组

1. 组装后的窘境

组装把碎片接成了一堆 contig，但它们还是混在一起的——这些 contig 分别来自几百上千个不同的菌，你不知道哪条属于谁：

```
contig 池（来历不明）：
  contig1  contig2  contig3  contig4  contig5  contig6 ...
    (?)      (?)      (?)      (?)      (?)      (?)
```

分箱（binning）的目标：把它们分成一堆堆，让“一堆 $\approx$ 一个基因组（MAG）”。靠两条独立线索：

2. 线索一：序列“文风”（四核苷酸频率）

同一个基因组的 contig，用碱基的“口味/文风”相似——专业说法是四核苷酸频率（tetranucleotide frequency）接近。

打个比方：不同作者写作有不同用词习惯

菌X的 contig：偏爱“GC、CG”组合……	└	
菌X的另一条：也偏爱“GC、CG”	—	文风一致 → 可能同一个菌
菌Y的 contig：偏爱“AT、TA”组合……	└	文风不同 → 不同菌

3. 线索二：在多个样本里“同进同退”（丰度共变）

同一个基因组的所有 contig，在某个样本里多，就一起多；在另一个样本里少，就一起少——因为它们本来就是同一个细胞的不同部分。

	样本1	样本2	样本3	样本4	
contigA	90	10	80	5	┌ 四条曲线“同涨同落” └─ → 很可能来自同一个基因组 └
contigB	88	12	82	6	
contigC	91	9	79	4	

contigD	5	85	8	90	← 涨落模式完全不同 → 另一个基因组

这就是为什么"多样本一起分箱"效果好得多：单个样本只有"文风"一条线索；多个样本才能看出"同进同退"，这条线索极强（教程 07.3 第 3 步算覆盖度就是为了它）。

4. 两条线索一合并 → 分出箱子

文风(组成) + 丰度共变模式



▼ 聚类算法 (MetaBAT2 等)




5. 分完还要"质检"和"精炼"

- 质检 (CheckM2, 模型 8) : 每个 Bin 完整吗 (completeness) ? 混进别的菌了吗 (contamination) ?
- 精炼: 单个工具分得不干净, 用 DAS_Tool / metaWRAP 综合多个工具的结果, 去掉混入的 contig、补全——土壤几乎必须做 (模型 7 的坑)。

粗分箱(多个工具各分各的) → DAS_Tool/metaWRAP 取长补短 → 更干净的 MAG → dRep 去重

全流程一图



恍然大悟点：组装是"拼图"（靠边缘重叠），分箱是"把多本被拼好又混在一起的书按文风和出场规律归类"。土壤太厚太杂，所以拼不全、分不净是常态——靠多样本、多工具、精炼来逼近。

下一难点：03-群落构建βNTI与RCbray.md

08.3 · 图解：群落构建 β NTI 与 RCbray（环境筛选还是运气？）

深扩模型 15、16。这套方法概念绕、统计像黑箱。这篇用大白话 + 流程图讲清楚：核心思路只有一句——先算出“如果纯靠运气，结果该长啥样”，再看真实数据离它有多远。离得远=有“看不见的手”（环境筛选）；离得近=运气主导。

一、先想清楚要回答的问题

面对两片土的微生物群落不一样，我们想知道差异是怎么来的？（呼应思维框架 4 的四过程）

- 群落为什么是现在这样？
- ├— 确定性：环境/相互作用“筛选”出适应者 ← 有“看不见的手”
 - ├— 随机性：
 - ├— 漂变：随机生生死死的涨落 ← 纯运气
 - ├— 扩散限制：想来的来不了（太隔离）
 - ├— 同质扩散：到处都能去，各地被“抹平”

难点在于：“随机”长什么样我们没有直觉。所以要先人造一个“纯随机世界”做尺子——这就是“零模型（null model）”。

二、零模型的灵魂：造一把“纯随机”的尺子

零模型 = 在电脑里反复模拟“如果一切都随机”会得到什么，当作比较的基准线。

打个比方——你想知道一枚硬币是不是被做了手脚：

1. 先假设“硬币是公平的”（零模型）
2. 在脑子/电脑里模拟“公平硬币抛100次”很多很多遍
→ 得到“正面次数”的随机分布：大多落在 50 附近，比如 40~60
3. 再看真实硬币：抛100次出了 85 次正面
4. 85 远远落在“公平模拟”的范围之外
→ 结论：这硬币不公平，有“看不见的手”在作弊（=确定性/选择）

群落构建完全是同一个套路，只是把“抛硬币”换成“随机组装群落”，把“正面次数”换成下面的 β NTI / RCbray 两把尺子。

三、第一把尺子： β NTI —— 测“环境筛选”

它在量什么：两片土的微生物，在进化亲缘关系上的差异，比“纯随机组装”预期的更大还是更小。

背后一个假设：亲缘近的菌，生态习性也近（叫“系统发育信号”，用前要检验）。所以“亲缘构成”能反映“环境把谁筛进来了”。

做法（概念版）：


观测值：真实两群落的“亲缘距离”


随机值：把物种在进化树上反复随机洗牌很多次，得到一堆“随机亲缘距离”

β NTI = 观测值 比 随机值的平均 偏离了多少个“标准差”

怎么读 β NTI（背下这张表即可）：

β NTI 数轴：





最终产出：统计所有样本对落在 5 类的百分比，例如：

本研究群落构建过程构成：

同质选择	45%	└─	确定性合计 60%
变量选择	15%	└─	

漂变	25%	└─	随机合计 40%
扩散限制	10%	└─	
同质扩散	5%	└─	

结论：该土壤群落由“确定性的同质选择”主导，说明相似的环境条件在持续筛选相似的微生物—环境是主要驱动力。

六、动手怎么做（对接模型 16、教程）

- R 包 iCAMP（一体化，最常用）、picante、NST。
- 输入：物种丰度表 + 一棵物种系统发育树（建树是前置步骤）。
- 常和 Sloan 中性模型（模型 15）一起报告，互相印证。

```

# 概念示意（具体见 iCAMP 官方教程）
library(iCAMP)

# 需要：群落表 comm、系统发育距离 pd
result <- icamp.big(comm = comm, pd.desc = pd, ...)

# 输出各群落对在 5 类过程上的比例

```

七、最容易误解的 3 个点

1. "中性/随机拟合得好 $\neq$ 环境不重要"——它只是说"用随机就能解释"，要结合 β NTI 一起下结论。
 2. β NTI 依赖"系统发育信号"假设——用前要检验亲缘近的菌生态位是否真的近，否则结论不可靠。
 3. 别死抠那几个百分比——方法对采样设计、分类分辨率敏感，结论要谨慎，重在"哪类主导"的定性判断。
-

恍然大悟点： β NTI 和 RCbray 不神秘——就是"先用电脑模拟一个纯随机世界当尺子，再量真实数据偏离了多远"。偏得多 = 环境在筛选（确定性）；偏得少 = 运气主导（随机），再细分是漂变、扩散限制还是同质扩散。

下一难点：[04-多样性与排序.md](#)

08.4 · 图解：多样性与排序（ α 、 β 、距离、PCoA 到底在算啥）

深扩模型 11、12。这些词天天见但容易糊。一句话剧透： α = 一个样本内部"多不多样"； β = 样本两两"差多少"；PCoA = 把"两两差多少"这张大表，压成一张能用眼睛看的散点图。

一、 α 多样性：单个样本内部，多不多样？

α 多样性看一个样本里两件事：种类多不多（丰富度） + 均不均匀（均匀度）。

用两个极端例子建立直觉（都是 100 个个体）：

样本甲（很不多样）	样本乙（很多样）
A A A A A A A A A A	A B C D E
A A A A A A A A A A	F G H I J
A A A A A A A A B C	K L M N O ... (20 种, 各 5 个)
种类: 3 极不均匀 → 多样性低	种类: 20 很均匀 → 多样性高

同一份数据，三个指标侧重不同（这是关键！）

指标	在乎什么	对稀有种的态度
丰富度($q=0$)	只数“有几种”	最在乎（来一个算一个）
Shannon($q=1$)	种类 + 均匀度	中立、不偏不倚
Simpson($q=2$)	主要看“优势种”格局	几乎忽视稀有种

为什么要同时看几个：只报 Shannon 一个数，会把"稀有种变化"和"优势种变化"混在一起。三个一起看，才知道差异到底出在哪。这就是 Hill 数 $q=0/1/2$ 框架的意义（模型 11）。

头号大坑：比 α 多样性前必须"抽平"

样本P 测了 100万条 reads → 发现 800 种 ┐ 这不是 P 真的更多样，
样本Q 测了 10万条 reads → 发现 400 种 ┘ 是 P 测得更深、抽到的更多！

正确做法：把所有样本随机"抽平"到相同深度（如都降到10万），再比。

(呼应模型 3 稀释曲线、教程 07.4 的 `rrarefy`)

二、 β 多样性：两个样本之间，差多少？

β 多样性 = 样本与样本之间的差异。第一步要把"差异"变成一个数，叫距离/相异度。

三种最常见的"差异分"

两个样本有哪些物种、各多少：

	A	B	C	D
样本X	10	5	0	0
样本Y	8	0	6	2

① Jaccard (只看"有没有"，不看多少)

X 有 {A,B}, Y 有 {A,C,D}; 共有 {A}=1 个, 共计 {A,B,C,D}=4 个
差异 = $1 - 1/4 = 0.75$

② Bray-Curtis (看"数量"差, 最常用)

按每个物种数量差异综合计算 → 0~1, 越大越不同

③ UniFrac (还考虑"亲缘远近")

差异的两个菌如果亲缘很近, 算"差得少"; 亲缘很远, 算"差得多"

选哪种？想强调"有无" → Jaccard；常规丰度比较 → Bray-Curtis；想纳入进化信息 → UniFrac；组成型严谨 → Aitchison（CLR 后的欧氏距离，见 08.1）。

算完得到一张"两两距离表"（距离矩阵）

	样本X	样本Y	样本Z
样本X	0	0.62	0.71
样本Y	0.62	0	0.45
样本Z	0.71	0.45	0

样本一多，这张表就是个大方阵——人眼根本看不出规律。于是需要第三步：排序。

三、排序（PCoA/NMDS）：把大表压成一张散点图

目标：把"高维的两两距离"压到二维平面上，让"表里距离近的样本，图上点也近"。这样你一眼就能看出哪些样本聚成一团。

一张看不懂的距离大表（ $N \times N$ 个数字）

PCoA / NMDS（降维）

一张二维散点图（ N 个点）

PCoA2



解读：同色点聚在一起、两组分开 = 处理改变了群落

- PCoA：尽量忠实保留"真实距离大小"。坐标轴会标"解释了百分之几的差异"。
- NMDS：只保留"谁离谁近的排名"，更适合非线性；看 stress 值（ <0.2 才算可信）。

头号大坑：眼睛会骗人，必须做统计检验

图上“看起来分开了” ≠ 真的有显著差异！

必须做 PERMANOVA (R 里的 `adonis2`)：

- R^2 = 分组能解释多少差异 (效应大小)
- p 值 = 这种分开是不是碰巧 (要 <0.05)

再做 `betadisper`：排除“是组内离散度不同造成的假分开”

(对接模型 12、教程 07.4 第五步)


四、 α 和 β ，别搞混 (一张对照)

	α 多样性	β 多样性
看的对象	一个样本内部	样本与样本之间
回答	“这片土自己多不多样”	“两片土差多少”
产物	一个数 (每样本一个)	一个距离矩阵 → 一张排序图
典型图	箱线图	PCoA/NMDS 散点图
关键坑	比之前要抽平	只看图不做 PERMANOVA

记忆法： α 是“自己跟自己比丰不丰富”， β 是“你跟我差多远”。

从数据到图，一条线

物种丰度表



恍然大悟点： α 是"一个样本内部多不多样"， β 是"样本两两差多少"。距离矩阵是中间产物，PCoA 只是把这张人看不懂的大表"拍扁"成一张散点图。图给你直觉，PERMANOVA 给你结论——缺一不可。

回到 08 难点图解总览 | 想要速查卡：[../09-速记卡片与速查图.md](#)

09 · 速记卡片与速查图

把最常用的阈值、流程、工具、基因、口诀做成一张张"看一眼就懂"的卡片。用法：贴在桌前 / 收藏，做分析、读论文、想不起来时扫一眼。详细解释点各卡片里的链接。

卡片 1 · 关键数字/阈值速查（最高频）

场景	指标	记住的数	含义	出处
质控	Phred Q 值	Q20=99% , Q30=99.9%	单碱基准确率	模型 4
组装	N50	越大越好	组装连续性	模型 6
MAG 高质量	完整度/污染度	>90% / <5%	+ 含 5S/16S/23S+≥18 tRNA	模型 8
MAG 中质量	完整度/污染度	≥50% / <10%	可用下限	模型 8
MAG 综合门槛	质量指数	完整度-5×污染度 >50	GTDB 常用	模型 8
群落构建	βNTI	βNTI >2 = 确定性	>2变量选择/<-2同质选择	模型 16
群落构建	RCbray	RC >0.95 = 非漂变	>.95扩散限制/<-.95同质扩散	模型 16
统计显著	p 值	<0.05	PERMANOVA/检验显著线	模型 12
排序可信	NMDS stress	<0.2	越小越可信	模型 12

卡片 2 · 分析流程命令骨架（照着改）

原始数据 *_1.fq.gz / *_2.fq.gz

| ① 质控 fastp -i .. -I .. -o .. -O .. -q 20 -l 50 --detect_adapter_for_pe

| ② 去宿主 bowtie2 -x host --un-conc-gz clean_%.fq.gz ..

└─ 路线甲(快):

| 物种谱 kraken2 --db DB --paired r1 r2 --report a.kreport

| bracken -d DB -i a.kreport -o a.bracken -r 150 -l S

| 功能谱 humann --input merged.fq.gz --output func/

└─ 路线乙(深):

 组装 megahit -1 r1 -2 r2 -o asm/ --min-contig-len 1000

 预测基因 prodigal -i contigs.fa -a prot.faa -p meta

 覆盖度 bowtie2.. | samtools sort ; jgi_summarize_bam_contig_depths

 分箱 metabat2 -i contigs.fa -a depth.txt -o bins/bin

 质控 checkm2 predict --input bins/ -x fa --output-directory ck/

 分类 gtdbtk classify_wf --genome_dir bins/ --out_dir gt/ -x fa

 功能注释 emapper.py -i prot.faa -o out --data_dir ~/db/egglog

→ 全部表进 R : vegan(多样性/PCoA/adonis2) + ALDEx2(差异) + SpiecEasi(网络)

详见 07-实操教程/

卡片 3 · 工具速查（按流程阶段）

阶段	首选	备选
质控	fastp	Trimmomatic, KneadData
去宿主	Bowtie2	BWA, KneadData
组装	MEGAHIT(省内存)	metaSPAdes(高质量), metaFlye(长读长)
基因预测	Prodigal	—
分箱	MetaBAT2	MaxBin2, CONCOCT, SemiBin2
分箱精炼	DAS_Tool / metaWRAP	—
去冗余	dRep	—
MAG 质控	CheckM2	CheckM, GUNC
MAG 分类	GTDB-Tk	—
读长物种	Kraken2+Bracken	MetaPhlAn
读长功能	HUMAnN	—
功能注释	eggNOG-mapper	DRAM, KEGG, CAZy
BGC 挖掘	antiSMASH	—
统计画图	R: vegan/phyloseq	microeco, QIIME2
差异丰度	ALDEx2	ANCOM-BC, LinDA, LEfSe
共现网络	SPIEC-EASI	SparCC
群落构建	iCAMP	picante, NST
中文一体化	EasyMetagenome	nf-core/mag, anvi'o

详见 05-工具与数据库速查.md

卡片 4 · 标志基因速查 (碳氮磷硫循环)

循环	过程	标志基因
氮 N	固氮	nifH
	氨氧化(硝化)	amoA
	反硝化	nirK/nirS , nosZ (管 N ₂ O)
碳 C	复杂碳降解	CAZy 家族(GH 等)
	产/氧化甲烷	mcrA / pmoA
	固碳	rbcL , accA
磷 P	溶磷/转运/矿化	phoD , pstB , phnJ , ppk
硫 S	硫还原/氧化	dsrAB , soxB

专用库：NCyc(氮) / PCyc(磷) / SCyc(硫)。详见 模型 19

卡片 5 · 决策速查 (我该选哪个?)

扩增子 还是 宏基因组？

只要“有谁”、样本多、预算紧 → 扩增子(16S/ITS)

要“能干啥/基因/基因组” → 鸟枪法宏基因组

读长(read-based) 还是 组装(assembly-based)？

快速出物种/功能谱、新手起步 → 读长(Kraken2/HUMAN)

要重建基因组(MAG)、挖新基因 → 组装+分箱

α 多样性比较前 → 一定先抽平！

看 PCoA 分组 → 一定做 PERMANOVA！

找差异物种 → 用 ALDEx2, 别用普通 t 检验！

建共现网络 → 用 SPIEC-EASI/SparCC, 别用 Pearson！

卡片 6 · 20 个模型一句话索引

#	模型	一句话
1	中心法则/基因即潜力	基因=能干什么的清单
2	扩增子vs宏基因组	查身份证 vs 读简历
3	测序深度/稀释曲线	测够深没？没饱和=漏了
4	Phred质量	Q30=99.9%，先质控
5	比对/同源	像不像→同不同源，看E-value
6	de Bruijn组装	碎片靠重叠接龙
7	分箱	文风+丰度共变归堆
8	MAG质控	单拷贝标记测完整/污染
9	k-mer/LCA分类	特异k-mer定身份
10	功能注释	比数据库借功能标签
11	α 多样性/Hill	样本内多不多样($q=0/1/2$)
12	β 多样性/排序	样本间差多少→PCoA
13	丰度分布	少数很多+多数很少(长尾)
14	组成型/CLR	比例要变换，防假阳性
15	中性模型	纯随机能解释多少
16	β NTI/RCbray	确定性 vs 随机定量
17	共现网络	谁和谁一起，谁是枢纽
18	生物地理	环境选择常胜过距离
19	循环功能基因	标志基因量化C/N/P/S
20	功能冗余	物种变功能不一定变

详见 02-必学模型/

卡片 7 · 7 个思维框架口诀

#	框架	口诀
1	尺度	"我的问题住哪层楼？"
2	数据生命周期	"垃圾进，垃圾出；设计>分析"
3	结构→功能→过程	"能干≠在干≠干了多少"
4	群落构建四过程	"筛选、迁移、运气、新生"
5	假说vs数据	"别在同一锅数据里又出题又判卷"
6	对照·重复	"n=1 不是数据，是轱事"
7	相关→因果	"相关给假设，实验给结论"

详见 03-思维框架.md

卡片 8 · 新手避坑清单（贴脑门上）

- | | |
|-----------------|--------------------------|
| × 测到基因 = 正在发挥作用 | → 只是潜力(框架3) |
| × 比例高 = 数量多 | → 组成型数据(模型14/图解08.1) |
| × 没测到 = 不存在 | → 可能测不够深(模型3) |
| × 一起出现 = 有因果关系 | → 相关≠因果(模型17/框架7) |
| × 跳过质控直接分析 | → 先 fastp(模型4) |
| × 不抽平就比多样性 | → 先 rarefy(模型3/11) |
| 只看PCoA图说"分开了" | → 做PERMANOVA(模型12) |
| 比例直接做t检验/相关 | → ALDEx2/SparCC(模型14/17) |
| 忘了去宿主 | → 否则"土里全是植物基因" |
| 不控批次效应 | → 处理打散到各批次(框架6) |

这张卡片集是"压缩包"。看不懂某条，就点链接去对应章节"解压"。先求会查，再求会用，最后求会判断。

[回到 知识库总览](#)

10 · 前沿模型与方法 · 总览

前面 1–9 讲的是主流必会的内容。这个模块带你看正在快速发展的前沿——它们大多是"他山之石"：把 AI、系统生物学、物理(Hi-C)、化学(同位素)等其它领域的利器，搬来攻克宏基因组的老大难问题。

双重提醒：① 前沿 = 变化快，本模块讲"思想和代表工具"，具体实现以最新文献为准；② 你仍是小白，所以每个前沿我都会先讲"它解决了基础篇里的哪个痛点"，把新东西挂到你已有的知识树上。

一句话先看懂：每个前沿在补哪块短板

基础篇留下的痛点	前沿用什么补	在本模块哪篇
原理6：大量序列比不上数据库（暗物质）	AI 基础模型：直接从序列预测结构/功能	01
模型7：土壤分箱难、质粒/噬菌体不知属于谁	Hi-C 邻近连接：用物理接触把碎片归到同一个细胞	02
几乎没讲的一整个维度：病毒/噬菌体	病毒组 + CRISPR：找出病毒并锁定它感染谁	02
框架3：潜力 ≠ 活性（基因有≠在干活）	qSIP 同位素探针：直接测"谁真的在生长"	03
模型17：共现≠ 真实互作	群落代谢模型(GEM)：模拟谁喂谁、谁抢谁	03

看出来了吗？前沿不是另起炉灶，而是精准地补基础篇每一个"做不到"。这就是为什么要先打好 1–9 的底子。

本模块内容

篇	前沿主题	借了谁的"石"
01-AI与基础模型.md	基因组/蛋白质语言模型、照亮暗物质、ML 预测应用	人工智能 / 深度学习
02-Hi-C邻近连接与病毒组.md	Hi-C 分箱、质粒/噬菌体定主、土壤病毒组	染色体构象(物理)、病毒生态
03-从基因潜力到活性与互作.md	qSIP 稳定同位素探针、群落代谢建模 GEM	同位素化学、系统生物学

前沿的总趋势（记住这条主线）

第一代 描述“有谁/有什么基因”

第二代 重建基因组、看清个体

第三代 看清“真在干活的是谁、怎么互动”

未来 用 AI 理解“暗物质”、预测、乃至设计

(read-based, 模型 9/10)

(genome-resolved / MAG, 模型 6-8)

(qSIP / 多组学 / 代谢模型, 本模块 + 模块11)

(基础模型 / 生成式, 本模块 01)

一句话：从"谁在"→"谁能"→"谁在干"→"谁和谁怎么干"→"AI 看懂并预测"。

从最热的开始： 01-AI与基础模型.md

10.1 · AI 与基础模型：用人工智能照亮"暗物质"

他山之石 = 人工智能 / 深度学习。这是宏基因组最火的前沿。一句话剧透：就像 ChatGPT 学了海量文本后会"理解"语言，"基因组/蛋白质语言模型"学了海量生命序列后，能"理解"DNA 和蛋白——于是它能给那些比不上任何数据库的"暗物质"序列，猜出结构和功能。

补的痛点：原理 6（大量土壤序列是暗物质）、模型 10（功能注释只能注释"已知"的）。

一、先回忆痛点：暗物质问题

基础篇反复说过：土壤里大量序列比不上任何已知数据库（微生物暗物质）。传统功能注释（模型 10）的逻辑是"去字典里查"——字典里没有，就只能标成"功能未知（hypothetical protein）"，白白丢掉。

土壤、海洋里的蛋白，绝大多数我们只知道它的氨基酸序列，对它的结构和功能一无所知——这就是"蛋白质暗物质"。

传统方法的死穴：只能认识"见过的"。而 AI 的突破点恰恰是：它能对"没见过的"做出有根据的推测。

二、关键思想：把"序列"当成"语言"来学

类比（重要，理解这个就懂了一半）：

自然语言模型(如 ChatGPT)		生命序列模型
学海量文本	→	学海量 DNA / 蛋白序列
学会"语法、语义、上下文"	→	学会"序列里的规律、约束、功能模式"
能续写、改写、回答	→	能预测结构/功能、补全、甚至"设计"新序列

为什么这招对生命序列管用？因为进化本身就是一种“语言”：能存活下来的序列不是随机的，它们遵循深层规律（哪些位点能变、哪些必须保守）。模型从亿万条序列里自己悟出这些规律，于是面对新序列也能举一反三。

行话：这类模型叫“基础模型 / 预训练大模型（foundation model）”——先在海量数据上自监督预训练，再用到各种下游任务。

三、两大类模型（小白只需记住“是什么、能干啥”）

A. 蛋白质语言模型（Protein Language Model）—— 照亮蛋白暗物质

- 代表：ESM 系列（如 ESMC，训练于约 28 亿条来自全生命的序列）、配套的结构预测 ESMFold；以及大名鼎鼎的 AlphaFold。
- 能干啥：直接从氨基酸序列预测三维结构和功能，不需要做实验。
- 对宏基因组的意义：ESM 宏基因组图谱（ESM Metagenomic Atlas）已经预测了 6 亿以上蛋白的结构，其中绝大多数来自环境样本（土壤、海洋）的“暗物质”蛋白——这是 AlphaFold 早期数据库里大片空白的部分。等于给暗物质蛋白第一次“拍了照片”。

一条来自土壤、谁都不认识的蛋白序列

| 传统：比数据库 → 查无此人 → 标“功能未知”，丢弃

|

└ AI：蛋白质语言模型 → 预测出三维结构 → 看它长得像哪类酶
→ “它的结构像水解酶” → 给出功能线索

B. 基因组/核酸语言模型（Genomic / DNA Language Model）—— 读懂 DNA 本身

- 代表：Evo / Evo 2（能从分子到整个基因组尺度建模、甚至生成序列）、Nucleotide Transformer、专为环境序列的 GenomeOcean、用于病原监测的宏基因组基础模型 METAGENE-1。
- 能干啥：直接在 DNA 层面预测功能元件、基因调控、变异影响，甚至生成式设计新的基因/基因组片段。
- 对宏基因组的意义：处理那些连基因边界都难界定的环境序列；为合成生物学、新酶/新功能挖掘开路。

四、另一条 AI 应用线：机器学习做"预测"（很实用的他山之石）

除了"读懂序列"，AI 还能把微生物组数据当成特征，去预测现实结果——这是离应用最近的一类。

典型应用（都是真实研究方向）：- 用土壤微生物组预测土壤健康指标（有研究数值评分预测 R^2 约 0.8）；- 预测作物产量、病害（如马铃薯产量与病害）；- 预测土壤对病原菌的抑制能力（disease suppressiveness）；- 宏基因组关联分析（MWAS）：像 GWAS 找致病基因那样，找"和某性状相关的微生物/基因"。

常用方法：随机森林（Random Forest，最常用、好上手）、支持向量机、梯度提升、深度学习等。

小白须知的坑：- "人的决策"极大影响结果：怎么预处理、怎么标准化、特征怎么选，会显著改变预测表现——有研究专门指出"机器学习里的人为上限"。- 能预测 $\neq$ 懂机制：模型说"这些菌和高产相关"，不代表它们导致高产（相关 $\neq$ 因果，框架 7）。预测和机制是两回事。- 样本量小、维度高（物种成千上万）时极易过拟合，必须交叉验证、独立测试集。

五、和你已有知识的连接（别把它当孤立新知识）

基础篇概念	AI 怎么升级它
模型 5 比对/同源（查字典）	从"查见过的" $\rightarrow$ AI"理解没见过的"
模型 10 功能注释	暗物质蛋白也能给出结构/功能线索
模型 7 分箱（深度学习已进场）	SemiBin2 等已用深度学习做更好的分箱
原理 6 暗物质	从"承认未知" $\rightarrow$ "尝试照亮未知"

六、给小白的态度建议

- 不必现在就会训练大模型——那是另一个深坑。先理解"它能做什么、不能做什么"。

- 会"用"比会"造"更实际：很多模型有现成的网页/接口（如查 ESM Atlas 里某蛋白的预测结构）。
- 保持清醒：AI 给的是有根据的推测，不是真理。结构预测、功能预测、产量预测，都需要实验或独立数据验证（框架 7）。

延伸阅读

- Evo：分子到基因组尺度的序列建模与设计 · <https://pmc.ncbi.nlm.nih.gov/articles/PMC12057570/>
- 基因组语言模型综述 · Frontiers in Genetics 2025 · <https://www.frontiersin.org/journals/genetics/articles/10.3389/fgene.2025.1634882/full>
- ESM 宏基因组蛋白结构图谱 · <https://esmatlas.com/about>
- 用机器学习与组学解析土壤 C/N/P 循环的环境调控 · JGR Biogeosciences 2025 · <https://agupubs.onlinelibrary.wiley.com/doi/full/10.1029/2024JG008470>
- "机器学习中的人为上限"：用土壤微生物组预测马铃薯产量与病害 · <https://pubmed.ncbi.nlm.nih.gov/39592933/>

下一前沿：02-Hi-C邻近连接与病毒组.md

10.2 · Hi-C 邻近连接 与 病毒组

两个前沿放一篇，因为它们都在补"归属"的短板：Hi-C 帮你把碎片(尤其质粒/噬菌体)归到正确的细胞；病毒组+CRISPR 帮你把病毒归到它感染的宿主。他山之石：染色体构象捕获(物理/分子生物学) + 病毒生态学。

第一部分 · Hi-C 邻近连接：用"物理接触"分箱

一、先回忆痛点

模型 7 说过：分箱靠"序列文风 + 丰度共变"两条间接线索，土壤分箱又难又不准，而且质粒、噬菌体这类游离 DNA 根本不知道属于哪个菌。

有没有更直接的证据，证明"这两段 DNA 来自同一个细胞"？有——看它们在细胞里是不是物理上挨在一起。

二、核心思想：在细胞被打碎前，先把"邻居"焊在一起

Hi-C / 邻近连接 (proximity ligation) 的巧妙之处：

普通宏基因组：先打碎细胞 → DNA 各自分离 → 谁和谁原来在一个细胞里，信息丢了
(所以分箱只能靠间接线索)

Hi-C：① 先用化学"胶水"把细胞内物理上靠近的 DNA 片段"焊"在一起(交联)
② 再打碎、测序
③ 测到"被焊在一起的两段" = 它们原来在同一个细胞里！(直接证据)

打个比方：

普通方法像把一栋楼炸了再去猜哪些砖原属同一户。Hi-C 像先给每户人家拍一张"全家福"再拆楼——谁和谁一家，一目了然。

三、它能做到普通分箱做不到的事

1. 更准的分箱：用"物理接触频率"把 contig 聚类，质量更高（尤其复杂的土壤）。
2. 给质粒/噬菌体"定主"：游离的质粒、整合的噬菌体，能凭"和谁焊在一起"找到它的宿主基因组——这是普通分箱完全做不到的。
3. 抗药基因溯源：抗性基因常在质粒上(案例7)，Hi-C 能告诉你"这个抗药质粒在谁体内"，对追踪传播极有价值。

四、代表工具

- bin3C、MetaTOR、MetaCC：基于 Hi-C 接触数据做分箱；
- ViralCC：专门从 Hi-C 数据里回收病毒基因组并锁定病毒-宿主配对。

代价：需要额外做一个 Hi-C 文库（实验更复杂、更贵），所以目前多用于重点研究而非常规普查。

第二部分 · 病毒组：被忽视的"隐形操盘手"

一、一个被基础篇略过的整片大陆

前面 1-9 几乎只讲细菌/古菌/真菌。但土壤里还有海量病毒（主要是噬菌体，即感染细菌的病毒），数量常比细菌还多。它们是生态系统的"隐形操盘手"：

病毒在土壤里干三件大事：

- ① 杀手：感染并裂解细菌 → 控制谁多谁少（“病毒打洞”塑造群落）
- ② 搬运工：在不同菌之间搬运基因（水平基因转移，含抗药基因！）
- ③ 改造者：携带“辅助代谢基因”，临时改写宿主代谢（影响碳氮循环）

不看病毒，等于研究一座城市却无视了所有的“流行病和物流”。

二、难点：病毒是“暗物质中的暗物质”

病毒没有像 16S 那样的通用标志基因，演化又快，导致：- 数据库覆盖极低，绝大多数土壤病毒序列无法注释（病毒暗物质）；- 怎么从一锅宏基因组里认出哪些 contig 是病毒，本身就是难题。

常用识别工具：geNomad、VirSorter2、CheckV（评估病毒基因组完整性）等。

三、关键问题：这个病毒感染谁？——CRISPR 间谍档案

最妙的招数是借用细菌自己的“免疫记忆”——CRISPR。

细菌的 CRISPR 系统会把“入侵过自己的病毒”的一小段 DNA（叫 spacer/间隔序列）存进自己的基因组，当作“通缉档案”，下次照着抓。

于是反过来：

- 如果某细菌基因组里的 CRISPR 档案(spacer) ←匹配→ 某病毒序列
- 说明这个病毒曾感染过这个细菌
- 我们就锁定了“病毒-宿主”配对！

打个比方：CRISPR spacer 就像细菌手机里存的“骚扰来电黑名单”。我们翻遍所有细菌的黑名单，就能反推“这个病毒打过谁的电话”。

现状：CRISPR spacer 比对是宿主预测的主力之一（某工具在已知数据上召回率约 49%、精确率约 69%），常与“前噬菌体扫描”“序列同源”等方法联用。还有像 ViralCC（Hi-C 法）从物理接触角度定宿主——两条路互相印证。

四、和你已有知识的连接

基础篇概念	病毒组怎么扩展它
三个核心问题(有谁/能干啥/为啥)	加上"谁在被谁控制"这一层
案例7 抗性组	病毒/质粒是抗药基因传播的载体
模型19 循环功能	病毒辅助代谢基因会临时改写宿主的碳氮代谢
 原理6 暗物质	病毒是暗物质里最暗的一块

延伸阅读

- MetaTOR : 基于 Hi-C 的高质量分箱 · <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC6710406/>
- bin3C / Hi-C 宏基因组分箱 (GitHub metaTOR) · <https://github.com/koszullab/metaTOR>
- 土壤深度剖面的病毒-宿主互作 · mBio 2023 · <https://journals.asm.org/doi/full/10.1128/mbio.02246-23>
- 用 CRISPR spacer 预测病毒宿主、破解病毒暗物质 · <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8034630/>
- VIRE : 行星尺度病毒组资源 · Nucleic Acids Research · <https://academic.oup.com/nar/article/54/D1/D902/8356007>

下一前沿： 03-从基因潜力到活性与互动.md

10.3 · 从"基因潜力"到"活性与互作"

这一篇直击全库最核心的两条遗憾：① 框架3 的"潜力 $\neq$ 活性"——基因有，不代表在干活。② 模型17 的"共现 $\neq$ 互作"——一起出现，不代表真有来往。前沿用两件利器分别补上：qSIP（同位素探针）测"谁真在生长" + 群落代谢模型（GEM）算"谁喂谁、谁抢谁"。

第一部分 · qSIP：直接测"谁真的在干活"

他山之石：稳定同位素化学。这是把"潜力"变"活性"的最优雅的招数之一。

一、痛点回顾

宏基因组测的是 DNA，只能告诉你"有能力"（框架3）。一个菌哪怕早就死了或在睡觉，它的 DNA 还在，照样被你测到。所以你永远分不清：这片土里，到底谁是"活跃打工人"，谁是"躺平的尸体"？

二、核心思想：让活跃的菌"自己变重"

稳定同位素探针（SIP, Stable Isotope Probing）的绝妙之处：

- ① 给土壤喂“重”食物：比如用 ^{13}C （比普通 ^{12}C 重）标记的葡萄糖，或 ^{15}N 标记的氮源。（同位素=同种元素的“重版本”，无放射性、安全）
- ② 谁活跃、谁生长，就会把这些“重原子”吃进去、用来造自己的新 DNA
→ 活跃菌的 DNA 变“重”了；躺平/死亡的菌 DNA 还是“轻”的。
- ③ 用超高速离心按“密度”把 DNA 分层：重的沉下去，轻的浮上面。
- ④ 只把“重”的那层拿去测序（宏基因组）
→ 测到的，就是“真正在生长、在利用这种食物”的活跃菌！

打个比方：

给整个城市发“带荧光的特制餐”。谁真在吃饭干活，身上就会发光；谁在装死，就不发光。我们只把发光的人挑出来登记——这些才是真正的活跃劳动力。

三、qSIP（定量版）让它更强

qSIP（quantitative SIP）进一步定量：通过 DNA “变重了多少”，算出每个基因组的生长速率/活性。结合宏基因组，就能做到：

- 把“身份”+ “功能”+ “真实活性”三者锁在一起——这是宏基因组单独做不到的圣杯。
- 例：研究证明土壤湿度如何影响哪些菌真正活跃（而不只是“存在”）。

四、和你已有知识的连接

想知道	单靠宏基因组	加上 qSIP
土里有谁		
谁能固氮(有 nifH)	潜力	
谁真在生长/固氮	测不出	活性

qSIP 是“爬证据阶梯”(框架7)、跨越“潜力→活性”(框架3)最有力的实验手段之一。

第二部分·群落代谢模型（GEM）：算出"谁喂谁、谁抢谁"

他山之石：系统生物学 / 代谢工程。把单个细胞的代谢网络，拼成整个群落的"经济模型"。

一、痛点回顾

模型17 的共现网络只能说"A 和 B 总一起出现"，但说不清它们到底在干嘛——是 A 把废料喂给 B（互利），还是它们抢同一种食物（竞争）？共现≠互作。

二、核心思想：给每个菌建一张"代谢地图"，再让它们"做生意"

基因组尺度代谢模型（GEM, Genome-scale Metabolic Model）：

- ① 拿一个基因组(MAG)，根据它有哪些酶基因，
重建出它的全套代谢反应网络 = 一张"这个菌能把什么变成什么"的地图。
- ② 把群落里多个菌的代谢地图拼到一起，
模拟它们共享同一锅"培养基"时会发生什么：
 - A 的废料(如乙酸)正好是 B 的食物 → 交叉喂养(cross-feeding, 互利)
 - A 和 B 都要抢同一种氮源 → 竞争
 - 谁离了谁活不下去 → 依赖
- ③ 用数学(通量平衡分析等)算出：谁能长、长多快、谁喂谁、谁抢谁。

打个比方：

给城里每个工厂画一张"进什么原料、出什么产品"的工艺图，再把它们接成一张产业链/经济网络，就能推演谁是上游供货、谁在抢原料、谁倒闭后整条链会不会断。

三、代表工具（小白只需知道名字和分工）

工具	干啥
CarveMe	快速从基因组"雕刻"出代谢模型（分钟级）
gapseq	更精细地重建模型（含补漏 gap-filling）
MICOM	群落层面模拟，可做"敲除某菌看影响"
SMETANA	专门推断成员间的代谢互作(交叉喂养/竞争)
metaGEM	把"宏基因组→建模→互作推断"串成流程

四、用处与坑

用处：从"统计相关"升级到"机制假说"——预测出"A 可能在喂 B"，再去做实验验证（接种、合成群落 SynCom）。

坑：- 模型基于"基因→反应"的自动推断，MAG 不全/注释有误 → 模型就不准（垃圾进垃圾出）。- 预测的是"代谢上可能发生什么"，仍是假说，不是实测，要验证(框架7)。- 土壤 MAG 质量普遍偏低(模型8)，给建模带来额外不确定性。

两件利器在"证据阶梯"上的位置（呼应框架7）

观测相关 → 共现网络 → 【GEM 代谢模型：给出互作机制假说】
→ 富集/标志基因(潜力)
→ 【qSIP / 宏转录组：证明真在活动(活性)】
→ 操控实验(接种/合成群落)：坐实因果

弱

本篇要义：qSIP 把"潜力"变成"实测的活性"；GEM 把"共现"变成"可检验的互作机制"。两者都不是取代宏基因组，而是站在它的肩膀上，往因果再走一步。

延伸阅读

- qSIP + 宏基因组：把微生物活性与土壤湿度联系起来 · mSystems · <https://journals.asm.org/doi/10.1128/msystems.00417-22>
- SIP 宏基因组标准化定量分析策略 · <https://pubmed.ncbi.nlm.nih.gov/37377419/>
- 群落尺度代谢建模综述 · <https://pmc.ncbi.nlm.nih.gov/articles/PMC10832553/>
- 自动化重建群落代谢模型的比较 · npj Systems Biology 2024 · <https://www.nature.com/articles/s41540-024-00384-y>

回到 模块10总览 | 升维到整合思想： [../11-多组学整合与他山之石/README.md](#)

11 · 多组学整合 与 他山之石 · 总览

这个模块回答你最关键的两个直觉：① "宏基因组是不是简单/基础版的组学？" —— 是"底层基础层"，但绝不"简单"。要看清全貌，得往上叠加其它组学层。这就是 01-组学阶梯与多组学整合.md。② "有没有他山之石？" —— 太多了！别的生态系统(海洋、肠道)、别的学科(生态学、网络科学、系统生物学、AI)都有现成的利器可借。这就是 02-他山之石.md。

一、先纠正一个常见误解

"宏基因组 = 简单版的组学" "宏基因组 = 组学阶梯的最底层、最基础那一级（测 DNA = 潜力）；它是地基，不是简化版。"

为什么说它是"地基"而非"简化版"？

- 它在功能链的最底端：DNA(能干什么) → RNA(在表达什么) → 蛋白(造出了什么) → 代谢物(产出了什么)。宏基因组测的是最稳定、最基础的 DNA 层，所以是其它一切的起点。
- 但它一点都不简单：土壤宏基因组的组装、分箱、暗物质，是全生物学最难的计算问题之一(原理6、模型6-8)。
- "基础"恰恰是它的价值：地基打得好，上面才能叠 RNA、蛋白、代谢物的楼层——这就是"多组学整合"。

一句话：宏基因组是多组学大厦的地基。地基不简单，而且没有地基，楼盖不起来。

二、本模块内容

篇	讲什么	回答你的哪个问题
01-组学阶梯与多组学整合.md	组学阶梯(DNA→RNA→蛋白→代谢物)总览、为什么宏基因组是地基、怎么往上叠、整合难点	"是不是简单版组学"
02-他山之石.md	入门：向海洋(Tara)、肠道、EMP 借经验；向生态学、网络科学、系统生物学、AI 借方法	"有没有他山之石"
03-各类组学详解.md	详解每一层组学：宏转录组/蛋白组/代谢组/表观组逐一展开 + 抗性组/移动组等子组学	"和组学的关系"(详)
04-从组学领域借方法.md	能在组学借鉴的：GWAS→MWAS、单细胞分辨、空间组学、UMAP/批次校正等	"能在组学借鉴的"
05-他山之石进阶.md	他山之石进阶：更多生态系统(极端/植物/古DNA) + 更多学科(博弈论/流行病学/因果推断/地统计…)	"他山之石"(扩充)

阅读建议：先 01 (总览) → 想深入组学关系看 03 → 想借方法看 04 → 想看更广的跨界看 02 + 05。

三、一图看懂"地基 + 楼层 + 外援"



先把"地基"在大厦里的位置看清：01-组学阶梯与多组学整合.md

11.1 · 组学阶梯与多组学整合

正面讲透你的问题：宏基因组在所有"组学"里到底是什么地位？为什么说它是地基不是简化版？怎么往上叠出完整图景？

一、组学阶梯：从"能干"到"真干了"的四级台阶

回忆中心法则(模型1)：DNA → RNA → 蛋白质 → 代谢/功能。每一步，都对应一种"组学"。它们构成一道阶梯，越往上越接近"到底发生了什么"：

台阶	组学(meta-)	测什么分子	回答	离"真相"多远
地基	宏基因组 Metagenomics	DNA	群落能干什么(潜力)	最基础
2 楼	宏转录组 Metatranscriptomics	RNA	此刻在表达哪些基因(活性)	更近
3 楼	宏蛋白组 Metaproteomics	蛋白质	真的造出了哪些酶/蛋白	又近
顶楼	代谢组 Metabolomics	代谢物	最终产出/消耗了哪些物质(结果)	最接近真相

用一个人来类比这四级：

- 宏基因组(DNA)

= 简历上的“技能证书”

→ 他会做饭、会开车、会编程（潜力）
- 宏转录组(RNA)

= 他今天的“待办清单”

→ 今天打算做饭（正打算干）
- 宏蛋白组(蛋白)

= 他手里“正用的工具”

→ 真的拿起了锅铲（真在干）
- 代谢组(代谢物)

= 桌上“做好的菜”

→ 一盘红烧肉（干出的结果）

这就是为什么宏基因组"基础但不简单"：它是最底层的"技能清单"，是理解其余一切的前提——但只看简历，你永远不知道他今天到底做没做饭。这正是框架3"潜力≠活性"的根源。

二、为什么"地基"既是优点也是局限

优点（为什么总从宏基因组做起）：- DNA 最稳定、最好测、信息最全（连不活跃的、罕见的都能记录）；- 能重建基因组(MAG)、建立"谁有什么家底"的完整名册；- 是其它组学的参照地图——比如宏转录组测到的 RNA，要先比对到宏基因组的基因目录才知道"这是谁的、什么基因"。

局限（为什么不能只停在这）：- 只到"潜力"，到不了"活性/结果"(框架3)；- 不知道随时间、随刺激的动态变化(DNA 相对稳定，RNA 才灵敏)。

所以："先用宏基因组打地基（谁在、有什么家底），再用上层组学看动态（谁在干、干出了什么）。"

三、多组学整合：把几层楼"对齐"着看

多组学整合 (multi-omics integration) = 对同一批样本同时测多个层级，再把它们联合分析，得到单一组学给不了的因果链条。

一个真实范例（土壤）：有研究整合了基因组解析的宏基因组 + 宏转录组 + 代谢组，去追踪雪融时土壤微生物"暴发"所利用的氮来源——

宏基因组：哪些菌、带哪些氮代谢基因(潜力)

+

宏转录组：雪融时这些氮基因是否被大量表达(活性)

+

代谢组：氮代谢物的实际变化(结果)

→ 拼出完整证据链：是“谁”、用“什么基因”、把“什么氮”变成了“什么”

这条链，任何单一组学都给不出——这就是整合的威力。

四、整合到底难在哪（小白要有心理准备）

多组学不是“多测几样拼一起”那么简单，难点很现实：

难点	说明
尺度/单位不同	基因丰度、RNA 表达量、代谢物浓度，量纲完全不同，不能直接相加
数据稀疏/缺失	不同组学测到的成员不一样，对不齐
时间错位	DNA 稳定、RNA 几分钟就变——采样时机稍差就对不上
统计陷阱	维度爆炸 + 组成型(模型14)，假相关风险更高
因果仍需实验	整合给出更强的相关链，但坐实因果还得操控实验(框架7)

常用整合方法：相关网络、典型对应分析、降维(如多组学因子分析 MOFA)、机器学习等——但先把每个单组学做扎实，再谈整合，否则是“垃圾 × 垃圾”。

五、给小白的路线建议

- 第1步：把宏基因组(地基)学扎实 ← 你正在做的事(本库 00-09)
- 第2步：理解上层组学“能补什么” ← 本篇
- 第3步：需要“活性/动态”时，加宏转录组
- 第4步：需要“真实产物/通量”时，加蛋白组/代谢组 + 同位素(qSIP, 见10.3)
- 第5步：多组学整合，但永远记得“整合≠因果，实验才坐实”

本篇要义：宏基因组是组学大厦的地基——基础、稳固、不可或缺，但也“只是地基”。看清生命活动的全貌，要顺着 DNA→RNA→蛋白→代谢物这道阶梯往上叠。这不是因为它“简单”，而是因为它“基础”。

延伸阅读

- 土壤 meta-omics：现状、挑战与应用 · <https://www.sciencedirect.com/science/article/abs/pii/S2405985425000904>
- 多组学揭示雪融期土壤微生物暴发的氮动态 · Nature Microbiology 2025 · <https://www.nature.com/articles/s41564-025-02213-2>
- 用 meta-omics 解析生物地球化学(观点) · EGU sphere 2025 · <https://egusphere.copernicus.org/preprints/2025/egusphere-2025-1716/egusphere-2025-1716.pdf>

下一篇：02-他山之石.md ——向别的领域借智慧

11.2 · 他山之石：向别的领域借智慧

"他山之石，可以攻玉"——别人山上的石头，能用来打磨自己的玉。土壤宏基因组的很多突破，不是自己凭空想出来的，而是从其它生态系统、其它学科借来的。这一篇告诉你：去哪借、借什么、怎么用。

分两类：向其它生态系统借经验 + 向其它学科借方法。

第一类 · 向其它生态系统借经验

海洋、人体肠道等微生物组研究，常常走在土壤前面（样本更易标准化、投入更大）。它们趟过的路、建好的方法，土壤可以直接借。

1. 海洋：Tara Oceans —— "大科学 + 大数据"的范本

- 它做了什么：全球航行采样，分析了数十万亿碱基的宏基因组，建成含4000 多万条非冗余基因的海洋微生物基因目录，并把分子数据和环境数据(温度、深度…)系统整合，开创"生态系统生物学"。
- 土壤能借什么：
- 标准化采样 + 配套环境元数据的范式(呼应框架2：好设计>好分析)；
- 建"参考基因目录"的思路——先建大目录，后续研究都来比对；
- 把群落数据和环境梯度联合建模的分析框架(呼应模型18 生物地理)。

2. 人体肠道：方法学的"练兵场"

人体微生物组(尤其肠道)投入巨大，很多分析方法在这里成熟后流向土壤：

肠道先行的方法	土壤如何借用
菌株级分辨(strain-level，区分同种不同株)	用于追踪土壤里特定功能菌株、抗药株
微生物组关联分析(类 GWAS)	找"和土壤健康/产量相关"的微生物(见10.1 ML)
多组学整合 + 机器学习做预测	从"诊断疾病"迁移到"诊断土壤健康"
纵向时间序列(追踪动态)	用于土壤的季节/演替动态

借的时候要警惕水土不服：土壤多样性比肠道高几个数量级、异质性极强(原理6)，肠道里好用的方法搬来常需大改。借思路，别照抄参数。

3. 地球微生物组计划(EMP)：跨生境的"大一统"

- 思路：用统一的标准流程测全球各种生境(土壤、水、动植物…)的微生物，让结果可横向比较。
- 土壤能借什么：标准化(可比较、可汇总)的理念；以及"把土壤放进全球生境大图里"的宏观视角。

第二类 · 向其它学科借方法

宏基因组的数据分析工具，绝大多数是从别的学科"进口"的。认出它们的"娘家"，能帮你更快理解和找资源。

1. 生态学 / 宏观生态 —— 把研究大象老虎的理论搬给微生物

整个模块 D(模型15-18)其实都是"进口货"：

研究森林、海岛、鸟兽的经典生态理论

| 搬给微生物 →

|— 中性理论(Hubbell) —————→ Sloan 中性模型(模型15)

|— 生态位 vs 中性辩论 —————→ 确定性 vs 随机(模型16)

|— 物种-面积/距离衰减 —————→ 微生物生物地理(模型18)

|— 多样性-稳定性、功能冗余 —————→ 模型20

启示：想找新思路，去翻经典生态学教材——很多还没被搬到微生物上的理论，就是你的机会。

2. 网络科学 —— 研究社交网络/互联网的工具

- 借来做什么：共现网络、关键种、模块化(模型17)——节点、连边、中心性、社团发现，这些概念直接来自社交网络/复杂网络研究。
- 还能再借：网络鲁棒性(删掉关键种群落会不会崩)、多层网络(把细菌-真菌-病毒网络叠起来)等更前沿的网络方法，土壤才刚开始用。

3. 系统生物学 / 代谢工程 —— 把"细胞代谢网络"搬到群落

- 借来做什么：群落代谢模型 GEM(见10.3)——通量平衡分析、代谢网络重建，本是研究单一菌株/细胞工厂的工具，被搬来模拟整个群落的"代谢经济"。

4. 人工智能 / 数据科学 —— 最猛的一股外援

- 借来做什么：基础模型读懂序列、机器学习做预测(整个10.1篇)；深度学习改进分箱(SemiBin2)；以及处理"高维 + 组成型"数据的各种统计学习方法。
- 特别提醒：AI 是最强也最容易被误用的他山之石——能预测≠懂机制，相关≠因果(框架5、7)。借它的力，守住科学的严谨。

5. 还有更多"娘家"

方法	来自
稳定同位素探针 qSIP(10.3)	同位素化学 / 地球化学
Hi-C 邻近连接(10.2)	染色体构象研究(分子生物学/物理)
组成型数据分析 CLR(模型14)	地质学家 Aitchison 的成分数据理论
序列比对算法	计算机科学(字符串算法)

三、怎么用好"他山之石"（方法论）

遇到一个解决不了的问题

|
问自己：“别的领域有没有人遇到过类似的结构性难题？”

- |
├— 别的生态系统(海洋/肠道)是不是已经有成熟流程？ → 借经验
├— 这本质上是个什么数学/计算问题？ → 去对应学科找工具
├— 借来后，针对土壤的特殊性(高多样性/异质/暗物质)做适配
|

★ 关键：借“思路 and 工具”，按土壤实际“重新调参/验证”，不照搬结论

本篇要义：土壤宏基因组是个十字路口学科——它的力量来自不断从海洋、肠道、生态学、网络科学、系统生物学、AI 借来"石头"。学会识别每个工具的"娘家"，你就拥有了一张通向无穷资源的地图，也更容易想出别人没想到的组合。

本篇是"他山之石"的入门版。想继续深入：- 专门从"其它组学领域"借方法 (GWAS→MWAS、单细胞、空间组学) → 04-从组学领域借方法.md - 更多生态系统 + 更多学科 (极端环境/植物/古DNA + 博弈论/流行病学/因果推断/地统计) → 05-他山之石进阶.md

延伸阅读

- 全球海洋微生物组的结构与功能 · Science(Tara Oceans) · <https://www.science.org/doi/10.1126/science.1261359>
- Tara Oceans : 迈向全球海洋生态系统生物学 · Nature Reviews Microbiology · <https://www.nature.com/articles/s41579-020-0364-5>
- 基于肠道微生物组的多组学整合分析进展 · Frontiers 2024 · <https://www.frontiersin.org/journals/microbiology/articles/10.3389/fmicb.2024.1509117/full>
- 微生物组精准(医学)：多组学 + 机器学习 · <https://www.sciencedirect.com/science/article/abs/pii/S094450132500343X>

[回到 模块11总览](#) | [知识库总览](#)

11.3 · 各类组学详解：宏基因组的"楼上邻居"们

上一篇(01)给了组学阶梯的全景。这一篇把宏基因组楼上的每一层逐一拆开讲清楚：它测什么、和宏基因组怎么配合、难在哪。还会介绍一批"功能子组学"（各种 -ome），它们是宏基因组的"专科切片"。

读法：把宏基因组(DNA/潜力)当成"地基"，下面是一层层往上走。

一、阶梯上层：从"潜力"逐级逼近"真相"

1. 宏转录组（Metatranscriptomics）—— 测 RNA，看"在表达什么"

- 测什么：群落里所有的 RNA（主要是 mRNA）。基因要"干活"，先得转录成 RNA——所以 RNA 多 = 这个基因正在被启用。
- 回答：从"能干什么(潜力)" → "此刻在干什么(活性)"。这是跨越框架3"潜力≠活性"最常用的一步。
- 怎么配合宏基因组：先用宏基因组建好"基因目录(谁有什么基因)"，再把测到的 RNA 比上去，才知道"是谁的、哪个基因在表达"。两者是地图 + 实时路况的关系。
- 难点：
 - RNA 极不稳定，几分钟就降解 → 采样、保存要求极高；
 - 绝大多数 RNA 是 rRNA(核糖体RNA)，会淹没有用的 mRNA → 需要"去 rRNA"；
 - 只是某一瞬间的快照 → 采样时机稍偏就失真。

2. 宏蛋白组（Metaproteomics）—— 测蛋白，看"真造出了什么"

- 测什么：群落里实际存在的蛋白质（用质谱仪）。蛋白是真正干活的"工人/酶"。
- 回答：比 RNA 更进一步——RNA 只是"打算造"，蛋白是"真造出来了"。
- 怎么配合宏基因组：质谱鉴定蛋白，需要一个"候选蛋白清单"去比对——这个清单通常就来自配套的宏基因组。没有宏基因组，宏蛋白组寸步难行。

- 难点：技术最难、灵敏度有限（低丰度蛋白测不到）、深度远不如测序、严重依赖数据库质量。

3. 代谢组 (Metabolomics) —— 测代谢物，看"产出了什么"

- 测什么：群落产生/消耗的小分子代谢物（氨基酸、有机酸、糖、次级代谢物等），用质谱或核磁。
- 回答：阶梯的顶端——最接近"到底发生了什么、留下了什么产物"。
- 怎么配合宏基因组："基因(能做) → 酶(在做) → 代谢物(做出的结果)"。代谢组给出"结果端"的实锤，和宏基因组的"潜力端"对接，能拼出完整因果链(见 01 篇的雪融氮案例)。
- 难点：
 - 不分物种——测到一个代谢物，常不知道是哪个菌产的（需结合其它组学推断）；
 - 大量代谢物身份未知（代谢暗物质）；
 - 受环境本底干扰大。

4. 宏表观组 (Metaepigenomics) —— 测 DNA 甲基化，一个新维度

- 测什么：DNA 上的甲基化修饰（细菌主要有 4mC、5mC、6mA 三类）。同一条 DNA 序列，可以带不同"化学标记"。
- 怎么测：纳米孔(Nanopore)长读长测序能在测序列的同时直接读出甲基化，不需额外处理。
- 意想不到的妙用（这点很前沿）：每个基因组有自己特异的甲基化"花纹" (motif)，像指纹/水印。于是甲基化能：
 - 改进分箱：用甲基化花纹把 contig 归到同一基因组(补模型7)；
 - 给质粒/移动元件定主：和宿主带同款花纹 = 同一个细胞；
 - 发现错误组装：花纹突然变了，提示 contig 是嵌合的。
- 代表工具：Nanomotif、MicrobeMod、Nanodisco。

看出规律没有：每往上一层，离"真相"更近一步，但技术更难、深度更浅、越依赖宏基因组当地图。这就是为什么宏基因组是不可替代的地基。

二、功能"子组学"：宏基因组的专科切片

除了纵向阶梯，还有一批以"-ome"命名的功能子集——它们不是新的分子层，而是从宏基因组里专门拎出某一类基因/元件深入研究。

子组学	聚焦什么	关键意义	关联
抗性组 Resistome	所有抗生素抗性基因 (ARGs)	公共卫生、One Health	案例7、CARD
移动组 Mobilome / 质粒组	质粒、转座子、整合子等可移动元件	基因(含抗药基因)传播的载体	10.2、Hi-C定主
病毒组 Virome	病毒/噬菌体	控制群落、搬运基因	见 10.2
碳水化合物活性酶组 (CAZyme)	降解/合成多糖的酶	碳循环、有机质分解	模型19、CAZy 库
次级代谢组 / BGC组	生物合成基因簇	新抗生素/天然产物挖掘	案例9、antiSMASH

这些"子组学"的好处：聚焦——不必处理全部海量数据，只盯你关心的那类功能，分析更深、更专。

三、一张图：宏基因组和它的"邻居们"

↑ 越往上越接近“真相”，但越难测、越浅、越依赖下层当地图

代谢组(代谢物·产出结果)	—— 质谱/核磁
宏蛋白组(蛋白·真造出)	—— 质谱(需宏基因组当蛋白清单)
宏转录组(RNA·在表达)	—— 测序(需宏基因组当基因目录)
宏表观组(甲基化·调控+水印)	—— 纳米孔(顺带改进分箱/定主)

宏基因组(DNA·潜力) = 地基 + 所有上层的“地图”

从这块地基里还能切出“专科子组学”：

↳ 抗性组 · 移动组 · 病毒组 · CAZyme组 · BGC组

本篇要义：宏基因组的“楼上”有转录组、蛋白组、代谢组、表观组，逐层逼近真相；“内部”还能切出抗性组、移动组等专科视角。理解每一层测什么、补什么、难在哪，你就能按问题选择该往上爬到哪一层。

延伸阅读

- 土壤 meta-omics 现状、挑战与应用 · <https://www.sciencedirect.com/science/article/abs/pii/S2405985425000904>
- 纳米孔测序发现微生物组多种 DNA 甲基化 · Nature Methods · <https://www.nature.com/articles/s41592-021-01109-3>
- Nanomotif：用甲基化花纹做基因组回收与质粒定主 · bioRxiv 2024 · <https://www.biorxiv.org/content/10.1101/2024.04.29.591623v2.full>
- 用甲基化模式解析异常大小/复杂结构的细菌基因组 · ISME J · <https://www.nature.com/articles/s41396-022-01242-7>

下一篇：04-从组学领域借方法.md ——把成熟组学的利器搬过来

11.4 · 从组学领域借方法：最该借的"他山之石"

这是你要的"能在组学借鉴的"。最该借的"他山"，恰恰是其它更成熟的组学领域——人类基因组学、单细胞组学、空间组学。它们烧了更多钱、趟了更多坑，方法成熟，很多能直接搬到土壤宏基因组来用。

本篇讲四大借法：① 从人类遗传学借 MWAS ② 从单细胞组学借单细胞分辨 ③ 从空间组学借原位定位 ④ 从单细胞分析借数据方法。

一、从人类基因组学借：GWAS → MWAS

人家的成熟方法：GWAS（全基因组关联分析）——扫描人类基因组，找"哪些基因变异和某疾病相关"。这套方法在医学里极其成熟。

怎么搬到宏基因组：MWAS（宏基因组关联分析）几乎是照着 GWAS 搭的：

GWAS： 人的基因变异 ——关联——> 疾病/性状

MWAS： 微生物的基因/物种丰度 ——关联——> 疾病 / 土壤健康 / 作物产量

- 做法：把微生物特征（物种、基因丰度）和你关心的结果（如土壤肥力、产量）做关联，找出"显著相关"的微生物/基因。为降维，常先把基因聚成"宏基因组物种/连锁群"。
- 土壤应用：找"和高产/抗病/健康土相关"的关键微生物或功能基因（呼应 10.1 的机器学习）。
- 借来时要注意的新坑：微生物的基因数比人类基因组多上百倍 → 多重检验问题严重得多，假阳性风险更高，必须严格校正(框架5、6)；而且关联≠因果(框架7)，GWAS 的这条铁律在 MWAS 同样成立。

工具示例：OMARU 等 MWAS 流程。本质是"把医学统计遗传学的工具箱搬到微生物上"。

二、从单细胞组学借：单细胞分辨（看清"一个个体"）

人家的成熟方法：单细胞测序（scRNA-seq 等）——不再测"一团组织的平均"，而是一个细胞一个细胞地测，看清个体差异。

怎么搬到宏基因组：单细胞基因组学 / 单细胞宏基因组：

普通宏基因组：一锅 DNA 混着测 → 靠算法“分箱”猜哪段属于谁（可能拼错/嵌合，模型7的痛）
单细胞基因组：先把单个细胞分离出来 → 单独扩增、测序 → 一个细胞 = 一个基因组（SAG）
（“谁”是确定的，不靠猜）

- 怎么分离单细胞：微流控(把细胞包进一个个微液滴)、流式分选(FACS)、激光技术(LIFT)等——这些都是从单细胞生物学借来的。
- 进展：微流控 + 全基因组扩增让单细胞基因组的完整度从 50–70% 提升到 80–90%(近三年)。已用于北极永久冻土的上百个未培养类群、单个土壤团聚体内的氮代谢菌等。
- 和 MAG 互补：

	MAG(分箱)	SAG(单细胞)
谁的基因组	算法猜(有嵌合风险)	确定(就这一个细胞)
通量/覆盖	一次得很多、覆盖全群落	一次少、偏向被挑中的细胞
扩增偏差	小	大(单细胞扩增不均匀)

最佳实践常是两者结合：SAG 提供"确定的参照基因组"，帮助校正和验证 MAG。

三、从空间组学借：原位定位（看清"在哪里"）

人家的成熟方法：空间转录组学（spatial transcriptomics）——不打碎组织，保留位置信息，看"哪个基因在组织的哪个位置表达"。

怎么搬到宏基因组：空间宏基因组 / 空间宏转录组——回答一个普通宏基因组永远答不了的问题：

普通宏基因组把土打成糊，丢掉了空间信息。但"谁挨着谁、谁住在根的哪一侧、谁聚在团聚体表面还是内部"恰恰至关重要(土壤极端异质，原理6)。

普通宏基因组：土 → 打碎成糊 → 只知道“有谁”，不知道“谁在哪、谁挨着谁”
空间组学：保留原位结构 → 在显微尺度上画出“微生物分布地图”

- 进展：空间宏转录组已能在植物叶片(拟南芥)上同时刻画细菌、真菌的"热点"和它们的空间互作；分辨率从 55μm 推进到 ~1μm（单细胞级）。
- 土壤意义：把"群落"从一锅平均，还原成有结构的"微生物社区地图"——这对理解根际、团聚体、微生境是革命性的。
- 现状：在土壤这种不透明、复杂基质里做空间组学仍非常前沿、技术门槛高，但方向极有前景。

四、从单细胞分析借：数据分析方法

单细胞领域不仅贡献了实验技术，还贡献了一整套数据分析武器，现在已被微生物组广泛借用：

借来的方法	原本用途(单细胞)	在宏基因组里
降维可视化 UMAP / t-SNE	把上万个细胞画到二维	把大量样本/物种画到二维(补充 PCoA，模型12)
批次效应校正	去除不同实验批次的干扰	去除测序批次/试剂批次(框架6)
聚类算法	给细胞分群(细胞类型)	给物种/样本/基因分群
拟时序 / 轨迹分析	推断细胞分化路径	推断群落演替/动态轨迹

启示：单细胞领域是微生物组分析方法最大的"上游供货商"之一。看到一个新的单细胞分析方法，可以想想"能不能搬来分析微生物群落？"——常常能。

五、方法论：怎么判断一个组学方法"能不能借"

看到其它组学领域一个好用的方法

- 问 1：它解决的本质问题，宏基因组里有没有对应版本？
(如：单细胞解决“混合样本看不清个体” = 宏基因组分箱难)
- 问 2：土壤的特殊性会不会让它失效或需要大改？
(高多样性、强异质、暗物质多、不透明基质…)
- 问 3：借来后怎么验证它在土壤里真的有效？

★ 原则：借“方法的内核”，按土壤实际重做参数与验证，别照搬。

本篇要义：最该借的“他山之石”是更成熟的组学领域——MWAS 借自 GWAS、单细胞分辨借自 scRNA-seq、原位定位借自空间转录组、UMAP/批次校正/拟时序也都是“进口”的。它们烧过的钱、踩过的坑，就是你的捷径。

延伸阅读

- 宏基因组关联研究(MWAS)：精挖微生物组 · Nature Reviews Microbiology · <https://www.nature.com/articles/nrmicro.2016.83>
- OMARU：稳健的 MWAS 多功能流程 · NAR Genomics and Bioinformatics · <https://academic.oup.com/nargab/article/4/1/lqac019/6543594>
- 获取未培养微生物基因组的单细胞基因组学工具 · <https://pmc.ncbi.nlm.nih.gov/articles/PMC10937852/>
- 单个土壤团聚体的单细胞基因组学(氮代谢) · Frontiers 2025 · <https://www.frontiersin.org/journals/microbiology/articles/10.3389/fmicb.2025.1557188/full>
- 空间宏转录组解析宿主-细菌-真菌互作 · <https://pubmed.ncbi.nlm.nih.gov/37985875/>
- 微米尺度空间宏基因组 · bioRxiv 2025 · <https://www.biorxiv.org/content/10.1101/2025.09.30.679663.full.pdf>

下一篇：05-他山之石进阶.md ——更多生态系统与跨学科借鉴

11.5 · 他山之石进阶：更多生态系统与跨学科

02 篇起了个头(海洋/肠道 + 生态学/网络/系统生物学/AI)，04 篇讲了从兄弟组学借方法。这一篇把"他山"的版图进一步扩大：更多可借经验的生态系统，以及更多能贡献思想的学科。

目的不是让你记住每一个，而是建立一种条件反射：遇到难题，先问"别人(别的系统/别的学科)是不是已经有招了？"

第一部分 · 更多生态系统：别处的微生物组经验

1. 极端环境 —— 宏基因组学的"发源地"之一

- 典型：酸性矿山废水、深海热泉、盐湖、永久冻土。
- 为什么值得借：这些环境物种少、相对简单，是最早成功重建出近完整群落基因组的地方(复杂度低，组装分箱容易)。很多宏基因组方法先在这里跑通，再挑战复杂的土壤。
- 土壤能借：方法的"试验田"思路——先在简单系统验证流程，再上复杂系统(呼应教程 07 的"先小数据跑通")。

2. 植物微生物组 —— 天然的"模式系统"

- 典型：根际、叶际、内生菌。
- 为什么值得借：比整片土边界更清晰、更可控、可做接种实验，是连接"微生物 ↔ 宿主功能(产量/抗病)"的绝佳模型，也最容易做因果验证(合成群落 SynCom 接种到无菌植物)。
- 土壤能借：用植物-微生物系统验证在复杂土壤里只能"相关"的假设(爬框架7的因果阶梯)。

3. 建成环境 —— 标准化大规模采样的范本

- 典型：医院、地铁(如全球地铁微生物组计划)、城市表面。

- 为什么值得借：示范了大规模、标准化、众包式采样如何做(成百上千样点统一流程)。
- 土壤能借：大规模协作采样与元数据标准化(呼应框架2、6 和 Tara 的经验)。

4. 古 DNA / 古微生物 —— 时间维度

- 典型：永久冻土、沉积岩芯、古牙结石里的远古微生物 DNA。
- 为什么值得借：贡献了处理高度降解、低浓度、易污染 DNA 的专门方法。
- 土壤能借：深层土、老样本的降解 DNA 处理；以及"时间尺度"的视角(土壤微生物组如何随地质/历史变化)。

第二部分 · 更多学科：意想不到的"娘家"

1. 博弈论 / 经济学 —— 解释"合作与背叛"

- 借什么：微生物之间有合作(交叉喂养)也有"搭便车/欺骗"。博弈论的公共物品、囚徒困境、分工等概念，被用来解释为什么群落里会演化出合作、又为何稳定。代表思想如"黑皇后假说"(丢掉自己能做的功能，依赖别人提供——精打细算的"外包")。
- 连接：给共现/代谢互作(模型17、10.3)提供理论解释。

2. 流行病学 —— 溯源与传播

- 借什么：来源追踪(如 SourceTracker：判断一份土的微生物有多少来自空气/水/粪肥)、菌株传播路径追踪——这些本是追踪传染病来源的方法。
- 连接：追踪抗药基因/病原从粪肥到土壤到作物的传播(案例7、One Health)。

3. 信息论 —— 多样性的数学根基

- 借什么：你天天用的 Shannon 多样性指数，本来就是信息论里的"熵"(模型11)！信息论还提供互信息等工具来度量物种间的关联。
- 连接：多样性、网络分析的底层数学其实都来自信息论。

4. 因果推断 —— 从"相关"突围到"因果"

- 借什么：经济学、流行病学发展出的因果推断框架(中介分析、工具变量、因果发现算法等)，正被引入微生物组，试图在观测数据里更严谨地逼近因果。
- 连接：直接服务框架7"相关→因果"——这是当前微生物组统计的前沿方向。


5. 地统计学 / 遥感 GIS —— 把微生物"画上地图"

- 借什么：地理学的空间插值(克里金 kriging)、遥感卫星数据——用来绘制大尺度的土壤微生物/功能分布图，并和气候、植被等空间图层叠加分析。
- 连接：生物地理(模型18)、全球图谱(案例1)的空间分析引擎。

6. 药物化学 / 天然产物 —— 土壤是"新药矿"

- 借什么：天然产物化学的思路——土壤微生物(尤其放线菌)是人类大多数抗生素的来源。结合 BGC 挖掘(案例9、antiSMASH)，宏基因组成了不依赖培养的新药发现新引擎。
- 连接：BGC 子组学(11.3)、案例9。

三、一张"借用地图" (总览)



四、把"借"变成你的核心能力

第一层(新手): 会用本领域的标准工具 ← 本库 00-09

第二层(进阶): 知道工具的"娘家", 能追根溯源 ← 本模块

第三层(高手): 主动去别的领域找"石头"解决新问题, 并做出别人没想到的组合

本篇要义: 土壤宏基因组是一门十字路口学科——它最强的能力不是某个工具, 而是不断从别处借石攻玉。生态系统借经验、组学借方法、学科借理论。养成"这问题别人解过吗"的条件反射, 你就拥有了一张通向无穷资源的地图。

延伸阅读

- 全球海洋微生物组结构与功能(Tara Oceans) · Science · <https://www.science.org/doi/10.1126/science.1261359>
- 微生物互作中的"黑皇后假说"与合作演化 (综述检索关键词: Black Queen Hypothesis microbial cooperation)
- 微生物组来源追踪 SourceTracker (检索: SourceTracker microbial source tracking)
- 用机器学习与组学解析土壤 C/N/P 循环的环境调控 · JGR Biogeosciences 2025 · <https://agupubs.onlinelibrary.wiley.com/doi/full/10.1029/2024JG008470>

回到 模块11总览 | 知识库总览

12 · 自测与练习 · 总览

前面 00–11 是"教"，这个模块是"考"。学习科学有个铁律：被动读十遍，不如主动答一遍。自己先试着回答、再对答案，比反复看书有效得多（这叫"主动回忆 active recall"）。

这里的题不为难你，每道都对应库里讲过的内容，答错了顺着链接回去复习就行。答案和解析都附在每套题末尾——请先自己答，再看答案。

四套练习

套	主题	覆盖	题型
01-基础概念自测.md	入门概念	00 启蒙、01 原理、模型 1–4、思维框架	选择 + 判断 + 简答
02-分析与统计自测.md	生信与统计	模型 5–14、实操、CLR/多样性	选择 + 计算 + 简答
03-生态与功能自测.md	生态与功能	模型 15–20、思维框架、前沿	选择 + 简答
04-纠错与案例分析.md	综合实战	全库综合	找错题 + 案例分析

第 04 套最有价值：模拟真实场景里"一段听起来挺像那么回事、其实有坑的说法"，让你来挑错。这直接训练你读论文、做研究时的判断力。

怎么用

1. 先学后测：建议每学完一个模块，做对应那套题。全学完后做第 04 套综合题。

- 2. 闭卷优先：先盖住答案自己答，哪怕不确定也写下来——"努力回忆"这个动作本身就在强化记忆。
- 3. 答错=宝藏：答错的题标记下来，回到对应章节重读，过几天再做一遍。
- 4. 不求满分：能答对 70% 就算掌握得不错了；剩下的就是你下一步该补的地方。

掌握度自评（做完四套后）

正确率	说明	建议
< 50%	还在熟悉期	重读 00–03，别急着上手跑数据
50–70%	入门了	可以跟着 07 实操跑通流程
70–90%	比较扎实	能读懂论文、独立分析，啃 08/10/11
> 90%	很可以	去读真文献、找真问题，本库当工具书查

从第一套开始：01-基础概念自测.md

自测 01 · 基础概念

覆盖：00 零基础启蒙、01 第一性原理、模型 1-4、思维框架。先盖住下方答案自己答，写完再核对。

一、选择题（单选）

1. 土壤宏基因组学要研究土壤微生物，为什么主要靠"直接测 DNA"而不是"培养出来观察"？ A. 培养太贵 B. 土壤微生物超过 99% 在实验室培养不出来 C. DNA 比细胞好保存 D. 培养会污染样本
 2. 下列哪项是"鸟枪法宏基因组"相比"扩增子(16S)"的核心优势？ A. 更便宜 B. 实验更简单 C. 能同时知道"有谁"和"能干什么" D. 不需要测序仪
 3. 测序得到的是 reads（短片段），最根本的原因是？ A. 测序仪没法一口气读完一条很长的 DNA B. DNA 本身就是碎的 C. 土壤 DNA 质量差 D. 为了省钱
 4. "稀释曲线（rarefaction curve）"没有到达平台期，说明？ A. 测序质量差 B. 测序深度可能不够，还有物种没被发现 C. 样本被污染 D. 物种太少
 5. Phred 质量值 Q30 代表这个碱基的出错概率约为？ A. 1/30 B. 1/100 C. 1/1000 D. 1/300
-

二、判断题（对/错，并说明为什么）

6. 一个微生物的基因组里有固氮基因 `nifH`，就说明它此刻正在固氮。
 7. 宏基因组测出"A 菌占 4%、B 菌占 2%"，可以推断 A 菌的绝对数量是 B 菌的两倍。
 8. "没有在样本里测到某个物种"等于"这片土里没有这个物种"。
 9. 跳过质控（QC）直接做下游分析，只要数据量够大就没问题。
-

三、简答题

10. 用你自己的话，一句话解释"宏基因组学"是干什么的。
11. 思维框架 3 说"潜力 $\neq$ 活性 $\neq$ 通量"。请各举一个例子说明这三者的区别。
12. 同事说："我们采了一个样、测得很深，发现施肥地块比对照地块多样性更高，所以施肥提高了多样性。" 用思维框架，指出这句话至少两个问题。

✓

答案与解析

1. B。这是整个学科的出发点（原理0）：养不活 $\rightarrow$ 只能直接读 DNA。其它选项都不是根本原因。
2. C。扩增子像"查身份证"（只知有谁），鸟枪法像"读简历全文"（有谁+能干啥）。鸟枪法更贵、更复杂，所以 A、B 错（模型 2）。
3. A。测序仪只能把 DNA 打断成短片段分别读（模型 6、原理 3）。DNA 本身不是碎的。
4. B。曲线没平 = 还在不断发现新物种 = 测得不够深（模型 3）。土壤常常测不饱和。
5. C。 $Q = -10 \cdot \log_{10}(P)$ ， $Q30 \rightarrow P=10^{-3}=1/1000$ ，准确率 99.9%（模型 4）。 $Q20=1/100$ 。
6. 错。基因存在只代表"能做"（潜力），不代表"正在做"（活性）。要知道在不在固氮，得测 RNA（宏转录组）或固氮速率（思维框架 3、模型 1）。这是全库最重要的一条。
7. 错。测序给的是相对比例不是绝对数量，而且是组成型数据（一个涨会逼别的在数字上跌）。不能由比例直接推断绝对数量之比（原理 4、模型 14）。
8. 错。"没测到"可能只是测序深度不够、没抽到稀有物种。"没看到" $\neq$ "不存在"（原理 5、模型 3）。
9. 错。垃圾进垃圾出。不质控，接头/低质量/宿主污染会让后续组装、比对、定量全部出错，数据量再大也救不回（模型 4、思维框架 2）。
10. 参考答案：直接读取一勺土里所有微生物混在一起的 DNA，搞清楚"土里有谁、它们能干什么、为什么是它们"。（能讲出"免培养+直接测DNA+回答三个问题"即可）

11. 参考：- 潜力：群落里有 `nifH` 基因（能固氮）。- 活性：`nifH` 正在被表达成 RNA/蛋白（正在固氮）。- 通量：每天每平方米实际固定了多少克氮（固了多少，需速率/同位素测定）。（对应技术：宏基因组 → 宏转录组/蛋白组 → 代谢组/同位素，思维框架 3）

12. 至少两个问题：- 没有重复："采了一个样" → $n=1$ ，无法做统计、无法判断差异是真是巧（思维框架 6：" $n=1$ 不是数据点，是轶事"）。- 深度未校正/未抽平：多样性对测序深度敏感，两组深度不同就直接比是假象，需先抽平（模型 3、模型 11）。- （加分）相关 ≠ 因果：即使差异真实，也只是"相关"，不能直接说"施肥提高了多样性"，需更多证据（思维框架 7）。

下一套：`02-分析与统计自测.md`

自测 02 · 分析与统计

覆盖：模型 5-14、07 实操教程、08 难点图解（CLR / 多样性 / 组装分箱）。含少量"动手算"的小题，别怕，都是一步算。先自己答再看答案。

一、选择题（单选）

1. 组装（assembly）这一步在做什么？ A. 把 DNA 提取出来 B. 把短 reads 按重叠关系拼成更长的 contig C. 给序列分类 D. 去掉低质量碱基
 2. 分箱（binning）依靠哪两条主要线索把 contig 归到同一基因组？ A. 序列长度 + GC 含量 B. 序列"文风"(四核苷酸频率) + 在多样本里的丰度共变 C. 测序深度 + 质量值 D. 物种名 + 功能注释
 3. 关于 MIMAG 的"高质量 MAG"，下列正确的是？ A. 完整度 >50%，污染度 <10% B. 完整度 >90%，污染度 <5% C. 完整度 >70%，污染度 <20% D. 只看完整度，不看污染度
 4. 比较两组样本的 α 多样性之前，必须先做什么？ A. 建系统发育树 B. 抽平到相同测序深度（或等效校正） C. 做共现网络 D. 组装
 5. 看 PCoA 图发现两组点"好像分开了"，下一步应该？ A. 直接下结论说两组有显著差异 B. 做 PERMANOVA（adonis2）检验显著性 C. 重新测序 D. 换一个配色
 6. 为什么不能直接用原始相对丰度（比例）做 Pearson 相关来建共现网络？ A. 计算太慢 B. 比例是组成型数据，会产生大量假阳性关联 C. 比例没有单位 D. Pearson 只能用于两个变量
 7. Kraken2 做物种分类时，一个 k-mer 若在多个物种里都出现，会归到？ A. 第一个匹配的物种 B. 随机一个物种 C. 它们的最近共同祖先（LCA） D. 丢弃
-

二、计算题（每题一步即可）

8. 某样本三个类群的相对丰度为 $A=64$ 、 $B=8$ 、 $C=2$ （同一单位）。(a) 求三者的几何平均。(b) 求 A 的 CLR 值 ($CLR = \ln(\text{值} / \text{几何平均})$)。

9. CheckM2 报告某 MAG：完整度 = 85%，污染度 = 9%。(a) 按"完整度 - $5 \times$ 污染度 > 50 "的门槛，它达标吗？(b) 它属于 MIMAG 的高质量还是中等质量？

三、简答题

10. 一句话说明 E-value 越小代表什么（模型 5）。

11. 为什么"多个样本一起分箱"比"单样本分箱"效果好得多？（提示：模型 7 的两条线索）

12. Hill 数里 $q=0$ 、 $q=1$ 、 $q=2$ 分别更看重什么？为什么建议三个一起看？

✓

答案与解析

1. B。组装 = 把碎片(reads)按重叠拼成长片段 contig（模型 6、图解 08.2）。

2. B。文风（四核苷酸频率）+ 丰度共变（多样本同涨同落）是分箱的两条核心线索（模型 7、图解 08.2）。

3. B。高质量：完整度 $> 90\%$ 且污染度 $< 5\%$ （还需 rRNA+tRNA）。选项 A 是"中等质量"的标准（模型 8）。

4. B。不抽平就比 α 多样性，深的样本天然"看起来"更高，是假象（模型 3、11；图解 08.4）。

5. B。图上"看起来分开"会骗人，必须 PERMANOVA 检验，并配 betadisper 排除离散度差异（模型 12、图解 08.4）。

6. B。组成型数据直接算相关会因"总和固定"产生大量假阳性，要用 SparCC/SPIEC-EASI（模型 14、17；图解 08.1）。

7. C。 Kraken2 把多物种共有的 k-mer 归到最近共同祖先 LCA (模型 9)。

8. (a) 几何平均 = $(64 \times 8 \times 2)^{(1/3)} = (1024)^{(1/3)}$ 。因为 $1024 = 2^{10}$ ，所以 $= 2^{(10/3)} \approx 2^{3.33} \approx 10.1$ 。(b) $CLR(A) = \ln(64 / 10.1) = \ln(6.34) \approx +1.85$ (A 远高于样本内平均水平，所以为较大正值)。(思路对、量级对即可，见图解 08.1)

9. (a) $85 - 5 \times 9 = 85 - 45 = 40$ ，不 > 50 ，不达标这个综合门槛。(b) 完整度 $> 50\%$ 且 污染度 $< 10\% \rightarrow$ 属于 中等质量 (高质量要污染度 $< 5\%$)。注意：污染度 9% 偏高，解读其代谢通路要谨慎 (模型 8)。

10. E-value 越小，这个比对匹配"纯属偶然"的可能性越低，结果越可信 (模型 5)。

11. 单样本只有"文风"一条线索；多样本才能看出"哪些 contig 在各样本里同涨同落" (丰度共变)，这条线索很强，能大幅提升分箱准确度 (模型 7、图解 08.2、实操 07.3 算覆盖度那步)。

12. - $q=0$ (丰富度)：只数种类，最看重稀有种；- $q=1$ (Shannon)：按比例加权，不偏不倚；- $q=2$ (Simpson 方向)：主要反映优势种，几乎忽视稀有种。三个一起看，才能区分"差异到底出在稀有种还是优势种"，只报一个会把它们混淆 (模型 11、图解 08.4)。

下一套： 03-生态与功能自测.md

自测 03 · 生态与功能

覆盖：模型 15–20、思维框架 4/7、10 前沿、11 多组学与他山之石。先自己答再看答案。

一、选择题（单选）

1. Vellend 的群落构建四过程是？ A. 出生、死亡、迁入、迁出 B. 选择、扩散、漂变、物种形成 C. 竞争、捕食、共生、寄生 D. 采样、测序、组装、注释
 2. $\beta NTI > +2$ 通常解释为？ A. 随机漂变主导 B. 变量选择（异质环境筛选）——确定性过程 C. 扩散限制 D. 数据出错
 3. 共现网络里的"关键种(keystone taxa)"通常指？ A. 丰度最高的物种 B. 连接度/中心性很高、对群落结构影响很大的物种 C. 最稀有的物种 D. 第一个被发现的物种
 4. "功能冗余(functional redundancy)"是指？ A. 一个物种有很多重复基因 B. 多个不同物种能执行同一种功能 C. 测序测了很多遍 D. 功能注释重复了
 5. 关于宏基因组与其它组学的关系，正确的是？ A. 宏基因组是最简单、最低级的组学 B. 宏基因组测 DNA，是组学阶梯的"地基/潜力层"，基础但不简单 C. 有了宏基因组就不需要别的组学 D. 代谢组比宏基因组更基础
 6. 下列哪项最能直接回答"谁真的在生长/活跃"（而非"谁存在"）？ A. 普通宏基因组 B. qSIP（定量稳定同位素探针）+ 宏基因组 C. 16S 扩增子 D. 组装
 7. MWAS（宏基因组关联分析）主要借鉴了哪个领域的方法？ A. 天文学 B. 人类遗传学的 GWAS C. 经济学 D. 材料学
-

二、判断题（对/错，并说明）

8. 共现网络里 A、B 两菌总是一起出现，就能证明它们之间存在相互作用。

9. 中性模型 (Sloan) 拟合得好，就说明环境因素对群落不重要。
10. 病毒 (噬菌体) 在土壤里数量少、作用小，研究宏基因组时可以忽略。

三、简答题

11. 用"证据阶梯" (思维框架 7) 排序：①共现网络相关 ②qSIP 证明活跃 ③接种合成群落做实验 ④观测到某菌随施肥增多。从弱到强排列，并说明哪一步才能谈"因果"。
12. 举两个"他山之石"的例子：分别说明土壤宏基因组从"别的生态系统"和"别的学科"各借了什么。
13. 你想验证"某土壤菌 X 能促进水稻抗病"。只靠宏基因组够吗？要爬到证据阶梯哪一步、可能需要哪些额外手段？

✓

答案与解析

1. B。选择(selection)、扩散(dispersal)、漂变(drift)、物种形成(speciation)——口诀"筛选、迁移、运气、新生" (思维框架 4)。
2. B。 $\beta NTI > +2$ = 比随机更"亲缘疏远" = 异质环境筛选 = 变量选择 (确定性)； < -2 是同质选择 (模型 16、图解 08.3)。
3. B。关键种 = 高连接度/高中心性的枢纽节点，不一定丰度最高 (模型 17)。
4. B。功能冗余 = 不同物种做同一件事，是群落韧性的来源 (模型 20)。
5. B。宏基因组是组学阶梯的地基 (DNA=潜力)，基础但计算上极难，不是"简化版"；它还是其它组学的"参照地图" (模块 11、文件 11.1)。
6. B。qSIP 让活跃菌的 DNA"变重"，密度分离后测序，直接锁定真正在生长的菌——跨越"潜力→活性" (前沿 10.3、思维框架 3)。
7. B。MWAS 几乎照搬 GWAS 的框架，把"基因变异↔疾病"换成"微生物特征↔表型" (文件 11.4)。

8. 错。一起出现可能只是"都喜欢同样的环境", 并非真有来往。共现 $\neq$ 互作 $\neq$ 因果 (模型 17、思维框架 7)。要证明互作需代谢建模/实验。

9. 错。中性拟合好只说明"随机能解释不少", 是基线; 环境是否重要要结合 β NTI 等一起判断, 不能据此说环境不重要 (模型 15、16)。

10. 错。土壤病毒数量常比细菌还多, 是控制群落、搬运基因 (含抗药基因)、改写宿主代谢的"隐形操盘手", 不应忽略 (前沿 10.2)。

11. 从弱到强: ④观测相关 $\rightarrow$ ①共现网络 $\rightarrow$ ②qSIP 证明活跃 $\rightarrow$ ③接种实验。只有走到 ③操控实验 (接种/合成群落) 才能谈因果; 前面都只是相关或活性证据 (思维框架 7、前沿 10.3)。

12. 参考: - 借生态系统: 从海洋 Tara Oceans 借"标准化大规模采样 + 建参考基因目录"; 从人体肠道借"菌株级分辨、MWAS、多组学预测"等 (文件 11.2/11.4)。- 借学科: 从生态学借中性理论/生态位理论 (模型 15–18); 从网络科学借共现网络/关键种 (模型 17); 从 AI 借基础模型照亮暗物质 (前沿 10.1)。(任举各一个、对应正确即可)

13. 只靠宏基因组不够——它最多告诉你"菌 X 与抗病相关, 且带有相关功能基因 (潜力)"。要谈"促进/导致"需爬到证据阶梯顶端: - 加宏转录组/qSIP 证明菌 X 在病害情境下真的活跃 (活性); - 做接种实验: 把菌 X (或合成群落) 接到无菌/标准化水稻上, 看抗病是否提升 (操控 $\rightarrow$ 因果); - 理想加代谢组看它产生的抗病相关代谢物。(核心: 相关 $\rightarrow$ 因果必须靠实验, 思维框架 7; 植物系统是做因果验证的好模型, 文件 11.5)

最后一套 (最有价值): 04-纠错与案例分析.md

自测 04 · 纠错与案例分析

这是最像"真功夫"的一套。下面每段话听起来都挺像那么回事，其实都埋了坑。你的任务：把坑找出来、说清为什么错、怎么改。这正是你将来读论文、审数据、做研究时最需要的判断力。先自己挑错，再看解析。

第一部分 · 找错题（每段至少 1 个错误）

错例 1（一句结论）

"我们在宏基因组里检测到大量 `amoA`（氨氧化）基因，证明这片土壤的硝化作用很强。"

错例 2（方法描述）

"为节省成本，每个处理组采集 1 个混合土样，提 DNA 后直接送测序、组装、分箱，得到的 MAG 用于后续所有分析。"

错例 3（统计）

"我们把各物种的相对丰度做 Pearson 相关，构建了共现网络，强相关的两个菌说明它们在代谢上相互依赖。"

错例 4（多样性比较）

"对照组测了 2000 万 reads、施肥组测了 800 万 reads。我们直接比较两组的物种丰富度，发现对照组多样性显著更高。"

错例 5（MAG 解读）

"我们得到一个完整度 62%、污染度 8% 的 MAG，根据它含有的基因，完整重建了该菌的全部碳代谢通路。"

错例 6 (前沿/AI)

"蛋白质语言模型预测这个暗物质蛋白的结构像某种水解酶，所以这个菌一定具有该水解功能并在土壤中发挥作用。"

错例 7 (组学关系)

"宏基因组是组学里最简单基础的一种，测了它就等于把这群微生物的功能都搞清楚了。"

第二部分 · 案例分析 (综合题)

案例 A 某团队比较"免耕 vs 翻耕"土壤：各设 4 个重复，统一深度采样、统一测序深度、做了去宿主和质控。结果发现免耕组 `nifH`、CAZy 相关基因相对丰度更高，PERMANOVA 显示群落结构差异显著 ($p < 0.01$)。他们下结论："免耕提升了土壤固氮和有机质降解的功能。"

问：这个研究设计哪些地方做得好？结论里有什么需要收敛的地方？要让结论更硬，建议补什么？

案例 B 你接手一份土壤宏基因组数据，想回答"哪些微生物与高产相关，并找出可能的作用机制"。请用本库学过的思维框架 + 模型 + 前沿手段，列出一个从数据到机制的合理分析与验证路线 (4–6 步即可)。

答案与解析

第一部分 · 找错题

错例 1^{*} "检测到基因 = 作用很强"。 - 坑：基因存在只是潜力，不是活性/速率。 amoA 多 ≠ 硝化真的强（思维框架 3、模型 1/19）。 - 改：可说"具备较强硝化潜力"；要谈强弱需配宏转录组/硝化速率/同位素。

错例 2^{*} 多处坑。 - n=1：每组只 1 个样，无重复，无法做统计、无法区分真实差异与偶然（思维框架 6）。 - "混合土样"掩盖了空间异质性（原理 6、框架 1）。 - （隐患）没提质控/去宿主（模型 4）。 - 改：每组 ≥3 生物学重复；保留重复做统计；规范质控。

错例 3 两个坑。 - 组成型陷阱：相对丰度直接做 Pearson 会大量假阳性，应用 SparCC/SPIEC-EASI（模型 14/17、图解 08.1）。 - 共现≠互作≠因果：强相关可能只是共享生态位（模型 17、思维框架 7）。 - 改：用组成型网络方法；把"相互依赖"降级为"统计相关，需代谢建模/实验验证"。

错例 4^{*} 深度不同直接比多样性。 - 坑：测得越深发现越多，丰富度被深度系统性影响（模型 3/11）。2000万 vs 800万差距很大。 - 改：先抽平到相同深度（或用对深度稳健的方法）再比。

错例 5^{*} 拿中低质量 MAG 当完整基因组。 - 坑：完整度仅 62%，缺的近四成基因可能只是没拼到；污染度 8% 偏高，可能混入别的菌的基因。"完整重建全部通路"不成立（模型 8）。 - 改：说明 MAG 质量等级，对缺失/污染保持谨慎；通路结论标注不确定性。

错例 6^{*} AI 预测被当成事实 + 潜力当活性。 - 坑：结构预测是有根据的推测，需实验验证；即便功能推断对，也只是"潜力"，不代表"在土壤中发挥作用"（前沿 10.1、思维框架 3/7）。 - 改："预测其可能具有水解功能（待实验证实），是否在原位发挥作用需进一步验证"。

错例 7 两个误解。 - 坑1：宏基因组不是"最简单"，它是组学地基（潜力层），计算上反而最难（文件 11.1）。 - 坑2：它只到"能干什么"，不等于搞清全部功能；要到活性/产物需上层组学（思维框架 3、模块 11）。 - 改："宏基因组是基础的潜力层，需多组学整合才能逼近真实功能。"

第二部分 · 案例分析

案例 A 参考 - 做得好：4 个生物学重复；统一采样深度与测序深度（可比）；做了去宿主和质控；用了 PERMANOVA 做显著性检验。设计相当规范（框架 2/6、模型 12）。 - 需收敛：结论说"提升了功能"过头了——测到的是功能基因相对丰度（潜力），且是相关，不是"提升了功能(活性)"，也未证因果（思维框架 3/7）。还应注意组成型问题，差异基因建议用 ALDEx2 等确认（模型 14）。 - 补强建议：①宏转录组/qSIP 证明这些功能真的更活跃；②实测固氮速率、有机质分解指标（通量）；③差异分析换组成型方法复核；④若要因果，做控制实验/梯度。 - 收敛后的表述："免耕地块与更高的固氮、碳降解功能潜力及不同群落结构相关（潜力层面），其实际功能与因果关系有待活性/速率与实验验证。"

案例 B 参考路线（合理即可，要素齐全） 1. 先想清楚问题在哪层（框架 1）+ 检查设计：有无重复、是否需控批次/混杂（框架 6）。 2. 标准流程出表：质控去宿主(模型4) → 读长物种/功能谱 或 组装分箱出 MAG(模型6-10)。 3. 关联分析：用组成型方法找"与高产相关"的物种/功能（模型14；可上 MWAS/机器学习，前沿10.1/文件11.4），严格多重检验校正（框架5）。 4. 生成机制假说：共现网络找关键种(模型17) + 群落代谢模型 GEM 推断交叉喂养/竞争(前沿 10.3)。 5. 验证活性：对候选菌/功能做宏转录组或 qSIP，确认在高产情境下真的活跃（框架 3、前沿10.3）。 6. 坐实因果：接种候选菌/合成群落到（无菌）植物或田间小区，看产量是否提升（框架7、文件11.5）。

关键判断：第 3 步只给相关，必须靠第 5、6 步才能从"相关"走到"活性/因果"。

全部做完了？

回到 12 自测总览 看"掌握度自评"。答错的题别灰心——每一道答错的题，都是你下一步最该补的地方。标记它们，回到对应章节，过几天再做一遍。

学习不是一次通关，是螺旋上升。你能读到这里、做到这里，已经从"小白"迈进"入门"了。

知识库总览

13 · 资源导航与优质教程（站在巨人肩上）

不要重复造轮子。社区里已经有大量高质量、免费、持续维护的教程、流程、数据库和综述。本篇把它们挑出来、做成带评价的导航：每个都标注「是什么 / 适合谁 / 何时用 / 和本库哪块互补」。

选择原则（也教你怎么自己判断好资源）：1. 看维护：近 1-2 年还在更新吗？GitHub 有没有持续 commit、issue 有人答？2. 看权威：是否有同行评议论文、知名团队/机构背书、大量被引/被用？3. 看匹配：它面向新手还是老手？中文还是英文？读长还是短读长？别拿屠龙刀切菜。4. 链接可能失效：失效时用「项目名 + GitHub/官网」重新搜即可。

一、中文一体化流程（小白首选，最省心）

资源	是什么	适合谁 / 何时用
EasyMetagenome（易宏基因组） GitHub	刘永鑫团队的中文宏基因组全流程；安装+分析+可视化+答疑齐全，iMeta 高被引论文	本库 07 实操的最佳搭档。想中文一条龙跑通，从这开始
EasyAmplicon（易扩增子） GitHub	配套的 16S/扩增子全流程	做扩增子(模型2)时用
EasyMicrobiome GitHub	上面两个流程依赖的工具与数据库集合	安装 Easy 系列时需要
微信公众号「宏基因组」「生信宝典」	刘永鑫团队等运营，上千篇中文教程/方法解读/可视化	遇到具体问题搜中文教程的首选
B 站：扩增子和宏基因组分析视频 链接	视频版讲解	喜欢看视频学的

小白路线：先用 EasyMetagenome 跟着跑通一个 demo，建立"从 reads 到结果"的整体感，再回本库 07/08 深究每一步原理。

二、 国际标准化流程（要可复现、要发论文）

资源	是什么	适合谁 / 何时用
nf-core/mag 官网 · GitHub	基于 Nextflow 的最佳实践组装+分箱+注释流程，容器化、可复现、社区维护	要标准化、可复现、能扩到集群的项目首选
metaWRAP GitHub	经典的基因组解析一体化（分箱+精炼强）	想要强力 bin 精炼
anvi'o 官网	强大的交互式可视化与精炼平台 + 大量教程	想可视化探索、手动精炼 MAG
ATLAS / MetaflowX	自动化端到端流程	大批量自动化
EasyNanoMeta GitHub	纳米孔长读长宏基因组流程	做长读长(案例9、前沿)
metaMDBG / nanoMDBG GitHub	轻量长读长宏基因组组装器，质量逼近 PacBio HiFi	长读长组装

中文友好 vs 国际标准：EasyMetagenome 上手快；nf-core/mag 更标准化可复现。两者思路一致，可对照学。

三、 免费实操培训（零基础 / 零代码也能练手）

资源	是什么	适合谁 / 何时用
Galaxy Training : Metagenomics 学习路径 链接	网页点点点、无需命令行的完整宏基因组教程 (质控→分类→分析)	没有服务器/不会 命令行的小白练手 最佳
QIIME 2 文档与教程 官网	微生物组（偏扩增子）一体化平台，"Moving Pictures"入门教程经典	扩增子分析、规范 统计
The Carpentries / Cloud- Span 宏基因组课	面向科研新手的开放式生信课（搜 "Cloud- Span metagenomics" / "Carpentries metagenomics"）	想系统补命令行 +流程基本功
anvi'o tutorials 链接	跟着做的交互式分析教程	配合 anvi'o 使用

四、统计与可视化 (R 为主，本库 07.4 的延伸)

资源	是什么	适合谁 / 何时用
microbiome.github.io 教程 链接	系统的 R 微生物组分析教程	学 R 做多样性/差异/排序
phyloseq 官网	微生物组数据管理+分析+画图的经典 R 包	数据整合与出图
Nicholas Ollberding : 微生物组统计入门 链接	写得很清楚的英文统计教程博客	想把统计原理搞透
ANCOM-BC 教程 Bioconductor	组成型差异丰度分析(模型14)	找差异物种/功能
microeco / MicrobiotaProcess (R)	国产、傻瓜化的一体化分析包	想少写代码出图
《The best practice for microbiome analysis using R》Protein & Cell 综述	系统对比 phyloseq/microeco/amplicon 等 R 包优劣	选 R 包前先读它
《Statistical Analysis of Microbiome Data in R》(Xia, Sun, Chen · Springer)	微生物组统计经典教材	想啃透统计的进阶者

五、权威综述与教材（先建立认知地图）

资源	是什么	备注
The metagenomics of soil Nature Reviews Microbiology	土壤宏基因组奠基性综述	经典(较早)，建立大局观
Cutting edge tools in soil microbiology 综述 2024	土壤微生物学最新工具综述	看近年技术全景
Structure and function of the global topsoil microbiome Nature 2018	全球表土图谱(本库案例1)	标杆研究
长读长宏基因组计算工具综述 GPB 2025	长读长工具全景	做长读长前必读
NEON土壤宏基因组：组装与基础分析 F1000	手把手的真实示例	配合实操学

六、数据库与公共平台官方入口

功能/分类数据库（本库 05、模型 10/19 用到） - GTDB <https://gtdb.ecogenomic.org> | KEGG <https://www.genome.jp/kegg/> | eggNOG <http://eggnog.embl.de> - CAZy <http://www.cazy.org> | CARD <https://card.mcmaster.ca> | Pfam/InterPro <https://www.ebi.ac.uk/interpro/>

大型分析平台 / 数据仓库 | 平台 | 用途 || --- | --- || MGnify (EBI) <https://www.ebi.ac.uk/metagenomics> | 欧洲 EBI 的宏基因组分析+数据平台，可在线分析、下数据 || JGI IMG/M <https://img.jgi.doe.gov> | 美国 JGI 的宏基因组数据与分析门户 || ESM Metagenomic Atlas <https://esmatlas.com> | 6 亿+ 环境蛋白结构预测(前沿10.1) |

练手用公共数据从哪下 - NCBI SRA <https://www.ncbi.nlm.nih.gov/sra> | ENA <https://www.ebi.ac.uk/ena> | MGnify / JGI IMG/M（同上） - 找数据技巧：读一篇你感兴趣的论文 → 文末 "Data availability" → 拿到 SRA/ENA 编号(如 PRJNA...) → 下载。

七、 怎么把这些资源和本库配合（避免重复）

建立认知 → 本库 00-03 + 五、综述 （先懂为什么）
跑通流程 → EasyMetagenome / Galaxy（零代码） + 本库 07 实操
查原理 → 本库 02 模型 / 08 图解 （为什么这么算）
做统计图 → microbiome.github.io / phyloseq + 本库 07.4
要可复现 → nf-core/mag
查工具数据库 → 本库 05 + 六、官方入口
遇到报错 → 本库 07.5 + 工具 GitHub Issues + 中文公众号
自我检验 → 本库 12 自测

本篇要义：本库负责帮你搭骨架、建判断力、串知识；具体某个工具/流程怎么跑到最细，交给这些已经做得很好的外部资源。两者配合 = 既有体系，又不重复造轮子。

一句话总清单（收藏版）

- 中文跑流程 → EasyMetagenome
- 零代码练手 → Galaxy Training
- 可复现标准流程 → nf-core/mag
- R 统计画图 → phyloseq / microbiome.github.io / microeco
- 建认知 → NRM 《The metagenomics of soil》 + 本库
- 下数据 → NCBI SRA / ENA / MGnify
- 查数据库 → GTDB / KEGG / eggNOG / CAZy / CARD

回到 知识库总览 | 术语速查见 06-术语表与延伸阅读.md