



土壤宏基因组学

小白系统学习库 · 完整合订本

第一性原理 · 20 个必学模型 · 7 个思维框架 · 10 个案例 · 实操教程 · 难点图解 · 前沿与多组学

共 35 章 · 自动合并生成 · 用浏览器「打印 → 另存为 PDF」即得电子书

目录

土壤宏基因组学·小白系统学习库

学习路线图（建议顺序）

目录结构

一张图看懂整个领域的工作流

学完自测（能答上来就算入门了）

00·零基础启蒙：用大白话把这门学科讲清楚

- 一、先建立一个画面：一勺土里藏着一座看不见的城市
- 二、我们到底想知道什么？——三个核心问题
- 三、笨办法行不通：为什么不能把微生物"养出来"数？
- 四、DNA：每个微生物随身带的"身份证 + 技能清单"
- 五、测序：把 DNA 变成电脑能读的一长串字母
- 六、关键一步：一堆"字母碎片"怎么变成"土里有谁、能干啥"？
- 七、两种打开方式：查身份证 vs 读简历
- 八、跟着走一遍：一个完整研究长什么样？
- 九、四个一定要破除的"小白误区"
- 十、我能学会吗？——心态、基础和怎么用这个库

01·第一性原理：从最基本的事实推出整个领域

- 原理 0（前提）：土壤里几乎全是微生物，而且绝大多数我们"养不活"
- 原理 1：DNA 是生命的信息载体，"我是谁 + 我能干什么"都写在里面
- 原理 2：环境里所有生物的 DNA 是混在一起的——这正是"宏（meta）"的含义
- 原理 3：测序把"生物学问题"变成了"数据/计算问题"
- 原理 4：我们测到的是"相对比例"，不是"绝对数量"
- 原理 5：我们永远只看到"样本"，看不到"全部"——所以一切都带不确定性
- 原理 6：土壤是地球上最复杂、最不均匀的微生物栖息地

把 7 条串起来：领域的逻辑闭环

下一步

02·20 个必学模型·总览

20 个模型总览表

20 个模型如何对应工作流

给小白的精读优先级

A 类·实验与测序模型（模型 1–4）

模型 1·中心法则 / "基因即功能潜力"模型

模型 2 · 扩增子 vs 鸟枪法宏基因组模型 必懂

模型 3 · 测序深度与稀释曲线 (饱和) 模型 必懂

模型 4 · Phred 质量分数与测序错误模型

B 类 · 生信分析模型 (模型 5–10)

模型 5 · 序列比对与同源性模型

模型 6 · de novo 组装 : de Bruijn 图模型

模型 7 · 分箱 (Binning) : 组成 + 丰度聚类模型

模型 8 · MAG 质量评估 : 单拷贝标记基因模型 必懂

模型 9 · 物种分类 : k-mer / LCA 模型

模型 10 · 功能注释 : 直系同源 / 数据库映射模型

C 类 · 多样性与统计模型 (模型 11–14)

模型 11 · α 多样性与 Hill 数模型 必懂

模型 12 · β 多样性与排序 (PCoA/NMDS) 模型 必懂

模型 13 · 物种丰度分布 / 等级-丰度模型

模型 14 · 组成型数据模型 (CLR / 差异丰度) 必懂

D 类 · 群落构建生态模型 (模型 15–18)

模型 15 · 中性群落模型 (Sloan Neutral Community Model)

模型 16 · 确定性 vs 随机 : 零模型框架 (β NTI / RCbray) 进阶必懂

模型 17 · 共现网络与关键种模型 (SparCC / SPIEC-EASI) 进阶必懂

模型 18 · 生物地理 : 距离衰减与"万物无处不在"模型

E 类 · 功能与生态系统模型 (模型 19–20)

模型 19 · 生物地球化学循环的功能基因模型 必懂

模型 20 · 结构-功能关系与功能冗余模型 进阶必懂

20 个模型小结

03 · 7 个重要思维框架

框架 1 · 尺度框架 (Scale Thinking)

框架 2 · 样品到洞见 : 数据生命周期框架 (Sample-to-Insight)

框架 3 · 结构 → 功能 → 过程框架 (多组学阶梯) 最重要

框架 4 · 群落构建四过程框架 (Community Assembly)

框架 5 · 假说驱动 vs 数据驱动框架 (Hypothesis vs Data-driven)

框架 6 · 对照 · 重复 · 可重复框架 (Controls & Reproducibility)

框架 7 · 相关 → 因果的证据阶梯 (Correlation to Causation)

七框架协同 : 一次"靠谱研究"的内心独白

04 · 案例库 : 10 个真实研究案例

案例 1 · 全球表土微生物组图谱 (奠基性大尺度研究)

案例 2 · 中国陆地生态系统表土微生物组 (区域对比)

案例 3 · 全球土壤功能冗余 (结构-功能解耦)

案例 4 · 长期施肥对碳氮循环功能的影响 (农业经典设计)

案例 5 · 减少耕作改善根际碳氮磷循能 (管理实践)

案例 6 · 氮沉降下荒漠草原的碳氮循环响应 (全球变化)

案例 7 · 土壤抗性组：抗生素抗性基因的环境分布 (One Health)

案例 8 · 沿降水梯度跨土壤深度恢复 679 个 MAG (数据资源型)

案例 9 · 超深度长读长测序挖掘土壤生物合成潜力 (前沿技术)

案例 10 · 群落构建：随机 vs 确定性如何随土壤剖面变化 (生态机制)

跨案例规律 (小白重点)

案例文献链接

05 · 工具与数据库速查

按流程阶段的工具地图

主流数据库速查

一体化流程 (小白强烈推荐从这里入门)

给小白的现实提醒

06 · 术语表与延伸阅读

中英文术语表

几个最常被误解的点 (小白避坑)

延伸阅读与入门资源

建议的学习节奏 (4 周入门计划)

07 · 手把手实操教程 · 总览

先读这段 (很重要, 能帮你避坑)

实操教程地图 (按顺序)

一眼看懂: 整个流程的"命令骨架"

给小白的策略建议

07.1 · 环境与软件安装

一、你需要一个 Linux 环境

二、装 conda (软件管家) —— 强烈推荐用 miniforge / mamba

三、用 conda 建环境、装工具

四、下载数据库 (最费时间和硬盘的一步)

五、整理你的数据和目录

本篇完成检查

07.2 · 质控与读长分析 (路线甲: 快速出第一批结果)

第 0 步 · 看一眼原始数据长什么样

第 1 步 · 质控：洗掉垃圾 (fastp)

第 2 步 · 去宿主 (土壤常需去植物/人 DNA)

第 3 步 · 物种谱：土里有谁？ (Kraken2 + Bracken)

第 4 步 · 功能谱：这群菌能干啥？ (HUMAnN / MetaPhlAn)

串起来：一个多样本的小脚本

本篇完成检查

07.3 · 组装、分箱与 MAG (路线乙：重建基因组)

第 1 步 · 组装：把碎片拼成长片段 (MEGAHIT)

第 2 步 · 预测基因 (Prodigal)

第 3 步 · 算覆盖度：为分箱准备"丰度信号"

第 4 步 · 分箱：把 contig 按物种归堆 (MetaBAT2)

第 5 步 · 给 MAG 质控 (CheckM2)

第 6 步 · 给 MAG 分类 (GTDB-Tk)

第 7 步 · 给 MAG 做功能注释 (eggNOG-mapper / DRAM)

这一篇的产物，如何连到结论

本篇完成检查

07.4 · 统计与可视化 (用 R 把表变成图)

一、准备：装 R 和需要的包

二、你需要两张表 (最常见的输入格式)

三、读数据 (R 代码)

四、 α 多样性：单样本里种类多不多 (模型 11)

五、 β 多样性 + 排序：样本之间差多大 (模型 12)

六、找出差异物种/功能 (组成型差异，模型 14)

七、(可选) 共现网络：谁和谁在一起 (模型 17)

出图小贴士

本篇完成检查

07.5 · 常见报错与排查 (新手急救手册)

排错总原则 (先做这 4 件事)

一、环境与安装类

二、数据与格式类

三、内存 / 资源类 (土壤最常见！)

四、结果"不对劲"类 (不报错但结果可疑)

五、统计 / R 类

六、什么时候该求助 & 怎么问得到答案

心态提醒

08 · 难点图解专版 · 总览

本模块内容

怎么用这个模块

一句话先剧透四个难点的"恍然大悟点"

08.1 · 图解：组成型数据与 CLR（最容易踩的坑）

- 一、问题的根源：你拿到的是"比例"，不是"数量"
 - 二、陷阱长什么样：一个菌"涨"，逼着别的菌"假跌"
 - 三、CLR 怎么救场：不比"占整张饼的比例"，比"相对全体的倍数"
 - 四、几何平均？对数？——再用大白话兜一遍
 - 五、还有个麻烦：零值（很多物种丰度是 0）
 - 六、落到实操：你该怎么做（对接模型 14、教程 07.4）
- 一图总结

08.2 · 图解：组装与分箱（看不见的过程，画出来）

- 第一部分：组装——把碎片接成长片段
- 第二部分：分箱——把 contig 归回各自的基因组
- 全流程一图

08.3 · 图解：群落构建 β NTI 与 RCbray（环境筛选 还是 运气？）

- 一、先想清楚要回答的问题
- 二、零模型的灵魂：造一把"纯随机"的尺子
- 三、第一把尺子： β NTI —— 测"环境筛选"
- 四、第二把尺子：RCbray —— 把"随机"再细分
- 五、两把尺子合起来：一张判定流程图
- 六、动手怎么做（对接模型 16、教程）
- 七、最容易误解的 3 个点

08.4 · 图解：多样性与排序（ α 、 β 、距离、PCoA 到底在算啥）

- 一、 α 多样性：单个样本内部，多不多样？
 - 二、 β 多样性：两个样本之间，差多少？
 - 三、排序（PCoA/NMDS）：把大表压成一张散点图
 - 四、 α 和 β ，别搞混（一张对照）
- 从数据到图，一条线

09 · 速记卡片与速查图

- 卡片 1 · 关键数字/阈值速查（最高频）
- 卡片 2 · 分析流程命令骨架（照着改）
- 卡片 3 · 工具速查（按流程阶段）
- 卡片 4 · 标志基因速查（碳氮磷硫循环）

卡片 5 · 决策速查 (我该选哪个?)

卡片 6 · 20 个模型一句话索引

卡片 7 · 7 个思维框架口诀

卡片 8 · 新手避坑清单 (贴脑门上)

10 · 前沿模型与方法 · 总览

一句话先看懂：每个前沿在补哪块短板

本模块内容

前沿的总趋势 (记住这条主线)

10.1 · AI 与基础模型：用人工智能照亮"暗物质"

一、先回忆痛点：暗物质问题

二、关键思想：把"序列"当成"语言"来学

三、两大类模型 (小白只需记住"是什么、能干啥")

四、另一条 AI 应用线：机器学习做"预测" (很实用的他山之石)

五、和你已有知识的连接 (别把它当孤立新知识)

六、给小白的态度建议

延伸阅读

10.2 · Hi-C 邻近连接 与 病毒组

一、先回忆痛点

二、核心思想：在细胞被打碎前，先把"邻居"焊在一起

三、它能做到普通分箱做不到的事

四、代表工具

一、一个被基础篇略过的整片大陆

二、难点：病毒是"暗物质中的暗物质"

三、关键问题：这个病毒感染谁？——CRISPR 间谍档案

四、和你已有知识的连接

延伸阅读

10.3 · 从"基因潜力"到"活性与互作"

一、痛点回顾

二、核心思想：让活跃的菌"自己变重"

三、qSIP (定量版) 让它更强

四、和你已有知识的连接

一、痛点回顾

二、核心思想：给每个菌建一张"代谢地图"，再让它们"做生意"

三、代表工具 (小白只需知道名字和分工)

四、用处与坑

两件利器在"证据阶梯"上的位置 (呼应框架7)

延伸阅读

11 · 多组学整合 与 他山之石 · 总览

- 一、先纠正一个常见误解
- 二、本模块内容
- 三、一图看懂"地基 + 楼层 + 外援"

11.1 · 组学阶梯与多组学整合

- 一、组学阶梯：从"能干"到"真干了"的四级台阶
- 二、为什么"地基"既是优点也是局限
- 三、多组学整合：把几层楼"对齐"着看
- 四、整合到底难在哪 (小白要有心理准备)
- 五、给小白的路线建议

延伸阅读

11.2 · 他山之石：向别的领域借智慧

1. 海洋：Tara Oceans —— "大科学 + 大数据"的范本
2. 人体肠道：方法学的"练兵场"
3. 地球微生物组计划(EMP)：跨生境的"大一统"
1. 生态学 / 宏观生态 —— 把研究大象老虎的理论搬给微生物
2. 网络科学 —— 研究社交网络/互联网的工具
3. 系统生物学 / 代谢工程 —— 把"细胞代谢网络"搬到群落
4. 人工智能 / 数据科学 —— 最猛的一股外援
5. 还有更多"娘家"
- 三、怎么用好"他山之石" (方法论)

延伸阅读

11.3 · 各类组学详解：宏基因组的"楼上邻居"们

1. 宏转录组 (Metatranscriptomics) —— 测 RNA，看"在表达什么"
2. 宏蛋白组 (Metaproteomics) —— 测蛋白，看"真造出了什么"
3. 代谢组 (Metabolomics) —— 测代谢物，看"产出了什么"
4. 宏表观组 (Metaepigenomics) —— 测 DNA 甲基化，一个新维度
- 三、一张图：宏基因组和它的"邻居们"

延伸阅读

11.4 · 从组学领域借方法：最该借的"他山之石"

- 一、从人类基因组学借：GWAS → MWAS
- 二、从单细胞组学借：单细胞分辨 (看清"一个个体")
- 三、从空间组学借：原位定位 (看清"在哪里")

四、从单细胞分析借：数据分析方法

五、方法论：怎么判断一个组学方法"能不能借"

延伸阅读

11.5 · 他山之石进阶：更多生态系统与跨学科

1. 极端环境 —— 宏基因组学的"发源地"之一

2. 植物微生物组 —— 天然的"模式系统"

3. 建成环境 —— 标准化大规模采样的范本

4. 古 DNA / 古微生物 —— 时间维度

1. 博弈论 / 经济学 —— 解释"合作与背叛"

2. 流行病学 —— 溯源与传播

3. 信息论 —— 多样性的数学根基

4. 因果推断 —— 从"相关"突围到"因果"

5. 地统计学 / 遥感 GIS —— 把微生物"画上地图"

6. 药物化学 / 天然产物 —— 土壤是"新药矿"

三、一张"借用地图" (总览)

四、把"借"变成你的核心能力

延伸阅读



土壤宏基因组学 · 小白系统学习库

一句话定义：土壤宏基因组学（Soil Metagenomics）= 直接从土壤里提取所有微生物的 DNA 一起测序，用计算的办法搞清楚"土里有谁、它们能干什么、为什么是它们"。

这个库是零基础设计的。它不堆术语，而是从最基本的事实（第一性原理）出发，一步步推出这个领域为什么要用那些方法、那些模型、那些工具。学完你应该能：

- 看懂一篇土壤宏基因组论文的方法和图；
 - 知道一个项目从采样到出结论要经过哪些步骤、每步用什么工具；
 - 用正确的"思维框架"去判断一个结论靠不靠谱。
-

学习路线图（建议顺序）

第 0 步 完全零基础先看这 → 00-零基础启蒙.md 新手从这开始
(大白话 + 生活类比, 不需要任何基础, 先建立整体感觉)

第 1 步 搞懂"为什么" → 01-第一性原理.md
(领域存在的根本逻辑, 全部后续内容的地基)

第 2 步 搞懂"用什么想" → 03-思维框架.md
(7 个思维框架, 先装上"思维操作系统"再学细节)

第 3 步 搞懂"用什么算" → 02-必学模型/ (20 个模型, 分 5 类)
├— A 实验与测序模型 (数据怎么来的)
├— B 生信分析模型 (序列怎么变成结论)
├— C 多样性与统计模型 (怎么量化和比较)
├— D 群落构建生态模型 (怎么解释"为什么是它们")
└— E 功能与生态系统模型 (怎么连到碳氮磷循环)

第 4 步 看"别人怎么做的" → 04-案例库.md (10 个真实研究案例)

第 5 步 动手时随时查 → 05-工具与数据库速查.md
→ 06-术语表与延伸阅读.md

以下为进阶模块 (想更详细 / 动手 / 啃硬骨头时看)

第 6 步 真的把流程跑起来 → 07-实操教程/ (手把手, 装软件→出图, 5 篇)

第 7 步 把难概念彻底搞懂 → 08-难点图解/ (CLR/组装分箱/ β NTI/多样性, 5 篇)

随时查 速记卡片扫一眼 → 09-速记卡片与速查图.md (阈值/流程/工具/口诀)

以下为拔高模块 (想看前沿 / 升维到多组学时看)

第 8 步 看正在发生的前沿 → 10-前沿模型与方法/ (AI/Hi-C/病毒组/qSIP/代谢建模)

第 9 步 升维: 组学全貌+借鉴 → 11-多组学整合与他山之石/ (组学阶梯 + 跨领域借智慧)

小白提示：完全没基础就先读 00-零基础启蒙（纯大白话，当故事看）。之后第一遍按"00 → 01 → 03 → 案例库"建立直觉，不必一开始就读懂全部模型公式；第二遍再回来啃 02 的 20 个模型。

目录结构

文件 / 文件夹	内容	给谁看
00-零基础启蒙.md	纯大白话 + 生活类比 + 一个贯穿到底的小故事，零基础也能懂"这门学科在干嘛"	完全小白，第 0 课
01-第一性原理.md	7 条不可再分的基本事实，整个领域都是从这里推出来的	所有人，必读第一篇
02-必学模型/	20 个必学模型，分 5 大类，每个含"是什么/解决什么/小白怎么理解/坑"	入门核心
03-思维框架.md	7 个思维框架：尺度、数据生命周期、结构-功能-过程、群落构建、假说vs数据、对照与可重复、相关到因果	入门核心
04-案例库.md	10 个真实案例：全球图谱、施肥、耕作、氮沉降、抗性基因组、MAG 恢复、长读长、关键种……	建立直觉、找选题
05-工具与数据库速查.md	按流程阶段排好的工具清单 + 主流数据库 + 中文友好的一体化流程	动手时查
06-术语表与延伸阅读.md	中英文术语对照 + 经典论文 + 入门资源	随时查
07-实操教程/	手把手实操：装环境→质控→读长分析→组装分箱→R 统计画图→报错排查（5 篇，含命令）	想动手跑数据
08-难点图解/	难点深挖：组成型/CLR、组装与分箱、 β NTI/RCbray、多样性与排序，全用图解讲透（5 篇）	某概念卡住时
09-速记卡片与速查图.md	阈值/流程/工具/标志基因/口诀/避坑，做成速查卡片	随时扫一眼
10-前沿模型与方法/	前沿：AI 基础模型(Evo/ESM)照亮暗物质、Hi-C 分箱、病毒组+CRISPR、qSIP 测活性、群落代谢建模(3 篇)	想看最新进展
11-多组学整合与他山之石/	升维：组学阶梯(讲透"宏基因组是地基不是简化版")、各类组学详解、从组学领域借方法(MWAS/单细胞/空间)、跨学科他山之石(5 篇)	想看大图景

一张图看懂整个领域的工作流

科学问题

| (我想知道：施肥会不会改变土壤固氮能力？)



采样设计 —→ 土壤取样、保存 —→ 提 DNA —→ 建库 —→ 高通量测序



原始数据 (一堆短序列 reads)



└─ 质控 (去低质量/去宿主)



【基于读长 read-based】

直接比对数据库出

物种谱 + 功能谱



【基于组装 assembly-based】

拼成长片段 contig —→ 分箱 —→ MAG

—→ 质控/分类/注释



多样性分析 / 统计检验 / 群落构建 / 共现网络



生物学解释 + 验证



结论 / 论文

这张图里的每一个方块，背后都对应 02-必学模型/ 里的一个或几个模型。学模型的时候随时回来对照这张图，就不会“只见树木不见森林”。

学完自测 (能答上来就算入门了)

1. 宏基因组和扩增子 (16S) 有什么本质区别？各自适合回答什么问题？ (→ 模型 2)
2. 为什么宏基因组测出来的丰度是“相对的”，不能直接比较绝对数量？这会带来什么坑？ (→ 模型 14)
3. 什么是 MAG？一个“高质量 MAG”的标准是什么？ (→ 模型 8)

4. 怎么判断一个土壤群落是"环境筛选 (确定性)"还是"随机扩散 (中性)"组装出来的?
(→ 模型 15、16)
 5. 宏基因组只能告诉你微生物"能干什么",不能告诉你"正在干什么"。为什么?想知道"正在干什么"该上什么技术?(→ 思维框架 3)
-

本库内容基于公开文献与主流工具整理,链接见各篇「延伸阅读」。领域发展很快,工具版本与数据库以官方最新为准。

00 · 零基础启蒙：用大白话把这门学科讲清楚

这一篇写给完全零基础的你——不懂生物、没碰过测序、不会编程，统统没关系。读完你会对"土壤宏基因组学到底在干嘛"有一个清楚的整体感觉。它是你的第 0 课，读它不需要任何准备。读法：放轻松，当故事看。遇到新词我都会立刻用大白话解释，不用怕，也不用记。

一、先建立一个画面：一勺土里藏着一座看不见的城市

随手挖一勺你家菜园子的土，大概几克重。你看它就是一坨土，但在显微镜下，这一勺土里住着几十亿个微生物（细菌、真菌、古菌等），种类成千上万。

打个比方：一勺土 $\approx$ 一座超级大城市。里面有：

- 各行各业的"居民"（不同种类的微生物）；
- 有人多的大族群（优势菌），也有人数极少、平时不起眼的小群体（稀有菌）；
- 每个居民都有自己的"工作"——有的在分解落叶（碳循环），有的在帮植物固定养分（氮循环），有的在对付污染物……

这座城市完全看不见、摸不着、听不到。土壤宏基因组学，就是一套"给这座看不见的城市做人口普查 + 职业普查"的办法。

记住这个"一勺土 = 一座城市"的画面，后面所有内容都能挂到它上面。

二、我们到底想知道什么？——三个核心问题

对这座看不见的城市，科学家其实就想搞清楚三件事：

问题	大白话	行话叫法
1. 有谁？	城里住着哪些居民？各有多少？	物种组成 / 多样性
2. 能干啥？	这些居民都会哪些"工作技能"？	功能潜力
3. 为啥是它们？	为什么是这些居民住这儿，而不是别的？	群落构建

整个学科、所有那些复杂工具和模型，归根到底都是为了回答这三个问题。你以后看任何一篇论文、学任何一个方法，都可以先问一句："它在回答这三个问题里的哪一个？"

三、笨办法行不通：为什么不能把微生物"养出来"数？

你可能会想：那简单啊，把土里的微生物挑出来，放培养皿里养大，一个个数、一个个看不就行了？

问题来了：土里的微生物，超过 99% 在实验室里根本养不活。

为什么？因为它们在土里是抱团生活的——A 菌的"废料"正好是 B 菌的"口粮"，C 菌要靠 D 菌发的化学信号才肯生长……你把某一个单独拎出来放进培养皿，它就像一个离开了整个城市供应链的人，断了水电粮食，活不下去。

这就好比：你想研究一座城市，却规定"只能研究那些愿意单独住到无人荒岛上还能活下来的人"——你最后看到的，是被严重扭曲的、极少数特殊居民，根本代表不了整座城。

结论：既然养不活，那就别养了，直接去读它们的"身份信息"。这就是这门学科的出发点，行话叫"免培养"（不靠培养）。

想看更系统的逻辑推导，读完这篇可以去看 01-第一性原理.md 。

四、DNA：每个微生物随身带的"身份证 + 技能清单"

那"身份信息"指的是什么？答案是 DNA。

你可以把 DNA 理解成每个生命体都随身携带的一份说明书，这份说明书有两个作用：

1. 它是身份证：每种微生物的 DNA 都不一样，读到这段 DNA，就能认出"哦，这是某某菌"。
2. 它是技能清单：DNA 是由一段段叫"基因"的片段组成的，一个基因大致对应一项本领（比如"会分解纤维素""会固定氮气"）。读完一个微生物的全部基因，就大致知道它会哪些活儿。

打个比方：DNA 就像一个人随身带的简历——上面既写了名字（身份），又列了"会计证、驾照、厨师证"（技能）。

DNA 本身是一条很长的链，由四种叫"碱基"的小积木组成，简写为 A、T、C、G 四个字母。所以一段 DNA，在电脑里看就是一长串字母，像这样：

```
...ATGCCGTTAGGCATTCGGATCCAGT...
```

生命的全部信息，就编码在这串字母的排列顺序里。这是个惊人但真实的事实：读懂了字母顺序，就读懂了"它是谁、它会什么"。

这里有个特别重要、贯穿全库的细节：简历上写着"会做饭"，不代表他此刻正在做饭。同理，一个微生物有某个基因，只代表它有能力做某件事，不代表它正在做。这个区别后面会反复提醒（第九节、思维框架 3）。

五、测序：把 DNA 变成电脑能读的一长串字母

知道了"信息在 DNA 的字母顺序里"，下一步自然就是：想办法把这串字母读出来。

把 DNA 的字母顺序读出来、变成电脑里的文本，这个过程就叫"测序"（sequencing）。干这活的机器叫"测序仪"。

但这里有个绕不开的现实困难：

- 测序仪没法一口气从头读到尾读完一条很长的 DNA。它只能把 DNA 打断成很多短片段，每段读个一两百个字母，读出成千上万亿条这样的小短串。
- 每一条小短串，行话叫一条 "read"（读段）。

更麻烦的是（这正是"宏"字的由来）：你从土里提取 DNA 时，是把一勺土里所有微生物的 DNA 全部混在一起提出来的，没法区分哪段来自哪个菌。

打个比方：

你把这座城市里每个居民的简历都收集起来，全部塞进一台碎纸机绞碎，最后得到一大堆碎纸条（reads）。每张碎纸条上只有几个字，而且不知道它原来属于谁。

"宏基因组测序"得到的，就是这样几千万到几十亿张混在一起、来历不明的碎纸条。

听起来一团乱？别急，下一步就是把它们重新整理出意义。

六、关键一步：一堆"字母碎片"怎么变成"土里有谁、能干啥"？

这一步是整个学科的核心魔法，全靠计算机和算法完成（这也是为什么做这行要懂一点编程和数据分析）。整理碎纸条主要有两条思路，配合使用：

思路 A：直接查字典（基于读长） 拿每一张碎纸条，去一个巨大的"已知 DNA 字典"里搜：哪段已知序列跟它最像？ - 像某个已知细菌 → 这张纸条多半来自那种菌（回答"有谁"）； - 像某个已知的"固氮基因" → 说明城里有居民会固氮（回答"能干啥"）。这种方法快，但只能认出"字典里已经收录"的东西。

思路 B：先拼回去，再研究（基于组装） 先像玩拼图一样，把大量碎纸条里边缘文字重叠的拼接起来，还原成更长的段落（行话叫 contig），甚至尽量拼回一个个居民的"简历全文"——也就是一个个基因组（行话叫 MAG，意思是"从宏基因组里拼出来的基因组"）。拼得越完整，对这个居民的了解就越深。这种方法信息更全，但很费算力，而且土壤太复杂、碎片太杂，常常拼不完整（这是土壤研究公认的难点）。

整理完之后，你就得到了梦寐以求的两张表： - 一张"居民名册"：土里有哪些菌、各占多少比例； - 一张"技能清单"：这群菌总共拥有哪些功能基因、各类功能有多强。

有了这两张表，就可以做统计、画图、和别的样本比较，最后得出结论了。

上面这一整段，就是后面 02-必学模型 里一连串模型（比对、组装、分箱、分类、注释）在做的事。现在只要懂这个大白话版就够了。

七、两种打开方式：查身份证 vs 读简历

刚才说的"把所有简历碎纸条全测"，是最全面的一种做法，叫"鸟枪法宏基因组"（就是本库的主角）。但它贵、数据量大、算起来累。

还有一种更省钱的做法，叫"扩增子"（比如常听到的"16S 测序"）：

它不读整本简历，只查每个居民的"身份证号"那一栏。

- 扩增子（查身份证）：便宜、快，能告诉你"城里有谁、各占多少"，但几乎说不清每个人会什么技能。适合样本特别多、只想知道"群落组成怎么变"的研究。
- 宏基因组（读简历全文）：贵、累，但"有谁 + 能干啥"都知道，还能拼出基因组。适合想深挖"功能、代谢、具体基因"的研究。

没有谁绝对更好，看你的问题和预算。很多研究两个一起用：先用便宜的扩增子大范围扫，再用宏基因组挑重点深挖。

详见 02-必学模型/01 的"模型 2"。

八、跟着走一遍：一个完整研究长什么样？

光讲零件还不够，我们用一个具体的小故事把所有零件拼起来跑一遍。看完你就有整体感了。

小张的问题：他想知道——给菜园施有机肥，会不会让土里"会固氮（帮土壤变肥）"的微生物变多、功能变强？

他会这样一步步做（括号里是对应本库的内容，现在不用点进去，先感受流程）：

1. 先想清楚问题和设计 —— 设两组地：一组施有机肥，一组不施（对照）。每组至少挖 3 块地分别取样，不能只挖一块（否则没法判断差异是真的还是巧合）。 这一步最关键，决定成败（思维框架 2、6）。

2. 取土、保存 —— 按规范采土，尽快冷冻，别让 DNA 坏掉。
3. 提 DNA、送测序 —— 把每份土里所有微生物的 DNA 提出来，送测序仪，拿回一大堆"碎纸条"(reads)。 第五节讲的那一步。
4. 质控（清垃圾） —— 先用软件把读得模糊不清的碎纸条、混进来的植物 DNA 等清理掉。不做这步，后面全是错的（模型 4）。
5. 整理出两张表 —— 用计算机把碎纸条整理成"居民名册"和"技能清单"。 第六节那两条思路（模型 5-10）。
6. 比一比、算一算 —— 比较施肥组和对照组：固氮基因（比如叫 `nifH` 的那个）是不是真的变多了？群落整体差异大不大？而且要做统计检验确认"这差异不是碰巧"。 模型 11-14、19。
7. 小心解读 —— 就算 `nifH` 基因变多了，小张也只能说"固氮的潜力变强了"，不能直接说"固氮量真的增加了"——因为基因多不等于真在干活。想下更硬的结论，得再测它们的"工作记录"（RNA）或直接测固氮速率。 这就是那条铁律：能干 $\neq$ 在干（思维框架 3、7）。
8. 出结论 —— "施有机肥后，土壤固氮相关微生物及其功能基因显著增加，提示固氮潜力增强（但实际速率有待进一步验证）。"

看，从一勺土到一个结论，中间这 8 步，每一步都对应本库里的某些模型和思维框架。你不用一下子全记住，但这个整体流程感非常重要——它就是你脑子里那张地图。

九、四个一定要破除的"小白误区"

这四个坑，几乎每个新手都踩过。现在就记住它们，能帮你省下大量冤枉路：

1. "测到这个基因 = 它正在发挥作用" → 只是有能力，不代表正在做（简历写了"会做饭" $\neq$ 正在做饭）。这是最大、最常犯的误区。
2. "某个菌占比 3%，就是说它数量是另一个占比 1.5% 的菌的两倍" → 测序给的是相对比例，不是绝对数量。而且比例有个怪脾气：一个菌"涨"了，会逼着别的菌在数字上"跌"，哪怕它们实际没变。所以比较时要用专门的统计方法（模型 14），不能想当然。

3. "我没测到它，所以土里没有它" → 可能只是你测得不够深（碎纸条收得不够多），稀有的居民没被抽到。"没看到"不等于"不存在"（模型 3）。
4. "A 菌和 B 菌总是一起出现，所以它俩肯定在合作 / 互相依赖" → 一起出现，可能只是它俩都喜欢同样的环境，并不一定真有来往。相关不等于因果（模型 17、思维框架 7）。

这四条，建议读完整个库之后再回来看一遍，你会有更深的体会。

十、我能学会吗？——心态、基础和怎么用这个库

能。但要有正确的预期：

- 这是一门交叉学科：一半是微生物/生态学，一半是数据科学（要用命令行、跑软件、做统计）。两边都不用一开始就精通，边学边补即可。
- 需要慢慢补的基础：① 一点点生物学常识（这个库够用了）；② Linux 命令行的基本操作；③ 一点 R 或 Python 做统计画图。这些都可以后面再说，现在不用怕。
- 算力现实：真正跑土壤数据需要服务器/云，个人电脑只够学命令、练小数据——这很正常，不是你的问题。

心态最重要：第一遍只求"看懂大概在讲什么"，看不懂的术语跳过去没关系。学习是螺旋上升的，第二遍、第三遍才慢慢"会判断""能动手"。别指望一遍到位，没人能一遍到位。

这个库，建议你这样用：

你现在在这 ——▶ 00 零基础启蒙（就是本篇，先建立整体感觉）

|
01 第一性原理（把"为什么"想得更透一点）

|
03 思维框架（学会怎么判断对错，比记知识点更重要）

|
04 案例库（看真实研究长啥样，建立直觉）

|
02 必学模型（20 个模型，第二遍再慢慢啃，别硬背）

|
05 工具速查 / 06 术语表（动手和查词的时候随时翻）

- 不懂的词 → 翻 06-术语表与延伸阅读.md，里面有中英对照和"避坑清单"。
- 想跟着电脑跑跑看 → 05-工具与数据库速查.md 里推荐了中文友好的入门流程 EasyMetagenome。
- 那篇还附了一个 4 周入门计划，照着走就行。

一句话总结这一课：土壤宏基因组学，就是通过读取一勺土里所有微生物混在一起的 DNA，来搞清楚"土里有谁、它们能干什么、为什么是它们"。剩下的所有复杂内容，都是为了把这件事做得更准、更可信。

准备好了，就翻开 01-第一性原理.md，我们把"为什么"想得更透一点。

01 · 第一性原理：从最基本的事实推出整个领域

第一性原理（First Principles）：不靠“别人都这么做”的类比，而是回到不可再分的基本事实，从这些事实一步步往上推。这篇是全库的地基。把这 7 条想透，后面 20 个模型、所有工具，你都能“猜”出它们为什么要存在。

读法：每条原理 = 一个基本事实 ➡ 推出一个必然的后果 ➡ 于是领域里诞生了某种方法/模型。

原理 0（前提）：土壤里几乎全是微生物，而且绝大多数我们“养不活”

基本事实：一克土壤里有约 $10^9 \sim 10^{10}$ 个微生物细胞、上万到百万级别的物种（OTU/类群）。但其中 99% 以上在实验室里培养不出来（缺它需要的伙伴、信号或环境）。

必然后果：如果只研究“能在培养皿里长出来的那 1%”，我们看到的是一个被严重扭曲的世界。要研究真实的土壤微生物，必须绕开培养。

于是诞生了：免培养（culture-independent）技术路线——不养细菌，直接去读它们的“分子身份证”。这就是宏基因组学的出发点。

一句话：养不活 → 只能直接读 DNA。这是这门学科存在的根本理由。

原理 1：DNA 是生命的信息载体，“我是谁 + 我能干什么”都写在里面

基本事实：每个细胞的 DNA 既编码了它的身份（谁的基因组就是谁），也编码了它潜在能做的所有事（每个基因 $\approx$ 一种蛋白 $\approx$ 一种功能/酶）。这就是分子生物学的中心法则：DNA → RNA → 蛋白质 → 功能。

必然后果：只要能读到一段 DNA，就能（通过和已知序列比对）推断它来自谁、以及它编码什么功能。

于是诞生了：用序列回答两个核心问题——"Who is there?"（物种组成）和 "What can they do?"（功能潜力）。后面的"物种分类模型""功能注释模型"都是为这两个问题服务的。

注意"潜力"二字：基因存在 ≠ 正在表达。这点会反复出现，见思维框架 3。

原理 2：环境里所有生物的 DNA 是混在一起的——这正是"宏 (meta) "的含义

基本事实：你从土里提的 DNA，不是某一个菌的，而是成千上万个物种的 DNA 碎片混在一桶里。

必然后果：测出来的不是一个基因组，而是一锅"基因组沙拉"。你拿到的是海量短片段（reads），每一段不知道来自哪个物种、哪个位置。

于是诞生了两条技术路线（这是全领域最重要的分叉，对应模型 2）：

路线	怎么做	比喻
扩增子（Amplicon，如 16S/ITS）	只挑一段"身份证基因"（16S rRNA）扩增测序	只查每个人的身份证号 → 便宜、快、只知道"有谁"
鸟枪法宏基因组（Shotgun Metagenomics）	把所有 DNA 随机打碎、全部测	把每个人的整本日记都撕碎了测 → 贵，但"有谁 + 能干啥"都知道

本库讲的"宏基因组"主要指鸟枪法；但扩增子是必须先理解的对照（模型 2 会讲清楚区别）。

原理 3：测序把"生物学问题"变成了"数据/计算问题"

基本事实：高通量测序的产物是文本——由 A/T/C/G 组成的字符串，配一个质量分数。

必然后果：一旦生物变成了字符串，生物学问题就变成了字符串处理 + 统计问题：怎么把碎片拼起来（组装）、怎么判断两段相不相似（比对）、怎么把它们归类（聚类/分箱）、怎么比较两组样本（统计检验）。

于是诞生了：整个生物信息学 (bioinformatics) 流程。模型 5–10（比对、组装、分箱、分类、注释）本质上都是在解字符串/算法问题。这也是为什么学宏基因组绕不开命令行和一点编程。

心态转变：做土壤宏基因组，一半是微生物学，一半是数据科学。

原理 4：我们测到的是"相对比例"，不是"绝对数量"

基本事实：一次测序的总数据量（总 reads 数）是仪器和上样量决定的人为上限，不是样品真实的细胞总数。所以你只能知道"A 菌占了 3%"，不知道"每克土里有多少个 A 菌"。

必然后果：数据是组成型的 (compositional) ——所有比例加起来必须等于 100%。这带来一个反直觉的陷阱：一个菌"涨"了，会逼着别的菌在数字上"跌"，哪怕它们绝对数量没变。直接用常规相关/比较会产生大量假阳性。

于是诞生了：组成型数据分析方法——CLR（中心对数比）变换、Aitchison 距离、ALDEx2/ANCOM 等差异分析工具（模型 14）。这是新手最容易忽视、最容易出错的地方。

记住这句话："看到的是比例，不是数量。" 它会救你很多次。

原理 5：我们永远只看到"样本"，看不到"全部"——所以一切都带不确定性

基本事实：你采的几克土、测的那些 reads，都只是真实土壤（一片地、一个生态系统）的一次抽样。抽样必然不完整：测得越浅，漏掉的稀有物种越多。

必然后果：

1. 同样的土，测两次结果不会完全一样 → 必须有生物学重复和统计。
2. 测序深度不够时，你"看到的多样性"会低于"真实多样性" → 需要稀释曲线判断够不够（模型 3）。
3. 任何结论都该带"误差棒"，不能因为"测到了 1 条 reads"就说"这里有这个功能"。

于是诞生了：多样性估计与稀释/饱和模型（模型 3、11）、重复设计与统计检验的整套规范（思维框架 6）。

一句话："没测到"不等于"不存在"，"测到一点点"也可能是噪声。

原理 6：土壤是地球上最复杂、最不均匀的微生物栖息地

基本事实：相比人肠道、海水，土壤的微生物多样性最高、最异质——隔几厘米的两团土，菌群可能完全不同；而且有巨大的"稀有生物圈（rare biosphere）"和大量"微生物暗物质（microbial dark matter）"（没有任何已知基因组可比对的未知类群）。

必然后果：

1. 复杂度极高 → 组装很难拼完整、覆盖度低、能恢复的高质量基因组（MAG）比例低（这是土壤生信公认的难点）。
2. 异质性强 → 采样设计极其关键，采错了后面神仙难救。
3. 大量序列比不上任何数据库 → 很多"功能未知"，结论天然不完整。

于是诞生了：针对土壤的深度测序、混合/长读长测序、bin 精炼等策略（模型 6–8、案例 8、9），以及"承认未知、谨慎下结论"的科研态度。

把 7 条串起来：领域的逻辑闭环

微生物养不活（原理0）

└─▶ 只能直接读 DNA（原理1：DNA 编码身份+功能）

└─▶ 但 DNA 是混在一起的（原理2：meta）

└─▶ 测序把它变成海量字符串（原理3：变成计算问题）

└─▶ 得到的是相对比例（原理4：组成型 → 要特殊统计）

└─▶ 只是抽样（原理5：不确定 → 要重复/稀释/多样性估计）

└─▶ 而且土壤极复杂（原理6：难组装/采样关键/大量未知）

这就是整个学科的骨架。之后你学的每一个模型、每一个工具，都是为了解决这条链上的某个具体困难。学新东西时问自己一句：

"它在解决上面哪一条原理带来的麻烦？"

能答上来，你就真懂了，而不是死记流程。

下一步

- 装上"思维操作系统"：03-思维框架.md
- 或直接学解决这些麻烦的工具：02-必学模型/

02 · 20 个必学模型 · 总览

这里的"模型"是广义的：既包括概念模型（一种理解世界的方式）、算法模型（一种计算方法），也包括统计/生态模型（一种量化和解释的工具）。它们共同构成了"从土壤到结论"所需的全部核心思想工具。20 个不要求一次记住，先看总览表建立全局，再按需精读。

每个模型在正文里都按统一格式讲解：① 是什么 ② 解决第一性原理中的哪个麻烦 ③ 小白怎么直观理解 ④ 关键参数/指标 ⑤ 常见坑

20 个模型总览表

A 类 · 实验与测序模型（数据是怎么来的）→ 01-实验与测序模型.md

#	模型	一句话
1	中心法则 / "基因即功能潜力"模型	为什么读 DNA 就能推断"谁 + 能干啥"
2	扩增子 vs 鸟枪法宏基因组模型	全领域最重要的分叉：查身份证 vs 读全本日记
3	测序深度与稀释曲线（饱和）模型	我测得够不够深？漏了多少没看见？
4	Phred 质量分数与测序错误模型	Q20/Q30 是什么，为什么必须先质控

B 类 · 生信分析模型（序列怎么变成结论）→ 02-生信分析模型.md

#	模型	一句话
5	序列比对与同源性模型	两段序列像不像？E-value、相似度怎么读
6	de novo 组装：de Bruijn 图模型	把海量碎片拼成长片段 contig
7	分箱（Binning）：组成+丰度聚类模型	把 contig 按"它属于谁"分堆，凑出基因组
8	MAG 质量评估：单拷贝标记基因模型	拼出来的基因组完整吗？污染吗？(MIMAG 标准)
9	物种分类：k-mer / LCA 模型	一条序列归到哪个物种（Kraken2 思想）
10	功能注释：直系同源 / 数据库映射模型	一个基因对应哪个功能（KEGG/eggNOG/CAZy/CARD）

C 类 · 多样性与统计模型（怎么量化和比较）→ 03-多样性与统计模型.md

#	模型	一句话
11	α 多样性与 Hill 数模型	单个样本里"种类多不多、均不均匀"怎么量化
12	β 多样性与排序（PCoA/NMDS）模型	样本之间差异多大，怎么画在一张图上
13	物种丰度分布 / 等级-丰度模型	为什么永远是"少数很多、多数很少"
14	组成型数据模型（CLR / 差异丰度）	比例数据的正确打开方式，避免假阳性


D 类 · 群落构建生态模型（怎么解释"为什么是它们"）→ 04-群落构建生态模型.md

#	模型	一句话
15	中性群落模型（Sloan Neutral Model）	假设"全凭运气"，能解释多少？
16	确定性 vs 随机：零模型框架（ β NTI/RCbray）	是环境筛选还是随机扩散在主导？
17	共现网络与关键种模型（SparCC/SPIEC-EASI）	谁和谁共存，谁是"枢纽"物种
18	生物地理：距离衰减与"万物无处不在"模型	越远越不同？还是环境说了算？

E 类 · 功能与生态系统模型（怎么连到碳氮磷循环） → 05-功能与生态系统模型.md

#	模型	一句话
19	生物地球化学循环的功能基因模型	用标志基因量化土壤的碳/氮/磷/硫循环能力
20	结构-功能关系与功能冗余模型	物种变了，功能一定变吗？(冗余 vs 脆弱)

20 个模型如何对应 workflow



给小白的精读优先级

- 第一优先（必懂）：2、3、8、11、12、14、19 —— 不懂这些读不了论文。
- 第二优先（进阶）：5、6、7、9、10、16、17、20。
- 第三优先（拓展）：1、4、13、15、18 —— 理解背景，不必先精通。

从 01-实验与测序模型.md 开始。

A 类 · 实验与测序模型（模型 1–4）

这一类讲"数据是怎么来的"。不懂数据怎么产生，后面所有分析都是空中楼阁。

模型 1 · 中心法则 / "基因即功能潜力"模型

- ① 是什么 分子生物学中心法则：DNA → 转录 → RNA → 翻译 → 蛋白质（酶）→ 执行功能。推论：每一个基因 ≈ 一种潜在功能。一个微生物拥有哪些基因，就大致决定了它"能做哪些代谢"。
 - ② 解决哪个麻烦 原理 1。它是"读 DNA 就能推断功能"这件事的理论依据——没有它，宏基因组数据就只是无意义的字符串。
 - ③ 小白怎么理解 把基因组想成一个人的技能证书清单。看到他有"会计证""驾照""厨师证"，你就知道他能做账、开车、做饭。宏基因组就是在统计一片土里所有微生物的"技能证书"。
 - ④ 关键概念 - 基因 (gene) → 蛋白 → 酶 → 反应：功能注释就是沿这条链反推。 - 功能潜力 (functional potential)：注意是"能做"，不是"正在做"。
 - ⑤ 常见坑 - "有证书 ≠ 正在上班"：基因存在不代表正在表达、正在起作用。要知道"正在干什么"，得用宏转录组 (metatranscriptomics, 测 RNA) 或宏蛋白/代谢组。这是宏基因组最根本的局限，贯穿全库（见思维框架 3）。★
-

模型 2 · 扩增子 vs 鸟枪法宏基因组模型 必懂

- ① 是什么 两种从环境 DNA 获取信息的根本不同策略：

维度	扩增子 Amplicon (16S/18S/ITS)	鸟枪法 Shotgun Metagenomics
测什么	只测一段标志基因 (细菌 16S rRNA、真菌 ITS)	随机打碎、测全部 DNA
能回答	有谁 (物种组成、多样性)	有谁 + 能干什么 (功能、通路、基因)
分辨率	通常到属, 难到种/株	可到种/株, 能拼出基因组(MAG)
成本	低 (适合大样本量)	高 (数据量大、算力贵)
功能	只能间接预测 (PICRUSt2 等, 误差大)	直接测到功能基因
偏差	PCR 引物偏好、拷贝数差异	受 DNA 提取、宿主污染、数据库覆盖影响

② 解决哪个麻烦 原理 2 (DNA 混在一起, 怎么取信息)。这是全领域最重要的一次方法分叉。

③ 小白怎么理解 一个班级 (一片土): - 扩增子 = 只收每个人的身份证号统计 → 快速知道"班里有哪些人、男女比例", 但不知道每个人会什么技能。 - 鸟枪法 = 把每个人的简历全文都收来 → 既知道有谁, 又知道谁会什么, 但贵、读起来累。

④ 怎么选 - 只想知道"群落组成随处理怎么变"、样本量大、预算紧 → 扩增子。 - 想知道"功能/代谢通路/具体基因/恢复基因组" → 鸟枪法。 - 很多研究两者结合: 扩增子铺广度, 宏基因组挖深度。

⑤ 常见坑 - 把扩增子 PICRUSt 预测的功能当成"真实测到的功能"——它只是基于 16S 的统计猜测。 - 16S 拷贝数在不同菌里差很多, 扩增子的"丰度"会被系统性扭曲。 - 误以为"宏基因组样样比扩增子强"——大样本量的生态学问题, 扩增子常更划算。

模型 3 · 测序深度与稀释曲线 (饱和) 模型 必懂

① 是什么 测序深度 (depth) = 一个样本测了多少数据 (reads/碱基数)。稀释曲线 (rarefaction curve): 横轴是抽到的 reads 数, 纵轴是"已发现的物种/基因数"。曲线爬升 → 变平 (饱和) 意味着"再多测也发现不了多少新东西了"。

② 解决哪个麻烦 原理 5 (只是抽样, 可能漏)。它回答一个生死攸关的问题: 我测得够深吗?

- ③ 小白怎么理解 像在一片森林里数鸟的种类。刚开始每走几步都见到新鸟（曲线陡升）；走久了新种越来越少（曲线变平）。没变平说明森林里还有很多种你没遇到——你的"测序深度"不够。
- ④ 关键指标 - 曲线是否到平台期：到了 → 深度足够；没到 → 低估了多样性。 - 土壤因极高多样性，常常测不饱和，这是土壤宏基因组的常态难点（原理 6）。
- ⑤ 常见坑 - 不同样本测序深度不一样就直接比多样性 → 深的样本天然"看起来"物种更多，是假象。要么抽平（rarefy 到相同深度），要么用对深度不敏感的方法。 - 把"没测到"当成"不存在"——可能只是没测够深。

模型 4 · Phred 质量分数与测序错误模型

- ① 是什么 测序仪给每个碱基一个置信度，用 Phred 质量值 Q 表示： $Q = -10 \times \log_{10}(P\text{出错})$ 。
- | Q 值 | 出错概率 | 准确率 |
|-----|--------|-------|
| Q20 | 1/100 | 99% |
| Q30 | 1/1000 | 99.9% |
- ② 解决哪个麻烦 原理 3 的副产品：序列里自带噪声。不先把噪声清掉，后面组装、比对、定量全会被污染（垃圾进、垃圾出）。
- ③ 小白怎么理解 像听一段有杂音的录音，每个字旁边标了"我有多确定听对了"。Q30 ≈ "千里挑一才错一个字"。质控就是把听不清的字和杂音剪掉。
- ④ 关键操作（质控 QC） - 切除低质量碱基/接头（adapter）；过滤过短、低复杂度序列。 - 去宿主/去污染：土壤样本可能混入植物根、动物 DNA。 - 常用工具：fastp、Trimmomatic、KneadData；查看质量报告：FastQC/MultiQC。
- ⑤ 常见坑 - 跳过质控直接分析——新手最常见、最致命的错误。 - 切得过猛把好数据也丢了，或忘记去接头导致组装出现嵌合。 - 忘了去宿主，导致"土壤里查出大量植物基因"的笑话。

下一类：02-生信分析模型.md（序列怎么变成结论）

B 类 · 生信分析模型（模型 5–10）

这一类是"把一堆短序列变成生物学结论"的核心算法思想。不要求会推导，但要懂它们在干什么、输出怎么读、坑在哪。

模型 5 · 序列比对与同源性模型

① 是什么 判断两段 DNA/蛋白序列像不像，从而推断它们是否同源（来自共同祖先）。相似 $\Rightarrow$ 很可能同源 $\Rightarrow$ 功能/身份很可能相近。这是几乎所有"注释"的底层逻辑。

② 解决哪个麻烦 原理 1 + 3：怎么把"未知序列"和"已知数据库"挂上钩，从而推断身份和功能。

③ 小白怎么理解 像搜索引擎：拿一段未知序列去庞大的"已知序列图书馆"里搜最像的几条。找到了高度相似的，就借用它的身份和功能标签。

④ 关键指标 - 相似度 / identity (%)：两条序列有多少位点一样。 - 覆盖度 / coverage：比对上的长度占比。 - E-value（期望值）：这个匹配"纯属巧合"的概率，越小越可信（如 $1e-50$ 远比 $1e-3$ 可靠）。 - 常用工具：BLAST、DIAMOND（快很多，宏基因组首选）、MMseqs2。

⑤ 常见坑 - 只看 identity 不看 coverage/E-value——一小段高相似可能是误导。 - 数据库里没有 $\neq$ 没功能：土壤大量序列比不上任何库（微生物暗物质，原理 6），这部分被默默丢掉，结论天然偏向"已知功能"。

模型 6 · de novo 组装：de Bruijn 图模型

① 是什么 组装（assembly）：把海量短 reads 拼接成更长的连续片段 contig。主流算法用 de Bruijn 图：把每条 read 切成更短的 k-mer，让重叠的 k-mer 首尾相连成图，再在图里找路径拼出长序列。

② 解决哪个麻烦 原理 2 + 3：reads 太短（100–250 bp），装不下一个完整基因/基因组，必须先拼长。

③ 小白怎么理解 像把一本被碎纸机绞碎的书复原：每个碎片 (read) 边缘和别的碎片有重叠的字，靠重叠把它们接回长段落 (contig)。k-mer 就是"用来对齐的那几个重叠的字"。

④ 关键概念 - k-mer 长度：小 k 容易连但易出错/产生假连接；大 k 更准但需要更高深度。 - N50：组装质量常用指标，越大通常越好（一半碱基位于 $\geq N50$ 长度的 contig 中）。 - 常用工具：MEGAHIT（省内存、土壤大数据常用）、metaSPAdes（质量高）；长读长用 metaFlye / hifiasm-meta。

⑤ 常见坑 - 土壤极难组装（原理 6）：多样性高、覆盖度低，大量 reads 拼不进去、contig 短而碎。 - 嵌合 contig：把不同物种的片段错接到一起，会污染后续分箱。 - 近缘菌株多时图里"分叉"严重，组装会断裂。

模型 7 · 分箱 (Binning)：组成 + 丰度聚类模型

① 是什么 分箱：把成千上万条来历不明的 contig，按"它们可能来自同一个基因组"分成一堆堆 (bin)。依据两条信号：1. 序列组成：同一基因组的 contig，四核苷酸频率 (tetranucleotide frequency) 等"文风"相似；2. 丰度共变：来自同一个菌的 contig，在多个样本里丰度同涨同落。

② 解决哪个麻烦 原理 2：组装只把碎片拼成 contig，还是"基因组沙拉"。分箱是把沙拉按物种重新归堆，逼近"一个箱 $\approx$ 一个基因组"。

③ 小白怎么理解 一地撕碎又拼成段落的多本书混在一起。分箱靠两点把它们分开：① 文风（每本书用词习惯不同 = 序列组成）；② 出现规律（同一本书的段落总是一起出现在某几个样本里 = 丰度共变）。

④ 关键概念 - 多个样本一起分箱（差异覆盖度）效果远好于单样本。 - 常用工具：MetaBAT2、MaxBin2、SemiBin2、CONCOCT、binny； - bin 精炼/整合：metaWRAP、DAS Tool；去冗余：dRep。

⑤ 常见坑 - 土壤分箱回收率低：高质量 MAG 占比小，bin 精炼几乎是必需步骤（土壤生信公认难点）。 - 单一分箱工具结果不稳，多工具 + 精炼才靠谱。

模型 8 · MAG 质量评估：单拷贝标记基因模型 必懂

- ① 是什么 分箱产物叫 MAG (Metagenome-Assembled Genome，宏基因组组装基因组)。怎么知道它好不好？用一组通用单拷贝标记基因（每个基因组应当不多不少正好有一份）来估：- 完整度 (completeness)：该有的标记基因找到了多少 → 越高越完整。- 污染度 (contamination)：本应只有一份的标记基因出现了多份 → 说明混进了别的基因组。
- ② 解决哪个麻烦 原理 5 + 6：拼出来的基因组可能残缺或污染，必须有客观质量标准，不能拿垃圾 MAG 下结论。
- ③ 小白怎么理解 像检查拼好的乐高套装：说明书规定每种特殊零件正好一个。- 缺零件 → 不完整 (completeness 低)；- 同一种特殊零件冒出两三个 → 混进了别套 (contamination 高)。
- ④ 关键标准 (MIMAG，业界通用)

等级	完整度	污染度	额外要求
高质量 High-quality	>90%	<5%	含 5S/16S/23S rRNA + ≥18 种 tRNA
中等质量 Medium	≥50%	<10%	—

- 常用质量评估：CheckM / CheckM2、GUNC (查谱系混杂)；
 - 标准化分类：GTDB-Tk (基于 GTDB 基因组分类数据库)。
 - GTDB 物种代表常用质量指数：完整度 - 5×污染度 > 50。
- ⑤ 常见坑 - 拿中低质量 MAG当成完整基因组解读其代谢通路——可能只是没拼到那段。- 只看完整度忽略污染度——高污染会让你"发现"根本不属于它的功能。

模型 9 · 物种分类：k-mer / LCA 模型

- ① 是什么 给每条 read 或 contig 贴"它来自谁"的标签 (taxonomic classification)。快速法 (如 Kraken2)：把序列切成 k-mer，去预建的数据库里查每个 k-mer 属于哪些物种；若一个 k-mer 在多个物种里都有，就归到它们的最近共同祖先 (LCA, Lowest Common Ancestor)。
- ② 解决哪个麻烦 原理 1 的"Who is there?"。在不组装的情况下也能快速出物种谱 (基于读长路线)。

- ③ 小白怎么理解 像通过口音/方言词猜一个人是哪里人：某些词只有特定地区用（物种特异 k-mer）→ 直接定位；某些词好几个地区都用 → 只能说"南方人"（退到更高层级 = LCA）。
- ④ 关键概念 - 基于读长：Kraken2 + Bracken（重估丰度）、MetaPhlAn（标志基因法）——快，但受数据库覆盖限制。 - 基于组装/基因组：GTDB-Tk 给 MAG 做标准化分类——准，但需先组装分箱。 - 分类层级：界→门→纲→目→科→属→种（domain→...→species）。
- ⑤ 常见坑 - 数据库偏差：库里没有的土壤未知菌会被错分或漏分（原理 6）。 - 不同工具/数据库结果不可直接横比（命名体系不同，如 NCBI vs GTDB）。 - 把"未分类比例高"当成数据差——在土壤里这恰恰是常态和真相。

模型 10 · 功能注释：直系同源 / 数据库映射模型

- ① 是什么 给基因贴"它能干什么"的标签（functional annotation）。先用基因预测工具（Prodigal）找出基因，再把蛋白序列比对到功能数据库，借用其中直系同源基因（ortholog，不同物种里由同一祖先基因演化来、功能通常保守）的功能标注。
- ② 解决哪个麻烦 原理 1 的"What can they do?"——把序列翻译成"代谢通路/酶/功能类别"。
- ③ 小白怎么理解 像给一堆零件查标准件目录：把每个零件比对到目录里"已知用途的标准件"，就知道它是螺丝、轴承还是齿轮，进而推断这台机器（群落）能完成哪些工序（代谢通路）。
- ④ 主流功能数据库（按用途）

数据库	看什么
KEGG	代谢通路、KO 功能号（最常用的"通路地图"）
eggNOG	直系同源分组 + 多层功能注释（eggNOG-mapper 很常用）
CAZy	碳水化合物活性酶（GH/GT/PL/CE/CBM）→ 碳降解能力
CARD	抗生素抗性基因（ARGs）→ 土壤抗性组
COG / Pfam	基础功能分类 / 蛋白结构域
NCyc / PCyc / SCyc	氮 / 磷 / 硫 循环专用基因库（见模型 19）

- 常用工具：eggNOG-mapper、DRAM（代谢整合）、antiSMASH（次级代谢/天然产物 BGC）。

⑤ 常见坑 - 仍然是"潜力 $\neq$ 活性" (模型 1 的坑) : 注释到基因不代表它在表达。 - 大量基因功能未知 (hypothetical protein) , 结论系统性偏向"已知功能"。 - 不同数据库对同一功能定义/粒度不同, 跨库比较要谨慎。

下一类 : 03-多样性与统计模型.md (怎么量化和比较)

C 类 · 多样性与统计模型（模型 11–14）

拿到物种谱/功能谱之后，怎么量化一个群落、怎么比较不同处理？这一类是统计的核心，也是论文里图最多的部分。



模型 11 · α 多样性与 Hill 数模型 必懂

① 是什么 α 多样性 (alpha diversity) = 单个样本内部的多样性，包含两个侧面：- 丰富度 (richness)：有多少种（物种数）。- 均匀度 (evenness)：各物种数量是否均衡。

经典指标可用统一的 Hill 数 (qD) 框架表达，由参数 q 控制"对稀有种的重视程度"：

q	对应经典指标	含义
$q=0$	物种丰富度 Richness	只数种类，不管多少（最看重稀有种）
$q=1$	Shannon 的指数 $\exp(H')$	按比例加权（不偏不倚）
$q=2$	Simpson 的倒数 $1/D$	主要反映优势种（最忽视稀有种）

② 解决哪个麻烦 原理 5：把"群落有多丰富"变成一个可比较的数。

③ 小白怎么理解 形容一个班级"多元不多元"：- 丰富度 = 有多少个不同省份的人；- 均匀度 = 是不是某个省占了一大半（不均匀）还是各省差不多（均匀）；- Hill 数的 q = 你统计时"多在乎人数极少的省份"—— q 越小越在乎稀有的。

④ 关键点 - Hill 数单位统一为"有效物种数"，可直接比较，比混用 Shannon/Simpson 更清晰。
- 对测序深度敏感（尤其 $q=0$ ），比较前需抽平或校正（见模型 3 的坑）。

⑤ 常见坑 - 不校正深度就比 α 多样性（最常见错误）。- 只报 Shannon 一个数——优势种和稀有种的变化会被混淆，最好同时看 $q=0/1/2$ 。

模型 12 · β 多样性与排序 (PCoA/NMDS) 模型 必懂

- ① 是什么 β 多样性 (beta diversity) = 样本之间的差异。两步：1. 用距离/相异度量化任意两样本差多少：Bray-Curtis (基于丰度)、Jaccard (基于有无)、UniFrac (考虑进化亲缘)、Aitchison (组成型，见模型 14)。2. 用排序 (ordination) 把高维距离压成二维图：PCoA (主坐标分析)、NMDS (非度量多维标度)。图上点离得近 = 群落像。
- ② 解决哪个麻烦 原理 5 + 实际需求：成百上千个物种没法直接看，必须降维成"一张点图"才能肉眼判断分组。
- ③ 小白怎么理解 给全国城市画"相似度地图"：先算每两座城市的"差异分" (距离矩阵)，再把它们摆到一张平面图上，相似的城市自然聚成一团。PCoA/NMDS 就是这张"群落相似度地图"。
- ④ 关键搭档：显著性检验 - 光看图"好像分开了"不算数，要做统计：PERMANOVA (adonis) 检验分组差异是否显著 (给 R^2 、p 值)；ANOSIM、betadisper (检验组内离散度差异) 等。
- ⑤ 常见坑 - 只看图说"分开了"不做 PERMANOVA——肉眼会骗人。- PERMANOVA 显著 $\neq$ 真有生物学差异，可能是组内离散度不同造成的假象 (要配合 betadisper)。- 距离选择影响结论：有无 vs 丰度、是否考虑进化，要按问题选。
-

模型 13 · 物种丰度分布 / 等级-丰度模型

- ① 是什么 描述"群落里各物种丰度如何分配"。几乎所有自然群落都呈现：极少数物种非常多 (优势种) + 绝大多数物种非常少 (稀有生物圈) ——这就是"长尾"。常用等级-丰度曲线 (rank-abundance) 展示，常用对数正态等分布拟合。
- ② 解决哪个麻烦 原理 6：解释"稀有生物圈 (rare biosphere)"为什么是土壤的常态，以及它为什么重要。
- ③ 小白怎么理解 像一个城市的财富分布：少数富豪掌握大量财富 (优势菌)，绝大多数是收入很低的普通人 (稀有菌)。但"普通人"数量巨大，是社会的潜力和韧性储备——环境一变，原本沉默的稀有菌可能突然"上位"。
- ④ 关键意义 - 稀有生物圈是功能的"种子库/备胎"：平时不显眼，扰动后可被"唤醒"接管功能，提供群落韧性 (与模型 20 功能冗余相关)。- 长尾意味着永远测不完 (呼应模型 3 稀释曲线难饱和)。

⑤ 常见坑 - 分析时把稀有种全部当噪声过滤掉——可能滤掉了重要的功能储备，要按问题谨慎设阈值。 - 组成型偏差会扭曲丰度排序（见模型 14）。★

模型 14 · 组成型数据模型 (CLR / 差异丰度) 必懂

① 是什么 测序数据是组成型 (compositional) 的：只有相对比例、总和固定为 1（原理 4）。直接对比例做常规统计（相关、t 检验）会产生大量假阳性。正确做法是先做对数比变换，最常用 CLR（中心对数比，centered log-ratio）：把每个分量除以样本内所有分量的几何平均再取对数，把“受约束的比例”转回“可正常做统计的空间”。

② 解决哪个麻烦 原理 4——这是新手最容易踩、后果最严重的统计坑。

③ 小白怎么理解 切披萨：每块的“百分比”是被绑死的——一块变大，别块在百分比上必然变小，哪怕它实际没动。直接比“百分比”会得出“它俩此消彼长”的假关系。CLR 相当于不再比“占整张饼的比例”，而是比“每块相对于全体平均的倍数关系”，从而解开这个绑定。

④ 关键工具与方法 - 变换/距离：CLR、Aitchison 距离（= CLR 后的欧氏距离，常用于模型 12 的排序）。 - 差异丰度分析（找出处理间显著变化的物种/基因）：ALDEx2、ANCOM/ANCOM-BC、LinDA、LEfSe 等。

⑤ 常见坑 - 直接用原始比例算 Pearson 相关 → 共现网络全是假边（这也是模型 17 要用 SparCC/SPIEC-EASI 的原因）。 - 零值处理：很多物种丰度为 0，取对数前要加伪计数 (pseudocount) 或专门方法。 - 不同差异分析工具结果常不一致，重要结论最好用 2–3 种方法取交集。

下一类：04-群落构建生态模型.md（怎么解释“为什么是它们”）

D 类 · 群落构建生态模型（模型 15–18）

量化完"有谁、差多少"之后，更深的问题是：为什么是这些微生物？是环境挑出来的，还是纯属运气？谁和谁在一起？这一类是微生物生态学的"解释引擎"。

总纲：Vellend 把群落构建归为四种基本过程——选择（selection，环境/相互作用筛选）、扩散（dispersal，迁移）、漂变（drift，随机生灭）、物种形成（speciation）。下面的模型都是在量化这四种力的相对大小（详见思维框架 4）。

模型 15 · 中性群落模型（Sloan Neutral Community Model）

① 是什么 一个故意"什么都不假设"的零模型：假定所有物种生态上完全等价（没有谁更适应环境），群落只由随机扩散 + 随机生灭（漂变）决定。Sloan 模型用一个参数 m （迁移率）去拟合"物种的出现频率 vs 其在总库中的相对丰度"的关系。

② 解决哪个麻烦 原理 5/6 的延伸：先看看"纯随机能解释多少观测"，没被解释的部分，才需要用"环境选择"去解释。

③ 小白怎么理解 先假设"班级座位完全随机分配"，画出理论上的座位分布。再看真实座位：- 大体符合随机预测 → 说明"运气"主导；- 某些人总是坐第一排（高于随机预测）或总是坐角落 → 说明有"非随机的力"（环境选择）在起作用。

④ 关键参数 - m （迁移/扩散率）：越大说明扩散越畅通、越不受扩散限制。- R^2 ：模型对数据的拟合优度——中性能解释的比例。- 落在中性预测区间外的物种，往往是受确定性选择（环境特别偏好或排斥）的对象。

⑤ 常见坑 - 把"中性拟合得好"误读成"环境不重要"——它只是基线，需配合模型 16 一起下结论。- 数据稀疏、抽样不足会让拟合失真。

模型 16 · 确定性 vs 随机：零模型框架 (β NTI / RCbray) 进阶必懂

① 是什么 当前定量群落构建最主流的框架 (Stegen 等提出)。用系统发育 + 零模型把构建过程拆成可量化的几类：

第一步 β NTI (β -最近种间亲缘指数) ——衡量"环境选择"：| β NTI 取值 | 含义 | 归类 | | --- | --- |
--- | | > +2 | 比随机更"亲缘疏远" | 变量选择 (异质环境筛选) → 确定性 | | < -2 | 比随机更"亲缘相近" | 同质选择 (相似环境筛选) → 确定性 | | -2 ~ +2 | 与随机无显著差异 | 交给第二步判断 → 随机 |

第二步 RCbray (基于 Bray-Curtis 的 Raup-Crick) ——把 β NTI 判为"随机"的那部分再细分：- | RCbray | < 0.95 → 漂变 (drift) 主导；- RCbray > +0.95 → 扩散限制 (迁移太少)；- RCbray < -0.95 → 同质扩散 (迁移太强、各地被"抹平")。

② 解决哪个麻烦 把抽象的"为什么是它们"变成可量化的百分比：例如"本研究中 60% 由同质选择主导、30% 漂变、10% 扩散限制"。

③ 小白怎么理解 判断一个小区为什么住着这些人：- β NTI 先问："是不是房价/学区 (环境) 把特定人群筛进来的？" (确定性) - 若不是，RCbray 再问："那是大家随机搬来搬去 (漂变)？还是交通太差没人搬得进来 (扩散限制)？还是四通八达谁都能来、各小区趋同 (同质扩散)？"

④ 关键工具 - R 包 iCAMP (一体化框架)、picante、ade4、minpack.lm；常和中性模型 (模型 15) 一起报告。

⑤ 常见坑 - β NTI 依赖"系统发育信号" (亲缘近的菌生态位也近) 这一假设，需先检验，否则结论不可靠。- 框架对采样设计、分类分辨率很敏感，结论要谨慎、别过度解读具体百分比。

模型 17 · 共现网络与关键种模型 (SparCC / SPIEC-EASI) 进阶必懂

① 是什么 把"哪些物种倾向于一起出现/此消彼长"画成网络图：节点 = 物种，连线 = 显著的共现/互斥关系。再用网络拓扑找出关键种 (keystone taxa) ——连接度极高的"枢纽 (hub)"节点，它们对群落结构和稳定性影响最大。

② 解决哪个麻烦 从"物种清单"升级到"关系网"，逼近群落里的相互作用与组织结构。

③ 小白怎么理解 像画社交网络：谁和谁总一起出现（朋友圈）、谁和谁从不同框（竞争）。其中"好友极多的网红"（hub）一旦离开，整个圈子可能散架——这就是关键种。

④ 关键方法与指标 - 因为是组成型数据（模型 14），不能用普通相关，要用专门方法：SparCC、SPIEC-EASI（精度更高）、FlashWeave、CoNet。 - 拓扑指标：度（degree）、中介中心性、模块（module）、网络的连通性/稳定性。 - 关键种判定：高度数 + 高中心性 + 在模块间起桥梁作用。

⑤ 常见坑 - 共现 $\neq$ 相互作用：两菌一起出现可能只是都喜欢同一种环境，并非真在"互动"（相关 $\neq$ 因果，思维框架 7）。 - 用普通 Pearson/Spearman 直接建网 $\rightarrow$ 组成型假阳性爆炸。 - "关键种"是统计推断，需实验（如接种、合成群落）验证才能确证。 - 数据过滤、阈值选择会显著改变网络结论，需说明并稳健性检验。

模型 18 · 生物地理：距离衰减与"万物无处不在"模型

① 是什么 研究微生物在空间上如何分布。两个核心命题： - 距离衰减（distance-decay）：地理距离越远，群落相似度越低（斜率反映空间结构强弱）。 - "Everything is everywhere, but the environment selects"（万物无处不在，但环境选择）（Baas Becking）：微生物因数量巨大、易扩散，理论上到处都有；最终谁能立足，由当地环境决定。

② 解决哪个麻烦 原理 6 的空间维度：土壤极端异质，群落差异到底来自地理隔离（扩散限制）还是环境差异（选择）？

③ 小白怎么理解 连锁奶茶店：种子（菌）四处都飘得到（无处不在），但只有符合当地口味/气候的店才开得起（环境选择）。两家店越远口味通常越不同（距离衰减），但到底是"距离"还是"当地条件不同"导致的，要拆开看。

④ 关键发现（呼应案例 1） - 全球尺度研究表明：土壤微生物的基因/群落组成随环境变量（尤其 pH、降水）的变化，常强于随地理距离的变化 $\rightarrow$ 支持"环境选择"在很多情形下占上风。 - 方法上常用 Mantel 检验、方差分解（VPA）区分"空间 vs 环境"的贡献。

⑤ 常见坑 - 空间和环境往往共变（近的地方环境也像），要用统计手段（偏 Mantel、VPA）拆分，别简单归因。 - 尺度依赖：厘米尺度和大陆尺度的主导因素完全不同，结论不能跨尺度套用。

下一类：05-功能与生态系统模型.md (怎么连到碳氮磷循环)

E 类 · 功能与生态系统模型 (模型 19–20)

土壤宏基因组的终极意义，是把"微观的基因"连到"宏观的地球过程"——碳氮磷硫循环、温室气体、土壤肥力、污染修复。这一类是"落地"环节。

★

模型 19 · 生物地球化学循环的功能基因模型 必懂

- ① 是什么 土壤微生物驱动着全球碳 (C)、氮 (N)、磷 (P)、硫 (S) 循环。每一步反应由特定的酶/功能基因催化，所以可以用"标志基因 (marker gene) 的丰度"来量化群落"做某一步"的潜力。这把化学过程翻译成了可在宏基因组里直接统计的基因清单。
- ② 解决哪个麻烦 原理 1 的终点：把"功能潜力"具体化为"这片土固氮/硝化/反硝化/降解纤维素的能力有多强"。
- ③ 小白怎么理解 把土壤微生物群落想成一座化工厂，每条生产线（碳线、氮线…）由若干工序组成，每道工序需要特定"工人证"（功能基因）。数某种工人证有多少，就能估这条生产线的产能。
- ④ 关键标志基因（建议记住几个核心的）

循环	过程	标志基因（示例）
氮 N	固氮	nifH
	硝化（氨氧化）	amoA
	反硝化	nirK/nirS 、 nosZ （产/消 N ₂ O 温室气体）
碳 C	复杂碳降解	CAZy 家族（纤维素酶 GH 等）
	甲烷生成/氧化	mcrA / pmoA
	固碳	rbcL （RuBisCO） 、 accA
磷 P	溶磷/转运/有机磷矿化	phoD 、 pstB 、 phnJ 、 ppk
硫 S	硫氧化/还原	dsrAB 、 soxB

- 专用数据库：NCycDB（氮）、PCycDB（磷）、SCycDB（硫），比通用库注释这些循环更准更全。

⑤ 常见坑 - 永远的"潜力 ≠ 通量"：nifH 多 ≠ 真的固了很多氮。要落到速率，需配合同位素、气体通量、宏转录组等（思维框架 3、7）。 - 同一功能可能有多条通路/多个基因，只盯一个基因会以偏概全。 - 组成型偏差（模型 14）同样影响功能基因的"相对丰度"解读。

模型 20 · 结构-功能关系与功能冗余模型 进阶必懂

① 是什么 回答一个深刻问题：群落的"物种组成（结构）"变了，它的"功能"一定跟着变吗？ - 功能冗余（functional redundancy）：很多不同物种能做同一件事。于是即便物种组成大变，整体功能可能基本不变（系统有韧性）。 - 反之，若某功能只有少数特定物种能做，物种一丢功能就崩（系统脆弱）。

② 解决哪个麻烦 连接 C 类（结构/多样性）与 E 类（功能）：解释为什么"多样性—功能"的关系有时强、有时弱，以及生态系统对扰动的韧性从何而来。

③ 小白怎么理解 一家公司： - 如果很多员工都会做关键工序（冗余高），走掉几个人公司照转（韧性强）； - 如果某关键工序只有一个老师傅会（冗余低），他一走整条线停摆（脆弱）。微生物群落的稳定性，很大程度取决于关键功能的"会做的人多不多"。

④ 关键意义与证据 - 全球尺度研究发现土壤微生物广泛存在功能冗余：物种谱差异巨大，但核心代谢功能谱相对保守。 - 稀有生物圈（模型 13）是冗余的重要来源：平时沉默的稀有菌是功能的"备胎库"，扰动后可被唤醒顶上。 - 实践含义：评估生态系统健康/恢复力，不能只看物种多样性，要看功能多样性与冗余度。

⑤ 常见坑 - 把"功能冗余"绝对化——并非所有功能都冗余，狭窄功能（如某些特化的氮/甲烷过程）常常冗余低、很脆弱。 - 用基因丰度论"功能稳定"时仍受"潜力≠活性"限制。 - "结构变了功能没变"也可能是注释分辨率不够掩盖了真实差异。

20 个模型小结

你现在手里有了一套完整的"思想工具箱"：

A 数据怎么来(1-4) → B 序列变结论(5-10) → C 量化比较(11-14) → D 生态解释(15-18) → E 功能落地

下一步强烈建议： - 用 03-思维框架.md 把这些模型"串成判断力"； - 去 04-案例库.md 看真实研究里这些模型怎么组合使用。

03 · 7 个重要思维框架

模型是“算什么工具”，思维框架是“怎么想的操作系统”。同样的数据，思维框架决定了你是得出可靠洞见，还是被噪声和假象牵着走。这 7 个框架是判断力的来源——比任何单个工具都重要。

#	框架	一句话	防什么错
1	尺度框架	你的问题住在哪一层？	张冠李戴、跨尺度乱套
2	样品到洞见（数据生命周期）	垃圾进，垃圾出	重分析、轻设计
3	结构→功能→过程	能干 ≠ 在干 ≠ 干了多少	把“潜力”当“活性”
4	群落构建四过程	选择/扩散/漂变/形成	“为什么是它们”答不清
5	假说驱动 vs 数据驱动	探索 ≠ 验证	在同一批数据里自我证明
6	对照·重复·可重复	没有对照就没有结论	批次效应、伪发现
7	相关→因果的证据阶梯	相关 ≠ 因果	过度解读相关性

框架 1 · 尺度框架（Scale Thinking）

核心：土壤宏基因组对象横跨多个层级，先想清楚你的问题在哪一层，再选对应的方法。


碱基/序列 → 基因 → 通路 → 基因组(MAG) → 种群 → 群落 → 生态系统 → 全球
(模型4) (模型10) (模型19) (模型8) (模型17) (模型11-18) (模型19-20) (案例1)
↑ 物理空间也分尺度：微团聚体 → 根际 → 土壤剖面 → 田块 → 区域 → 大陆

怎么用：- 问“施肥改变了哪个层级？”——是某个基因丰度（基因层）、某条通路（通路层）、还是整个群落结构（群落层）？层级不同，分析方法和结论都不同。- 警惕跨尺度乱推：厘米尺度主导群落的因素（微环境）和大陆尺度（气候、pH）完全不同，结论不能互相套用（见模型 18 的坑）。

每次开始分析前先问：“我这个问题，住在哪一层楼？”

框架 2 · 样品到洞见：数据生命周期框架（Sample-to-Insight）

核心：结论的可靠性由最薄弱的那一环决定，而最薄弱的往往是最前面、最不“高大上”的环节——采样设计。



怎么用：- GIGO（Garbage In, Garbage Out）：采样没设计好（重复不够、混淆因素没控制、保存不当 DNA 降解），后面再花哨的算法也救不回来。- 看论文时，先翻方法学的前半段（采样与重复设计），那里藏着结论能不能信的关键。- 新手最大误区：把 90% 精力放在“跑哪个软件”，只给采样设计 10%——应该反过来。

"实验设计阶段花的一小时，胜过分析阶段熬的十个夜。"

框架 3 · 结构 → 功能 → 过程框架（多组学阶梯） 最重要

核心：宏基因组只能到“能干什么（潜力）”，到不了“正在干什么”和“干了多少”。想往上爬，要换/加技术。

层级	回答	技术	在测什么
结构 Who	有谁	扩增子 / 宏基因组分类	DNA（身份）
功能潜力 What can	能干什么	宏基因组	DNA（基因）
功能活性 What doing	正在干什么	宏转录组（RNA）、宏蛋白组	RNA / 蛋白
过程/通量 How much	干了多少	代谢组、同位素示踪、气体通量、酶活	代谢物 / 速率

怎么用：- 看到"土壤含大量 `nifH` 基因，固氮能力强"——立刻警觉：这只是潜力，不代表真在固氮。- 想说"功能上调"，至少要有宏转录组；想说"过程加快"，要有速率/通量数据。- 设计研究时主动想：我的结论需要爬到哪一层？就配哪一层的技术。

把"潜力 ≠ 活性 ≠ 通量"刻进脑子。这是审稿人最爱挑、新手最爱犯的问题（呼应模型 1、19）。

框架 4 · 群落构建四过程框架（Community Assembly）

核心（Vellend 综合框架）：任何群落"为什么长成这样"，都可归结为四种基本力的组合：

过程	是什么	类比	对应模型
选择 Selection	环境/相互作用筛选出适应者（确定性）	房价学区筛选住户	βNTI（模型16）
扩散 Dispersal	物种从别处迁入/迁出	交通是否便利	RCbray、m（模型15/16）
漂变 Drift	随机的出生/死亡涨落	纯运气	中性模型（模型15）
物种形成 Speciation	新物种产生（长时间尺度）	本地新移民诞生	进化分析

怎么用：- 面对"这片土为什么是这些菌"，不要只答"因为 pH 高"，而要拆：选择、扩散、漂变各占多少？（用模型 15、16 量化）。- 这是把零散生态现象统一归因的总框架，让你的讨论有结构、不流于罗列。

一句口诀："筛选、迁移、运气、新生"——四个字解释一切群落。

框架 5 · 假说驱动 vs 数据驱动框架 (Hypothesis vs Data-driven)

核心：宏基因组天然产出海量相关性，极易"在数据里找到任何你想找的东西"。必须分清两种模式，不能用同一批数据既生成假说又验证假说。

模式	干什么	风险	正确姿势
数据驱动 (探索)	海里捞针、生成假说	多重比较 → 大量假阳性	当成"线索", 需 FDR 校正
假说驱动 (验证)	检验一个明确预测	事后编故事 (HARKing)	预先注册、独立数据验证

怎么用：- 做了 5000 个基因的差异检验，总有几百个"显著"——必须做多重检验校正 (FDR/BH)，否则全是噪声。- 探索阶段发现的模式，理想情况下用另一批独立样本或实验去验证，而不是在原数据里反复挖。- 写讨论时诚实区分："这是我们发现的相关线索"还是"这是我们验证的假说"。

"在同一锅数据里既出题又判卷" = 自欺欺人。

框架 6 · 对照 · 重复 · 可重复框架 (Controls & Reproducibility)

核心：没有对照和重复的"发现"不是科学发现。宏基因组还有几类特有的混淆来源必须主动防。

三个"复"：1. 生物学重复 (biological replicates)：≥3，缺了无法做统计、无法估变异 (呼应原理 5)。注意区别于"技术重复"。2. 对照 (controls)：处理组 vs 对照组；还要有阴性对照/空白来发现试剂污染 (kitome，提取试剂自带的微生物 DNA，对低生物量样本尤其致命)。3. 可重复 (reproducibility)：记录软件版本、参数、数据库版本；数据与流程公开 (FAIR 原则)，别人能复现。

宏基因组特有的坑 (务必主动控制)：- 批次效应 (batch effect)：不同时间提取/测序/试剂批次会引入系统差异，可能完全盖过真实生物学差异。设计时把处理打散到各批次，别让"处理"和"批次"重合。- 组成型偏差 (模型 14)、测序深度差异 (模型 3) 也是系统性混淆，比较前要校正。

怎么用：看到一篇没有重复、没有阴性对照、不交代批次安排的论文，对其结论大幅打折。

"n=1 不是数据点，是轶事。"

框架 7 · 相关 → 因果的证据阶梯 (Correlation to Causation)

核心：宏基因组绝大多数结果是相关性。从"相关"走到"因果"，需要一级一级往上爬证据。相关 ≠ 因果是这门学科被滥用最多的地方。

- | | |
|---|--------------------------------------|
| 弱 | —— ① 观测到相关 / 共变（某菌随某处理变化） |
| | ② 共现网络关系（模型17：但共现 ≠ 互作） |
| | ③ 功能富集 / 标志基因证据（模型19：但潜力 ≠ 活性） |
| | ④ MAG 层面证据（该基因确属某基因组，链条更完整） |
| | ⑤ 宏转录/宏蛋白/代谢组（证明真在表达/进行，框架3） |
| 强 | —— ⑥ 操控实验验证：接种、敲除、合成群落(SynCom)、同位素示踪 |
| | （微生物组版"科赫法则"，才能谈因果） |

怎么用：- 下"A 菌导致了 B 现象"这类因果结论前，问自己：我的证据爬到了第几级？停在①②③ 就只能说"相关/可能相关"。- 强结论配强证据：越往上越接近因果，但成本也越高。明确你的结论需要爬到哪一级。

"相关给你假设，实验给你结论。"（呼应框架 5、模型 17）

七框架协同：一次"靠谱研究"的内心独白

"我的问题在哪一层（框1）？采样和重复设计够稳吗（框2、6）？我得到的是结构、功能潜力还是真实活性（框3）？群落差异是选择还是随机（框4）？这是探索线索还是验证结论（框5）？我做了对照、校正了批次和组成型偏差吗（框6）？我的证据爬到了因果阶梯的第几级（框7）？"

把这段独白养成习惯，你看论文、做研究的判断力会立刻上一个台阶。

下一步：去 [04-案例库.md](#) 看这些框架和模型在真实研究里怎么组合。

04 · 案例库：10 个真实研究案例

模型和框架是"招式"，案例是"实战录像"。每个案例按统一格式拆解：① 研究问题 ② 怎么做的 ③ 关键发现 ④ 用到了哪些模型/框架 ⑤ 小白能学到什么

案例按"从宏观到方法、从经典到前沿"排列。文末有完整文献链接。

案例 1 · 全球表土微生物组图谱（奠基性大尺度研究）

- ① 问题：全球尺度上，土壤微生物的多样性和功能由什么决定？是地理距离，还是环境？
 - ② 怎么做：跨全球 189 个样点采集表土，结合宏基因组 + 扩增子，刻画细菌、真菌的多样性与基因功能组成。
 - ③ 关键发现：- 细菌（而非真菌）遗传多样性在温带最高；- 微生物基因组成随环境变量的变化，强于随地理距离的变化；- 真菌与细菌存在全球生态位分化，对降水和 pH 的多样性响应相反。
 - ④ 用到的模型/框架：生物地理（模型18）、多样性（模型11/12）、功能注释（模型10）、尺度框架（框架1）、相关→因果（框架7）。
 - ⑤ 学到什么：大尺度上"环境选择"常压过"地理距离"——印证 Baas Becking 的"环境选择"。这是理解土壤微生物生物地理的标杆。
-

案例 2 · 中国陆地生态系统表土微生物组（区域对比）

- ① 问题：中国六大陆地生态系统（森林、草原、荒漠、农田、湿地、喀斯特等）的土壤微生物功能谱有何差异？
- ② 怎么做：采集六大生态系统 41 份表土做宏基因组，比较代谢通路、碳/氮/硫循环基因。

③ 关键发现：- 寡营养环境（荒漠、喀斯特）的代谢通路多样性反而显著更高（资源贫瘠 → 代谢更"全能"以求生存）；- 鉴定出 6 个核心 CAZyme 基因（土壤有机碳降解/合成）、62 个氮循环基因（7 个酶簇）、15 个硫循环基因（3 个酶簇）。

④ 用到的模型/框架：功能基因/生物地球化学（模型19）、CAZy 注释（模型10）、结构-功能（模型20）、尺度框架（框架1）。

⑤ 学到什么："贫瘠 ≠ 功能简单"，反直觉的发现往往最有价值；也展示了如何用循环基因横向对比不同生态系统。

案例 3 · 全球土壤功能冗余（结构-功能解耦）

① 问题：土壤物种组成差异巨大，但功能是否也同样多变？

② 怎么做：基于全球多点宏基因组数据集，比较物种组成（结构）与功能基因组成（功能）在空间上的变异程度。

③ 关键发现：土壤微生物群落存在广泛的功能冗余——物种谱差异大，但核心功能谱相对保守。不同物种"接力"完成相同功能。

④ 用到的模型/框架：功能冗余（模型20）、结构→功能阶梯（框架3）、多样性（模型11/12）。

⑤ 学到什么：评估生态系统韧性不能只看物种多样性，要看功能冗余度；这也是"物种变了功能没变"现象的机制解释。

案例 4 · 长期施肥对碳氮循环功能的影响（农业经典设计）

① 问题：长期施化肥 vs 有机肥，如何改变黑土区土壤碳、氮循环的功能潜力？

② 怎么做：依托长期定位施肥试验（同一地块多年不同施肥处理），对土壤做宏基因组，比较 C/N 循环功能基因丰度。

③ 关键发现：化肥与有机肥导致碳氮循环功能谱分化；有机肥通常富集更多有机质降解和氮转化相关功能；不同处理下固氮/硝化/反硝化基因丰度此消彼长。

④ 用到的模型/框架：氮/碳循环基因（模型19）、差异丰度（模型14）、对照·重复（框架6，长期定位试验是绝佳对照设计）、相关→因果（框架7）。

⑤ 学到什么：长期定位试验是农业土壤研究的黄金对照框架；同时牢记功能基因丰度变化是"潜力"，要落到速率需配套测定（框架3）。

案例 5 · 减少耕作改善根际碳氮磷循能（管理实践）

① 问题：少耕/免耕相比传统耕作，是否改善土壤（本体土与根际）碳、氮、磷循环功能？

② 怎么做：宏基因组对比不同耕作方式下本体土 vs 根际土的 C/N/P 循环功能谱。

③ 关键发现：减少耕作改善了 C/N/P 循环的功能profile；根际与本体土的功能组成存在系统差异（根际效应）。

④ 用到的模型/框架：功能基因（模型19）、尺度框架（框架1：根际 vs 本体土是空间微尺度）、差异丰度（模型14）。

⑤ 学到什么："在哪取样"本身就是一个变量——根际和几厘米外的本体土是不同的世界（呼应框架1、2 的采样设计）。

案例 6 · 氮沉降下荒漠草原的碳氮循环响应（全球变化）

① 问题：大气氮沉降增加，如何影响荒漠草原微生物群落及其碳氮循环功能基因？

② 怎么做：设置不同氮添加梯度，宏基因组追踪群落结构与 C/N 循环功能基因的响应。

③ 关键发现：氮添加重塑群落结构，并改变碳氮循环关键功能基因丰度（如硝化/反硝化相关基因响应明显），揭示荒漠草原对氮输入的敏感性。

④ 用到的模型/框架：氮循环基因（模型19）、梯度实验设计（框架6）、群落构建（框架4）。

⑤ 学到什么：梯度实验（而非简单两组对比）能揭示剂量-响应关系，是研究全球变化驱动因子的有力设计。

案例 7 · 土壤抗性组：抗生素抗性基因的环境分布（One Health）

- ① 问题：土壤里有哪些抗生素抗性基因（ARGs）？它们如何随人为活动（施肥、用药）变化？
 - ② 怎么做：宏基因组 reads/contig 比对 CARD 等抗性数据库，量化抗性组（resistome）组成与丰度，常结合可移动遗传元件（MGE）评估传播风险。
 - ③ 关键发现：土壤是巨大的天然抗性基因库；畜禽粪肥施用等会显著富集 ARGs 并增加其向病原菌水平转移的风险——直接关系食品安全与公共卫生。
 - ④ 用到的模型/框架：功能注释/CARD（模型10）、组成型差异（模型14）、相关→因果（框架7：检出 ARG ≠ 证明传播，需进一步证据）。
 - ⑤ 学到什么：宏基因组的应用远超生态学，直通 One Health（人-动物-环境一体化健康）；也是“功能注释”在公共卫生上的落地。
-

案例 8 · 沿降水梯度跨土壤深度恢复 679 个 MAG（数据资源型）

- ① 问题：能否从不同深度、不同降水条件的土壤中，系统恢复出大量基因组（MAG）？
 - ② 怎么做：沿降水梯度、跨不同土壤深度采样测序，经组装→分箱→质控，恢复出 679 个 MAG，发布为数据资源。
 - ③ 关键发现：得到一批跨深度/气候的 MAG，可用于研究深层土壤、未培养类群的代谢潜力；展示了土壤 MAG 恢复的完整工程化流程。
 - ④ 用到的模型/框架：组装（模型6）、分箱（模型7）、MAG 质量/MIMAG（模型8）、分类 GTDB-Tk（模型9）、尺度框架（框架1：深度梯度）。
 - ⑤ 学到什么：“基因组分辨（genome-resolved）宏基因组”是当前主流方向——不止看基因碎片，而是重建出一个个基因组。也体现了土壤 MAG 恢复之难（需精炼、回收率有限）。
-

案例 9 · 超深度长读长测序挖掘土壤生物合成潜力（前沿技术）

- ① 问题：短读长难以组装土壤复杂群落，长读长能否捕获更完整的基因组和生物合成基因簇（BGC，新药/抗生素来源）？

② 怎么做：对土壤做超深度长读长宏基因组测序，组装出更长更完整的 contig 和 MAG，挖掘其分类与生物合成潜力。

③ 关键发现：长读长显著提升了组装连续性，捕获到更完整的 BGC 和更广的分类/功能多样性——短读长会系统性漏掉这些复杂区域。

④ 用到的模型/框架：组装（模型6，长读长 vs 短读长）、MAG（模型8）、功能注释/antiSMASH（模型10）、尺度框架（框架1）。

⑤ 学到什么：测序技术决定你能看到什么（呼应框架2/3）。土壤难组装的瓶颈，长读长/混合测序是当前突破口；BGC 挖掘把土壤变成"新药矿"。

案例 10 · 群落构建：随机 vs 确定性如何随土壤剖面变化（生态机制）

① 问题：从表层到深层土壤，群落是被"环境选择"主导还是"随机过程"主导？这与代谢有何关系？

② 怎么做：沿土壤剖面采样，用 β NTI/RCbray 零模型框架 + 中性模型量化各层的确定性/随机比例，并与微生物代谢联系起来。

③ 关键发现：群落构建的"确定性 vs 随机"随深度/环境梯度系统变化（常见表层确定性更强、深层随机性上升或扩散限制增强），且与代谢策略耦合。

④ 用到的模型/框架：中性模型（模型15）、 β NTI/RCbray（模型16）、群落构建四过程（框架4）、尺度框架（框架1：深度）。

⑤ 学到什么：把生态学理论（构建过程）与功能/代谢结合，是从"描述现象"走向"解释机制"的范例——这正是高水平研究的特征。

跨案例规律（小白重点）

1. 几乎都靠"对照/梯度"：长期定位试验、降水/氮/深度梯度——好研究先有好设计（框架2、6）。
2. 功能基因是连接微观与宏观的桥：C/N/P/S 循环基因反复出现（模型19）。

3. 反复强调"潜力≠活性"：再前沿的研究也守这条线（框架3）。

4. 方向趋势：read-based 描述 → genome-resolved (MAG) → 长读长/多组学机制。

案例文献链接

1. 全球表土微生物组 · Nature 2018 : <https://www.nature.com/articles/s41586-018-0386-6>
2. 中国陆地生态系统表土微生物组 · Frontiers in Microbiology 2025 : <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC12414936/>
3. 全球土壤功能冗余 · 2022 : <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9108720/>
4. 黑土区长期施肥碳氮功能 · Geoderma 2022 : <https://www.sciencedirect.com/science/article/abs/pii/S0016706122001537>
5. 减少耕作与 C/N/P 循环 · Soil & Tillage Research 2024 : <https://www.sciencedirect.com/science/article/abs/pii/S0167880924004894>
6. 氮沉降下荒漠草原 · Frontiers in Microbiology 2024 : <https://www.frontiersin.org/journals/microbiology/articles/10.3389/fmicb.2024.1369196/full>
7. CARD 抗生素抗性数据库 2023 : <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9825576/>
8. 跨深度降水梯度 679 个 MAG · Scientific Data 2025 : <https://www.nature.com/articles/s41597-025-04884-2>
9. 超深度长读长土壤宏基因组 · GigaScience 2024 : <https://academic.oup.com/gigascience/article/doi/10.1093/gigascience/giaf135/8300805>
10. 土壤剖面群落构建与代谢耦合 · 2020 : <https://pmc.ncbi.nlm.nih.gov/articles/PMC7289589/>

动手分析时查：05-工具与数据库速查.md

05 · 工具与数据库速查

按分析流程的先后顺序排好。小白不必全装全会——先认识"每一步该用什么类的工具"，需要时再深入某一个。 版本/参数以各工具官方文档最新为准；土壤数据量大，多数步骤需要服务器/集群而非个人电脑。

按流程阶段的工具地图

①质控 → ②(可选)组装 → ③分箱 → ④质控/分类/注释 → ⑤丰度定量 → ⑥统计可视化
或 ② 基于读长分类/功能

① 质量控制（QC） — 对应模型 4

工具	用途
fastp	一步搞定切接头、去低质量、出报告（最常用）
Trimmomatic	经典质控/切除
KneadData	质控 + 去宿主一体化
FastQC / MultiQC	查看质量报告（多样本汇总）
Bowtie2 / BWA	比对到宿主基因组以去宿主（如去植物/人 DNA）

② 序列组装 (Assembly) — 对应模型 6

工具	适用
MEGAHIT	省内存、速度快，土壤大数据首选
metaSPAdes	组装质量高，资源消耗更大
metaFlye / hifiasm-meta	长读长 (PacBio/Nanopore) 组装
QUAST / metaQUAST	评估组装质量 (N50 等)

③ 基因预测 & 分箱 (Binning) — 对应模型 7

工具	用途
Prodigal	从 contig 预测基因 (ORF)
MetaBAT2 / MaxBin2 / CONCOCT / SemiBin2 / binny	分箱 (建议多工具并用)
metaWRAP / DAS Tool	bin 整合与精炼 (土壤几乎必需)
dRep	多样本 MAG 去冗余
CoverM	计算 contig/MAG 的覆盖度与丰度

④ MAG 质控 / 物种分类 / 功能注释 — 对应模型 8/9/10

工具	用途
CheckM / CheckM2	MAG 完整度 & 污染度 (MIMAG 标准)
GUNC	检测谱系混杂 (chimerism)
GTDB-Tk	MAG 标准化分类 (基于 GTDB)
Kraken2 + Bracken	基于读长的快速物种分类与丰度重估
MetaPhlAn	基于标志基因的物种profile
eggNOG-mapper	功能注释 (直系同源 + 多层注释)
DRAM	MAG 代谢功能整合注释 (很适合解读循环)
antiSMASH	次级代谢/生物合成基因簇 (BGC) 挖掘
HUMAnN	基于读长的物种+通路功能profile

⑤ 比对/定量

BWA、Bowtie2、minimap2 (长读长)、Salmon、CoverM。

⑥ 统计与可视化（多在 R / Python） — 对应模型 11–18

包	用途
vegan (R)	多样性、距离、PCoA/NMDS、PERMANOVA（生态分析主力）
phyloseq (R)	微生物组数据整合管理与画图
microeco (R)	一体化微生物组分析（中文社区常用）
ALDEx2 / ANCOM-BC / LinDA / LEfSe	组成型差异丰度分析（模型14）
iCAMP (R)	群落构建定量（ β NTI/RCbray，模型16）
SpiecEasi / SparCC	共现网络（模型17）
QIIME2	扩增子为主的一体化平台（也涉宏基因组）
Python: pandas / scikit-bio / scikit-learn /  matplotlib	通用数据科学

主流数据库速查

物种 / 基因组分类

数据库	说明
GTDB	基因组分类数据库，MAG 分类的标准（配 GTDB-Tk）
NCBI nr / nt	最全的核酸/蛋白库（比对兜底）
NCBI RefSeq、SILVA（16S）、UNITE（真菌 ITS）	参考序列 / 扩增子专用

功能注释 (对应模型 10、19)

数据库	看什么
KEGG	代谢通路、KO 功能号 (最常用通路地图)
eggNOG	直系同源分组 + 多层功能注释
CAZy	碳水化合物活性酶 (GH/GT/PL/CE/CBM) → 碳降解
CARD	抗生素抗性基因 (ARGs) → 抗性组
COG / Pfam / TIGRFAM	基础功能分类 / 蛋白结构域
NCycDB / PCycDB / SCycDB	氮 / 磷 / 硫 循环专用基因库 (比通用库更准)
MIBiG / antiSMASH DB	生物合成基因簇 (天然产物)

一体化流程 (小白强烈推荐从这里入门)

流程	特点
EasyMetagenome (易宏基因组)	中文友好, 刘永鑫团队, 含安装/分析/可视化/答疑全套, 配套"宏基因组"公众号与 B 站视频, 最适合中文小白
nf-core/mag	基于 Nextflow 的标准化、可复现 MAG 流程, 社区维护
metaWRAP	经典的基因组分辨宏基因组一体化 (分箱+精炼强)
anvi'o	强大的交互式可视化与精炼平台
ATLAS / MetaflowX / MAGNETO	自动化、可扩展到集群的端到端流程

入门建议：先用 EasyMetagenome 跟着跑通一个完整 demo，建立"从 reads 到结果"的整体感，再逐个深入单个工具。

给小白的现实提醒

1. 算力：土壤宏基因组组装/分箱动辄要几十 GB~上百 GB 内存，需要服务器或云，个人笔记本只够学命令、跑小数据。
 2. Linux + 命令行是基本功；conda/mamba 管理软件环境；学一点 R 或 Python 做统计画图。
 3. 先读长(read-based)后组装(assembly-based)：新手先用 Kraken2/HUMAnN 快速出谱建立直觉，再挑战组装+分箱。
 4. 存好中间文件和参数：可重复性是科研底线（思维框架 6）。
-

遇到不懂的词：[06-术语表与延伸阅读.md](#)

06 · 术语表与延伸阅读

遇到陌生词先查这里。术语按主题分组，附英文，方便读英文文献时对照。

中英文术语表

基础概念

中文	英文	一句话解释
宏基因组学	Metagenomics	直接对环境全部微生物 DNA 测序研究
扩增子	Amplicon	只测某段标志基因（如 16S）的测序方法
鸟枪法宏基因组	Shotgun metagenomics	随机打碎、测全部 DNA
免培养	Culture-independent	不依赖实验室培养的研究手段
微生物组	Microbiome	某环境中全部微生物及其基因/产物的总和
微生物群落	Microbial community	共存于同一环境的微生物集合
功能潜力	Functional potential	基因层面"能做什么"（≠ 正在做）

数据与序列

中文	英文	解释
读长/读段	Read	测序仪输出的一段短序列
重叠群	Contig	由 reads 拼接成的连续长片段
k-mer	k-mer	长度为 k 的短序列子串
测序深度	Sequencing depth / coverage	测了多少数据 / 某位点被覆盖的次数
质量值	Phred quality (Q)	单碱基测序置信度，Q30≈99.9%
组成型数据	Compositional data	只有相对比例、总和固定的数据
抽平	Rarefaction	把样本随机降到相同深度以便比较

分析产物

中文	英文	解释
组装	Assembly	把 reads 拼成 contig
分箱	Binning	把 contig 按来源基因组分堆
宏基因组组装基因组	MAG	从宏基因组分箱重建出的（近似）基因组
完整度 / 污染度	Completeness / Contamination	MAG 质量两大指标（MIMAG 标准）
操作分类单元	OTU / ASV	序列聚类出的"物种"近似单位
直系同源	Ortholog	不同物种中源自同一祖先基因、功能常保守
功能注释	Functional annotation	给基因贴"功能"标签
物种分类	Taxonomic classification	给序列贴"来自谁"标签

生态与统计

中文	英文	解释
α / β 多样性	Alpha / Beta diversity	样本内 / 样本间多样性
Hill 数	Hill numbers	统一多样性指标的框架 ($q=0/1/2$)
排序	Ordination (PCoA/NMDS)	把高维群落差异降维成图
稀有生物圈	Rare biosphere	大量低丰度物种构成的"长尾"
微生物暗物质	Microbial dark matter	无已知基因组可比对的未知类群
功能冗余	Functional redundancy	多个物种能做同一件事
关键种	Keystone taxa	对群落结构/稳定性影响超大的物种
群落构建	Community assembly	群落如何形成 (选择/扩散/漂变/物种形成)
确定性 / 随机过程	Deterministic / Stochastic	环境筛选 vs 随机扩散漂变
中性理论	Neutral theory	假设物种生态等价、由随机主导的模型
β NTI / RCbray	β NTI / RCbray	量化确定性 vs 随机的零模型指标
共现网络	Co-occurrence network	物种共存/互斥关系的网络图
距离衰减	Distance-decay	地理越远群落越不同
批次效应	Batch effect	不同批次操作引入的系统性偏差
多重检验校正	Multiple testing correction (FDR)	控制大量比较带来的假阳性

功能与应用

中文	英文	解释
生物地球化学循环	Biogeochemical cycling	C/N/P/S 等元素在生态系统中的循环
标志基因	Marker gene	代表某功能/分类的指示基因（如 nifH）
抗生素抗性基因	ARG (Antibiotic Resistance Gene)	赋予抗药性的基因，环境健康热点
抗性组	Resistome	一个环境中全部 ARG 的集合
生物合成基因簇	BGC (Biosynthetic Gene Cluster)	合成天然产物/抗生素的基因簇
根际	Rhizosphere	受植物根系影响的土壤微区
水平基因转移	HGT (Horizontal Gene Transfer)	基因在物种间横向传递

几个最常被误解的点（小白避坑）

1. "测到基因 = 有这个功能在运行" —— 只是潜力（框架3）。
2. "丰度高 = 数量多" —— 是相对比例，组成型数据（模型14）。
3. "没测到 = 不存在" —— 可能测序不够深（模型3）。
4. "PCoA 图上分开了 = 有显著差异" —— 要做 PERMANOVA（模型12）。
5. "共现 = 相互作用 = 因果" —— 相关≠因果（模型17、框架7）。
6. "宏基因组比扩增子全面所以总是更好" —— 看问题和预算（模型2）。

延伸阅读与入门资源

中文友好资源（小白首选）

- EasyMetagenome（易宏基因组）流程 · GitHub：<https://github.com/YongxinLiu/EasyMetagenome>
- 论文（iMeta 2025）：<https://news.qq.com/rain/a/20250221A0903Z00>
- 国内镜像 Gitee：<https://gitee.com/yongxinliu/EasyMetagenome>

- 配套 B 站视频（扩增子和宏基因组分析）：<https://www.bilibili.com/video/BV1Hg411G7Fx/>
- "宏基因组"公众号 / iMeta 期刊：大量中文教程、可视化与方法解读。

经典 / 综述文献

- 全球表土微生物组（生物地理奠基）· Nature 2018：<https://www.nature.com/articles/s41586-018-0386-6>
- 稀有生物圈生态 · Nature Reviews Microbiology：<https://www.nature.com/articles/nrmicro3400>
- 功能多样性与冗余综述 · FEMS Microbiology Reviews 2024：<https://academic.oup.com/femsre/article/doi/10.1093/femsre/fuae031/7926968>
- MAG 进展、挑战与生态洞见 · Microorganisms 2025：<https://www.mdpi.com/2076-2607/13/5/985>
- 群落构建确定性 vs 随机框架（综述）· Frontiers 2019：<https://www.frontiersin.org/journals/microbiology/articles/10.3389/fmicb.2019.01536/full>

工具 / 方法

- 比较共现网络指南 · iMeta 2023：<https://onlinelibrary.wiley.com/doi/full/10.1002/int2.71>
- 微生物组归一化与差异丰度分析 · npj Biofilms and Microbiomes 2020：<https://www.nature.com/articles/s41522-020-00160-w>
- CARD 抗性数据库 2023：<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9825576/>
- NEON 土壤宏基因组组装与分析（实操示例）· F1000Research：<https://f1000research.com/articles/10-299>

数据库官网

- GTDB：<https://gtdb.ecogenomic.org/> | KEGG：<https://www.genome.jp/kegg/>
 - eggNOG：<http://eggnogetool.embl.de/> | CAZy：<http://www.cazy.org/> | CARD：<https://card.mcmaster.ca/>
-

建议的学习节奏（4 周入门计划）

周	目标	做什么
第 1 周	建立全局观	读完 01 第一性原理 + 03 思维框架 + 04 案例库
第 2 周	啃核心模型	精读模型 2/3/8/11/12/14/19（必懂优先级）
第 3 周	跑通流程	用 EasyMetagenome 跑一个小 demo（QC→分类→功能）
第 4 周	啃进阶 + 复盘	模型 5-7/9-10/16-17/20 + 用思维框架重读一篇论文

学习是螺旋上升的：第一遍求"懂大意"，第二遍求"会判断"，第三遍求"能动手"。别指望一遍到位。

[回到 知识库总览](#)

07 · 手把手实操教程 · 总览

这个模块带你真的把流程跑起来——从一台空白的 Linux 机器，到最后画出能放进论文的图。面向小白，每条命令都告诉你"这是在干嘛、为什么要这步、跑出来该长什么样"。

先读这段（很重要，能帮你避坑）


- 1. 命令是"教学示例"，不是圣经。生信工具版本、参数、数据库名更新很快。本教程给的是长期稳定的核心用法 + 每个参数的含义，你照着改即可；遇到报错，永远以该工具官方文档/GitHub 最新说明为准。
- 2. 这些步骤需要 Linux + 一定算力。组装/分箱动辄要几十~上百 GB 内存，个人笔记本只够练命令和跑超小数据，真实数据要用服务器或云。没有服务器也没关系——先在小数据上把流程跑通、把每步看懂，比什么都重要。
- 3. 路径、文件名按你自己的改。教程里 `sample`、`~/db` 这种都是占位符。
- 4. 强烈建议先跟 EasyMetagenome（易宏基因组）跑一遍——它是中文的一体化流程，安装/分析/可视化/答疑都有，本教程的思路和它一致，可以对照着用。

实操教程地图（按顺序）

篇	内容	你会得到
01-环境与软件安装.md	装 Linux/conda、装齐工具、下数据库	一个能干活的分析环境
02-质控与读长分析.md	原始数据 → 质控 → 物种谱 + 功能谱	不用组装就能出的第一批结果
03-组装分箱与MAG.md	组装 → 分箱 → MAG 质控/分类/注释	一个个重建出来的基因组(MAG)
04-统计与可视化.md	用 R 做多样性、差异、排序、画图	论文级别的图表
05-常见报错与排查.md	新手最常撞的坑和解法	卡住时的急救手册

一眼看懂：整个流程的"命令骨架"

下面是你接下来几篇会敲的命令的全景缩略图（现在看不懂没关系，跑完回来看就懂了）：



给小白的策略建议

- 先跑"路线甲"（基于读长）：不用组装，快、门槛低，能马上出物种和功能结果，建立成就感和直觉。
- 再挑战"路线乙"（基于组装）：理解了甲再做乙，组装分箱的概念会清楚很多。
- 每一步都先在"超小数据"上跑通：可以拿工具自带的 test data，或把自己的数据用 seqkit head 截一小段，确认命令通了，再上全量。
- 把命令和参数记进一个脚本文件：别在终端里手敲一次性命令。写进 run.sh，可重复、可追溯（思维框架 6）。

开始：01-环境与软件安装.md

07.1 · 环境与软件安装

目标：从零搭一个能干活的分析环境。核心就三件事：① 有个 Linux ② 装 conda 管软件 ③ 用 conda 把工具和数据库装齐。

一、你需要一个 Linux 环境

生信工具几乎都在 Linux 上跑。你有几种选择：

你的情况	建议
有实验室/学校的服务器或集群	最佳，直接用（土壤数据必须靠它）
只有 Windows 电脑	装 WSL2（Win 自带的 Linux 子系统），适合学习练手
只有 Mac	终端是类 Unix，可用；但大数据仍需服务器
啥都没有	用云服务器（按量付费），或先在小数据上学

小白练习用 WSL2 或一台小云主机即可。真实土壤数据 = 服务器，这点改变不了。

检查你在不在 Linux 里、有多少资源：

```
uname -a      # 看系统信息，出现 Linux 就对了
nproc         # 有几个 CPU 核
free -h      # 有多少内存（土壤组装建议 ≥128G，学习够用即可）
df -h        # 硬盘空间（宏基因组很占地，预留几百 G）
```

二、装 conda（软件管家）——强烈推荐用 miniforge / mamba

为什么要 conda？生信工具依赖关系极其复杂（A 工具要 python3.8、B 要 python3.10……）。conda 能为每个项目建独立小房间（环境），互不打架。mamba 是 conda 的加速版，装东西快很多。

```
# 下载并安装 miniforge（自带 conda + mamba，且默认用国内外都友好的 conda-forge 源）
wget "https://github.com/conda-forge/miniforge/releases/latest/download/Miniforge3-Linux-x86_64"
bash Miniforge3-Linux-x86_64.sh      # 一路回车/yes，装完重开终端

# 验证
conda --version
mamba --version
```

国内下载慢的话，给 conda 和 pip 配国内镜像源（清华 TUNA 等），速度会快很多。具体配置搜"conda 清华镜像"。

三、用 conda 建环境、装工具

核心思想：按流程阶段分几个环境，别全堆一个环境里（容易冲突）。下面是一套够用的分组。

```
# 环境1：质控 + 读长分析
mamba create -n qc -c bioconda -c conda-forge \
    fastp fastqc multiqc bowtie2 samtools seqkit kraken2 bracken
# -n qc      给环境起名叫 qc
# -c bioconda -c conda-forge  从这两个频道找软件（生信软件几乎都在 bioconda）

# 环境2：组装 + 分箱
mamba create -n assembly -c bioconda -c conda-forge \
    megahit spades prodigal metabat2 maxbin2 das_tool drep

# 环境3：MAG 质控 + 分类 + 功能注释
mamba create -n annot -c bioconda -c conda-forge \
    checkm2 gtdbtk eggno-mapper

# 用某个环境前先“进房间”，用完“出房间”
conda activate qc      # 进入 qc 环境
fastp --version        # 测一下装好没
conda deactivate       # 退出
```

有些大工具（如 GTDB-Tk、HUMAnN）单独建环境更稳，避免和别人抢依赖。

四、下载数据库（最费时间和硬盘的一步）

工具是“引擎”，数据库是“字典”——没有字典，工具认不出任何序列。数据库通常很大（几十 G 到上百 G），提前下、放在固定目录。

```
mkdir -p ~/db      # 统一放数据库的地方
```

数据库	给谁用	大小量级	说明
Kraken2/Bracken 库	物种分类	几十~几百 G	有 Standard、PlusPF 等预建库可下；越大
GTDB (GTDB-Tk 用)	MAG 标准分类	~100 G	用 GTDB-Tk 自带脚本下，注意版本(如 R220)
CheckM2 库	MAG 质控	几 G	<code>checkm2 database --download</code> 一键下
eggNOG 库	功能注释	几十 G	<code>download_eggnog_data.py</code> 下载
KEGG/CAZy/CARD	功能/碳酶/抗性	视情况	部分需授权或用公开镜像

示例（具体命令以官方为准，这里给你"长什么样")：

```
# CheckM2 数据库
conda activate annot
checkm2 database --download --path ~/db/checkm2

# eggNOG 数据库
download_eggnog_data.py --data_dir ~/db/eggnog -y

# GTDB-Tk 数据库（按官方指示下载对应版本并设置环境变量 GTDBTK_DATA_PATH）
# 下载脚本：download-db.sh，下完 export GTDBTK_DATA_PATH=~/db/gtdbtk/release220
```

数据库下载常常是新手的第一个大坑：慢、断、占满硬盘。建议用 `nohup / screen / tmux` 后台挂着下，别让 SSH 一断就前功尽弃（见第 05 篇）。

五、整理你的数据和目录

养成清晰的目录习惯，未来的你会感谢现在的你：

```
project/
├── raw/          # 原始测序数据 sample_1.fq.gz, sample_2.fq.gz ...
├── clean/        # 质控后的干净数据
├── taxonomy/     # 物种分类结果
├── function/     # 功能注释结果
├── assembly/     # 组装 contigs
├── bins/         # 分箱得到的 MAG
├── results/      # 统计与图
├── scripts/      # 你写的所有 run.sh 脚本（可重复！）
└── db -> ~/db    # 数据库（软链接过来）
```

```
mkdir -p project/{raw,clean,taxonomy,function,assembly,bins,results,scripts}
```

本篇完成检查

- [] `conda activate qc` 能进环境，`fastp --version` 有输出
- [] 三个环境（qc / assembly / annot）都建好了
- [] 至少下好了 CheckM2 和（如果要做读长分类）Kraken2 的库
- [] 建好了清晰的项目目录

下一篇：`02-质控与读长分析.md` ——开始真正处理数据！

07.2 · 质控与读长分析（路线甲：快速出第一批结果）

这一篇你会：把脏数据洗干净 → 不用组装，直接得到"物种谱"和"功能谱"。这是最快见到成果的一条路，适合新手第一次跑。

对应模型：质控=模型 4；物种分类=模型 9；功能注释=模型 10。

第 0 步 · 看一眼原始数据长什么样

测序公司给你的通常是成对的压缩文件（双端测序）：`sample_1.fq.gz`（正向）、`sample_2.fq.gz`（反向）。

```
cd project
zcat raw/sample_1.fq.gz | head -8      # 看前两条 read
seqkit stats raw/sample_*.fq.gz       # 看有多少条、多长、质量如何
```

每条 read 占 4 行：① @ 开头的名字 ② 序列(ATCG) ③ + ④ 质量字符串。看懂这个就够了。

第 1 步 · 质控：洗掉垃圾（fastp）

为什么：原始数据里有接头序列、低质量碱基、太短的 read——不洗掉，后面全是错（垃圾进垃圾出）。

```
conda activate qc
```

```
fastp \  
-i raw/sample_1.fq.gz -I raw/sample_2.fq.gz \      # 输入：正向/反向  
-o clean/sample_1.fq.gz -O clean/sample_2.fq.gz \   # 输出：洗干净的  
-q 20 \      # 质量阈值 Q20（出错率<1%），低于的剪掉  
-l 50 \      # 长度阈值：洗完短于 50bp 的扔掉  
--detect_adapter_for_pe \   # 自动识别并切除接头  
-w 8 \      # 用 8 个线程  
-j clean/sample.fastp.json -h clean/sample.fastp.html # 生成报告
```

怎么看结果：打开 `clean/sample.fastp.html`（浏览器），重点看：- 过滤前后 read 数：掉了多少（掉太多说明数据质量差）；- Q20/Q30 比例：洗后应明显提升；- 接头、重复序列比例。

多个样本想一次看完？用 `multiqc clean/` 把所有报告汇总成一张总表。

第 2 步 · 去宿主（土壤常需去植物/人 DNA）

为什么：土壤样本常混入植物根、动物或操作人员的 DNA。不去掉，你会“在土里查出一堆植物基因”。

思路：把干净 read 比对到宿主基因组，比对上的扔掉，剩下的才是微生物的。

```
# 1) 先把宿主基因组（如某植物）建索引（只需一次）  
bowtie2-build host_genome.fa db/host_index  
  
# 2) 比对，并只保留“没比对上宿主”的 read  
bowtie2 -x db/host_index \  
-1 clean/sample_1.fq.gz -2 clean/sample_2.fq.gz \  
--un-conc-gz clean/sample_nohost_%.fq.gz \   # 没比对上的（=微生物）输出到这  
-p 8 -S /dev/null                          # 比对结果本身不要，丢弃
```

不知道宿主是什么 / 没有明显宿主？可以跳过这步，但要意识到可能有污染。KneadData 工具能把质控+去宿主一步搞定，新手可考虑。

第 3 步 · 物种谱：土里有谁？（Kraken2 + Bracken）

做什么：把每条 read 归到物种（模型 9 的 k-mer/LCA 思想），再用 Bracken 估算各物种的丰度。

```
# Kraken2 分类
kraken2 --db ~/db/kraken2_db \
  --paired clean/sample_nohost_1.fq.gz clean/sample_nohost_2.fq.gz \
  --threads 8 \
  --report taxonomy/sample.kreport \    # 关键输出：各分类层级的统计
  --output taxonomy/sample.kout         # 每条 read 的归属（文件大，可后续删）

# Bracken 重估“种”水平丰度（让丰度更准）
bracken -d ~/db/kraken2_db \
  -i taxonomy/sample.kreport \
  -o taxonomy/sample.bracken \
  -r 150 \      # 你的 read 长度（按实际改）
  -l S          # 估算到 species（种）水平；也可 G=属
```

怎么看结果：taxonomy/sample.bracken 里每行一个物种和它的估计丰度。多个样本各跑一遍后，合并成一张“物种 × 样本”的丰度表，就能进 R 分析了（第 04 篇）。

未分类比例高很正常——土壤大量未知菌（微生物暗物质，原理 6），别慌，这是真相不是 bug。

第 4 步 · 功能谱：这群菌能干啥？（HUMAnN / MetaPhlAn）

做什么：不组装，直接估算样本里有哪些通路/基因家族及其丰度（模型 10）。HUMAnN 会顺带用 MetaPhlAn 出物种谱。

```
# HUMAnN 需要把双端 read 先合并成一个文件输入
cat clean/sample_nohost_1.fq.gz clean/sample_nohost_2.fq.gz > clean/sample_merged.fq.gz

humann --input clean/sample_merged.fq.gz \
        --output function/sample_humann \
        --threads 8
```

主要输出三个表：- *_pathabundance.tsv：通路丰度（最常用，能说“碳/氮代谢通路强不强”）；- *_genefamilies.tsv：基因家族丰度；- *_pathcoverage.tsv：通路完整度。

跑完多样本后，用 humann_join_tables 合并，再 humann_renorm_table 做标准化，就能比较了。

想专门看碳氮磷硫循环基因（模型 19）？常见做法是：把基因预测出的蛋白比对到 NCyc/PCyc/SCyc 等专用库——但那通常基于组装结果，见第 03 篇。

串起来：一个多样本的小脚本

真实项目有很多样本，别一个个手敲。写个循环（存进 scripts/run_qc.sh）：

```
#!/bin/bash
conda activate qc
for s in sampleA sampleB sampleC; do          # 你的样本名列表
    fastp -i raw/${s}_1.fq.gz -I raw/${s}_2.fq.gz \
        -o clean/${s}_1.fq.gz -O clean/${s}_2.fq.gz \
        -q 20 -l 50 --detect_adapter_for_pe -w 8 \
        -j clean/${s}.json -h clean/${s}.html
    kraken2 --db ~/db/kraken2_db --paired clean/${s}_1.fq.gz clean/${s}_2.fq.gz \
        --threads 8 --report taxonomy/${s}.kreport --output /dev/null
    bracken -d ~/db/kraken2_db -i taxonomy/${s}.kreport -o taxonomy/${s}.bracken -r 150 -l 5
done
echo "全部跑完！"
```

```
bash scripts/run_qc.sh          # 一条命令搞定所有样本
```

本篇完成检查

- [] 每个样本都有了 `clean/` 里的干净数据 + fastp 报告
- [] 有了每个样本的物种丰度表 (bracken)
- [] (可选) 有了功能/通路丰度表 (humann)
- [] 把命令写进了 `scripts/` 里的脚本

想更深入 (重建基因组) : 03-组装分箱与MAG.md 想直接出图 : 04-统计与可视化.md

07.3 · 组装、分箱与 MAG（路线乙：重建基因组）

这一篇你会：把碎片拼成长片段(contig) → 把 contig 按物种归堆(分箱) → 得到一个个基因组(MAG) → 给 MAG 质控、分类、注释。这是宏基因组的"硬核"部分，也是最有成就感的部分——你将亲手"复活"一个个从未被培养过的微生物的基因组。

对应模型：组装=模型 6；分箱=模型 7；MAG 质控=模型 8；分类=模型 9；注释=模型 10。

前提：先做完第 02 篇的质控、去宿主，拿到干净 read。

第 1 步 · 组装：把碎片拼成长片段（MEGAHIT）

做什么：把几千万条 read，按重叠关系拼成更长的 contig（模型 6 的 de Bruijn 图）。

```
conda activate assembly

megahit \
  -1 clean/sample_1.fq.gz \
  -2 clean/sample_2.fq.gz \
  -o assembly/sample_megahit \   # 输出目录
  -t 16 \                         # 线程
  --min-contig-len 1000           # 只保留 ≥1000bp 的 contig（短的没分析价值）
# 结果在 assembly/sample_megahit/final.contigs.fa
```

为什么用 MEGAHIT：省内存、快，土壤这种超大数据首选。追求更高质量、内存够 → 可用 `metaspades.py`。

检查组装质量：

```
seqkit stats assembly/sample_megahit/final.contigs.fa
# 关注：contig 数量、总长度、N50（越大通常越好，模型6）
```

土壤极难组装（原理 6）：大量 read 拼不进去、contig 又短又碎、N50 偏低，都很正常，不是你做错了。

进阶：把多个样本一起组装（co-assembly）或分别组装后合并，能帮后面分箱（提供"丰度共变"信号）。

第 2 步 · 预测基因（Prodigal）

做什么：在 contig 上找出一个个基因（开放阅读框 ORF），翻译成蛋白序列，供后面功能注释。

```
prodigal \
-i assembly/sample_megahit/final.contigs.fa \
-a function/sample.proteins.faa \    # 蛋白序列（功能注释要用）
-d function/sample.genes.fna \      # 核酸序列
-p meta                             # 宏基因组模式（关键！多物种混合）
```

第 3 步 · 算覆盖度：为分箱准备"丰度信号"

为什么：分箱要靠"同一基因组的 contig 在各样本里丰度同涨同落"（模型 7）。所以先把 read 比回 contig，算每条 contig 在每个样本的覆盖深度。

```
# 1) 给 contig 建索引
bowtie2-build assembly/sample_megahit/final.contigs.fa assembly/sample_index

# 2) 把每个样本的 read 比回去, 得到排序好的 bam
bowtie2 -x assembly/sample_index \
  -1 clean/sample_1.fq.gz -2 clean/sample_2.fq.gz -p 16 | \
  samtools sort -@ 8 -o assembly/sample.bam
samtools index assembly/sample.bam

# 3) 汇总成深度表 (MetaBAT2 自带工具)
jgi_summarize_bam_contig_depths \
  --outputDepth assembly/sample.depth.txt \
  assembly/sample.bam
```

多样本时, 把所有样本的 bam 都列在最后, 得到"多样本深度表", 分箱效果会好很多。

第 4 步 · 分箱: 把 contig 按物种归堆 (MetaBAT2)

```
metabat2 \
  -i assembly/sample_megahit/final.contigs.fa \      # contig
  -a assembly/sample.depth.txt \                      # 深度表
  -o bins/sample_bin \                                # 输出前缀: 会生成 sample_bin.1.fa, .2.fa ...
  -m 1500 \                                           # 参与分箱的最小 contig 长度
  -t 16
# 每个 bins/sample_bin.N.fa 就是一个候选基因组(MAG)
```

进阶但强烈推荐: 用多个分箱工具 (MetaBAT2 + MaxBin2 + CONCOCT/SemiBin2) 各跑一遍, 再用 DAS_Tool 或 metaWRAP 的 bin_refinement 整合精炼——土壤分箱质量低, 精炼几乎是必需的 (模型 7 的坑)。多样本还要用 dRep 去冗余。

第 5 步 · 给 MAG 质控 (CheckM2)

做什么：评估每个 MAG 的完整度和污染度（模型 8、MIMAG 标准）。

```
conda activate annot

checkm2 predict \
  --threads 16 \
  --input bins/ \           # 放所有 .fa 的目录
  --extension fa \
  --output-directory results/checkm2
# 看 results/checkm2/quality_report.tsv：每个 MAG 的 Completeness 和 Contamination
```

筛选标准（MIMAG）：- 高质量：完整度 >90% 且 污染度 <5% - 中等质量：完整度 ≥50% 且 污染度 <10% - 一个常用综合门槛：完整度 - 5×污染度 > 50

```
# 示例：用 awk 挑出“完整度>50 且 污染度<10”的 MAG 名单
awk -F'\t' 'NR>1 && $2>50 && $3<10 {print $1}' results/checkm2/quality_report.tsv
```

别拿中低质量 MAG 当完整基因组解读它的通路——缺的那段可能只是没拼到（模型 8 的坑）。

第 6 步 · 给 MAG 分类 (GTDB-Tk)

做什么：用标准化的 GTDB 数据库，告诉你每个 MAG 是“门→纲→…→种”的什么（模型 9）。

```
gtdbtk classify_wf \
  --genome_dir bins/ \
  --extension fa \
  --out_dir results/gtdbtk \
  --cpus 16 \
  --skip_ani_screen      # 新版本常需此参数或提供 --mash_db；以官方文档为准
# 结果 results/gtdbtk/*.summary.tsv 里有每个 MAG 的分类
```

第 7 步 · 给 MAG 做功能注释 (eggNOG-mapper / DRAM)

做什么：给 MAG 里的基因贴功能标签 (KEGG/COG/CAZy 等，模型 10)。

```
# 先对某个 MAG 预测蛋白（或用第2步的整体蛋白按 bin 拆分）
prodigal -i bins/sample_bin.1.faa -a bins/sample_bin.1.faa -p single

# eggNOG-mapper 注释
emapper.py \
  -i bins/sample_bin.1.faa \
  -o results/sample_bin.1 \
  --output_dir results/egglog \
  --data_dir ~/db/egglog \
  --cpu 16
# 结果 *.emapper.annotations 里有每个基因的 KEGG KO、COG、CAZy 等注释
```

想系统看 MAG 的代谢全貌 → 用 DRAM (自动整理出碳氮硫等代谢通路表)。想看碳氮磷硫循环基因 (模型 19) → 把蛋白比对到 CAZy / NCyc / PCyc / SCyc 专用库。想挖新药/抗生素生物合成基因簇 BGC (案例 9) → 用 antiSMASH。

这一篇的产物，如何连到结论

```
clean reads
├── megahit → contigs ───┬── prodigal → 蛋白 → egglog/DRAM → 功能表
                        │
                        └── 覆盖度 → metabat2 → MAG ───┬── checkm2 → 质量表
                                                         ├── gtdbtk → 分类表
                                                         └── egglog → 各MAG功能表
全部表 → 进 R (第 04 篇) 做统计、比较、画图 → 结论
```

本篇完成检查

- [] 有了 final.contigs.fa , 看过 N50

- [] 分箱得到一批 bins/*.fa
- [] CheckM2 质量表出来了，会挑高/中质量 MAG
- [] GTDB-Tk 给出了分类
- [] (可选) 做了功能注释

下一篇：04-统计与可视化.md ——把这些表变成图。

07.4 · 统计与可视化（用 R 把表变成图）

前面几步得到的都是"表"（物种丰度表、功能表）。这一篇用 R 把它们变成论文里那些图：多样性箱线图、PCoA 排序图、差异物种图。不用怕 R——你只需会改路径、改分组、跑现成代码块。

对应模型： α 多样性=模型 11； β 多样性/排序=模型 12；组成型差异=模型 14。

一、准备：装 R 和需要的包

```
mamba create -n rstats -c conda-forge -c bioconda \
    r-base r-vegan r-tidyverse r-ape bioconductor-phyloseq \
    r-igraph bioconductor-aldex2
conda activate rstats
R          # 进入 R 交互界面；或用 RStudio
```

中文社区的 microeco、amplicon（刘永鑫团队）等 R 包把很多分析"傻瓜化"了，强烈推荐小白试试。

二、你需要两张表（最常见的输入格式）

1. 丰度表 `feature_table.tsv`：行=物种/功能，列=样本，值=丰度。
2. 分组信息 `metadata.tsv`：行=样本，列里至少有一列是"分组"（如 `group`：施肥 vs 对照）。

```
# feature_table.tsv (示意)
species      sampleA sampleB sampleC sampleD
Bacillus...   120    98    300    280
Pseudomon...  45     60    12     20
...
```

```
# metadata.tsv (示意)
sample  group
sampleA control
sampleB control
sampleC fertilized
sampleD fertilized
```

三、读数据 (R 代码)

```
library(vegan); library(tidyverse)

# 读丰度表：第一列做行名
otu <- read.delim("results/feature_table.tsv", row.names = 1, check.names = FALSE)
meta <- read.delim("results/metadata.tsv", row.names = 1)

# vegan 习惯：行=样本、列=物种，所以转置一下
otu_t <- t(otu)
# 确保样本顺序一致
otu_t <- otu_t[rownames(meta), ]
```

四、 α 多样性：单样本里种类多不多（模型 11）

```
# 抽平到相同深度再比，避免“测得深=多样性高”的假象（模型3的坑！）
set.seed(123)
otu_rare <- rrarefy(otu_t, min(rowSums(otu_t)))

# 算三个常用指标
richness <- specnumber(otu_rare)           # 丰富度 (q=0)
shannon  <- diversity(otu_rare, "shannon") # 香农 (q=1)
simpson  <- diversity(otu_rare, "simpson") # 辛普森 (q=2 方向)

alpha <- data.frame(meta, richness, shannon, simpson)

# 检验两组差异是否显著
wilcox.test(shannon ~ group, data = alpha) # 两组用 Wilcoxon

# 画箱线图
ggplot(alpha, aes(group, shannon, fill = group)) +
  geom_boxplot() + geom_jitter(width = .15) +
  labs(y = "Shannon 多样性", x = "") + theme_bw()
ggsave("results/alpha_shannon.pdf", width = 4, height = 4)
```

五、 β 多样性 + 排序：样本之间差多大（模型 12）

```
# 1) 算 Bray-Curtis 距离（基于丰度的“群落差异分”）
bray <- vegdist(otu_rare, method = "bray")

# 2) PCoA 降维
pcoa <- cmdscale(bray, k = 2, eig = TRUE)
pts <- data.frame(pcoa$points, meta)
colnames(pts)[1:2] <- c("PCoA1", "PCoA2")
var <- round(pcoa$eig / sum(pcoa$eig) * 100, 1) # 每轴解释度

# 3) 画图
ggplot(pts, aes(PCoA1, PCoA2, color = group)) +
  geom_point(size = 3) + stat_ellipse() +
  labs(x = paste0("PCoA1 (", var[1], "%)"),
       y = paste0("PCoA2 (", var[2], "%)")) + theme_bw()
ggsave("results/pcoa.pdf", width = 5, height = 4)

# 4) ★关键★ 别只看图！做 PERMANOVA 检验分组是否真的显著（模型12的坑）
adonis2(bray ~ group, data = meta, permutations = 999)
# 看 R2（差异有多大）和 Pr(>F)（p值, <0.05 才算显著）
```

图上“看起来分开了”不算数，必须 PERMANOVA 显著才能说有差异。再配 `betadisper()` 排除“组内离散度不同”造成的假象。

六、找出差异物种/功能（组成型差异，模型 14）

别用普通 t 检验比比例（组成型陷阱，原理 4）。用专门方法，例如 ALDEx2：

```
library(ALDEx2)
# 输入：原始计数表（行=物种，列=样本），分组向量
conds <- meta$group
x <- aldex(otu, conds, mc.samples = 128, test = "t", effect = TRUE)

# 看结果：wi.eBH = 校正后 p 值；effect = 效应量
sig <- x[x$wi.eBH < 0.05, ]      # 显著差异的物种
head(sig[order(sig$effect), ])
```

ALDEx2 内部用了 CLR 变换（模型 14）处理组成型问题，比直接比比例可靠得多。重要结论最好再用 ANCOM-BC / LinDA 等换一种方法验证，取交集更稳。

七、（可选）共现网络：谁和谁在一起（模型 17）

```
# 思路：用 SpiecEasi（专门处理组成型数据）建网，再用 igraph 画
# install: remotes::install_github("zdk123/SpiecEasi")
library(SpiecEasi); library(igraph)
se <- spiec.easi(as.matrix(otu_t), method = "mb") # 计算量大，先用小数据试
g <- adj2igraph(getRefit(se))
plot(g, vertex.size = 4, vertex.label = NA)
# 找“枢纽”关键种：看度(degree)最高的节点
sort(degree(g), decreasing = TRUE)[1:10]
```

网络对参数/过滤很敏感，共现≠因果（模型17、框架7），结论要谨慎。

出图小贴士

- 存 PDF/SVG（矢量图）放论文，不要存模糊的 PNG。
- 配色用色盲友好方案（如 `viridis`、`RColorBrewer`）。
- 每张图都问自己：它回答了哪个科学问题？（别为画图而画图）

本篇完成检查

- [] 出了 α 多样性箱线图 + 显著性检验
- [] 出了 PCoA 图 + 做了 PERMANOVA
- [] 用 ALDEx2 (或同类) 找出了差异物种/功能
- [] 图都存成了矢量格式

卡住了？看 [05-常见报错与排查.md](#)

07.5 · 常见报错与排查（新手急救手册）

跑流程卡住是常态，不是你笨。这一篇收录新手最常撞的坑和解法。遇到报错，先按这里对号入座。

排错总原则（先做这 4 件事）

- 1. 完整读报错信息：真正的原因往往在最后几行，或带 `Error` / `command not found` / `No such file` 的那行。
- 2. 从小数据复现：用 `test data` 或截一小段（`seqkit head -n 10000`）重跑，快速定位。
- 3. 一次只改一个变量：别同时改 5 个参数，改完不知道哪个起作用。
- 4. 复制报错去搜：把关键那行（去掉你自己的路径）丢进搜索引擎 / 工具的 GitHub Issues，99% 别人遇到过。

一、环境与安装类

报错/现象	原因	解法
<code>command not found</code>	没激活环境，或没装该工具	<code>conda activate <env></code> ； <code>conda list grep 工具名</code> 确认装了
conda 装包卡住/解不开依赖	用了慢的 solver	改用 mamba；减少一次装的包数；分环境装
装包报 <code>PackagesNotFoundError</code>	频道不对	加 <code>-c bioconda -c conda-forge</code>
下载极慢/断	网络	配国内镜像源；用 <code>nohup</code> / <code>tmux</code> 挂后台下

二、数据与格式类

报错/现象	原因	解法
No such file or directory	路径/文件名打错	ls 确认文件真在那；注意相对/绝对路径
双端数据"不配对"报错	R1/R2 顺序或条数不一致	确认 _1 / _2 正确配对；seqkit stats 看条数
中文/空格路径出错	路径有空格或中文	文件和目录名只用英文、数字、下划线
.gz 文件报错	文件下载不完整/损坏	gzip -t file.gz 测完整性；重新下

三、内存 / 资源类（土壤最常见！）

报错/现象	原因	解法
进程被 Killed（无报错直接死）	内存爆了（OOM），土壤组装常见	换更大内存机器；MEGAHIT 比 metaSPAdes 省内存；减少 co-assembly 样本数
跑到一半磁盘满 No space left	中间文件巨大	清理 .bam / 中间文件；换大硬盘；及时压缩
跑得极慢	线程没给够 / IO 瓶颈	加 -t/--threads；数据放本地盘别放网络盘
SSH 一断任务就没了	前台运行	用 tmux / screen / nohup 后台跑（见下）

后台挂任务（必学）：

```
tmux new -s job      # 建一个会话；断网也不丢
# 在里面运行你的长任务...
# 按 Ctrl+b 再按 d 离开 (detach)，任务继续跑
tmux attach -t job    # 下次回来重新接上
```

四、结果"不对劲"类（不报错但结果可疑）

现象	可能原因	怎么办
未分类比例特别高	土壤未知菌多（暗物质）	正常现象（原理6），不是 bug
组装 N50 很低、 contig 很碎	土壤复杂 + 深度不足	正常（原理6）；加深测序、co-assembly 可改善
几乎分不出高质量 MAG	土壤分箱本就难	多工具 + bin 精炼（DAS_Tool/ metaWRAP）；提高深度
"查出大量植物基因"	忘了去宿主	回第 02 篇做去宿主
某物种丰度异常高	可能是宿主/污染/试剂污 染(kitome)	查去宿主、设阴性对照
两组多样性差异巨大	可能是测序深度不同造成 假象	先抽平再比（模型3）
PCoA 图分组完美分 开	可能是批次效应而非生物 学	查样本是否按批次聚集（框架6）

五、统计 / R 类

报错/现象	原因	解法
could not find function	没 library() 加载包，或没装	先 install.packages() / library()
样本对不上、行列错位	丰度表与 metadata 样本顺序/ 名称不一致	用样本名对齐： otu[rownames(meta),]
取 log 出现 -Inf	数据里有 0（组成型零值）	加伪计数，或用 ALDEx2 等自带处 理的方法
PERMANOVA 显著但图 没分开	效应小但稳定，或离散度问题	看 R ² ；配 betadisper

六、什么时候该求助 & 怎么问得到答案

先自己查（搜报错、读官方文档/GitHub Issues），还不行再问。会问问题能极大提高得到帮助的概率：

好的提问 = 我想做什么 + 用了什么命令（贴出来）+ 完整报错（贴出来）+ 软件版本 + 我已经试过什么。 差的提问 = "我的代码报错了，怎么办？"

求助去处：- 工具的 GitHub Issues（最权威，先搜有没有人问过）；- 中文社区："宏基因组"公众号、iMeta、生信技能树等；- EasyMetagenome 的问答部分 专门收录常见问题。

心态提醒

报错和卡壳是这一行的日常，连资深的人每天也在 debug。把每个解决掉的报错记进一个 `notes.md`，半年后你就是别人眼里的"高手"了。

回到 [07 实操教程总览](#) | 想把概念彻底搞懂：[08-难点图解/](#)

08 · 难点图解专版 · 总览

有些概念，第一次看必然懵。这个模块专挑最劝退的几个，用图解 + 一步步拆 + 具体数字例子讲到你“啊原来如此”。这也是对 02-必学模型 里几个硬核模型的深度展开版——模型篇给你“骨架”，这里给你“血肉”。

本模块内容

篇	讲透什么难点	对应模型	为什么难
01-组成型数据与 CLR.md	为什么"比例数据"不能直接算，CLR 到底干了啥	模型 14	反直觉，但最容易出错
02-组装与分箱.md	碎片怎么拼成基因组，k-mer/de Bruijn 图、分箱怎么归堆	模型 6、7	抽象，看不见过程
03-群落构建βNTI与 RCbray.md	怎么判断群落是"环境筛选"还是"运气"，零模型在干嘛	模型 15、16	概念绕，统计黑箱
04-多样性与排序.md	α/β 多样性、距离、PCoA 到底在算什么	模型 11、12	名词多，几何直觉缺失

怎么用这个模块

- 配合模型篇读：先读 02-必学模型 对应模型的概览，再来这里看图解深挖。
- 不必按顺序：哪个概念卡住就读哪篇。
- 跟着数字算一遍：每篇都有“拿具体数字走一遍”的例子，自己拿笔跟着算，比读十遍都管用。

一句话先剧透四个难点的"恍然大悟点"

1. 组成型/CLR：测序给的是"切好的披萨各占几分之几"，不是"披萨多重"。一块变大别块占比必然变小——所以要换成"每块相对全体平均的倍数"来比。
 2. 组装/分箱：组装靠"碎片边缘重叠的字"接龙；分箱靠"文风像 + 在各样本里同进同退"把段落归回各自的书。
 3. β NTI/RCbray：先假设"纯随机"会长啥样，再看真实数据偏离随机多远——偏得多=环境在筛选，偏得少=运气主导。
 4. 多样性/排序： α =一个样本内部多不多样； β =样本两两差多少；PCoA=把"两两差多少"这张大表压成一张能用眼睛看的散点图。
-

从最容易踩坑的开始：01-组成型数据与CLR.md

08.1 · 图解：组成型数据与 CLR（最容易踩的坑）

深扩模型 14。这是新手最容易忽视、后果最严重的统计问题。读完你会彻底明白：为什么不能直接比"百分比"，CLR 又是怎么救场的。

一、问题的根源：你拿到的是"比例"，不是"数量"

回忆原理 4：测序总量是仪器决定的人为上限。所以你永远只知道"谁占百分之几"，不知道"每克土里有多少个"。

打个比方：

真实的土壤（你看不到绝对数量）		测序后你拿到的（只有比例）	
A菌 1000个		A菌 50%	
B菌 600个	总共2000个	B菌 30%	（加起来=100%）
C菌 400个		C菌 20%	
↑ 你想知道这个		↑ 你只能拿到这个	

关键：100% 是一块固定大小的饼。这就埋下了陷阱。

二、陷阱长什么样：一个菌"涨"，逼着别的菌"假跌"

假设从"对照"到"施肥"，只有 A 菌真的暴涨，B、C 的绝对数量根本没变。看看比例会怎样：

	绝对数量（真实）				→ 比例（你看到的）			
	A菌	B菌	C菌	总数	A菌	B菌	C菌	
对照	1000	600	400	2000	50%	30%	20%	
施肥	4000	600	400	5000	80%	12%	8%	← B、C 的“数量”没变！
						↑ ↑ ↑	↑ ↑ ↑	
						但比例却“跌”了！纯属被 A 挤的		

致命后果：如果你只看比例，会得出“施肥让 B、C 菌减少了”——完全错误，它们根本没变。更糟的是，你还会发现 A 和 B/C “此消彼长”，误以为它们之间有“竞争关系”——假的。

这就是组成型数据陷阱：比例之间被“总和=100%”这根绳子绑死了，一个动，其余被动跟着变。直接拿比例做相关、做差异检验、建共现网络，会产生大量假阳性。

三、CLR 怎么救场：不比“占整张饼的比例”，比“相对全体的倍数”

CLR = 中心对数比（Centered Log-Ratio）。它的思路特别朴素：

与其问“A 占整张饼的百分之几”（受总量绑架），不如问“A 相对于这个样本里所有成分的‘平均水平’，是高还是低、高多少倍”（不受绑架）。

三步走（拿上面“施肥”那组的比例 80%、12%、8% 算给你看）：

- 第1步：取每个成分的值

A=80 B=12 C=8 （用比例或计数都行）
- 第2步：算它们的几何平均

几何平均 = $(80 \times 12 \times 8)^{(1/3)}$
= $(7680)^{(1/3)} \approx 19.7$
- 第3步：每个值 ÷ 几何平均，再取对数(ln) ← 这就是 CLR 值

CLR(A) = $\ln(80 / 19.7) = \ln(4.06) \approx +1.40$ （远高于平均→正且大）
CLR(B) = $\ln(12 / 19.7) = \ln(0.61) \approx -0.50$ （低于平均→负）
CLR(C) = $\ln(8 / 19.7) = \ln(0.41) \approx -0.90$ （更低→更负）

为什么这能解开绑定？ - "除以几何平均"= 用样本自己的"内部基准"做参照，不再依赖会乱动的总和。 - "取对数"= 让"涨 2 倍"和"跌到 1/2"在数值上对称 (+0.69 和 -0.69)，符合"比例变化"的本质。

变换之后，CLR 值就回到了普通统计能正常处理的空间——可以算欧氏距离（就是 Aitchison 距离，模型 12 排序常用）、做线性模型、建网络，假阳性大大减少。

四、几何平均？对数？——再用大白话兜一遍

- 为什么用几何平均不用普通平均：比例/倍数的世界里，"乘除"才是自然运算（A 是 B 的 2 倍）。几何平均是"乘除世界"的中心，普通平均是"加减世界"的中心。用错了中心，参照就歪。
- 为什么取对数：把"倍数关系"拉直成"加减关系"。 $\ln(\text{涨}3\text{倍})=+1.1$ ， $\ln(\text{缩到}1/3)=-1.1$ ，一正一负、大小相等——公平。

一句话记住：CLR = "我比这桌菜的平均水平高几倍/低几倍"，而不是"我占整桌菜的百分之几"。前者不受"这桌一共多少菜"影响。

五、还有个小麻烦：零值（很多物种丰度是 0）


取对数前不能有 0 ($\ln(0)$ = 负无穷)。而宏基因组里大量物种在某些样本丰度为 0。怎么办？

- 最简单：加一个很小的伪计数 (pseudocount)，比如所有值 +0.5，再做 CLR。
 - 更讲究：用专门处理零值的方法（贝叶斯估计等）——ALDEx2 等工具内部已经替你处理好了，这也是推荐用现成工具而非手搓的原因。
-

六、落到实操：你该怎么做（对接模型 14、教程 07.4）

你要做的事	别这样	该这样
比较样本整体差异	用比例算欧氏距离	CLR 后算欧氏距离（=Aitchison），或用 Bray-Curtis
找差异物种	比例直接做 t 检验	ALDEx2 / ANCOM-BC / LinDA（内置 CLR 思想）
建共现网络	比例做 Pearson 相关	SparCC / SPIEC-EASI（模型 17）

一图总结



恍然大悟点：测序数据是“切好的披萨占比”，不是“披萨重量”。CLR 把“占整张饼几分之几”换成“相对这桌平均的几倍”，从而挣脱那根绑死所有成分的绳子。

下一难点：02-组装与分箱.md

08.2 · 图解：组装与分箱（看不见的过程，画出来）

深扩模型 6、7。组装和分箱最难点地方在于“看不见过程”。这篇把它画出来，用一句话剧透：组装 = 靠碎片边缘“重叠的字”接龙拼长；分箱 = 靠“文风像 + 在各样本同进同退”把段落归回各自的书。

第一部分：组装——把碎片接成长片段

1. 我们手上有什么？

测序把基因组打碎，得到一堆短 read（每条一两百字母），而且来历不明、还互相重叠：

真实的一段基因组（你不知道）：

A T G C A T T G C A T C G

测序得到的碎片 reads（你拿到的，乱序、重叠）：

read1: A T G C A T

read2: A T T G C A ← 注意和 read1 尾巴有重叠

read3: G C A T C G

2. 核心技巧：k-mer 接龙（de Bruijn 图）

把每条 read 切成更短、长度固定为 k 的小片段（k-mer），让首尾重叠的 k-mer 连起来。这里用 k=4 演示：

把 read 切成 4-mer (每次右移一位) :

ATGCAT → ATGC, TGCA, GCAT

ATTGCA → ATTG, TTGC, TGCA, GCAT ...

让“后3位 = 前3位”的 k-mer 接龙 (重叠部分对齐) :

ATGC

TGCA ATGC → TGCA → GCAT → CATT → ATTG → TTGC ...

GCAT

CATT

...

拼出更长的连续序列 (contig) :

A T G C A T T G C A ...

这就是 de Bruijn 图：每个 k-mer 是一个节点，重叠就连一条边，沿着边走就拼出 contig。计算机能在几亿个 k-mer 里高速做这件事。

3. 为什么 k 的大小是个权衡？

k 太小 → 几乎所有片段都能接上，但“撞车”多：

不同位置碰巧有相同短串 → 接错 → 假连接、图很乱

k 太大 → 接得准，但要求每处都被测到足够多次（高深度）：

深度不够就接不上 → contig 断成一截截

土壤深度常不足 → 这就是它难组装的原因之一（原理 6）。

4. 现实里会断裂的两个“拦路虎”

① 重复序列：基因组里有两段一模一样

...XYZ[重复R]ABC...XYZ[重复R]DEF...

走到重复 R 时，图分叉，不知道该接 ABC 还是 DEF → contig 在此断开

② 近缘菌株：两个很像的菌混在一起

它们的序列时同时异 → 图里大量小分叉（“泡泡”）→ 拼出嵌合或断裂

结论：土壤组装出来又碎又短、N50 低，是正常的，不是你做错了。

第二部分：分箱——把 contig 归回各自的基因组

1. 组装后的窘境

组装把碎片接成了一堆 contig，但它们还是混在一起的——这些 contig 分别来自几百上千个不同的菌，你不知道哪条属于谁：

contig 池（来历不明）：

contig1	contig2	contig3	contig4	contig5	contig6 ...
(?)	(?)	(?)	(?)	(?)	(?)

分箱（binning）的目标：把它们分成一堆堆，让“一堆 $\approx$ 一个基因组（MAG）”。靠两条独立线索：

2. 线索一：序列“文风”（四核苷酸频率）

同一个基因组的 contig，用碱基的“口味/文风”相似——专业说法是四核苷酸频率（tetranucleotide frequency）接近。

打个比方：不同作者写作有不同用词习惯

菌X的 contig：偏爱“GC、CG”组合……	└
菌X的另一条：也偏爱“GC、CG”	└—— 文风一致 → 可能同一个菌
菌Y的 contig：偏爱“AT、TA”组合……	└ 文风不同 → 不同菌

3. 线索二：在多个样本里“同进同退”（丰度共变）

同一个基因组的所有 contig，在某个样本里多，就一起多；在另一个样本里少，就一起少——因为它们本来就是同一个细胞的不同部分。

	样本1	样本2	样本3	样本4	
contigA	90	10	80	5	┌ 四条曲线“同涨同落” └—— → 很可能来自同一个基因组 └
contigB	88	12	82	6	
contigC	91	9	79	4	

contigD	5	85	8	90	← 涨落模式完全不同 → 另一个基因组

这就是为什么"多样本一起分箱"效果好得多：单个样本只有"文风"一条线索；多个样本才能看出"同进同退"，这条线索极强（教程 07.3 第 3 步算覆盖度就是为了它）。

4. 两条线索一合并 → 分出箱子

文风(组成) + 丰度共变模式



▼ 聚类算法 (MetaBAT2 等)




5. 分完还要"质检"和"精炼"

- 质检 (CheckM2, 模型 8) : 每个 Bin 完整吗 (completeness) ? 混进别的菌了吗 (contamination) ?
- 精炼: 单个工具分得不干净, 用 DAS_Tool / metaWRAP 综合多个工具的结果, 去掉混入的 contig、补全——土壤几乎必须做 (模型 7 的坑)。

粗分箱(多个工具各分各的) → DAS_Tool/metaWRAP 取长补短 → 更干净的 MAG → dRep 去重

全流程一图



恍然大悟点：组装是"拼图"（靠边缘重叠），分箱是"把多本被拼好又混在一起的书按文风和出场规律归类"。土壤太厚太杂，所以拼不全、分不净是常态——靠多样本、多工具、精炼来逼近。

下一难点：03-群落构建βNTI与RCbray.md

08.3 · 图解：群落构建 β NTI 与 RCbray（环境筛选还是运气？）

深扩模型 15、16。这套方法概念绕、统计像黑箱。这篇用大白话 + 流程图讲清楚：核心思路只有一句——先算出“如果纯靠运气，结果该长啥样”，再看真实数据离它有多远。离得远=有“看不见的手”（环境筛选）；离得近=运气主导。

一、先想清楚要回答的问题

面对两片土的微生物群落不一样，我们想知道差异是怎么来的？（呼应思维框架 4 的四过程）

群落为什么是现在这样？

- ├— 确定性：环境/相互作用“筛选”出适应者 ← 有“看不见的手”
- ├— 随机性：
 - ├— 漂变：随机生生死死的涨落 ← 纯运气
 - ├— 扩散限制：想来的来不了（太隔离）
 - ├— 同质扩散：到处都能去，各地被“抹平”

难点在于：“随机”长什么样我们没有直觉。所以要先人造一个“纯随机世界”做尺子——这就是“零模型（null model）”。

二、零模型的灵魂：造一把“纯随机”的尺子

零模型 = 在电脑里反复模拟“如果一切都随机”会得到什么，当作比较的基准线。

打个比方——你想知道一枚硬币是不是被做了手脚：

1. 先假设“硬币是公平的”（零模型）
2. 在脑子/电脑里模拟“公平硬币抛100次”很多很多遍
→ 得到“正面次数”的随机分布：大多落在 50 附近，比如 40~60
3. 再看真实硬币：抛100次出了 85 次正面
4. 85 远远落在“公平模拟”的范围之外
→ 结论：这硬币不公平，有“看不见的手”在作弊（=确定性/选择）

群落构建完全是同一个套路，只是把"抛硬币"换成"随机组装群落"，把"正面次数"换成下面的 β NTI / RCbray 两把尺子。

三、第一把尺子：βNTI —— 测“环境筛选”

它在量什么：两片土的微生物，在进化亲缘关系上的差异，比"纯随机组装"预期的更大还是更小。

做法（概念版）：

观测值：真实两群落的“亲缘距离”

随机值：把物种在进化树上反复随机洗牌很多次，得到一堆“随机亲缘距离”

BNTI = 观测值 比 随机值的平均 偏离了多少个“标准差”

怎么读 β NTI (背下这张表即可) :

βNTI 数轴：

$$<-2 \quad \text{-----} \quad -2 \quad \text{=====} \quad +2 \quad \text{-----} \quad >2$$

随机区间

同质选择

(交给第二把尺子)

变量选择

(相似环境筛选)

(差异环境筛选)

↑ 确定性

↑ 确定性

↑ ↑ ↑ 这中间 = 随机, 需要 RCbray 进一步判断


β NTI	含义	归类
$> +2$	比随机更"亲缘疏远" → 不同环境筛出不同类群	变量选择 (确定性)
< -2	比随机更"亲缘相近" → 相似环境筛出相似类群	同质选择 (确定性)
$-2 \sim +2$	和随机没差别	随机 → 进入第二把尺子

四、第二把尺子：RCbray —— 把"随机"再细分

β NTI 判为"随机" ($-2 \sim +2$) 的那些，还能再分是哪种随机。用 RCbray (基于 Bray-Curtis 的 Raup-Crick)：

它问：真实两群落"共有多少物种"，比"随机抽配"预期的多还是少。


RCbray 数轴：



RCbray	含义	归类
$> +0.95$	比随机更"不共有" → 想来的来不了	扩散限制
< -0.95	比随机更"都共有" → 到处都能去、被抹平	同质扩散
$-0.95 \sim +0.95$	和随机没差别	漂变 (纯运气涨落)

五、两把尺子合起来：一张判定流程图

对每一对样本，先用 β NTI、再用 RCbray，归到 5 个类别之一：



最终产出：统计所有样本对落在 5 类的百分比，例如：

本研究群落构建过程构成：

同质选择	45%	└─	确定性合计 60%
变量选择	15%	└─	

漂变	25%	└─	随机合计 40%
扩散限制	10%	└─	
同质扩散	5%	└─	

结论：该土壤群落由“确定性的同质选择”主导，说明相似的环境条件在持续筛选相似的微生物—环境是主要驱动力。

六、动手怎么做（对接模型 16、教程）

- R 包 iCAMP（一体化，最常用）、picante、NST。
- 输入：物种丰度表 + 一棵物种系统发育树（建树是前置步骤）。
- 常和 Sloan 中性模型（模型 15）一起报告，互相印证。

```

# 概念示意（具体见 iCAMP 官方教程）
library(iCAMP)

# 需要：群落表 comm、系统发育距离 pd
result <- icamp.big(comm = comm, pd.desc = pd, ...)

# 输出各群落对在 5 类过程上的比例

```

七、最容易误解的 3 个点

1. "中性/随机拟合得好 $\neq$ 环境不重要"——它只是说"用随机就能解释"，要结合 β NTI 一起下结论。
 2. β NTI 依赖"系统发育信号"假设——用前要检验亲缘近的菌生态位是否真的近，否则结论不可靠。
 3. 别死抠那几个百分比——方法对采样设计、分类分辨率敏感，结论要谨慎，重在"哪类主导"的定性判断。
-

恍然大悟点： β NTI 和 RCbray 不神秘——就是"先用电脑模拟一个纯随机世界当尺子，再量真实数据偏离了多远"。偏得多 = 环境在筛选（确定性）；偏得少 = 运气主导（随机），再细分是漂变、扩散限制还是同质扩散。

下一难点：[04-多样性与排序.md](#)

08.4 · 图解：多样性与排序（ α 、 β 、距离、PCoA 到底在算啥）

深扩模型 11、12。这些词天天见但容易糊。一句话剧透： α = 一个样本内部"多不多样"； β = 样本两两"差多少"；PCoA = 把"两两差多少"这张大表，压成一张能用眼睛看的散点图。

一、 α 多样性：单个样本内部，多不多样？

α 多样性看一个样本里两件事：种类多不多（丰富度） + 均不均匀（均匀度）。

用两个极端例子建立直觉（都是 100 个个体）：

样本甲（很不多样）	样本乙（很多样）
A A A A A A A A A A	A B C D E
A A A A A A A A A A	F G H I J
A A A A A A A A B C	K L M N O ... (20 种, 各 5 个)
种类: 3 极不均匀 → 多样性低	种类: 20 很均匀 → 多样性高

同一份数据，三个指标侧重不同（这是关键！）

指标	在乎什么	对稀有种的态度
丰富度($q=0$)	只数“有几种”	最在乎（来一个算一个）
Shannon($q=1$)	种类 + 均匀度	中立、不偏不倚
Simpson($q=2$)	主要看“优势种”格局	几乎忽视稀有种

为什么要同时看几个：只报 Shannon 一个数，会把"稀有种变化"和"优势种变化"混在一起。三个一起看，才知道差异到底出在哪。这就是 Hill 数 $q=0/1/2$ 框架的意义（模型 11）。

头号大坑：比 α 多样性前必须"抽平"

样本P 测了 100万条 reads → 发现 800 种 ┐ 这不是 P 真的更多样，
样本Q 测了 10万条 reads → 发现 400 种 ┘ 是 P 测得更深、抽到的更多！

正确做法：把所有样本随机"抽平"到相同深度（如都降到10万），再比。

(呼应模型 3 稀释曲线、教程 07.4 的 `rrarefy`)

二、 β 多样性：两个样本之间，差多少？

β 多样性 = 样本与样本之间的差异。第一步要把"差异"变成一个数，叫距离/相异度。

三种最常见的"差异分"

两个样本有哪些物种、各多少：

	A	B	C	D
样本X	10	5	0	0
样本Y	8	0	6	2

① Jaccard (只看"有没有"，不看多少)

X 有 {A,B}, Y 有 {A,C,D}; 共有 {A}=1 个, 共计 {A,B,C,D}=4 个
差异 = $1 - 1/4 = 0.75$

② Bray-Curtis (看"数量"差, 最常用)

按每个物种数量差异综合计算 → 0~1, 越大越不同

③ UniFrac (还考虑"亲缘远近")

差异的两个菌如果亲缘很近, 算"差得少"; 亲缘很远, 算"差得多"

选哪种？想强调"有无" → Jaccard；常规丰度比较 → Bray-Curtis；想纳入进化信息 → UniFrac；组成型严谨 → Aitchison（CLR 后的欧氏距离，见 08.1）。

算完得到一张"两两距离表"（距离矩阵）

	样本X	样本Y	样本Z
样本X	0	0.62	0.71
样本Y	0.62	0	0.45
样本Z	0.71	0.45	0

样本一多，这张表就是个大方阵——人眼根本看不出规律。于是需要第三步：排序。

三、排序（PCoA/NMDS）：把大表压成一张散点图

目标：把"高维的两两距离"压到二维平面上，让"表里距离近的样本，图上点也近"。这样你一眼就能看出哪些样本聚成一团。

一张看不懂的距离大表（ $N \times N$ 个数字）

PCoA / NMDS（降维）

一张二维散点图（ N 个点）

PCoA2



解读：同色点聚在一起、两组分开 = 处理改变了群落

- PCoA：尽量忠实保留"真实距离大小"。坐标轴会标"解释了百分之几的差异"。
- NMDS：只保留"谁离谁近的排名"，更适合非线性；看 stress 值（ <0.2 才算可信）。

头号大坑：眼睛会骗人，必须做统计检验

图上“看起来分开了” ≠ 真的有显著差异！

必须做 PERMANOVA (R 里的 `adonis2`)：

- R^2 = 分组能解释多少差异（效应大小）
- p 值 = 这种分开是不是碰巧（要 <0.05 ）

再做 `betadisper`：排除“是组内离散度不同造成的假分开”

(对接模型 12、教程 07.4 第五步)


四、 α 和 β ，别搞混（一张对照）

	α 多样性	β 多样性
看的对象	一个样本内部	样本与样本之间
回答	“这片土自己多不多样”	“两片土差多少”
产物	一个数（每样本一个）	一个距离矩阵 → 一张排序图
典型图	箱线图	PCoA/NMDS 散点图
关键坑	比之前要抽平	只看图不做 PERMANOVA

记忆法： α 是“自己跟自己比丰不丰富”， β 是“你跟我差多远”。

从数据到图，一条线

物种丰度表



恍然大悟点： α 是"一个样本内部多不多样"， β 是"样本两两差多少"。距离矩阵是中间产物，PCoA 只是把这张人看不懂的大表"拍扁"成一张散点图。图给你直觉，PERMANOVA 给你结论——缺一不可。

回到 08 难点图解总览 | 想要速查卡：[../09-速记卡片与速查图.md](#)

09 · 速记卡片与速查图

把最常用的阈值、流程、工具、基因、口诀做成一张张"看一眼就懂"的卡片。用法：贴在桌前 / 收藏，做分析、读论文、想不起来时扫一眼。详细解释点各卡片里的链接。

卡片 1 · 关键数字/阈值速查（最高频）

场景	指标	记住的数	含义	出处
质控	Phred Q 值	Q20=99% , Q30=99.9%	单碱基准确率	模型 4
组装	N50	越大越好	组装连续性	模型 6
MAG 高质量	完整度/污染度	>90% / <5%	+ 含 5S/16S/23S+≥18 tRNA	模型 8
MAG 中质量	完整度/污染度	≥50% / <10%	可用下限	模型 8
MAG 综合门槛	质量指数	完整度-5×污染度 >50	GTDB 常用	模型 8
群落构建	βNTI	βNTI >2 = 确定性	>2变量选择/<-2同质选择	模型 16
群落构建	RCbray	RC >0.95 = 非漂变	>.95扩散限制/<-.95同质扩散	模型 16
统计显著	p 值	<0.05	PERMANOVA/检验显著线	模型 12
排序可信	NMDS stress	<0.2	越小越可信	模型 12

卡片 2 · 分析流程命令骨架（照着改）

原始数据 *_1.fq.gz / *_2.fq.gz

| ① 质控 fastp -i .. -I .. -o .. -O .. -q 20 -l 50 --detect_adapter_for_pe

| ② 去宿主 bowtie2 -x host --un-conc-gz clean_%.fq.gz ..

└─ 路线甲(快):

| 物种谱 kraken2 --db DB --paired r1 r2 --report a.kreport

| bracken -d DB -i a.kreport -o a.bracken -r 150 -l S

| 功能谱 humann --input merged.fq.gz --output func/

└─ 路线乙(深):

 组装 megahit -1 r1 -2 r2 -o asm/ --min-contig-len 1000

 预测基因 prodigal -i contigs.fa -a prot.faa -p meta

 覆盖度 bowtie2.. | samtools sort ; jgi_summarize_bam_contig_depths

 分箱 metabat2 -i contigs.fa -a depth.txt -o bins/bin

 质控 checkm2 predict --input bins/ -x fa --output-directory ck/

 分类 gtdbtk classify_wf --genome_dir bins/ --out_dir gt/ -x fa

 功能注释 emapper.py -i prot.faa -o out --data_dir ~/db/egglog

→ 全部表进 R : vegan(多样性/PCoA/adonis2) + ALDEx2(差异) + SpiecEasi(网络)

详见 07-实操教程/

卡片 3 · 工具速查（按流程阶段）

阶段	首选	备选
质控	fastp	Trimmomatic, KneadData
去宿主	Bowtie2	BWA, KneadData
组装	MEGAHIT(省内存)	metaSPAdes(高质量), metaFlye(长读长)
基因预测	Prodigal	—
分箱	MetaBAT2	MaxBin2, CONCOCT, SemiBin2
分箱精炼	DAS_Tool / metaWRAP	—
去冗余	dRep	—
MAG 质控	CheckM2	CheckM, GUNC
MAG 分类	GTDB-Tk	—
读长物种	Kraken2+Bracken	MetaPhlAn
读长功能	HUMAnN	—
功能注释	eggNOG-mapper	DRAM, KEGG, CAZy
BGC 挖掘	antiSMASH	—
统计画图	R: vegan/phyloseq	microeco, QIIME2
差异丰度	ALDEx2	ANCOM-BC, LinDA, LEfSe
共现网络	SPIEC-EASI	SparCC
群落构建	iCAMP	picante, NST
中文一体化	EasyMetagenome	nf-core/mag, anvi'o

详见 05-工具与数据库速查.md

卡片 4 · 标志基因速查 (碳氮磷硫循环)

循环	过程	标志基因
氮 N	固氮	nifH
	氨氧化(硝化)	amoA
	反硝化	nirK/nirS , nosZ (管 N ₂ O)
碳 C	复杂碳降解	CAZy 家族(GH 等)
	产/氧化甲烷	mcrA / pmoA
	固碳	rbcL , accA
磷 P	溶磷/转运/矿化	phoD , pstB , phnJ , ppk
硫 S	硫还原/氧化	dsrAB , soxB

专用库：NCyc(氮) / PCyc(磷) / SCyc(硫)。详见 模型 19

卡片 5 · 决策速查 (我该选哪个?)

扩增子 还是 宏基因组?

只要“有谁”、样本多、预算紧 → 扩增子(16S/ITS)

要“能干啥/基因/基因组” → 鸟枪法宏基因组

读长(read-based) 还是 组装(assembly-based)?

快速出物种/功能谱、新手起步 → 读长(Kraken2/HUMAN)

要重建基因组(MAG)、挖新基因 → 组装+分箱

α 多样性比较前 → 一定先抽平!

看 PCoA 分组 → 一定做 PERMANOVA!

找差异物种 → 用 ALDEx2, 别用普通 t 检验!

建共现网络 → 用 SPIEC-EASI/SparCC, 别用 Pearson!

卡片 6 · 20 个模型一句话索引

#	模型	一句话
1	中心法则/基因即潜力	基因=能干什么的清单
2	扩增子vs宏基因组	查身份证 vs 读简历
3	测序深度/稀释曲线	测够深没？没饱和=漏了
4	Phred质量	Q30=99.9%，先质控
5	比对/同源	像不像→同不同源，看E-value
6	de Bruijn组装	碎片靠重叠接龙
7	分箱	文风+丰度共变归堆
8	MAG质控	单拷贝标记测完整/污染
9	k-mer/LCA分类	特异k-mer定身份
10	功能注释	比数据库借功能标签
11	α 多样性/Hill	样本内多不多样($q=0/1/2$)
12	β 多样性/排序	样本间差多少→PCoA
13	丰度分布	少数很多+多数很少(长尾)
14	组成型/CLR	比例要变换，防假阳性
15	中性模型	纯随机能解释多少
16	β NTI/RCbray	确定性 vs 随机定量
17	共现网络	谁和谁一起，谁是枢纽
18	生物地理	环境选择常胜过距离
19	循环功能基因	标志基因量化C/N/P/S
20	功能冗余	物种变功能不一定变

详见 02-必学模型/

卡片 7 · 7 个思维框架口诀

#	框架	口诀
1	尺度	"我的问题住哪层楼？"
2	数据生命周期	"垃圾进，垃圾出；设计>分析"
3	结构→功能→过程	"能干≠在干≠干了多少"
4	群落构建四过程	"筛选、迁移、运气、新生"
5	假说vs数据	"别在同一锅数据里又出题又判卷"
6	对照·重复	"n=1 不是数据，是轶事"
7	相关→因果	"相关给假设，实验给结论"

详见 03-思维框架.md

卡片 8 · 新手避坑清单（贴脑门上）

- | | |
|-----------------|--------------------------|
| × 测到基因 = 正在发挥作用 | → 只是潜力(框架3) |
| × 比例高 = 数量多 | → 组成型数据(模型14/图解08.1) |
| × 没测到 = 不存在 | → 可能测不够深(模型3) |
| × 一起出现 = 有因果关系 | → 相关≠因果(模型17/框架7) |
| × 跳过质控直接分析 | → 先 fastp(模型4) |
| × 不抽平就比多样性 | → 先 rarefy(模型3/11) |
| 只看PCoA图说"分开了" | → 做PERMANOVA(模型12) |
| 比例直接做t检验/相关 | → ALDEx2/SparCC(模型14/17) |
| 忘了去宿主 | → 否则"土里全是植物基因" |
| 不控批次效应 | → 处理打散到各批次(框架6) |

这张卡片集是"压缩包"。看不懂某条，就点链接去对应章节"解压"。先求会查，再求会用，最后求会判断。

[回到 知识库总览](#)

10 · 前沿模型与方法 · 总览

前面 1–9 讲的是主流必会的内容。这个模块带你看正在快速发展的前沿——它们大多是"他山之石"：把 AI、系统生物学、物理(Hi-C)、化学(同位素)等其它领域的利器，搬来攻克宏基因组的老大难问题。

双重提醒：① 前沿 = 变化快，本模块讲"思想和代表工具"，具体实现以最新文献为准；② 你仍是小白，所以每个前沿我都会先讲"它解决了基础篇里的哪个痛点"，把新东西挂到你已有的知识树上。

一句话先看懂：每个前沿在补哪块短板

基础篇留下的痛点	前沿用什么补	在本模块哪篇
原理6：大量序列比不上数据库（暗物质）	AI 基础模型：直接从序列预测结构/功能	01
模型7：土壤分箱难、质粒/噬菌体不知属于谁	Hi-C 邻近连接：用物理接触把碎片归到同一个细胞	02
几乎没讲的一整个维度：病毒/噬菌体	病毒组 + CRISPR：找出病毒并锁定它感染谁	02
框架3：潜力 ≠ 活性（基因有≠在干活）	qSIP 同位素探针：直接测"谁真的在生长"	03
模型17：共现≠ 真实互作	群落代谢模型(GEM)：模拟谁喂谁、谁抢谁	03

看出来了吗？前沿不是另起炉灶，而是精准地补基础篇每一个"做不到"。这就是为什么要先打好 1–9 的底子。

本模块内容

篇	前沿主题	借了谁的"石"
01-AI与基础模型.md	基因组/蛋白质语言模型、照亮暗物质、ML 预测应用	人工智能 / 深度学习
02-Hi-C邻近连接与病毒组.md	Hi-C 分箱、质粒/噬菌体定主、土壤病毒组	染色体构象(物理)、病毒生态
03-从基因潜力到活性与互作.md	qSIP 稳定同位素探针、群落代谢建模 GEM	同位素化学、系统生物学

前沿的总趋势（记住这条主线）

第一代

描述“有谁/有什么基因”

(read-based, 模型 9/10)

|

第二代

重建基因组、看清个体

(genome-resolved / MAG, 模型 6-8)

|

第三代

看清“真在干活的是谁、怎么互动”

(qSIP / 多组学 / 代谢模型, 本模块 + 模块11)

|

未来

用 AI 理解“暗物质”、预测、乃至设计

(基础模型 / 生成式, 本模块 01)

一句话：从"谁在"→"谁能"→"谁在干"→"谁和谁怎么干"→"AI 看懂并预测"。

从最热的开始：01-AI与基础模型.md

10.1 · AI 与基础模型：用人工智能照亮"暗物质"

他山之石 = 人工智能 / 深度学习。这是宏基因组最火的前沿。一句话剧透：就像 ChatGPT 学了海量文本后会"理解"语言，"基因组/蛋白质语言模型"学了海量生命序列后，能"理解"DNA 和蛋白——于是它能给那些比不上任何数据库的"暗物质"序列，猜出结构和功能。

补的痛点：原理 6（大量土壤序列是暗物质）、模型 10（功能注释只能注释"已知"的）。

一、先回忆痛点：暗物质问题

基础篇反复说过：土壤里大量序列比不上任何已知数据库（微生物暗物质）。传统功能注释（模型 10）的逻辑是"去字典里查"——字典里没有，就只能标成"功能未知（hypothetical protein）"，白白丢掉。

土壤、海洋里的蛋白，绝大多数我们只知道它的氨基酸序列，对它的结构和功能一无所知——这就是"蛋白质暗物质"。

传统方法的死穴：只能认识"见过的"。而 AI 的突破点恰恰是：它能对"没见过的"做出有根据的推测。

二、关键思想：把"序列"当成"语言"来学

类比（重要，理解这个就懂了一半）：

自然语言模型(如 ChatGPT)		生命序列模型
学海量文本	→	学海量 DNA / 蛋白序列
学会"语法、语义、上下文"	→	学会"序列里的规律、约束、功能模式"
能续写、改写、回答	→	能预测结构/功能、补全、甚至"设计"新序列

为什么这招对生命序列管用？因为进化本身就是一种“语言”：能存活下来的序列不是随机的，它们遵循深层规律（哪些位点能变、哪些必须保守）。模型从亿万条序列里自己悟出这些规律，于是面对新序列也能举一反三。

行话：这类模型叫“基础模型 / 预训练大模型 (foundation model)”——先在海量数据上自监督预训练，再用到各种下游任务。

三、两大类模型（小白只需记住“是什么、能干啥”）

A. 蛋白质语言模型（Protein Language Model）—— 照亮蛋白暗物质

- 代表：ESM 系列（如 ESMC，训练于约 28 亿条来自全生命的序列）、配套的结构预测 ESMFold；以及大名鼎鼎的 AlphaFold。
- 能干啥：直接从氨基酸序列预测三维结构和功能，不需要做实验。
- 对宏基因组的意义：ESM 宏基因组图谱（ESM Metagenomic Atlas）已经预测了 6 亿以上蛋白的结构，其中绝大多数来自环境样本（土壤、海洋）的“暗物质”蛋白——这是 AlphaFold 早期数据库里大片空白的部分。等于给暗物质蛋白第一次“拍了照片”。

一条来自土壤、谁都不认识的蛋白序列

| 传统：比数据库 → 查无此人 → 标“功能未知”，丢弃

|

└ AI：蛋白质语言模型 → 预测出三维结构 → 看它长得像哪类酶
→ “它的结构像水解酶” → 给出功能线索

B. 基因组/核酸语言模型（Genomic / DNA Language Model）—— 读懂 DNA 本身

- 代表：Evo / Evo 2（能从分子到整个基因组尺度建模、甚至生成序列）、Nucleotide Transformer、专为环境序列的 GenomeOcean、用于病原监测的宏基因组基础模型 METAGENE-1。
- 能干啥：直接在 DNA 层面预测功能元件、基因调控、变异影响，甚至生成式设计新的基因/基因组片段。
- 对宏基因组的意义：处理那些连基因边界都难界定的环境序列；为合成生物学、新酶/新功能挖掘开路。

四、另一条 AI 应用线：机器学习做"预测"（很实用的他山之石）

除了"读懂序列"，AI 还能把微生物组数据当成特征，去预测现实结果——这是离应用最近的一类。

典型应用（都是真实研究方向）：- 用土壤微生物组预测土壤健康指标（有研究数值评分预测 R^2 约 0.8）；- 预测作物产量、病害（如马铃薯产量与病害）；- 预测土壤对病原菌的抑制能力（disease suppressiveness）；- 宏基因组关联分析（MWAS）：像 GWAS 找致病基因那样，找"和某性状相关的微生物/基因"。

常用方法：随机森林（Random Forest，最常用、好上手）、支持向量机、梯度提升、深度学习等。

小白须知的坑：- "人的决策"极大影响结果：怎么预处理、怎么标准化、特征怎么选，会显著改变预测表现——有研究专门指出"机器学习里的人为上限"。- 能预测 $\neq$ 懂机制：模型说"这些菌和高产相关"，不代表它们导致高产（相关 $\neq$ 因果，框架 7）。预测和机制是两回事。- 样本量小、维度高（物种成千上万）时极易过拟合，必须交叉验证、独立测试集。

五、和你已有知识的连接（别把它当孤立新知识）

基础篇概念	AI 怎么升级它
模型 5 比对/同源（查字典）	从"查见过的" $\rightarrow$ AI"理解没见过的"
模型 10 功能注释	暗物质蛋白也能给出结构/功能线索
模型 7 分箱（深度学习已进场）	SemiBin2 等已用深度学习做更好的分箱
原理 6 暗物质	从"承认未知" $\rightarrow$ "尝试照亮未知"

六、给小白的态度建议

- 不必现在就会训练大模型——那是另一个深坑。先理解"它能做什么、不能做什么"。

- 会"用"比会"造"更实际：很多模型有现成的网页/接口（如查 ESM Atlas 里某蛋白的预测结构）。
- 保持清醒：AI 给的是有根据的推测，不是真理。结构预测、功能预测、产量预测，都需要实验或独立数据验证（框架 7）。

延伸阅读

- Evo：分子到基因组尺度的序列建模与设计 · <https://pmc.ncbi.nlm.nih.gov/articles/PMC12057570/>
- 基因组语言模型综述 · Frontiers in Genetics 2025 · <https://www.frontiersin.org/journals/genetics/articles/10.3389/fgene.2025.1634882/full>
- ESM 宏基因组蛋白结构图谱 · <https://esmatlas.com/about>
- 用机器学习与组学解析土壤 C/N/P 循环的环境调控 · JGR Biogeosciences 2025 · <https://agupubs.onlinelibrary.wiley.com/doi/full/10.1029/2024JG008470>
- "机器学习中的人为上限"：用土壤微生物组预测马铃薯产量与病害 · <https://pubmed.ncbi.nlm.nih.gov/39592933/>

下一前沿：02-Hi-C邻近连接与病毒组.md

10.2 · Hi-C 邻近连接 与 病毒组

两个前沿放一篇，因为它们都在补"归属"的短板：Hi-C 帮你把碎片(尤其质粒/噬菌体)归到正确的细胞；病毒组+CRISPR 帮你把病毒归到它感染的宿主。他山之石：染色体构象捕获(物理/分子生物学) + 病毒生态学。

第一部分 · Hi-C 邻近连接：用"物理接触"分箱

一、先回忆痛点

模型 7 说过：分箱靠"序列文风 + 丰度共变"两条间接线索，土壤分箱又难又不准，而且质粒、噬菌体这类游离 DNA 根本不知道属于哪个菌。

有没有更直接的证据，证明"这两段 DNA 来自同一个细胞"？有——看它们在细胞里是不是物理上挨在一起。

二、核心思想：在细胞被打碎前，先把"邻居"焊在一起

Hi-C / 邻近连接 (proximity ligation) 的巧妙之处：

普通宏基因组：先打碎细胞 → DNA 各自分离 → 谁和谁原来在一个细胞里，信息丢了
(所以分箱只能靠间接线索)

Hi-C：① 先用化学"胶水"把细胞内物理上靠近的 DNA 片段"焊"在一起(交联)
② 再打碎、测序
③ 测到"被焊在一起的两段" = 它们原来在同一个细胞里！(直接证据)

打个比方：

普通方法像把一栋楼炸了再去猜哪些砖原属同一户。Hi-C 像先给每户人家拍一张"全家福"再拆楼——谁和谁一家，一目了然。

三、它能做到普通分箱做不到的事

1. 更准的分箱：用"物理接触频率"把 contig 聚类，质量更高（尤其复杂的土壤）。
2. 给质粒/噬菌体"定主"：游离的质粒、整合的噬菌体，能凭"和谁焊在一起"找到它的宿主基因组——这是普通分箱完全做不到的。
3. 抗药基因溯源：抗性基因常在质粒上(案例7)，Hi-C 能告诉你"这个抗药质粒在谁体内"，对追踪传播极有价值。

四、代表工具

- bin3C、MetaTOR、MetaCC：基于 Hi-C 接触数据做分箱；
- ViralCC：专门从 Hi-C 数据里回收病毒基因组并锁定病毒-宿主配对。

代价：需要额外做一个 Hi-C 文库（实验更复杂、更贵），所以目前多用于重点研究而非常规普查。

第二部分 · 病毒组：被忽视的"隐形操盘手"

一、一个被基础篇略过的整片大陆

前面 1-9 几乎只讲细菌/古菌/真菌。但土壤里还有海量病毒（主要是噬菌体，即感染细菌的病毒），数量常比细菌还多。它们是生态系统的"隐形操盘手"：

病毒在土壤里干三件大事：

- ① 杀手：感染并裂解细菌 → 控制谁多谁少（“病毒打洞”塑造群落）
- ② 搬运工：在不同菌之间搬运基因（水平基因转移，含抗药基因！）
- ③ 改造者：携带“辅助代谢基因”，临时改写宿主代谢（影响碳氮循环）

不看病毒，等于研究一座城市却无视了所有的“流行病和物流”。

二、难点：病毒是“暗物质中的暗物质”

病毒没有像 16S 那样的通用标志基因，演化又快，导致：- 数据库覆盖极低，绝大多数土壤病毒序列无法注释（病毒暗物质）；- 怎么从一锅宏基因组里认出哪些 contig 是病毒，本身就是难题。

常用识别工具：geNomad、VirSorter2、CheckV（评估病毒基因组完整性）等。

三、关键问题：这个病毒感染谁？——CRISPR 间谍档案

最妙的招数是借用细菌自己的“免疫记忆”——CRISPR。

细菌的 CRISPR 系统会把“入侵过自己的病毒”的一小段 DNA（叫 spacer/间隔序列）存进自己的基因组，当作“通缉档案”，下次照着抓。

于是反过来：

- 如果某细菌基因组里的 CRISPR 档案(spacer) ←匹配→ 某病毒序列
- 说明这个病毒曾感染过这个细菌
- 我们就锁定了“病毒-宿主”配对！

打个比方：CRISPR spacer 就像细菌手机里存的“骚扰来电黑名单”。我们翻遍所有细菌的黑名单，就能反推“这个病毒打过谁的电话”。

现状：CRISPR spacer 比对是宿主预测的主力之一（某工具在已知数据上召回率约 49%、精确率约 69%），常与“前噬菌体扫描”“序列同源”等方法联用。还有像 ViralCC（Hi-C 法）从物理接触角度定宿主——两条路互相印证。

四、和你已有知识的连接

基础篇概念	病毒组怎么扩展它
三个核心问题(有谁/能干啥/为啥)	加上"谁在被谁控制"这一层
案例7 抗性组	病毒/质粒是抗药基因传播的载体
模型19 循环功能	病毒辅助代谢基因会临时改写宿主的碳氮代谢
 原理6 暗物质	病毒是暗物质里最暗的一块

延伸阅读

- MetaTOR : 基于 Hi-C 的高质量分箱 · <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC6710406/>
- bin3C / Hi-C 宏基因组分箱 (GitHub metaTOR) · <https://github.com/koszullab/metaTOR>
- 土壤深度剖面的病毒-宿主互作 · mBio 2023 · <https://journals.asm.org/doi/full/10.1128/mbio.02246-23>
- 用 CRISPR spacer 预测病毒宿主、破解病毒暗物质 · <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8034630/>
- VIRE : 行星尺度病毒组资源 · Nucleic Acids Research · <https://academic.oup.com/nar/article/54/D1/D902/8356007>

下一前沿： 03-从基因潜力到活性与互动.md

10.3 · 从"基因潜力"到"活性与互作"

这一篇直击全库最核心的两条遗憾：① 框架3 的"潜力 $\neq$ 活性"——基因有，不代表在干活。② 模型17 的"共现 $\neq$ 互作"——一起出现，不代表真有来往。前沿用两件利器分别补上：qSIP（同位素探针）测"谁真在生长" + 群落代谢模型（GEM）算"谁喂谁、谁抢谁"。

第一部分 · qSIP：直接测"谁真的在干活"

他山之石：稳定同位素化学。这是把"潜力"变"活性"的最优雅的招数之一。

一、痛点回顾

宏基因组测的是 DNA，只能告诉你"有能力"（框架3）。一个菌哪怕早就死了或在睡觉，它的 DNA 还在，照样被你测到。所以你永远分不清：这片土里，到底谁是"活跃打工人"，谁是"躺平的尸体"？

二、核心思想：让活跃的菌"自己变重"

稳定同位素探针（SIP, Stable Isotope Probing）的绝妙之处：

- ① 给土壤喂“重”食物：比如用 ^{13}C （比普通 ^{12}C 重）标记的葡萄糖，或 ^{15}N 标记的氮源。（同位素=同种元素的“重版本”，无放射性、安全）
- ② 谁活跃、谁生长，就会把这些“重原子”吃进去、用来造自己的新 DNA
→ 活跃菌的 DNA 变“重”了；躺平/死亡的菌 DNA 还是“轻”的。
- ③ 用超高速离心按“密度”把 DNA 分层：重的沉下去，轻的浮上面。
- ④ 只把“重”的那层拿去测序（宏基因组）
→ 测到的，就是“真正在生长、在利用这种食物”的活跃菌！

打个比方：

给整个城市发“带荧光的特制餐”。谁真在吃饭干活，身上就会发光；谁在装死，就不发光。我们只把发光的人挑出来登记——这些才是真正的活跃劳动力。

三、qSIP（定量版）让它更强

qSIP（quantitative SIP）进一步定量：通过 DNA “变重了多少”，算出每个基因组的生长速率/活性。结合宏基因组，就能做到：

- 把“身份”+ “功能”+ “真实活性”三者锁在一起——这是宏基因组单独做不到的圣杯。
- 例：研究证明土壤湿度如何影响哪些菌真正活跃（而不只是“存在”）。

四、和你已有知识的连接

想知道	单靠宏基因组	加上 qSIP
土里有谁		
谁能固氮(有 nifH)	潜力	
谁真在生长/固氮	测不出	活性

qSIP 是“爬证据阶梯”(框架7)、跨越“潜力→活性”(框架3)最有力的实验手段之一。

第二部分·群落代谢模型（GEM）：算出"谁喂谁、谁抢谁"

他山之石：系统生物学 / 代谢工程。把单个细胞的代谢网络，拼成整个群落的"经济模型"。

一、痛点回顾

模型17 的共现网络只能说"A 和 B 总一起出现"，但说不清它们到底在干嘛——是 A 把废料喂给 B（互利），还是它们抢同一种食物（竞争）？共现≠互作。

二、核心思想：给每个菌建一张"代谢地图"，再让它们"做生意"

基因组尺度代谢模型（GEM, Genome-scale Metabolic Model）：

- ① 拿一个基因组(MAG)，根据它有哪些酶基因，
重建出它的全套代谢反应网络 = 一张"这个菌能把什么变成什么"的地图。
- ② 把群落里多个菌的代谢地图拼到一起，
模拟它们共享同一锅"培养基"时会发生什么：
 - A 的废料(如乙酸)正好是 B 的食物 → 交叉喂养(cross-feeding, 互利)
 - A 和 B 都要抢同一种氮源 → 竞争
 - 谁离了谁活不下去 → 依赖
- ③ 用数学(通量平衡分析等)算出：谁能长、长多快、谁喂谁、谁抢谁。

打个比方：

给城里每个工厂画一张"进什么原料、出什么产品"的工艺图，再把它们接成一张产业链/经济网络，就能推演谁是上游供货、谁在抢原料、谁倒闭后整条链会不会断。

三、代表工具（小白只需知道名字和分工）

工具	干啥
CarveMe	快速从基因组"雕刻"出代谢模型（分钟级）
gapseq	更精细地重建模型（含补漏 gap-filling）
MICOM	群落层面模拟，可做"敲除某菌看影响"
SMETANA	专门推断成员间的代谢互作(交叉喂养/竞争)
metaGEM	把"宏基因组→建模→互作推断"串成流程

四、用处与坑

用处：从"统计相关"升级到"机制假说"——预测出"A 可能在喂 B"，再去做实验验证（接种、合成群落 SynCom）。

坑：- 模型基于"基因→反应"的自动推断，MAG 不全/注释有误 → 模型就不准（垃圾进垃圾出）。- 预测的是"代谢上可能发生什么"，仍是假说，不是实测，要验证(框架7)。- 土壤 MAG 质量普遍偏低(模型8)，给建模带来额外不确定性。

两件利器在"证据阶梯"上的位置（呼应框架7）

观测相关 → 共现网络 → 【GEM 代谢模型：给出互作机制假说】
→ 富集/标志基因(潜力)
→ 【qSIP / 宏转录组：证明真在活动(活性)】
→ 操控实验(接种/合成群落)：坐实因果

弱

本篇要义：qSIP 把"潜力"变成"实测的活性"；GEM 把"共现"变成"可检验的互作机制"。两者都不是取代宏基因组，而是站在它的肩膀上，往因果再走一步。

延伸阅读

- qSIP + 宏基因组：把微生物活性与土壤湿度联系起来 · mSystems · <https://journals.asm.org/doi/10.1128/msystems.00417-22>
- SIP 宏基因组标准化定量分析策略 · <https://pubmed.ncbi.nlm.nih.gov/37377419/>
- 群落尺度代谢建模综述 · <https://pmc.ncbi.nlm.nih.gov/articles/PMC10832553/>
- 自动化重建群落代谢模型的比较 · npj Systems Biology 2024 · <https://www.nature.com/articles/s41540-024-00384-y>

回到 模块10总览 | 升维到整合思想： [../11-多组学整合与他山之石/README.md](#)

11 · 多组学整合 与 他山之石 · 总览

这个模块回答你最关键的两个直觉：① "宏基因组是不是简单/基础版的组学？" —— 是"底层基础层"，但绝不"简单"。要看清全貌，得往上叠加其它组学层。这就是 01-组学阶梯与多组学整合.md。② "有没有他山之石？" —— 太多了！别的生态系统(海洋、肠道)、别的学科(生态学、网络科学、系统生物学、AI)都有现成的利器可借。这就是 02-他山之石.md。

一、先纠正一个常见误解

"宏基因组 = 简单版的组学" "宏基因组 = 组学阶梯的最底层、最基础那一级（测 DNA = 潜力）；它是地基，不是简化版。"

为什么说它是"地基"而非"简化版"？

- 它在功能链的最底端：DNA(能干什么) → RNA(在表达什么) → 蛋白(造出了什么) → 代谢物(产出了什么)。宏基因组测的是最稳定、最基础的 DNA 层，所以是其它一切的起点。
- 但它一点都不简单：土壤宏基因组的组装、分箱、暗物质，是全生物学最难的计算问题之一(原理6、模型6-8)。
- "基础"恰恰是它的价值：地基打得好，上面才能叠 RNA、蛋白、代谢物的楼层——这就是"多组学整合"。

一句话：宏基因组是多组学大厦的地基。地基不简单，而且没有地基，楼盖不起来。

二、本模块内容

篇	讲什么	回答你的哪个问题
01-组学阶梯与多组学整合.md	组学阶梯(DNA→RNA→蛋白→代谢物)总览、为什么宏基因组是地基、怎么往上叠、整合难点	"是不是简单版组学"
02-他山之石.md	入门：向海洋(Tara)、肠道、EMP 借经验；向生态学、网络科学、系统生物学、AI 借方法	"有没有他山之石"
03-各类组学详解.md	详解每一层组学：宏转录组/蛋白组/代谢组/表观组逐一展开 + 抗性组/移动组等子组学	"和组学的关系"(详)
04-从组学领域借方法.md	能在组学借鉴的：GWAS→MWAS、单细胞分辨、空间组学、UMAP/批次校正等	"能在组学借鉴的"
05-他山之石进阶.md	他山之石进阶：更多生态系统(极端/植物/古DNA) + 更多学科(博弈论/流行病学/因果推断/地统计…)	"他山之石"(扩充)

阅读建议：先 01 (总览) → 想深入组学关系看 03 → 想借方法看 04 → 想看更广的跨界看 02 + 05。

三、一图看懂"地基 + 楼层 + 外援"



先把"地基"在大厦里的位置看清：01-组学阶梯与多组学整合.md

11.1 · 组学阶梯与多组学整合

正面讲透你的问题：宏基因组在所有"组学"里到底是什么地位？为什么说它是地基不是简化版？怎么往上叠出完整图景？

一、组学阶梯：从"能干"到"真干了"的四级台阶

回忆中心法则(模型1)：DNA → RNA → 蛋白质 → 代谢/功能。每一步，都对应一种"组学"。它们构成一道阶梯，越往上越接近"到底发生了什么"：

台阶	组学(meta-)	测什么分子	回答	离"真相"多远
地基	宏基因组 Metagenomics	DNA	群落能干什么(潜力)	最基础
2 楼	宏转录组 Metatranscriptomics	RNA	此刻在表达哪些基因(活性)	更近
3 楼	宏蛋白组 Metaproteomics	蛋白质	真的造出了哪些酶/蛋白	又近
顶楼	代谢组 Metabolomics	代谢物	最终产出/消耗了哪些物质(结果)	最接近真相

用一个人来类比这四级：

宏基因组(DNA) = 简历上的“技能证书” → 他会做饭、会开车、会编程（潜力）

宏转录组(RNA) = 他今天的“待办清单” → 今天打算做饭（正打算干）

宏蛋白组(蛋白) = 他手里“正用的工具” → 真的拿起了锅铲（真在干）

代谢组(代谢物) = 桌上“做好的菜” → 一盘红烧肉（干出的结果）

这就是为什么宏基因组"基础但不简单"：它是最底层的"技能清单"，是理解其余一切的前提——但只看简历，你永远不知道他今天到底做没做饭。这正是框架3"潜力≠活性"的根源。

二、为什么"地基"既是优点也是局限

优点（为什么总从宏基因组做起）：- DNA 最稳定、最好测、信息最全（连不活跃的、罕见的都能记录）；- 能重建基因组(MAG)、建立"谁有什么家底"的完整名册；- 是其它组学的参照地图——比如宏转录组测到的 RNA，要先比对到宏基因组的基因目录才知道"这是谁的、什么基因"。

局限（为什么不能只停在这）：- 只到"潜力"，到不了"活性/结果"(框架3)；- 不知道随时间、随刺激的动态变化(DNA 相对稳定，RNA 才灵敏)。

所以："先用宏基因组打地基（谁在、有什么家底），再用上层组学看动态（谁在干、干出了什么）。"

三、多组学整合：把几层楼"对齐"着看

多组学整合 (multi-omics integration) = 对同一批样本同时测多个层级，再把它们联合分析，得到单一组学给不了的因果链条。

一个真实范例（土壤）：有研究整合了基因组解析的宏基因组 + 宏转录组 + 代谢组，去追踪雪融时土壤微生物"暴发"所利用的氮来源——

宏基因组：哪些菌、带哪些氮代谢基因(潜力)

+

宏转录组：雪融时这些氮基因是否被大量表达(活性)

+

代谢组：氮代谢物的实际变化(结果)

→ 拼出完整证据链：是“谁”、用“什么基因”、把“什么氮”变成了“什么”

这条链，任何单一组学都给不出——这就是整合的威力。

四、整合到底难在哪（小白要有心理准备）

多组学不是“多测几样拼一起”那么简单，难点很现实：

难点	说明
尺度/单位不同	基因丰度、RNA 表达量、代谢物浓度，量纲完全不同，不能直接相加
数据稀疏/缺失	不同组学测到的成员不一样，对不齐
时间错位	DNA 稳定、RNA 几分钟就变——采样时机稍差就对不上
统计陷阱	维度爆炸 + 组成型(模型14)，假相关风险更高
因果仍需实验	整合给出更强的相关链，但坐实因果还得操控实验(框架7)

常用整合方法：相关网络、典型对应分析、降维(如多组学因子分析 MOFA)、机器学习等——但先把每个单组学做扎实，再谈整合，否则是“垃圾 × 垃圾”。

五、给小白的路线建议

- 第1步：把宏基因组(地基)学扎实 ← 你正在做的事(本库 00-09)
- 第2步：理解上层组学“能补什么” ← 本篇
- 第3步：需要“活性/动态”时，加宏转录组
- 第4步：需要“真实产物/通量”时，加蛋白组/代谢组 + 同位素(qSIP, 见10.3)
- 第5步：多组学整合，但永远记得“整合≠因果，实验才坐实”

本篇要义：宏基因组是组学大厦的地基——基础、稳固、不可或缺，但也“只是地基”。看清生命活动的全貌，要顺着 DNA→RNA→蛋白→代谢物这道阶梯往上叠。这不是因为它“简单”，而是因为它“基础”。

延伸阅读

- 土壤 meta-omics：现状、挑战与应用 · <https://www.sciencedirect.com/science/article/abs/pii/S2405985425000904>
- 多组学揭示雪融期土壤微生物暴发的氮动态 · Nature Microbiology 2025 · <https://www.nature.com/articles/s41564-025-02213-2>
- 用 meta-omics 解析生物地球化学(观点) · EGU sphere 2025 · <https://egusphere.copernicus.org/preprints/2025/egusphere-2025-1716/egusphere-2025-1716.pdf>

下一篇：02-他山之石.md ——向别的领域借智慧

11.2 · 他山之石：向别的领域借智慧

"他山之石，可以攻玉"——别人山上的石头，能用来打磨自己的玉。土壤宏基因组的很多突破，不是自己凭空想出来的，而是从其它生态系统、其它学科借来的。这一篇告诉你：去哪借、借什么、怎么用。

分两类：向其它生态系统借经验 + 向其它学科借方法。

第一类 · 向其它生态系统借经验

海洋、人体肠道等微生物组研究，常常走在土壤前面（样本更易标准化、投入更大）。它们趟过的路、建好的方法，土壤可以直接借。

1. 海洋：Tara Oceans —— "大科学 + 大数据"的范本

- 它做了什么：全球航行采样，分析了数十万亿碱基的宏基因组，建成含4000 多万条非冗余基因的海洋微生物基因目录，并把分子数据和环境数据(温度、深度…)系统整合，开创"生态系统生物学"。
- 土壤能借什么：
- 标准化采样 + 配套环境元数据的范式(呼应框架2：好设计>好分析)；
- 建"参考基因目录"的思路——先建大目录，后续研究都来比对；
- 把群落数据和环境梯度联合建模的分析框架(呼应模型18 生物地理)。

2. 人体肠道：方法学的"练兵场"

人体微生物组(尤其肠道)投入巨大，很多分析方法在这里成熟后流向土壤：

肠道先行的方法	土壤如何借用
菌株级分辨(strain-level，区分同种不同株)	用于追踪土壤里特定功能菌株、抗药株
微生物组关联分析(类 GWAS)	找"和土壤健康/产量相关"的微生物(见10.1 ML)
多组学整合 + 机器学习做预测	从"诊断疾病"迁移到"诊断土壤健康"
纵向时间序列(追踪动态)	用于土壤的季节/演替动态

借的时候要警惕水土不服：土壤多样性比肠道高几个数量级、异质性极强(原理6)，肠道里好用的方法搬来常需大改。借思路，别照抄参数。

3. 地球微生物组计划(EMP)：跨生境的"大一统"

- 思路：用统一的标准流程测全球各种生境(土壤、水、动植物…)的微生物，让结果可横向比较。
- 土壤能借什么：标准化(可比较、可汇总)的理念；以及"把土壤放进全球生境大图里"的宏观视角。

第二类 · 向其它学科借方法

宏基因组的数据分析工具，绝大多数是从别的学科"进口"的。认出它们的"娘家"，能帮你更快理解和找资源。

1. 生态学 / 宏观生态 —— 把研究大象老虎的理论搬给微生物

整个模块 D(模型15-18)其实都是"进口货"：

研究森林、海岛、鸟兽的经典生态理论

| 搬给微生物 →

|— 中性理论(Hubbell) —————→ Sloan 中性模型(模型15)

|— 生态位 vs 中性辩论 —————→ 确定性 vs 随机(模型16)

|— 物种-面积/距离衰减 —————→ 微生物生物地理(模型18)

|— 多样性-稳定性、功能冗余 —————→ 模型20

启示：想找新思路，去翻经典生态学教材——很多还没被搬到微生物上的理论，就是你的机会。

2. 网络科学 —— 研究社交网络/互联网的工具

- 借来做什么：共现网络、关键种、模块化(模型17)——节点、连边、中心性、社团发现，这些概念直接来自社交网络/复杂网络研究。
- 还能再借：网络鲁棒性(删掉关键种群落会不会崩)、多层网络(把细菌-真菌-病毒网络叠起来)等更前沿的网络方法，土壤才刚开始用。

3. 系统生物学 / 代谢工程 —— 把"细胞代谢网络"搬到群落

- 借来做什么：群落代谢模型 GEM(见10.3)——通量平衡分析、代谢网络重建，本是研究单一菌株/细胞工厂的工具，被搬来模拟整个群落的"代谢经济"。

4. 人工智能 / 数据科学 —— 最猛的一股外援

- 借来做什么：基础模型读懂序列、机器学习做预测(整个10.1篇)；深度学习改进分箱(SemiBin2)；以及处理"高维 + 组成型"数据的各种统计学习方法。
- 特别提醒：AI 是最强也最容易被误用的他山之石——能预测≠懂机制，相关≠因果(框架5、7)。借它的力，守住科学的严谨。

5. 还有更多"娘家"

方法	来自
稳定同位素探针 qSIP(10.3)	同位素化学 / 地球化学
Hi-C 邻近连接(10.2)	染色体构象研究(分子生物学/物理)
组成型数据分析 CLR(模型14)	地质学家 Aitchison 的成分数据理论
序列比对算法	计算机科学(字符串算法)

三、怎么用好"他山之石" (方法论)

遇到一个解决不了的问题

|
问自己：“别的领域有没有人遇到过类似的结构性难题？”
|
|—— 别的生态系统(海洋/肠道)是不是已经有成熟流程？ → 借经验
|—— 这本质上是个什么数学/计算问题？ → 去对应学科找工具
|—— 借来后，针对土壤的特殊性(高多样性/异质/暗物质)做适配
|
★ 关键：借“思路 and 工具”，按土壤实际“重新调参/验证”，不照搬结论

本篇要义：土壤宏基因组是个十字路口学科——它的力量来自不断从海洋、肠道、生态学、网络科学、系统生物学、AI 借来"石头"。学会识别每个工具的"娘家"，你就拥有了一张通向无穷资源的地图，也更容易想出别人没想到的组合。

本篇是"他山之石"的入门版。想继续深入：- 专门从"其它组学领域"借方法 (GWAS→MWAS、单细胞、空间组学) → 04-从组学领域借方法.md - 更多生态系统 + 更多学科 (极端环境/植物/古DNA + 博弈论/流行病学/因果推断/地统计) → 05-他山之石进阶.md

延伸阅读

- 全球海洋微生物组的结构与功能 · Science(Tara Oceans) · <https://www.science.org/doi/10.1126/science.1261359>
- Tara Oceans : 迈向全球海洋生态系统生物学 · Nature Reviews Microbiology · <https://www.nature.com/articles/s41579-020-0364-5>
- 基于肠道微生物组的多组学整合分析进展 · Frontiers 2024 · <https://www.frontiersin.org/journals/microbiology/articles/10.3389/fmicb.2024.1509117/full>
- 微生物组精准(医学)：多组学 + 机器学习 · <https://www.sciencedirect.com/science/article/abs/pii/S094450132500343X>

[回到 模块11总览](#) | [知识库总览](#)

11.3 · 各类组学详解：宏基因组的"楼上邻居"们

上一篇(01)给了组学阶梯的全景。这一篇把宏基因组楼上的每一层逐一拆开讲清楚：它测什么、和宏基因组怎么配合、难在哪。还会介绍一批"功能子组学"（各种 -ome），它们是宏基因组的"专科切片"。

读法：把宏基因组(DNA/潜力)当成"地基"，下面是一层层往上走。

一、阶梯上层：从"潜力"逐级逼近"真相"

1. 宏转录组（Metatranscriptomics）—— 测 RNA，看"在表达什么"

- 测什么：群落里所有的 RNA（主要是 mRNA）。基因要"干活"，先得转录成 RNA——所以 RNA 多 = 这个基因正在被启用。
- 回答：从"能干什么(潜力)" → "此刻在干什么(活性)"。这是跨越框架3"潜力≠活性"最常用的一步。
- 怎么配合宏基因组：先用宏基因组建好"基因目录(谁有什么基因)"，再把测到的 RNA 比上去，才知道"是谁的、哪个基因在表达"。两者是地图 + 实时路况的关系。
- 难点：
 - RNA 极不稳定，几分钟就降解 → 采样、保存要求极高；
 - 绝大多数 RNA 是 rRNA(核糖体RNA)，会淹没有用的 mRNA → 需要"去 rRNA"；
 - 只是某一瞬间的快照 → 采样时机稍偏就失真。

2. 宏蛋白组（Metaproteomics）—— 测蛋白，看"真造出了什么"

- 测什么：群落里实际存在的蛋白质（用质谱仪）。蛋白是真正干活的"工人/酶"。
- 回答：比 RNA 更进一步——RNA 只是"打算造"，蛋白是"真造出来了"。
- 怎么配合宏基因组：质谱鉴定蛋白，需要一个"候选蛋白清单"去比对——这个清单通常就来自配套的宏基因组。没有宏基因组，宏蛋白组寸步难行。

- 难点：技术最难、灵敏度有限（低丰度蛋白测不到）、深度远不如测序、严重依赖数据库质量。

3. 代谢组 (Metabolomics) —— 测代谢物，看"产出了什么"

- 测什么：群落产生/消耗的小分子代谢物（氨基酸、有机酸、糖、次级代谢物等），用质谱或核磁。
- 回答：阶梯的顶端——最接近"到底发生了什么、留下了什么产物"。
- 怎么配合宏基因组："基因(能做) → 酶(在做) → 代谢物(做出的结果)"。代谢组给出"结果端"的实锤，和宏基因组的"潜力端"对接，能拼出完整因果链(见 01 篇的雪融氮案例)。
- 难点：
 - 不分物种——测到一个代谢物，常不知道是哪个菌产的（需结合其它组学推断）；
 - 大量代谢物身份未知（代谢暗物质）；
 - 受环境本底干扰大。

4. 宏表观组 (Metaepigenomics) —— 测 DNA 甲基化，一个新维度

- 测什么：DNA 上的甲基化修饰（细菌主要有 4mC、5mC、6mA 三类）。同一条 DNA 序列，可以带不同"化学标记"。
- 怎么测：纳米孔(Nanopore)长读长测序能在测序列的同时直接读出甲基化，不需额外处理。
- 意想不到的妙用（这点很前沿）：每个基因组有自己特异的甲基化"花纹" (motif)，像指纹/水印。于是甲基化能：
 - 改进分箱：用甲基化花纹把 contig 归到同一基因组(补模型7)；
 - 给质粒/移动元件定主：和宿主带同款花纹 = 同一个细胞；
 - 发现错误组装：花纹突然变了，提示 contig 是嵌合的。
- 代表工具：Nanomotif、MicrobeMod、Nanodisco。

看出规律没有：每往上一层，离"真相"更近一步，但技术更难、深度更浅、越依赖宏基因组当地图。这就是为什么宏基因组是不可替代的地基。

二、功能"子组学"：宏基因组的专科切片

除了纵向阶梯，还有一批以"-ome"命名的功能子集——它们不是新的分子层，而是从宏基因组里专门拎出某一类基因/元件深入研究。

子组学	聚焦什么	关键意义	关联
抗性组 Resistome	所有抗生素抗性基因 (ARGs)	公共卫生、One Health	案例7、CARD
移动组 Mobilome / 质粒组	质粒、转座子、整合子等可移动元件	基因(含抗药基因)传播的载体	10.2、Hi-C定主
病毒组 Virome	病毒/噬菌体	控制群落、搬运基因	见 10.2
碳水化合物活性酶组 (CAZyme)	降解/合成多糖的酶	碳循环、有机质分解	模型19、CAZy 库
次级代谢组 / BGC组	生物合成基因簇	新抗生素/天然产物挖掘	案例9、antiSMASH

这些"子组学"的好处：聚焦——不必处理全部海量数据，只盯你关心的那类功能，分析更深、更专。

三、一张图：宏基因组和它的"邻居们"

↑ 越往上越接近“真相”，但越难测、越浅、越依赖下层当地图

代谢组(代谢物·产出结果)	—— 质谱/核磁
宏蛋白组(蛋白·真造出)	—— 质谱(需宏基因组当蛋白清单)
宏转录组(RNA·在表达)	—— 测序(需宏基因组当基因目录)
宏表观组(甲基化·调控+水印)	—— 纳米孔(顺带改进分箱/定主)

宏基因组(DNA·潜力) = 地基 + 所有上层的“地图”

从这块地基里还能切出“专科子组学”：

抗性组 · 移动组 · 病毒组 · CAZyme组 · BGC组

本篇要义：宏基因组的“楼上”有转录组、蛋白组、代谢组、表观组，逐层逼近真相；“内部”还能切出抗性组、移动组等专科视角。理解每一层测什么、补什么、难在哪，你就能按问题选择该往上爬到哪一层。

延伸阅读

- 土壤 meta-omics 现状、挑战与应用 · <https://www.sciencedirect.com/science/article/abs/pii/S2405985425000904>
- 纳米孔测序发现微生物组多种 DNA 甲基化 · Nature Methods · <https://www.nature.com/articles/s41592-021-01109-3>
- Nanomotif：用甲基化花纹做基因组回收与质粒定主 · bioRxiv 2024 · <https://www.biorxiv.org/content/10.1101/2024.04.29.591623v2.full>
- 用甲基化模式解析异常大小/复杂结构的细菌基因组 · ISME J · <https://www.nature.com/articles/s41396-022-01242-7>

下一篇：04-从组学领域借方法.md ——把成熟组学的利器搬过来

11.4 · 从组学领域借方法：最该借的"他山之石"

这是你要的"能在组学借鉴的"。最该借的"他山"，恰恰是其它更成熟的组学领域——人类基因组学、单细胞组学、空间组学。它们烧了更多钱、趟了更多坑，方法成熟，很多能直接搬到土壤宏基因组来用。

本篇讲四大借法：① 从人类遗传学借 MWAS ② 从单细胞组学借单细胞分辨 ③ 从空间组学借原位定位 ④ 从单细胞分析借数据方法。

一、从人类基因组学借：GWAS → MWAS

人家的成熟方法：GWAS（全基因组关联分析）——扫描人类基因组，找"哪些基因变异和某疾病相关"。这套方法在医学里极其成熟。

怎么搬到宏基因组：MWAS（宏基因组关联分析）几乎是照着 GWAS 搭的：

GWAS： 人的基因变异 ——关联——> 疾病/性状

MWAS： 微生物的基因/物种丰度 ——关联——> 疾病 / 土壤健康 / 作物产量

- 做法：把微生物特征（物种、基因丰度）和你关心的结果（如土壤肥力、产量）做关联，找出"显著相关"的微生物/基因。为降维，常先把基因聚成"宏基因组物种/连锁群"。
- 土壤应用：找"和高产/抗病/健康土相关"的关键微生物或功能基因（呼应 10.1 的机器学习）。
- 借来时要注意的新坑：微生物的基因数比人类基因组多上百倍 → 多重检验问题严重得多，假阳性风险更高，必须严格校正(框架5、6)；而且关联≠因果(框架7)，GWAS 的这条铁律在 MWAS 同样成立。

工具示例：OMARU 等 MWAS 流程。本质是"把医学统计遗传学的工具箱搬到微生物上"。

二、从单细胞组学借：单细胞分辨（看清"一个个体"）

人家的成熟方法：单细胞测序（scRNA-seq 等）——不再测"一团组织的平均"，而是一个细胞一个细胞地测，看清个体差异。

怎么搬到宏基因组：单细胞基因组学 / 单细胞宏基因组：

普通宏基因组：一锅 DNA 混着测 → 靠算法“分箱”猜哪段属于谁（可能拼错/嵌合，模型7的痛）
单细胞基因组：先把单个细胞分离出来 → 单独扩增、测序 → 一个细胞 = 一个基因组（SAG）
（“谁”是确定的，不靠猜）

- 怎么分离单细胞：微流控(把细胞包进一个个微液滴)、流式分选(FACS)、激光技术(LIFT)等——这些都是从单细胞生物学借来的。
- 进展：微流控 + 全基因组扩增让单细胞基因组的完整度从 50–70% 提升到 80–90%(近三年)。已用于北极永久冻土的上百个未培养类群、单个土壤团聚体内的氮代谢菌等。
- 和 MAG 互补：

	MAG(分箱)	SAG(单细胞)
谁的基因组	算法猜(有嵌合风险)	确定(就这一个细胞)
通量/覆盖	一次得很多、覆盖全群落	一次少、偏向被挑中的细胞
扩增偏差	小	大(单细胞扩增不均匀)

最佳实践常是两者结合：SAG 提供"确定的参照基因组"，帮助校正和验证 MAG。

三、从空间组学借：原位定位（看清"在哪里"）

人家的成熟方法：空间转录组学（spatial transcriptomics）——不打碎组织，保留位置信息，看"哪个基因在组织的哪个位置表达"。

怎么搬到宏基因组：空间宏基因组 / 空间宏转录组——回答一个普通宏基因组永远答不了的问题：

普通宏基因组把土打成糊，丢掉了空间信息。但"谁挨着谁、谁住在根的哪一侧、谁聚在团聚体表面还是内部"恰恰至关重要(土壤极端异质，原理6)。

普通宏基因组：土 → 打碎成糊 → 只知道“有谁”，不知道“谁在哪、谁挨着谁”
空间组学：保留原位结构 → 在显微尺度上画出“微生物分布地图”

- 进展：空间宏转录组已能在植物叶片(拟南芥)上同时刻画细菌、真菌的"热点"和它们的空间互作；分辨率从 55μm 推进到 ~1μm（单细胞级）。
- 土壤意义：把"群落"从一锅平均，还原成有结构的"微生物社区地图"——这对理解根际、团聚体、微生境是革命性的。
- 现状：在土壤这种不透明、复杂基质里做空间组学仍非常前沿、技术门槛高，但方向极有前景。

四、从单细胞分析借：数据分析方法

单细胞领域不仅贡献了实验技术，还贡献了一整套数据分析武器，现在已被微生物组广泛借用：

借来的方法	原本用途(单细胞)	在宏基因组里
降维可视化 UMAP / t-SNE	把上万个细胞画到二维	把大量样本/物种画到二维(补充 PCoA，模型12)
批次效应校正	去除不同实验批次的干扰	去除测序批次/试剂批次(框架6)
聚类算法	给细胞分群(细胞类型)	给物种/样本/基因分群
拟时序 / 轨迹分析	推断细胞分化路径	推断群落演替/动态轨迹

启示：单细胞领域是微生物组分析方法最大的"上游供货商"之一。看到一个新的单细胞分析方法，可以想想"能不能搬来分析微生物群落？"——常常能。

五、方法论：怎么判断一个组学方法"能不能借"

看到其它组学领域一个好用的方法

- 问 1：它解决的本质问题，宏基因组里有没有对应版本？
(如：单细胞解决“混合样本看不清个体” = 宏基因组分箱难)
- 问 2：土壤的特殊性会不会让它失效或需要大改？
(高多样性、强异质、暗物质多、不透明基质…)
- 问 3：借来后怎么验证它在土壤里真的有效？

★ 原则：借“方法的内核”，按土壤实际重做参数与验证，别照搬。

本篇要义：最该借的“他山之石”是更成熟的组学领域——MWAS 借自 GWAS、单细胞分辨借自 scRNA-seq、原位定位借自空间转录组、UMAP/批次校正/拟时序也都是“进口”的。它们烧过的钱、踩过的坑，就是你的捷径。

延伸阅读

- 宏基因组关联研究(MWAS)：精挖微生物组 · Nature Reviews Microbiology · <https://www.nature.com/articles/nrmicro.2016.83>
- OMARU：稳健的 MWAS 多功能流程 · NAR Genomics and Bioinformatics · <https://academic.oup.com/nargab/article/4/1/lqac019/6543594>
- 获取未培养微生物基因组的单细胞基因组学工具 · <https://pmc.ncbi.nlm.nih.gov/articles/PMC10937852/>
- 单个土壤团聚体的单细胞基因组学(氮代谢) · Frontiers 2025 · <https://www.frontiersin.org/journals/microbiology/articles/10.3389/fmicb.2025.1557188/full>
- 空间宏转录组解析宿主-细菌-真菌互作 · <https://pubmed.ncbi.nlm.nih.gov/37985875/>
- 微米尺度空间宏基因组 · bioRxiv 2025 · <https://www.biorxiv.org/content/10.1101/2025.09.30.679663.full.pdf>

下一篇：05-他山之石进阶.md ——更多生态系统与跨学科借鉴

11.5 · 他山之石进阶：更多生态系统与跨学科

02 篇起了个头(海洋/肠道 + 生态学/网络/系统生物学/AI)，04 篇讲了从兄弟组学借方法。这一篇把"他山"的版图进一步扩大：更多可借经验的生态系统，以及更多能贡献思想的学科。

目的不是让你记住每一个，而是建立一种条件反射：遇到难题，先问"别人(别的系统/别的学科)是不是已经有招了？"

第一部分 · 更多生态系统：别处的微生物组经验

1. 极端环境 —— 宏基因组学的"发源地"之一

- 典型：酸性矿山废水、深海热泉、盐湖、永久冻土。
- 为什么值得借：这些环境物种少、相对简单，是最早成功重建出近完整群落基因组的地方(复杂度低，组装分箱容易)。很多宏基因组方法先在这里跑通，再挑战复杂的土壤。
- 土壤能借：方法的"试验田"思路——先在简单系统验证流程，再上复杂系统(呼应教程 07 的"先小数据跑通")。

2. 植物微生物组 —— 天然的"模式系统"

- 典型：根际、叶际、内生菌。
- 为什么值得借：比整片土边界更清晰、更可控、可做接种实验，是连接"微生物 ↔ 宿主功能(产量/抗病)"的绝佳模型，也最容易做因果验证(合成群落 SynCom 接种到无菌植物)。
- 土壤能借：用植物-微生物系统验证在复杂土壤里只能"相关"的假设(爬框架7的因果阶梯)。

3. 建成环境 —— 标准化大规模采样的范本

- 典型：医院、地铁(如全球地铁微生物组计划)、城市表面。

- 为什么值得借：示范了大规模、标准化、众包式采样如何做(成百上千样点统一流程)。
- 土壤能借：大规模协作采样与元数据标准化(呼应框架2、6 和 Tara 的经验)。

4. 古 DNA / 古微生物 —— 时间维度

- 典型：永久冻土、沉积岩芯、古牙结石里的远古微生物 DNA。
- 为什么值得借：贡献了处理高度降解、低浓度、易污染 DNA 的专门方法。
- 土壤能借：深层土、老样本的降解 DNA 处理；以及"时间尺度"的视角(土壤微生物组如何随地质/历史变化)。

第二部分 · 更多学科：意想不到的"娘家"

1. 博弈论 / 经济学 —— 解释"合作与背叛"

- 借什么：微生物之间有合作(交叉喂养)也有"搭便车/欺骗"。博弈论的公共物品、囚徒困境、分工等概念，被用来解释为什么群落里会演化出合作、又为何稳定。代表思想如"黑皇后假说"(丢掉自己能做的功能，依赖别人提供——精打细算的"外包")。
- 连接：给共现/代谢互作(模型17、10.3)提供理论解释。

2. 流行病学 —— 溯源与传播

- 借什么：来源追踪(如 SourceTracker：判断一份土的微生物有多少来自空气/水/粪肥)、菌株传播路径追踪——这些本是追踪传染病来源的方法。
- 连接：追踪抗药基因/病原从粪肥到土壤到作物的传播(案例7、One Health)。

3. 信息论 —— 多样性的数学根基

- 借什么：你天天用的 Shannon 多样性指数，本来就是信息论里的"熵"(模型11)！信息论还提供互信息等工具来度量物种间的关联。
- 连接：多样性、网络分析的底层数学其实都来自信息论。

4. 因果推断 —— 从"相关"突围到"因果"

- 借什么：经济学、流行病学发展出的因果推断框架(中介分析、工具变量、因果发现算法等)，正被引入微生物组，试图在观测数据里更严谨地逼近因果。
- 连接：直接服务框架7"相关→因果"——这是当前微生物组统计的前沿方向。


5. 地统计学 / 遥感 GIS —— 把微生物"画上地图"

- 借什么：地理学的空间插值(克里金 kriging)、遥感卫星数据——用来绘制大尺度的土壤微生物/功能分布图，并和气候、植被等空间图层叠加分析。
- 连接：生物地理(模型18)、全球图谱(案例1)的空间分析引擎。

6. 药物化学 / 天然产物 —— 土壤是"新药矿"

- 借什么：天然产物化学的思路——土壤微生物(尤其放线菌)是人类大多数抗生素的来源。结合 BGC 挖掘(案例9、antiSMASH)，宏基因组成了不依赖培养的新药发现新引擎。
- 连接：BGC 子组学(11.3)、案例9。

三、一张"借用地图" (总览)



四、把"借"变成你的核心能力

第一层(新手)：会用本领域的标准工具 ← 本库 00-09

第二层(进阶)：知道工具的"娘家"，能追根溯源 ← 本模块

第三层(高手)：主动去别的领域找"石头"解决新问题，并做出别人没想到的组合

本篇要义：土壤宏基因组是一门十字路口学科——它最强的能力不是某个工具，而是不断从别处借石攻玉。生态系统借经验、组学借方法、学科借理论。养成"这问题别人解过吗"的条件反射，你就拥有了一张通向无穷资源的地图。

延伸阅读

- 全球海洋微生物组结构与功能(Tara Oceans) · Science · <https://www.science.org/doi/10.1126/science.1261359>
- 微生物互作中的"黑皇后假说"与合作演化 (综述检索关键词：Black Queen Hypothesis microbial cooperation)
- 微生物组来源追踪 SourceTracker (检索：SourceTracker microbial source tracking)
- 用机器学习与组学解析土壤 C/N/P 循环的环境调控 · JGR Biogeosciences 2025 · <https://agupubs.onlinelibrary.wiley.com/doi/full/10.1029/2024JG008470>

回到 模块11总览 | 知识库总览